

Outomatiese teks-na-spraak-stelsel vir Viëtnamese gebruik

Kunsmatige Intelligensie

Thanh-Danh Vo ¹, Ngo-Ho Anh-Khoa ¹ en Ngo-Ho Anh-Khoi ^{1*}

¹ Fakulteit Inligtingstechnologie, Nam Can Tho Universiteit, Nguyen Van Custra 168, An Binh Wyk, Can Tho City, Vietnam

____HOU_0____, , ,

nhakhoi@nctu.edu.vn

Abstrak. In die konteks van digitale transformasie en die vinnige vooruitgang van kunsmatige intelligensie, het die vraag na teks-na-spraak (TTS)-stelsels raak toenemend krities oor domeine soos virtuele assistente, onderwys, outomatiese oproepsentrums, en toeganklikheid gereedskap vir die visueel benadeel. Genereer egter natuurlik, konteksbewus en prosodies gepaste spraak bly 'n groot uitdaging, veral vir Viëtnamese—'n toontaal met komplekse toonhoogtekontoure en streeks diversiteit. Hierdie navorsing stel voor en ontwikkel 'n Viëtnamese TTS-stelsel wat gebou is op moderne diepleermodelle om die beperkings van tradisionele te oorkom metodes. Die stelsel maak gebruik van die nuutste argitekture, insluitend Tacotron, FastSpeech en VITS, gekombineer met masjienleertegniese sintese kwaliteit te verbeter. Konstruksie en evaluering word uitgevoer op a diverse Viëtnamese dataset, wat aanpasbaarheid by verskeie werklike wêreld verseker kontekste. Resultate toon dat die stelsel natuurlik, duidelik, hoogs bereik buigsame spraakuitset met breë potensiaal vir ontplooiing in digitale platforms en intelligente dienste.

Sleutelwoorde: Teks-na-spraak (TTS), Kunsmatige Intelligensie (KI), Deep Learning, Natuurlike Taalverwerking (NLP), Spraaksintese.

1 Inleiding

Gedryf deur digitale transformasie en die vordering van kunsmatige intelligensie, die behoefte om bou teks-na-spraak (TTS)-stelsels word al hoe belangriker op gebiede soos as virtuele assistente, onderwys, outomatiese oproepsentrums, en ondersteuning vir die visueel benadeel. Die TTS-probleem strek egter verder as die omskakeling van teks in audio; dit vereis dat die gesintetiseerde stem natuurlik moet wees, gepaste intonasie dra, en pas by die gegewe konteks - 'n besonder moeilike taak vir Viëtnamese, 'n taal met 'n komplekse toonstelsel en aansienlike streeksvariasie (Do, 2026). Tradisionele konkatenatiewe en formant-gebaseerde TTS-metodes (Zen et al., 2019) en Hidden Markov Model (HMM)-gebaseerde sintese (Zen et al., 2019) vertoon beperkings in buigsamheid, natuurlikheid en skaalbaarheid. In reaksie, moderne diep leer modelle soos Tacotron (Wang et al., 2017), Tacotron 2 (Shen et al., 2018), FastSpeech (Ren) 2 F. Skrywer en S. Skrywer et al., 2019,2020), en VITS (Kim et al., 2021) het meer effektiewe weë oopgemaak deur direk uit data te leer. Voortbou op hierdie vooruitgang, fokus hierdie studie op die navorsing en ontwikkeling van 'n Viëtnamese TTS-stelsel wat daarop gemik is om stemkwaliteit en praktiese toepaslikheid te verbeter.

2 Verwante werk

Die Viëtnamese TTS-mark beskik oor verskeie prominente plaaslike platforms saam met internasionale oplossings. FPT Smart Cloud Text to Speech, ontwikkel

deur FPT Corporation, lewer 'n hoë-gehalte Viëtnamese TTS-diens deur 'n kommersiële API (Vu et al., 2025; Nguyen, 2023). Dit pas diepleer-argitektuur soos Tacotron (Wang et al., 2017) en Transformer-variante (Vaswani et al., 2017) toe tesame met vokoders soos WaveNet (Oord et al., 2016) en HiFi-GAN (Kong et al., 2020) om met diverse spoed, stem- en streeksbeheer te produseer. Die stelsel word wyd gebruik in interaktiewe stemrespons (IVR), audioboeke, virtuele assistente en aanlyn onderwys (Do, 2026). Viettel AI Text-to-Speech bied 'n SaaS-gebaseerde oplossing wat vir Viëtnameses geoptimaliseer is (Vu et al., 2025; Nguyen, 2023), wat gebruik maak van gevorderde neurale modelle wat op grootskaalse, Viëtnamesespesifieke spraakkorpora opgelei is om akkurate 206-uitspraak, en ekspressiewe, natuurlike uitspraak, oor- en uitspraak te verseker. al., 2016; Kong et al., 2020). Zalo AI Text to Speech, 'n produk van VNG Corporation, integreer diep NLP-modelle soos PhoBERT (Nguyen & Tuan, 2020) en BERT-styl vooropleiding (Devlin et al., 2019) met sintese-argitektuur insluitend Tacotron, FastSpeech, en Rens et al., VITS, 20 et al. 2019; Kim et al., 2021), wat massiewe gebruikersdata gebruik om veelvuldige praatstyle te ondersteun (Vu et al., 2025). Voice.vn spesialiseer in spraaksintese en stemkloning (Vu et al., 2025) deur gebruik te maak van end-tot-end-modelle soos VITS (Kim et al., 2021) en stemomskakelingstegnieke (Casanova et al., 2022; Chen et al., 2022), wat pasmaak vir stemafsluiting moontlik maak en pasmaak vir advertensies, podcasting en speletjies. Google AI Studio verskaf 'n wolk-gebaseerde omgewing vir TTS via die Gemini-familie en Google Cloud Text-to-Speech (Vaswani et al., 2017; Ren et al., 2019), met veeltalige, natuurlike en konteks-aanpasbare stemgenerering (She et al., 2018, 2018). EventLab bied TTS- en stemkloningnutsmiddels gebou op end-tot-end TTS (Wang et al., 2017) en luidsprekerinbeddingsmodelle (Chen et al., 2022; Kim et al., 2021; Casanova et al., 2022). Oor die algemeen skuif die mark van eenvoudige teksleesstelsels na intelligente kommunikasieplatforms, met sterk neigings in stemkloning (Jia et al., 2018) en multimodale KI.

Die oopbrongemeenskap het 'n reeks Viëtnamese TTS-modelle bygedra. VietTTS is 'n verteenwoordigende stelsel wat gebou is met enkodeerder-dekodeerder of transformator-argitektuur (Wang et al., 2017; Vaswani et al., 2017; Ren et al., 2019), opgelei op noukeurig genormaliseerde Viëtnamese data (Do, 2026) om tone, saamgestelde woorde en sintydstrukture te hanteer, wat geskikte naby-tyd-strukture bied, wat werklike latensie bied. e-leer en audioboekproduksie (Nguyen, 2023; Vu et al., 2025). NeuTTS-Air fokus op liggewig, doeltreffende afleiding, balansering van stemkwaliteit en spoed om op SVE's of laehulpbrontoestelle te werk (Ren et al., 2019, 2020; Kim et al., 2021),

Bydrae Titel (verkort indien te lank) 3

geoptimaliseer vir chatbots, IVR en IoT-toepassings (Ping et al., 2017; Kalchbrenner et al., 2018). Kani-TTS is 'n grootskaalse model met ongeveer 370 miljoen parameters, wat mik na hoë ekspressiwiteit en professionele klankgehalte (Kim et al., 2021; Casanova et al., 2022), wat uitblink in oudioboek- en mediaproduksie, maar kragtige GPU's benodig vir ontplooiing (Ren et al., 2019; Kall et al., 2019 et al. 2018). VieNeu-TTS kombineer TTS met stemkloning, onttrek sprekerkenmerke via tegnieke soos AutoVC (Qian et al., 2019) en StarGAN-VC (Kameoka et al., 2018) en pas dit toe op gesintetiseerde spraak (Casanova et al., 2022; Jiabing et al., 2018, maar ook personalization), maar ook etiese en veiligheidskewessies. ViXTTS dien as 'n demonstrasieprojek vir stemkloning, wat die tegnologie vir vinnige eksperimentering illustreer (Thinh, 2024; Kim et al., 2021). Valtec-TTS is 'n kompakte model wat geoptimaliseer is vir uiters hulpbronbeperkte omgewings soos ingebedde toestelle en IoT (Ren et al., 2019,2020; Ping et al., 2017; Kalchbrenner et al., 2018), wat voldoende duidelikheid lewer vir eenvoudige toepassingkennisgewing en leiding. Gesamentlik illustreer hierdie modelle die rypwording van Viëtnamese TTS, met gespesialiseerde takke wat wissel van hoëgehalte-sintese tot liggewig-ontplooiing en stemverpersoonliking.

Datakwaliteit is die grondslag vir TTS. Die VLSP Speech Corpus is 'n groot, akademies georiënteerde datastel met multi-luidspreker opnames in gekontroleerde toestande (Ardila et al., 2020; Vu et al., 2025), ryklik geannoteer met fonetiese en streeksinligting (Yamagishi et al., 2019; Do, 2026). VIVOS is 'n kleiner oopbronskorpus (ongeveer 10–20 uur) van skoongeleesde spraak (Ardila et al., 2020; Ito & Johnson, 2017), wat wyd gebruik word vir aanvanklike modellering ondanks beperkte emosionele en werklike diversiteit (Do, 2026). Kommersiële datastelle van FPT Corporation, Viettel Group en VNG Corporation is baie groter en meer gedetailleerd. FPT se datastel bestaan uit honderde tot duisende ure se opnames van ateljeegehalte met volledige aantekeninge (Vu et al., 2025; Do, 2026; Oord et al., 2016; Kong et al., 2020). Viettel se data kombineer ateljee- en werklike wêreldopnames wat uiteenlopende aksente dek (Vu et al., 2025; Yamagishi et al., 2019; Jia et al., 2018; Do, 2026). Zalo se data trek voordeel uit sy breë gebruikersekosisteem, wat kontemporêre taalgebruik insluit (Vu et al., &2025; Nguyen&Tuan, 2020; Devlin et al., 2019; Kim et al., 2021). Daarbenewens bied VietTTS 'n basiese oop datastel met teks-klankpare wat voldoende is vir kleinskaalse eksperimente (Nguyen, &2023; Ito&Johnson, 2017; Vu et al., 2025). In die algemeen bepaal datastelskaal, diversiteit, annotasiediepte en realisme TTS-prestasie direk.

3 Stelselontwerp

Vroeë TTS-stelsels het staatgemaak op aaneenlopende en formant-gebaseerde metodes, wat spraakeenhede saamstel of wiskundig modelleer, maar ly aan onbuigsaamheid, hoë databasiskoste en onnatuurlike prosodie (Zen et al., 2019). Statistiese parametrisiese sintese met behulp van Hidden Markov Models (HMM) het buigsaamheid verbeter, maar steeds eentonige, minder natuurlike uitset gelever (Zen et al., 2019). Die koms van diep leer het end-tot-end-modelle gebring soos Tacotron en Tacotron 2, wat enkodeerder-dekodeerder-argitekture gebruik met aandag aan direk kaartteks na

4 F. Skrywer en S. Skrywer

mel-spektrogramme, gevolg deur vokoders soos WaveNet (Oord et al., 2016) of WaveGlow (Prenger et al., 2019) om golfvorms te genereer (Wang et al., 2017; Shen et al., 2018; Vaswani et al., 2017). Hierdie modelle leer outomaties fonetiese en prosodiese kenmerke, wat aansienlik meer natuurlike spraak lewer, maar het beperkings in afleidingsspoed en aandagfoute. FastSpeech en FastSpeech 2 het hierdie kwessies aangespreek deur aandag tydens afleiding te verwyder en duur-, toonhoogte- en energievoorspellers te gebruik, om vinniger en meer stabiele sintese met eksplisiete prosodiebeheer te bewerkstellig (Ren et al., 2019,2020; Vaswani et al., 2017). Die jongste sprong, VITS, integreer 'n &variasie-ouo-enkodeerder (Kingma&Welling, 2014) met 'n generatiewe teenstandernetwerk (Goodfellow et al., 2014) om golfvorms direk vanaf teks in 'n enkele end-tot-end-raamwerk te genereer, wat 'n aparte vocoder uitskakel en gehalte en doeltreffendheid verder bevorder., nova20 et al. 2022). Stemkloning en multi-luidsprekersintese het ook gevorder, met behulp van luidsprekerinbeddings en styltekens om verpersoonliking en nulskoot-aanpassing moontlik te maak (Jia et al., 2018; Casanova et al., 2022; Chen et al., 2022; Wang et al., 2018). Boonop versag oordrag en self-toesig leermetodes (Baevski et al., 2020; Hsu et al., 2021; Radford et al., 2022) dataskaarste vir Viëtnames deur vooropleiding op groot veeltalige korpus. 'n Moderne TTS-pyplyn sluit tipies data-insameling en voorverwerking, teksnormalisering (Do, 2026), modelopleiding en golfvormgenerering in (Wang et al., 2017; Kim et al., 2021).

Die voorgestelde stelsel implementeer 'n emosionele TTS-pyplyn: invoerteks wat emosie-etiket bevat, word volgens emosie gesegmenteer, elke segment word via viXTTS gesintetiseer, en die gevolglike golfvorms word aaneengeskakel met stiltegapings om die finale oudiolêer te produseer




Fig. 1. *Werkvloei van die voorgestelde emosie-gebaseerde spraaksintese stelsel*

In die eerste laag word teksreël vir reële geskandeer. Wanneer 'n reël 'n emosie-etiket tussen hakies bevat, word die stelsel dit na 'n emosie-kaart-etiket deur 'n Viëtnamese sleutelwoordeboek te gebruik. Openvolgende reëls wat dieselfde emosie deel, word in 'n stuk (teks, emosie) gegroepeer. Vir sintese word die teks skoongemaak deur merkinoud te verwyder, spasies te normaliseer in Vietnamese ortografie te standaardiseer. In die tweede laag word elke deel na die viXTTS-inferensie-enjin oorgedra tesame met luidsprekermerke wat uit 'n verwysingsoudiolêer onttrek is. 'n Emosiekaart ken 'n toe verwysing lêer per emosie (bv. neutraal → base_voice.wav, vrolik → cheerful_ref.wav). Om konsekwente spreker-identiteit te handhaaf, word latente spreker-inbeddings een keer uit 'n gebruiker-verskafde stemmonster onttrek en oor alle stukke hergebruik (Jia et al., 2018; Casanova et al., 2022). Die sintese produseer 'n golfvorm vir elkeen



6 F. Skrywer en S. Skrywer

stuk, soos geformaliseer in die volgende algoritme

In die derde laag word die gegenereerde golfvorms opeenvolgend aaneengeskakel met 300 ms se stilte wat ingevoeg word om emosionele draaie te skei en abrupte snye te vermy. Die finale uitset word as 'n WAV-lêer gestoor. Hierdie ontwerp kombineer effektief sleutelwoord-gebaseerde emosieklasifikasie met voorwaardelike TTS en audio-naverwerking, wat merkergedrewe, ekspressiewe spraaksintese moontlik maak deur 'n verenigde stemidentiteit te gebruik.

4 Evalueringsmetrieke

Om die teks-na-spraak- en stemkloningstelsel volledig te assesser, word twee komplementêre diep-leer-gebaseerde maatstawwe gebruik: sprekerooreenkoms via Resemblyzer, en waargenome spraakkwaliteit via DNSMOS.

Resemblyzer is 'n neurale netwerk-gebaseerde instrument vir sprekerverifikasie en stemooreenkomsmeting (Mishra et al., 2023). In sy kern gebruik dit 'n sprekerverifikasie-enkodeerder wat opgelei is met 'n algemene end-tot-end verlies (Wan et al., 2018). Die operasionele beginsel is soos volg: eerstens, 'n insetuiting - óf die oorspronklike verwysingstem óf die gesintetiseerde gekloonde stem - word verwerk deur 'n diep neurale netwerk wat 'n vaste-dimensionele inbeddingsvektor onttrek (dikwels na verwys as 'n d-vektor of luidsprekerinbedding). Hierdie vektor is ontwerp om die unieke vokale identiteit van die spreker vas te vang, insluitend eienskappe soos timbre, toonhoogte kontoer en praatstyl, terwyl dit grootliks onveranderlik is van die linguistiese inhoud of die spesifieke woorde wat gespreek word. Met ander woorde, ongeag wat die persoon sê, moet die inbedding konsekwent bly vir dieselfde spreker en duidelik verskillend vir verskillende sprekers (Wan et al., 2018).

Sodra die inbeddingsvektore vir beide die verwysingsoudio A (die oorspronklike spreker se stem) en die gesintetiseerde oudio B (die gekloonde stem) verkry is, word hul ooreenkoms gekwantifiseer deur die cosinus-ooreenkoms metriek te gebruik:

$$\text{Cosine Gelykvormigheid} = \cos(A, B) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}}$$

$i=1$ B i

2

Die cosinus-ooreenkoms meet die hoek tussen die twee vektore in die hoë-dimensionele inbeddingsruimte. 'n Waarde naby aan 1 dui aan dat die vektore in byna dieselfde rigting wys, wat beteken dat die twee stemme as hoogs eenders of amper identies in terme van sprekeridentiteit beskou word (Jia et al., 2018; Wan et al., 2018). Omgekeerd, 'n waarde naby aan 0 of negatief sal verskillende sprekers voorstel. Resemblyzer verskaf dus 'n objektiewe, outomatiese en reproduceerbare maatstaf om te evalueer hoe getrou 'n stemkloningstelsel die oorspronklike spreker se vokale eienskappe bewaar.

DNSMOS (Deep Noise Suppression Mean Opinion Score) is 'n nie-indringende, diep leer-gebaseerde maatstaf wat ontwerp is om die perseptuele kwaliteit van spraakseine te skat sonder om 'n skoon verwysing oudiosein te vereis (Reddy et al., 2021). Dit maak dit

5 Eksperimente en resultate

Opleiding . dataset. Die stelsel is opgelei en geëvalueer deur gebruik te maak van die viVoice-korpus (Le, 2024), die eerste publiek beskikbare grootskaalse Viëtnamese spraakdataset wat ontwerp is vir veelsprekende teks-na-spraak. viVoice bestaan uit meer as 1 000 uur se skoongemaakte oudio en gepaardgaande transkripsies afkomstig van 186 YouTube-kanale. Alle oudiomonsters word verskaf teen 'n 24 kHz-steekproeftempo in WAV-formaat, met agtergrondmusiek en geraas verwyder om skoon opleidingsdata te verseker. Die dataset dek 'n wye verskeidenheid luidsprekers, aksente (Noordelike, Sentraal, Suidelike) en praatstyle, wat dit veral geskik maak vir die opleiding van robuuste multi-luidspreker Viëtnamese TTS-modelle soos XTTS-v2. viVoice word vrygestel onder die CC BY-NC-SA 4.0-lisensie.

Die voorverwerkingspyplyn is ontwerp om wisselvalligheid uit te skakel wat spreker-ooreenkoms kan verswak. Stappe het ingesluit: (i) handmatige verifikasie van transkripsie-akkuraatheid om perfekte belyning te verseker; (ii) teksnormalisering met behulp van VietNormalizer (Do, 2026) om afkortings uit te brei, nommers na woorde om te skakel en leestekens te standaardiseer; (iii) fonetiese belyning met 'n gedwonge belyning wat op Viëtnamese opgelei is, wat foon-gebaseerde raamwerk lewer; stilte-stroop aan die begin en einde van uitsprake om leidende/sluitende stilte te verwyder; en (v) hardheid normalisering tot -23 LUFS om konsekwente waargenome volume oor sprekers te handhaaf. Van kardinale belang, vir elke spreker is 'n hoë-gehalte luidspreker inbedding onttrek met behulp van die Resemblyzer enkodeerder en gestoor as 'n verwysing vektor. Die kondisionering van die generatiewe model op hierdie inbeddings tydens opleiding moedig die dekodeerder aan om sprekeridentiteit te bewaar, wat direk bygedra het tot die hoë cosinus-ooreenkomstings (0.90+) wat in die eksperimente waargeneem is.

Eksperimentele opstelling. Die evaluering is uitgevoer op 'n GIGABYTE G5 GD-skootrekenaar, 'n speletjie-georiënteerde notaboek waarvan die spesifikasies in Tabel 1 gelys word. Die stelsel het veral 'n toegewyde NVIDIA GeForce RTX GPU (Ampere-argitektuur, diskreet) saam met 'n geïntegreerde Intel UHD-grafiese adapter. Die PyTorch-omgewing wat vir afleidings gebruik is, was egter slegs 'n SVE-bou, wat beteken dat alle sintese-bewerkings op die Intel Core i5-11400H SVE gehardloop het sonder GPU-versnelling. Hierdie opstelling weerspieël 'n algemene ontplooiingsscenario waar CUDA-bestuurders of biblioteke nie geïnstalleer is nie, of waar die stelsel versoenbaarheid bo maksimum spoed prioritiseer.

Tabel 1. Stelselkonfigurasie van die toetsplatform.

Komponent	Spesifikasie
Model	GIGABYTE G5 GD
ALMAL	Intel Core i5-11400H (8 kerne, 12 drade, 2,70 GHz basis)
RAM	16 GB DDR4 (15,8 GB bruikbaar)
GPU	Intel UHD-grafika (geïntegreer)
Diskrete GPU-	NVIDIA GeForce RTX (Ampere, toegewyd)
bedryfstelsel	Windows 11 Huis Enkeltaal

Stemooreenkoms en spraakkwaliteit. . Die stelsel is geëvalueer deur oorspronklike en gesintetiseerde (gekloonde) spraakmonsters van vier sprekers te vergelyk. Elke monsterpaar het bestaan uit 'n reference.wav-lêer en sy kloon. Twee assesseringsmetodes is toegepas: Resemblyzer vir stemooreenkoms (Wan et al., 2018; Mishra et al., 2023), en DNSMOS vir waargenome klankkwaliteit (Reddy et al., 2021). Stemooreenkomsresultate word in Tabel 2 aangebied. Alle pare bereik 'n cosinus-ooreenkoms van ongeveer 0.90 (wat wissel van 0.9013 tot 0.9346), wat bevestig dat die VITS-model, ten spyte van die gebruik van die SVE, vokale timbre en sprekeridentiteit merkwaardig goed bewaar (Jia et al., 2018).

Stemooreenkoms-resultate vir die viXTTS-model word in Tabel 2 aangebied. Alle pare bereik 'n cosinus-ooreenkoms van ongeveer 0.90 (wat wissel van 0.9013 tot 0.9346), wat bevestig dat die model vokale timbre en sprekeridentiteit merkwaardig goed bewaar (Jia et al., 2018). Luidspreker-ooreenkoms vir ander enjins is nie in hierdie evaluasieloope gemeet nie, aangesien die meeste van hulle nie inheems stemkloning ondersteun nie of 'n aparte verwysing-inbedding-onttrekkingstap vereis.

Tabel 2. Stemooreenkoms tussen oorspronklike en gekloonde spraak.

Lekker klank	Ooreenkomstigheid
giong_goc af giong_clone	0,9038
Danh_1 en Danh_clone	0,9019
Khang1 en Khang_clone Ngoc1	0,9346
en Ngoc_clone	0,9013

Spraakkwaliteitsresultate van DNSMOS oor al sewe geëvalueerde enjins word in Tabel 3 opgesom. Vier maatstawwe is aangeteken: OVRL (algehele kwaliteit), SIG (spraakkwaliteit), BAK (agtergrondgeraas-indringendheid), en die aanvullende P808-telling ('n algehele luisterkwaliteitberamer wat met ITU-T P.808 belyn is). Tellings is op die standaard 1–5 gemiddelde opinietellingskaal, waar hoër waardes beter perseptuele kwaliteit aandui.

Tabel 3. DNSMOS-evaluering van gesintetiseerde Viëtnamese spraakkwaliteit..

Model	Lêer audio	OVRL MOS	SIG MOS	BAK MOS	P808 MOS
Voorgestelde viXTTS-gebaseer					
Stem kloning stelsel	giong_clone.wav	3,38	3,60	4.14	4.03
Piper Viëtnamese TTS	Piper_Viëtnameses_TTS	3.00	3,40	3,81	3.15
Valtec Viëtnamese TTS	Valtec Viëtnameses			4.04	3,95
v2	TTS_ver2.wav	3.07	3,34		
Viëtnamese TTS	ViëtnamesesTTS.wav	2.07	2,75	2,86	2,73
Valtec Viëtnamese TTS				4.16	4.21
	Valtec_Viëtnamese.wav	3,37	3,58		
VietTTS				4.15	3,64
	VietTTS.wav	3.05	3,25		
VieNeu-TTS	VietNeu_TTS.wav	3.31	3,54	4.16	3,68

10 F. Skrywer en S. Skrywer

Die DNSMOS-evalueringsresultate toon merkbare verskille in gesintetiseerde Viëtnamese spraakkwaliteit tussen die geëvalueerde TTS-stelsels. Oor die algemeen behaal die voorgestelde viXTTS-gebaseerde stemkloningstelsel, verteenwoordig deur giong_clone.wav, die hoogste OVRL MOS-telling van 3.38 en die hoogste SIG MOS-telling van 3.60. Hierdie resultate dui aan dat die voorgestelde stelsel spraak produseer met sterk algehele perseptuele kwaliteit en duidelike spraakseine. Die hoë BAK MOS-telling van 4.14 dui ook daarop dat die gegenereerde klank baie min agtergrondgeraas bevat. Daarom demonstreer die viXTTS-gebaseerde model sterk prestasie in beide spraakhelderheid en geraasonderdrukking.

Onder die vergelykende stelsels presteer Valtec_Vietnamese.wav ook mededingend, met 'n OVRL MOS van 3.37 en 'n SIG MOS van 3.58, wat baie na aan die voorgestelde stelsel is. Boonop behaal hierdie model die hoogste P808 MOS-telling van 4.21, wat daarop dui dat luisteraars die algehele klankgehalte daarvan gunstig kan waarneem. Die voorgestelde giong_clone.wav presteer egter steeds effens beter as dit in die twee hoof DNSMOS-aanwysers, OVRL en SIG. Dit dui daarop dat die voorgestelde model 'n klein maar meetbare voordeel het in terme van algehele spraakkwaliteit en seinhelderheid.

Die VietNeu_TTS.wav-model behaal ook sterk resultate, met 'n OVRL MOS van 3.31, SIG MOS van 3.54, BAK MOS van 4.16 en P808 MOS van 3.68. Hierdie tellings plaas dit in die hoëpresterende groep, veral in terme van agtergrondgeraasonderdrukking. Sy BAK-telling is van die hoogste in die vergelyking, wat wys dat die gegenereerde klank skoon en stabiel is. Alhoewel sy algehele en seinkwaliteitellings effens laer is as dié van giong_clone.wav en Valtec_Vietnamese.wav, bly dit 'n betroubare model vir Viëtnamese spraaksintese.

Die middelpresterende groep sluit Valtec Vietnamese TTS_ver2.wav, VietTTS.wav en Piper_Vietnamese_TTS in. Hierdie modelle verkry OVRL MOS-tellings wat wissel van 3.00 tot 3.07, wat aanvaarbare maar nie uitstaande gesintetiseerde spraakkwaliteit aandui nie. Hul SIG MOS-tellings, wat wissel van 3,25 tot 3,40, dui daarop dat die spraaksein redelik duidelik is, maar steeds minder natuurlik of minder gedetailleerd as die toppresterende stelsels. Veral, VietTTS.wav behaal 'n hoë BAK MOS-telling van 4.15, wat wys dat die klankuitset relatief skoon is. Die laer OVRL- en SIG-tellings dui egter daarop dat agtergrondskoonheid alleen nie voldoende is om hoë algehele spraakkwaliteit te verseker nie.

Die stelsel wat die laagste presteer is VietnameseTTS.wav, wat 'n OVRL MOS van 2.07, SIG MOS van 2.75, BAK MOS van 2.86 en P808 MOS van 2.73 verkry. Hierdie tellings is aansienlik laer as dié van die ander modelle. Die lae OVRL- en SIG-tellings dui veral daarop dat die gesintetiseerde spraak merkbare artefakte, verminderde natuurlikheid of onduidelike uitspraak kan bevat. Die lae BAK-telling dui ook aan dat die oudio meer agtergrondinterferensie of geraas kan insluit in vergelyking met die ander stelsels.

'n Algemene neiging kan oor die sterker modelle waargeneem word: die meeste stelsels behaal hoë BAK MOS-tellings bo 4.0, wat beteken dat moderne Viëtnamese TTS-modelle oor die algemeen effektief is om skoon oudio met beperkte agtergrondgeraas te produseer. Verskille in OVRL- en SIG-tellings toon egter dat skoon klank nie altyd nie

Bydrae Titel (verkort indien te lank) 11

waarborg natuurlike en verstaanbare spraak. Spraaknatuurlikheid, duidelikheid en seinkwaliteit bly belangrike faktore om die beste presterende modelle te onderskei.

Samevattend, die voorgestelde viXTTS-gebaseerde stemkloningmodel giong_clone.wav behaal die beste algehele prestasie in terme van OVRL en SIG MOS, wat dit die sterkste stelsel in hierdie vergelyking maak. Valtec_Vietnamese.wav en VietNeu_TTS.wav demonstreer ook mededingende prestasie en kan as sterk alternatiewe beskou word. Intussen toon VietnameseTTS.wav die swakste resultate en kan verdere optimalisering vereis om spraaknatuurlikheid, helderheid en agtergrondgeraasbeheer te verbeter.

Intydse prestasie- en vertragsanalise: : Die mees kritieke prestasiemaatstaf van die huidige prototipe is die einde-tot-einde sintese latency. Vir 'n tipiese invoerteks van 750 karakters (gelykstaande aan ongeveer 50 sekondes se gegenereerde audio teen 'n standaard Viëtnamese-sprekende tempo van ongeveer 900 karakters per minuut), benodig die stelsel ongeveer 2 minute en 50 sekondes (170 sekondes) om die finale WAV-lêer te produseer. Dit lewer 'n Real-Time Factor (RTF) van ongeveer 3.4, ver bo die intydse drempel van 1.0. Die latensie is egter nie vas nie; dit wissel meetbaar na gelang van die linguistiese kompleksiteit van die invoerteks. Twee faktore oorheers die bykomende verwerkingsbokoste:  Emosie-etiket. Elke emosionele grens dwing 'n nuwe sintese-stuk af met 'n aparte viXTTS-afleidingsoproep, wat lei tot veelvuldige konteksskakelaar en modellaai bokoste. Meer merkers verhoog die aantal stukke en die kumulatiewe pouse-invoegtyd.

 Engelse woorde en nie-Viëtnamese segmente. Dit vereis ekstra grafeem-tot-foneemstappe binne die teksnormaliseringslaag (Do, 2026), en kan aandagfoute veroorsaak wat die dekodeerder dwing om herbelyning te probeer, wat bydra tot die totale looptyd.

Die waargenome latensie spruit uit die loop van die volle VITS-pyplyn op die SVE sonder om die beskikbare RTX GPU te gebruik. Die SVE-enigste PyTorch-bou kan nie die massiewe parallelisme van die GPU se tensorkerne ontgin nie, wat matriksvermenigvuldigings en konvolusies laat om opeenvolgend bereken te word. Ten spyte hiervan, bly die stelsel aanvaarbaar vir nabylyn-inhoudskeppingstake soos podcast-oorklanking, opvoedkundige vertelling of stemposgenerering – toepassings waar 'n paar minute se leweringstyd geduld word in ruil vir hoëgehalte, emosioneel ekspressiewe uitset.

Die masjien is krities toegerus met 'n NVIDIA GeForce RTX GPU, wat ten volle in staat is om die afleiding te versnel. Om na 'n CUDA-geaktiveerde PyTorch-installasie te skuif, sal die RTF tot ver onder 0.1 verminder (gebaseer op tipiese GPU maatstawwe vir VITS), wat intydse stroomsintese moontlik maak. Daarbenewens kan modelkwantisering na FP16 of INT8, en oorskakeling na geoptimaliseerde inferensie-enjins soos ONNX Runtime met OpenVINO, latensie verder halveer terwyl die hoë ooreenkomste en MOS-tellings behoue bly.

6 Gevolgtrekking

In hierdie navorsing is 'n Viëtnamese teks-na-spraak-stelsel wat op kunsmatige intelligensie en diep leer gebaseer is, deeglik ontwerp, geïmplementeer en geëvalueer. Die stelsel

ontgin moderne modelle soos Tacotron, FastSpeech en VITS om teks outomaties in natuurlike spraakseine om te skakel, en leer die unieke fonetiese en prosodiese kenmerke van Viëtnameses. Eksperimentele uitkomst toon dat die voorgestelde model duidelike, natuurlike spraak met toepaslike intonasie genereer en stabiele prestasie oor verskeie toestande en kontekste handhaaf.

Die resultate wat behaal is, bevestig nie net die doeltreffendheid van diep leer in Viëtnamese spraaksintese nie, maar beklemtoon ook die stelsel se breë toepaslikheid in die praktyk, veral in virtuele assistente, onderwys, outomatiese oproepsentrums en hulpmiddels vir gesiggestremdes. Toekomstige werk kan fokus op die uitbreiding en verryking van die spraakdatastel, die verbetering van plaaslike natuurlikheid, die optimalisering van modelle vir hulpbronbeperkte toestelle, en die integrasie van die stelsel in werklike wêreldplatforms om uitvoerbaarheid en bruikbaarheid te verbeter.

Verwysings

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. & M., & Weber, G. (2020). Common Voice: A massively- multilingual speech corpus. arXiv. <https://arxiv.org/abs/1912.06670>
2. Baevski, A., Zhou, Y., Mohamed, & A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, & E., & Ponti, M. A. (2022). YourTTS: Na nul-skoot multi-luidspreker TTS en zero-shot stem omskakeling vir almal. arXiv. <https://arxiv.org/abs/2205.12010>
4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Pratap, V., Conneau, A., Collobert, R., Synnaeve, G., & Auli, M. (2022). WavLM: Large-scale self-supervised pre-training for full stack speech processing. arXiv. <https://arxiv.org/abs/2110.13900>
5. Devlin, J., Chang, M. W., Lee, & K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. arXiv. <https://arxiv.org/abs/1810.04805>
6. Do, N. (2026). VietNormalizer: An open-source, dependency-free Python library for Vietnamese text normalization in TTS and NLP applications. arXiv. <https://arxiv.org/abs/2603.04145>
7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative adversarial networks. arXiv. <https://arxiv.org/abs/1406.2661>
8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhota, K., Salakhutdinov, & R., & Mohamed, A. (2021). HuBERT: Self-toesig spraakvoorstelling leer deur gemaskerde voorspelling van verborge eenhede. arXiv. <https://arxiv.org/abs/2106.04550>
9. Ito, K., & Johnson, L. (2017). The LJ Speech Dataset. <https://keithito.com/LJ-Speech-Dataset/>
10. Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, X., Chen, Z., Nguyen, P., Pang, R., Moreno, I. L., & Wu, & Y. (2018). Transfer learning from speaker verification to multispeaker text-to-speech synthesis. Advances in Neural Information Processing Systems, 31. <https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

Bydrae Titel (verkort indien te lank) 13

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Efficient neural audio synthesis. arXiv. <https://arxiv.org/abs/1802.08435>
12. Kameoka, H., Kaneko, T., Tanaka, &K.,&Hojo, N.(2018). StarGAN-VC: Non-parallel many-to-many voice conversion using star generative adversarial networks. arXiv.

<https://arxiv.org/abs/1806.02169>

13. Kim, J., Kong, &J.,&Son, J.(2021). Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech. arXiv. <https://arxiv.org/abs/2106.06103>

14. Kingma, D. &P.,&Welling, M.(2014). Auto-encoding variational bayes. arXiv. <https://arxiv.org/abs/1312.6114>

15. Kong, J., Kim, &J.,&Bae, J.(2020). HiFi-GAN: Generative adversarial networks for efficient and high fidelity speech synthesis. arXiv. <https://arxiv.org/abs/2010.05646>
16. Mishra, P., Choudhury, J. A., Kho, E., Basu, &B.,&Nandi, A.(2023). Speaker identification, differentiation and verification using deep learning for human machine interface. In 2023 Photonics & Electromagnetics Research Symposium (PIERS) (pp. 861–870). IEEE. <https://ieeexplore.ieee.org/document/10221344>

17. Nguyen, D. &Q.,&Tuan, N. D.(2020). PhoBERT: Pre-trained language models for Vietnamese. arXiv. <https://arxiv.org/abs/2003.00744>

18. Nguyen, N. (2023). VietTTS: Vietnamese text to speech library. GitHub. <https://github.com/NTT123/vietTTS>

19. Oord, A. van den, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, &A.,&Kavukcuoglu, K.(2016). WaveNet: A generative model for raw audio. arXiv. <https://arxiv.org/abs/1609.03499>

20. Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Raiman, J., Miller, &J.,&Sengupta, S.(2017). Deep Voice 3: Scaling text-to-speech with convolutional sequence learning. arXiv. <https://arxiv.org/abs/1710.07654>

21. Prenger, R., Valle, &R.,&Catanzaro, B.(2019). WaveGlow: A flow-based generative network for speech synthesis. arXiv. <https://arxiv.org/abs/1811.00002>

22. Qian, K., Zhang, Y., Chang, S., Yang, &X.,&Hasegawa-Johnson, M.(2019). AutoVC: Zero-shot voice style transfer with only autoencoder loss. arXiv.

<https://arxiv.org/abs/1905.05879>

23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, &C.,&Sutskever, I.(2022).

Robuuste spraakherkenning deur grootskaalse swak toesig. arXiv.

<https://arxiv.org/abs/2212.04356>

24. Reddy, C. K., Gopal, &V.,&Cutler, R.(2021). DNSMOS: A non-intrusive perceptual objective speech quality metric to evaluate noise suppressors. In ICASSP 2021–2021 IEEE International Conference on Acoustics, Speech and Signal Processing(pp. 6493–6497). IEEE.

____HOU_0____

25. Ren, Y., Ruan, Y., Chen, X., Qin, T., Zhao, S., & Liu, T. (2019). FastSpeech: Fast, robust and controllable text to speech. arXiv. <https://arxiv.org/abs/1905.09263>

26. Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T. (2020). FastSpeech 2: Fast and high-quality end-to-end text to speech. arXiv. <https://arxiv.org/abs/2006.04558>
27. Shen, J., Pang, R., Weiss, R. J., Schuster, M.,

Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyrgiannakis, & Y., & Wu, Y. (2018).

Natuurlike TTS-sintese deur WaveNet te kondisioneer op mel-spektrogramvoorspellings. arXiv.

<https://arxiv.org/abs/1712.05884>

28. Thinh, L. (2024). viXTTS: A Vietnamese voice cloning text-to-speech model. GitHub.

<https://github.com/thinhlp/vixtts-demo>

- 14 F. Skrywer en S. Skrywer
29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Aandag is al wat jy nodig het. arXiv. __HOU_0__
30. Vu, T., Nguyen, L. T., & Nguyen, D. Q. (2025). Zero-shot text-to-speech for Vietnamese. arXiv. __HOU_0__
31. Wan, L., Wang, Q., Papir, & A., & Moreno, I. L. (2018). Generalized end-to-end loss for spreker verifikasie. In 2018 IEEE Internasionale Konferensie oor akoestiek, spraak en Seinverwerking (ICASSP) (pp. 4879–4883). IEEE. <https://ieeexplore.ieee.org/abstract/document/8462665>
32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Agiomyrgiannakis, Y., Clark, R., & Saurous, R. A. (2017). Tacotron: Op pad na end-tot-end spraaksintese. arXiv. <https://arxiv.org/abs/1703.10132>
33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R. J., Battenberg, E., Shor, J., Xiao, Y., Jia, Y., Ren, F., & Saurous, R. A. (2018). Styltekens: stylmodellering sonder toesig, beheer en oordrag in end-tot-end spraaksintese. arXiv. <https://arxiv.org/abs/1803.09017>
34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: English multi-sprekerskorpus vir CSTR stem kloning toolkit (weergawe 0.92). Universiteit van Edinburgh. <https://datashare.ed.ac.uk/handle/10283/3443>
35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R. J., Jia, Y., Chen, Z., & Wu, Y. (2019). LibriTTS: 'n Korpus afgelei van LibriSpeech vir teks-na-spraak. arXiv. <https://arxiv.org/abs/1904.02882>
36. Le, T. (2024). viVoice: A large-scale multi-speaker Vietnamese speech dataset for text-to-toespraak. Gesig omhels. __HOU_0__