

越南语自动文本转语音系统 人工智能

Thanh-Danh Vo¹, Ngo-Ho Anh-Khoa¹ 和 Ngo-Ho Anh-Khoi^{1*}

¹ 南芹苴大学信息技术学院, 168 Nguyen Van Cu Street, An

芹苴市平区, Vietnam

danh223566@studentnctu.edu.vn, , ,

nhakhoi@nctu.edu.vn

摘要。 在数字化转型和信息化快速推进的背景下
人工智能, 对文本转语音 (TTS) 系统的需求已经
在虚拟助理等领域变得越来越重要,
教育、自动呼叫中心和视觉辅助工具

受损。然而, 生成自然的、上下文感知的、韵律的
适当的言论仍然是一个重大挑战, 特别是对于

越南语——一种具有复杂音高轮廓和地域性的声调语言
多样性。本研究提出并开发了越南语 TTS 系统
现代深度学习模型克服了传统深度学习的局限性

方法。该系统利用最先进的架构, 包括

Tacotron、FastSpeech 和 VITS, 与机器学习技术相结合

以提高合成质量。构建和评估是在

多样化的越南数据集, 确保适应多个现实世界

上下文。结果表明, 该系统实现了自然、清晰、高度

灵活的语音输出, 在数字平台中具有广泛的部署潜力

和智能化服务。

关键词: 文本转语音 (TTS)、人工智能 (AI)、深度学习、
自然语言处理 (NLP)、语音合成。

1 简介

在数字化转型和人工智能进步的推动下, 需要

构建文本转语音 (TTS) 系统在以下领域变得越来越重要

作为虚拟助理、教育、自动呼叫中心以及视觉支持

受损。然而, TTS 问题不仅仅是将文本转换为

音频; 它要求合成语音自然、语调恰当、

并适应给定的语境——对于越南语来说, 这是一项特别困难的任务, 因为越南语是一种语言

复杂的音调系统和显着的地区差异 (Do, 2026)。

传统的串联和基于共振峰的 TTS 方法 (Zen 等人, 2019) 和

基于隐马尔可夫模型 (HMM) 的综合 (Zen 等人, 2019) 表现出局限性

灵活性、自然性和可扩展性。作为回应, 现代深度学习模型

例如 Tacotron (Wang et al., 2017)、Tacotron 2 (Shen et al., 2018)、FastSpeech (Ren

2 F. 作者和 S. 作者

et al., 2019,2020) 和 VITS(Kim et al., 2021) 通过直接从数据中学习开辟了更有效的途径。基于这些进展, 本研究重点研究和开发越南语 TTS 系统, 旨在提高语音质量和实际适用性。

2 相关工作

越南 TTS 市场拥有多个著名的国内平台和国际解决方案。FPT Smart Cloud Text to Speech 由 FPT Corporation 开发, 通过商业 API 提供高质量的越南语 TTS 服务 (Vu 等人, 2025 年; Nguyen, 2023 年)。它应用 Tacotron (Wang 等人, 2017) 和 Transformer 变体 (Vaswani 等人, 2017) 等深度学习架构以及 WaveNet (Oord 等人, 2016) 和 HiFi-GAN (Kong 等人, 2020) 等声码器来产生自然的、区域多样化的声音, 并且速度、音调和暂停可控。该系统广泛应用于交互式语音应答 (IVR)、有声读物、虚拟助理和在线教育 (Do, 2026)。Viettel AI 文本转语音提供针对越南语进行优化的基于 SaaS 的解决方案 (Vu 等人, 2025; Nguyen, 2023), 采用在大规模越南语特定语音语料库上训练的高级神经模型, 以确保准确的发音、自然的停顿和表达输出 (Do, 2026; Oord 等人, 2016; Kong 等人, 2020)。Zalo AI Text to Speech 是 VNG Corporation 的产品, 它将 PhoBERT (Nguyen&Tuan, 2020) 和 BERT &式预训练 (Devlin et al., 2019) 等深度 NLP 模型与 Tacotron、FastSpeech 和 VITS (Wang et al., 2017; Ren et al., 2019; Kim et al., 2021) 等综合架构集成在一起, 利用海量用户数据支持多种说话风格 (Vu et al., 2025)。Voice.vn 专注于语音合成和语音克隆 (Vu 等人, 2025), 使用 VITS (Kim 等人, 2021) 等端到端模型和语音转换技术 (Casanova 等人, 2022; Chen 等人, 2022), 为广告、播客和游戏实现高保真语音克隆和定制。Google AI Studio 通过 Gemini 系列和 Google Cloud Text-to-Speech 为 TTS 提供基于云的环境 (Vaswani 等人, 2017 年; Ren 等人, 2019 年), 具有多语言、自然且上下文自适应的语音生成功能 (Casanova 等人, 2022 年; Shen 等人, 2018 年)。EventLab 提供基于端到端 TTS 的 TTS 和语音克隆工具 (Wang 等人, 2017 年) 和说话人嵌入模型 (Chen 等人, 2022 年; Kim 等人, 2021 年; Casanova 等人, 2022 年)。总体而言, 市场正在从简单的文本阅读系统转向智能通信平台, 其中语音克隆 (Jia et al., 2018) 和多模式人工智能的趋势强劲。

开源社区贡献了一系列越南语 TTS 模型。VietTTS 是一个采用编码器解码器或 Transformer 架构构建的代表性系统 (Wang 等人, 2017 年; Vaswani 等人, 2017 年; Ren 等人, 2019 年), 在仔细规范化的越南语数据 (Do, 2026) 上进行训练, 以处理语气、复合词和句子结构, 提供适合虚拟助手、电子学习和有声读物制作的近实时延迟 (Nguyen, 2023; Vu 等人, 2025)。NeuTTS-Air 专注于轻量级、高效的推理, 平衡语音质量和在 CPU 或低资源设备上运行的速度 (Ren 等人, 2019,2020; Kim 等人, 2021),

针对聊天机器人、IVR 和物联网应用进行了优化（Ping 等人，2017 年；Kalchbrenner 等人，2018 年）。Kani-TTS 是一个拥有约 3.7 亿个参数的大型模型，旨在实现高表现力和专业音频质量（Kim et al., 2021；Casanova et al., 2022），在有声读物和媒体制作方面表现出色，但需要强大的 GPU 来部署（Ren et al., 2019；Ping et al., 2017；Kalchbrenner et al., 2018）。VicNeu-TTS 将 TTS 与语音克隆相结合，通过 AutoVC（Qian 等人，2019）和 StarGAN-VC（Kameoka 等人，2018）等技术提取说话人特征，并将其应用于合成语音（Casanova 等人，2022；Jia 等人，2018），实现了强大的个性化，但也引发了道德和安全问题。ViXTTS 作为语音克隆的示范项目，展示了快速实验技术（Thinh, 2024；Kim 等人，2021）。Valtec-TTS 是一种紧凑模型，针对嵌入式设备和物联网等资源极其有限的环境进行了优化（Ren 等人，2019,2020；Ping 等人，2017；Kalchbrenner 等人，2018），为简单的通知和指导应用提供足够的清晰度。总的来说，这些模型说明了越南 TTS 的成熟，其专业分支涵盖从高质量合成到轻量级部署和语音个性化。

数据质量是 TTS 的基础。VLSP 语音语料库是一个大型的、面向学术的数据集，在受控条件下包含多说话者录音（Ardila 等人，2020 年；Vu 等人，2025 年），并带有丰富的语音和区域信息注释（Yamagishi 等人，2019 年；Do, 2026 年）。VIVOS 是一个较小的开源语料库（大约 10-20 小时），包含清晰朗读的语音（Ardila et al., 2020；Ito & Johnson, 2017），尽管情感和现实世界的多样性有限，但广泛用于初始建模（Do, 2026）。FPT Corporation、Viettel Group 和 VNG Corporation 的商业数据集规模更大、更详细。FPT 的数据集包含数百至数千小时的录音室质量录音，并带有详尽的注释（Vu 等人，2025 年；Do, 2026 年；Oord 等人，2016 年；Kong 等人，2020 年）。Viettel 的数据融合了录音室和现实世界的录音，涵盖不同的口音（Vu 等人，2025 年；Yamagishi 等人，2019 年；Jia 等人，2018 年；Do, 2026 年）。Zalo 的数据受益于其广泛的用户生态系统，结合了当代语言的使用（Vu & 等人，2025；Nguyen&Tuan, 2020；Devlin 等人，2019；Kim 等人，2021）。此外，VietTTS 提供了一个基本的开放数据集，其中包含足以进行小规模实验的文本音频对（Nguyen, 2023；Ito&Johnson, 2017；Vu & 等人，2025）。总体而言，数据集规模、多样性、注释深度和真实度直接决定 TTS 性能。

3 系统设计

早期的 TTS 系统依赖于连接和基于共振峰的方法，这些方法对语音单元进行组装或数学建模，但存在不灵活性、数据库成本高和韵律不自然的问题（Zen 等人，2019）。使用隐马尔可夫模型（HMM）的统计参数综合提高了灵活性，但仍然产生单调、不太自然的输出（Zen 等人，2019）。深度学习的出现带来了 Tacotron 和 Tacotron 2 等端到端模型，它们采用编码器-解码器架构，注重将文本直接映射到

4 F. 作者和 S. 作者

mel 频谱图，然后使用 WaveNet (Oord 等人, 2016) 或 WaveGlow (Prenger 等人, 2019) 等声码器生成波形 (Wang 等人, 2017 ; Shen 等人, 2018 ; Vaswani 等人, 2017)。这些模型自动学习语音和韵律特征，产生更加自然的语音，但在推理速度和注意力错误方面存在局限性。FastSpeech 和 FastSpeech 2 通过在推理过程中消除注意力并使用持续时间、音调和能量预测器来解决这些问题，通过明确的韵律控制实现更快、更稳定的合成 (Ren 等人, 2019,2020 ; Vaswani 等人, 2017)。最新的飞跃，VITS，将变分自动编码器 (Kingma & Welling, 2014) 与生成对抗网络 (Goodfellow 等, 2014) 集成在一起，在单个端到端框架中直接从文本生成波形，消除了单独的声码器并进一步提高了质量和效率 (Kim 等, 2021 ; Casanova 等, 2022)。语音克隆和多说话人合成也取得了进步，使用说话人嵌入和风格标记来实现个性化和零样本适应 (Jia et al., 2018 ; Casanova et al., 2022 ; Chen et al., 2022 ; Wang et al., 2018)。此外，迁移和自监督学习方法 (Baevski et al., 2020 ; Hsu et al., 2021 ; Radford et al., 2022) 通过对大型多语言语料库进行预训练来缓解越南语的数据稀缺性。现代 TTS 管道通常包括数据收集和预处理、文本标准化 (Do, 2026)、模型训练和波形生成 (Wang 等人, 2017 年 ; Kim 等人, 2021 年)。

所提出的系统实现了情感 TTS 管道：包含情感标签的输入文本按情感进行分段，每个片段通过 viXTTS 合成，所得波形与静音间隙连接以生成最终的音频文件




图 1. 所提出的基于情感的语音合成系统的工作流程

在第一层中，文本被逐行扫描。当一行在括号中包含情感标签时，系统会使用越南语关键字词典将其映射到情感标签。具有相同情感的连续行被分组为一个块（文本，情感）。在合成之前，通过删除标签内容、标准化空格和标准化越南语拼写来清理文本。在第二层中，每个块与从参考音频文件中提取的说话者特征一起传递到 viXTTS 推理引擎。情感地图分配了一个参考文件每情感（例如中立的 → 基本语音.wav，开朗的 → 快乐的_ref.wav）。为了保持一致的说话人身份，从用户提供的语音样本中提取一次潜在说话人嵌入，并在所有块中重复使用（Jia 等人，2018 年；Casanova 等人，2022 年）。合成为每个产生一个波形





6 F. 作者和 S. 作者

块，如下算法形式化

在第三层中，生成的波形按顺序连接，并插入 300 毫秒的静音，以分隔情感转变并避免突然中断。最终输出保存为 WAV 文件。该设计有效地将基于关键字的情感分类与条件 TTS 和音频后处理相结合，从而使用统一的语音身份实现标签驱动、富有表现力的语音合成。

4 评估指标

为了全面评估文本到语音和语音克隆系统，采用了两种互补的基于深度学习的指标：通过 Resemblyzer 评估说话者相似度，以及通过 DNSMOS 感知语音质量。

Resemblyzer 是一种基于神经网络的工具，用于说话人验证和语音相似性测量 (Mishra 等人, 2023)。它的核心是采用经过广义端到端损失训练的说话人验证编码器 (Wan 等人, 2018)。其工作原理如下：首先，输入话语（原始参考语音或合成克隆语音）由深度神经网络处理，提取固定维嵌入向量（通常称为 d 向量或说话人嵌入）。该矢量旨在捕捉说话者独特的声音特征，包括音色、音高轮廓和说话风格等特征，同时在很大程度上不随语言内容或所说的特定单词变化。换句话说，无论人说什么，嵌入对于同一说话者都应保持一致，而对于不同说话者则应明显不同 (Wan et al., 2018)。

一旦获得参考音频 A（原始说话者的语音）和合成音频 B（克隆语音）的嵌入向量，就可以使用余弦相似度度量来量化它们的相似度：

$$\text{余弦相似度 } A, B = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}}$$

余弦相似度测量高维嵌入空间中两个向量之间的角度。接近 1 的值表示向量指向几乎相同的方向，这意味着两个声音在说话人身份方面被认为高度相似或几乎相同 (Jia et al., 2018 ; Wan et al., 2018)。相反，接近 0 或负值的值表明说话者不同。因此，Resemblyzer 提供了一个客观、自动且可重复的指标，用于评估语音克隆系统如何忠实地保留原始说话者的声音特征。

DNSMOS（深度噪声抑制平均意见分数）是一种非侵入式、基于深度学习的指标，旨在估计语音信号的感知质量，而不需要干净的参考音频信号 (Reddy 等人, 2021)。这使得

5 实验与结果

训练数据集。该系统使用 .viVoice 语料库 (Le, 2024) 进行训练和评估, 这是第一个公开的大型越南语语音数据集, 专为多说话者文本转语音而设计。viVoice 包含来自 186 个 YouTube 频道的 1,000 多个小时的清理音频和随附转录。所有音频样本均以 WAV 格式以 24 kHz 采样率提供, 并消除背景音乐和噪音以确保训练数据干净。该数据集涵盖了各种说话人、口音 (北部、中部、南部) 和说话风格, 使其特别适合训练强大的多说话人越南语 TTS 模型, 例如 XTTS-v2。viVoice 根据 CC BY-NC-SA 4.0 许可证发布。

预处理管道旨在消除可能降低说话者相似度的可变性。步骤包括: (i) 手动验证抄本准确性, 以确保完美对齐; (ii) 使用 VietNormalizer (Do, 2026) 进行文本标准化, 以扩展缩写、将数字转换为单词并标准化标点符号; (iii) 使用在越南语上训练的强制对齐器进行语音对齐, 产生帧级音素边界; (iv) 在话语开头和结尾进行基于能量的静音剥离, 以消除前导/尾随静音; (v) 响度归一化至 -23 LUFS, 以保持扬声器之间一致的感知音量。至关重要的是, 使用 Resemblyzer 编码器提取每个说话人的高质量说话人嵌入并将其存储为参考向量。在训练期间根据这些嵌入调节生成模型可以鼓励解码器保留说话者身份, 这直接导致了实验中观察到的高余弦相似度得分 (0.90+)。

实验设置。此次评估是在技嘉 G5 GD 笔记本电脑上进行的, 这是一款面向游戏的笔记本电脑, 其规格如表 1 所示。值得注意的是, 该系统配备了专用的 NVIDIA GeForce RTX GPU (Ampere 架构, 独立) 以及集成的 Intel UHD 显卡适配器。然而, 用于推理的 PyTorch 环境是仅 CPU 构建, 这意味着所有综合操作都在 Intel Core i5-11400H CPU 上运行, 没有 GPU 加速。此配置反映了一种常见的部署场景, 其中未安装 CUDA 驱动程序或库, 或者系统优先考虑兼容性而不是最大速度。

表1. 测试平台的系统配置。

组件	规格
型号	技嘉G5 GD
中央处理器	Intel Core i5-11400H (8 核、12 线程、2.70 GHz 基础)
内存	16 GB DDR4 (15.8 GB 可用)
图形处理器	英特尔超核芯显卡 (集成)
独立GPU操	NVIDIA GeForce RTX (安培, 专用)
作系统	Windows 11 家庭单语言

(内部版本 26200)

推理后端

PyTorch 仅 CPU, 4 线程

语音相似度和语音质量。通过比较. 来自四个说话者的原始语音样本和合成（克隆）语音样本来评估该系统。每个样本对都包含一个 `reference.wav` 文件及其克隆文件。应用了两种评估方法：用于语音相似性的 `Resemblyzer` (Wan 等人, 2018 ; Mishra 等人, 2023) 和用于感知音频质量的 `DNSMOS` (Reddy 等人, 2021)。语音相似度结果如表 2 所示。所有配对的余弦相似度约为 0.90（范围从 0.9013 到 0.9346），这证实了 VITS 模型尽管在 CPU 上运行，但仍能很好地保留声音音色和说话人身份 (Jia 等人, 2018)。

`viXTTS` 模型的语音相似度结果如表 2 所示。所有配对的余弦相似度约为 0.90（范围从 0.9013 到 0.9346），证实该模型很好地保留了声音音色和说话人身份 (Jia et al., 2018)。在此评估运行中未测量其他引擎的说话人相似性，因为它们中的大多数本身不支持语音克隆或需要单独的参考嵌入提取步骤。

表 2. 原始语音和克隆语音之间的语音相似性。

Câp 音频	相似度
giong_goc 和 giong_clone	0.9038
Danh_1 和 Danh_clone	0.9019
Khang1 和 Khang_clone	0.9346
Ngoc1 和 Ngoc_clone	0.9013

表 3 总结了 `DNSMOS` 在所有七个评估引擎中的语音质量结果。记录了四个指标：`OVRL`（总体质量）、`SIG`（语音质量）、`BAK`（背景噪声侵入性）和补充 `P808` 分数（与 `ITU-T P.808` 一致的总体收听质量估计器）。分数采用标准的 1-5 平均意见分数量表，其中值越高表示感知质量越好。

表 3. `DNSMOS` 对越南语合成语音质量的评估。

型号	文件音频	过压MOS	西格莫斯	比克摩斯	P808MOS
提议基于 <code>viXTTS</code>					
语音克隆系统	<code>giong_clone.wav</code>	3.38	3.60	4.14	4.03
Piper 越南语 TTS	<code>Piper_越南语_TTS</code>	3.00	3.40	3.81	3.15
Valtec 越南语 TTS	<code>Valtec 越南语</code>			4.04	3.95
v2	<code>TTS_ver2.wav</code>	3.07	3.34		
越南语语音合成	<code>越南语 TTS.wav</code>	2.07	2.75	2.86	2.73
Valtec 越南语 TTS				4.16	4.21
	<code>Valtec_越南语.wav</code>	3.37	3.58		
越南TTS				4.15	3.64
	<code>越南TTS.wav</code>	3.05	3.25		
VieNeu-TTS	<code>VietNeu_TTS.wav</code>	3.31	3.54	4.16	3.68

DNSMOS 评估结果显示, 所评估的 TTS 系统之间的合成越南语语音质量存在显著差异。总体而言, 所提出的基于viXTTS的语音克隆系统 (以 giong_clone.wav 为代表) 获得了最高的 OVRL MOS 分数 3.38 和最高的 SIG MOS 分数 3.60。这些结果表明, 所提出的系统产生的语音具有很强的整体感知质量和清晰的语音信号。4.14 的高 BAK MOS 分数也表明生成的音频包含很少的背景噪音。因此, 基于viXTTS的模型在语音清晰度和噪声抑制方面都表现出了很强的性能。

在比较的系统中, Valtec_Vietnamese.wav 的表现也很有竞争力, OVRL MOS 为 3.37, SIG MOS 为 3.58, 与所提出的系统非常接近。此外, 该型号获得了最高的 P808 MOS 得分 4.21, 这表明听众对其整体音质的感受可能不错。然而, 所提出的 giong_clone.wav 在 OVRL 和 SIG 这两个主要 DNSMOS 指标上仍然略胜于它。这表明所提出的模型在整体语音质量和信号清晰度方面具有微小但可测量的优势。

VietNeu_TTS.wav 模型也取得了不错的成绩, OVRL MOS 为 3.31, SIG MOS 为 3.54, BAK MOS 为 4.16, P808 MOS 为 3.68。这些分数使其跻身高性能组, 尤其是在背景噪声抑制方面。其 BAK 分数在比较中名列前茅, 表明生成的音频干净且稳定。尽管其整体和信号质量得分略低于 giong_clone.wav 和 Valtec_Vietnamese.wav, 但它仍然是越南语语音合成的可靠模型。

表现中等的组包括 Valtec_Vietnam_TTS_ver2.wav、VietTTS.wav 和 Piper_Vietnamese_TTS。这些模型获得的 OVRL MOS 分数范围为 3.00 到 3.07, 表明合成语音质量可以接受, 但并不突出。它们的 SIG MOS 分数范围为 3.25 到 3.40, 表明语音信号相当清晰, 但仍然不如性能最佳的系统自然或细节少。值得注意的是, VietTTS.wav 获得了 4.15 的高 BAK MOS 分数, 表明其音频输出相对干净。然而, 其较低的 OVRL 和 SIG 分数表明, 仅靠背景清洁度不足以确保较高的整体语音质量。

性能最低的系统是 VietnamTTS.wav, 其 OVRL MOS 为 2.07, SIG MOS 为 2.75, BAK MOS 为 2.86, P808 MOS 为 2.73。这些分数大大低于其他模型的分数。特别是, 较低的 OVRL 和 SIG 分数表明合成语音可能包含明显的伪影、自然度降低或发音不清楚。低 BAK 分数还表明与其他系统相比, 音频可能包含更多背景干扰或噪音。

在更强的模型中可以观察到一个总体趋势: 大多数系统的 BAK MOS 分数都在 4.0 以上, 这意味着现代越南 TTS 模型通常可以有效地生成背景噪声有限的干净音频。然而, OVRL 和 SIG 分数的差异表明干净的音频并不总是

保证语音自然、清晰。语音自然度、清晰度和信号质量仍然是区分性能最佳模型的重要因素。

综上所述，所提出的基于 viXTTS 的语音克隆模型 `giong_clone.wav` 在 OVRL 和 SIG MOS 方面实现了最佳的整体性能，使其成为本次比较中最强的系统。`Valtec_Vietnamese.wav` 和 `VietNeu_TTS.wav` 也表现出有竞争力的性能，可以被视为强有力的替代品。同时，`VietnamTTS.wav` 显示的结果最弱，可能需要进一步优化以提高语音自然度、清晰度和背景噪声控制。

实时性能和延迟分析：当前原型最关键的性能指标是端到端综合延迟。对于：750 个字符的典型输入文本（相当于以每分钟约 900 个字符的标准越南语语速生成的约 50 秒的音频），系统需要大约 2 分 50 秒（170 秒）来生成最终的 WAV 文件。这会产生大约 3.4 的实时因子 (RTF)，远高于实时阈值 1.0。然而，延迟并不是固定的；它根据输入文本的语言复杂性而显着变化。有两个因素决定了额外的处理开销：情感标签。每个情感边界都会通过单独的 viXTTS 推理调用强制创建一个新的合成块，从而导致多个上下文切换和模型加载开销。更多标签会增加块的数量和累积暂停插入时间。

□ □ 英语单词和非越南语片段。这些需要文本规范化层中额外的字素到音素步骤 (Do, 2026)，并且可能会引入注意错误，迫使解码器重试对齐，从而增加总运行时间。

观察到的延迟源于在 CPU 上运行完整的 VITS 管道而没有利用可用的 RTX GPU。仅使用 CPU 的 PyTorch 构建无法利用 GPU 张量核心的大规模并行性，从而导致矩阵乘法和卷积按顺序计算。尽管如此，该系统仍然可以接受近线内容创建任务，例如播客配音、教育旁白或语音邮件生成等应用程序，在这些应用程序中可以容忍几分钟的渲染时间，以换取高质量、富有情感表现力的输出。

关键的是，该机配备了 NVIDIA GeForce RTX GPU，完全有能力加速推理。迁移到支持 CUDA 的 PyTorch 安装会将 RTF 降低至远低于 0.1（基于 VITS 的典型 GPU 基准），从而实现实时流合成。此外，模型量化为 FP16 或 INT8，并切换到优化的推理引擎（例如带有 OpenVINO 的 ONNX Runtime），可以进一步将延迟减半，同时保持高相似性和 MOS 分数。

6 结论

在这项研究中，我们对基于人工智能和深度学习的越南语文本转语音系统进行了彻底的设计、实施和评估。系统

利用 Tacotron、FastSpeech 和 VITS 等现代模型自动将文本转换为自然语音信号，学习越南语独特的语音和韵律特征。实验结果表明，所提出的模型可以生成清晰、自然、语调适当的语音，并在各种条件和上下文中保持稳定的性能。所取得的结果不仅验证了深度学习在越南语语音合成中的有效性，而且凸显了该系统在实践中的广泛适用性，特别是在虚拟助理、教育、自动呼叫中心和视障人士辅助工具方面。未来的工作可能集中在扩展和丰富语音数据集、提高区域自然度、优化资源受限设备的模型以及将系统集成到现实世界的平台中以增强可行性和可用性。

参考文献

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. & M., & Weber, G. (2020). Common Voice: A massively-multilingual speech corpus. arXiv. <https://arxiv.org/abs/1912.06670>
2. Baevski, A., Zhou, Y., Mohamed, & A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, & E., & Ponti, M. A. (2022). YourTTS : 面向所有人的零样本多扬声器 TTS 和零样本语音转换。 arXiv. __保留_0__
4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Pratap, V., Conneau, A., Collobert, R., Synnaeve, G. 和 Auli, M. (2022). WavLM : 用于全栈语音处理的大规模自监督预训练。 arXiv. __保留_1__
5. Devlin, J., Chang, M. & W., Lee, K. 和 Toutanova, K. (2019)。 BERT : 用于语言理解的深度双向转换器的预训练。 arXiv. __保留_0__
6. Do, N. (2026)。 VietNormalizer : 一个开源、无依赖的 Python 库，用于 TTS 和 NLP 应用程序中的越南语文本规范化。 arXiv. __保留_0__
7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, & S., Courville, A. 和 Bengio, Y. (2014)。 生成对抗网络。 arXiv. __保留_0__
8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhotia, K., Salakhutdinov, & R. 和 Mohamed, A. (2021)。 HuBERT : 通过隐藏单元的屏蔽预测进行自监督语音表示学习。 arXiv. __保留_0__
9. 伊藤 K. 和 约翰逊 & L. (2017)。 LJ 语音数据集。 <https://keithito.com/LJ-Speech-数据集/>
10. 贾 Y., 张 Y., 韦斯 R. J., 王 Q., 沉 J., 任 X., 陈 & Z., 阮 P., 庞 R., 莫雷诺, I. L., & 吴 Y. (2018)。 从说话者验证到多说话者文本到语音合成的迁移学习。 神经信息处理系统的进展, 31。
<https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Efficient neural audio synthesis. arXiv. <https://arxiv.org/abs/1802.08435>
12. Kameoka, H., Kaneko, T., Tanaka, &K.,&Hojo, N.(2018). StarGAN-VC: Non-parallel many-to-many voice conversion using star generative adversarial networks. arXiv. __保留_0__
13. Kim, J., Kong, &J., &Son, J. (2021) 。具有端到端文本到语音的对抗性学习的条件变分自动编码器。 arXiv. __保留_1__
- &14.Kingma, D.P., &Welling, M. (2014) 。自动编码变分贝叶斯。 arXiv. __保留_0__
15. &Kong, J., Kim, J., &Bae, J. (2020) 。 HiFi-GAN : 用于高效、高保真语音合成的生成对抗网络。 arXiv. <https://arxiv.org/abs/2010.05646>
16. Mishra, &P., Choudhury, J. A., Kho, E., Basu, B. 和 Nandi, A.(2023)。 使用深度学习进行人机界面的说话人识别、区分和验证。 2023 年光子学与电磁学研究研讨会 (PIERS) (第 861-870 页)。 IEEE。 __保留_2__
17. Nguyen, D. Q. 和 &Tuan, N. D. (2020) 。 PhoBERT : 越南语预训练语言模型。 arXiv. __保留_3__
- 18.Nguyen, N. (2023) 。 VietTTS : 越南语文本转语音库。 GitHub。 __保留_0__
19. Oord, A. van den, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, &A., Kalchbrenner, N., Senior, A. 和 Kavukcuoglu, K.(2016)。 WaveNet : 原始音频的生成模型。 arXiv. __保留_1__
20. Ping, W., Peng, K., Gibiansky, A., Ar&ik, S.O., Kannan, A., Narang, S., Raiman, J., Miller, J., &Sengupta, S. (2017) 。 Deep Voice 3 : 通过卷积序列学习缩放文本到语音。 &arXiv. __保留_2__
- 21.普伦格, R., 瓦莱, R., 和卡坦扎罗, B. (2019) 。 WaveGlow : 用于语音合成的基于流的生成网络。 arXiv. __保留_3__
22. &钱K., 张Y., 张S., 杨X., &长谷川-约翰逊, M.(2019)。 AutoVC : 零样本语音风格传输, 仅自动编码器损失。 arXiv. __保留_0__
23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C. 和 &Sutskever, I.(2022) 。 通过大规模弱监督实现鲁棒语音识别。 arXiv. __保留_0__
- 24.Reddy, &C.K., Gopal, V.和Cutler, R.(2021)。 DNSMOS : 一种非侵入式感知客观语音质量指标, 用于评估噪声抑制器。在 ICASSP 2021-2021 IEEE 国际声学、语音和信号处理会议 (第 6493-6497 页) 中。 IEEE。 __保留_0__
25. 任Y., 阮Y., 陈X., 秦T., 赵S., 刘T. (2019) 。 FastSpeech : 快速、稳健且可控的文本转语音。 arXiv. __保留_1__
26. 任勇、胡成、谭X、秦天、赵S、赵Z.和刘T. (2020) 。 FastSpeech 2 : 快速、高质量的端到端文本转语音。 arXiv. <https://arxiv.org/abs/2006.04558>
27. Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyrgiannakis, Y. 和 Wu, &Y.(2018)。 通过根据梅尔频谱图预测调节 WaveNet 进行自然 TTS 合成。 arXiv. __保留_0__
- 28.Thinh, L.(2024)。 viXTTS : 越南语音克隆文本转语音模型。 GitHub。
<https://github.com/thinhlpg/vixtts-demo>

29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & 波洛苏欣, I. (2017)。您所需要的就是关注。 arXiv. __保留_0__
30. Vu, T., Nguyen, L. T., & Nguyen, D. Q. (2025). Zero-shot text-to-speech for Vietnamese. arXiv. __保留_0__
31. Wan, L., Wang, Q., Papir, & A., & Moreno, I. L. (2018). Generalized end-to-end loss for 说话人验证。2018年IEEE声学、语音和声学国际会议 信号处理 (ICASSP) (第 4879–4883 页)。 IEEE。
<https://ieeexplore.ieee.org/abstract/document/8462665>
32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Agiomyriannakis, Y., Clark, R. 和 Saurous, R. A. (2017)。Tacotron：走向端到端语音合成。 arXiv。
<https://arxiv.org/abs/1703.10132>
33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R. J., Battenberg, E., Shor, J., Xiao, Y., Jia, Y., & Ren, F., & Saurous, R. A. (2018)。风格标记：无监督风格建模，端到端语音合成中的控制和传输。 arXiv。
<https://arxiv.org/abs/1803.09017>
34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: English multi-CSTR语音克隆工具包的说话人语料库（版本0.92）。爱丁堡大学。
<https://datashare.ed.ac.uk/handle/10283/3443>
35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R. J., Jia, Y., Chen, Z., & Wu, Y. (2019). LibriTTS：源自 LibriSpeech 的文本转语音语料库。 arXiv。
<https://arxiv.org/abs/1904.02882>
36. Le, T. (2024). viVoice: A large-scale multi-speaker Vietnamese speech dataset for text-to-演讲。拥抱脸。 __保留_0__