

HệThống Dịch Văn Bản GiữNguyên Định Dạng Gốc Sử Dụng Trí TuệNhân Tạo

Tekstvertaalselsel handhaaf oorspronklike formaat deur kunsmatige intelligensie te gebruik

Hà Hoàng-Phúc ¹ and Second Author ²[1111-2222-3333-4444]
Ha Hoang-Phuc 1 en Tweede skrywer 2[1111-2222-3333-4444]

¹ Khoa Công Nghệ Thông Tin, Trường Đại học Nam Cần Thơ, Việt Nam ² Springer Heidelberg, Tiergartenstr. 17, 69121
Heidelberg, Germany lns@springer.com
¹ Fakulteit Inligtingstegnologie, Southern Can Tho Universiteit, Vietnam ² Springer Heidelberg, Tiergartenstr. 17, 69121
Heidelberg, Duitsland

Tóm tắt. Trong bối cảnh các hệ thống dịch thuật sử dụng trí tuệ nhân tạo phát triển nhanh chóng từ năm 2016, việc thiếu vắng nghiên cứu tổng quan hệ thống về công nghệ, phương pháp và tiêu chuẩn đánh giá khả năng bảo toàn định dạng tài liệu đã tạo ra khoảng trống lớn trong lĩnh vực này. Nghiên cứu này thực hiện tổng quan toàn diện về các hệ thống dịch văn bản AI có khả năng giữ nguyên định dạng gốc thông qua phân tích 40 tài liệu nghiên cứu từ năm 2016 đến 2025, bao gồm cả tiếng Việt và tiếng Anh, sử dụng phương pháp phân loại và so sánh có hệ thống theo năm nhóm chính gồm sản phẩm thương mại, mã nguồn mở, bộ dữ liệu, hướng tiếp cận kỹ thuật và phương pháp đánh giá. Kết quả phân tích cho thấy ba xu hướng công nghệ chính gồm hệ thống dịch dựa trên quy tắc với ưu điểm đơn giản nhưng thiếu linh hoạt, mạng nơ-ron dịch máy với khả năng xử lý ngữ cảnh tốt hơn nhưng yêu cầu dữ liệu lớn, và mô hình ngôn ngữ lớn chiếm ưu thế hiện nay với các sản phẩm như DeepL đạt hơn một triệu người dùng doanh nghiệp, Google Translate API với hàng trăm triệu lượt gọi mỗi ngày và Adobe Acrobat AI định vị phân khúc chuyên nghiệp, chủ yếu sử dụng GPT-4 và các mô hình chuyên biệt với kỹ thuật prompt engineering kết hợp phân tích cấu trúc tài liệu.

Opsomming. In die konteks van vertaalselsels wat kunsmatige intelligensie gebruik wat vinnig ontwikkel sedert 2016, het die gebrek aan sistematiese navorsing oor tegnologie, metodes en standarde vir die evaluering van die vermoë om dokumentformate te behou 'n groot leemte in hierdie veld geskep. Hierdie studie gee 'n omvattende oorsig van KI-teksvertalingstelsels wat in staat is om die oorspronklike formaat te behou deur die ontleding van 40 navorsingsdokumente van 2016 tot 2025, insluitend Viëtnamese en Engels, met behulp van 'n sistematiese klassifikasie- en vergelykingsmetode volgens vyf hoofgroepe insluitend kommersiële produkte, oopbronskode, datastelle, tegniese benaderings en evalueringmetodes. Die ontledingsresultate toon dat drie hooftegnologieë reëlgebaseerde vertaalselsels insluit met die voordeel van eenvoud maar gebrek aan buigsaamheid, masjienvertaling neurale netwerke met beter konteksverwerkingsvermoëns maar groot data benodig, en groot taalmodelle wat vandag oorheers met produkte soos DeepL wat meer as een miljoen ondernemingsgebruikers bereik, Google Translate API met honderde miljoene oproepe per dag, en Adobe Acrobat wat hoofsaaklik die professionele AI-segment gebruik. GPT-4 en gespesialiseerde modelle met vinnige ingenieurstechnieke gekombineer met dokumentstruktuuranalise.

Từ khóa: dịch máy thần kinh, bảo toàn định dạng, xử lý PDF, xử lý DOCX, mô hình ngôn ngữ lớn, translation API.

Sleutelwoorde: neurale masjienvertaling, formaatbewaring, PDF-verwerking, DOCX-verwerking, groot taalmodelle, vertaling API.

1 Giới Thiệu

1 Inleiding

Cùng với sự phát triển mạnh mẽ của các mô hình ngôn ngữ lớn như GPT-3, GPT-4 và Claude từ năm 2019 trở đi, việc ứng dụng trí tuệ nhân tạo vào lĩnh vực dịch thuật tài liệu có cấu trúc phức tạp đã bắt đầu xuất hiện thông qua các hệ thống dịch tự động có khả năng bảo toàn định dạng gốc.

Saam met die sterk ontwikkeling van groot taalmodelle soos GPT-3, GPT-4 en Claude vanaf 2019, het die toepassing van kunsmatige intelligensie op die gebied van die vertaling van dokumente met komplekse strukture begin verskyn deur outomatiese vertaalstelsels wat in staat is om die oorspronklike formaat te behou.

Trước khi đi vào phân tích chi tiết, cần làm rõ một số thuật ngữ và khái niệm chính yếu được sử dụng xuyên suốt nghiên cứu này để đảm bảo người đọc có sự hiểu biết thống nhất. Dịch máy hay Machine Translation (MT) là quá trình sử dụng phần mềm máy tính để tự động dịch văn bản từ ngôn ngữ nguồn sang ngôn ngữ đích mà không cần hoặc cần rất ít sự can thiệp của con người, sử dụng các kỹ thuật xử lý ngôn ngữ tự nhiên và học sâu để hiểu ngữ nghĩa và tạo ra bản dịch phù hợp (Vaswani và cộng sự, 2017). Bảo toàn định dạng hay Format Preservation là khả năng của hệ thống dịch

Voordat jy in gedetailleerde ontleding gaan, is dit nodig om 'n paar sleutel terme en -begrippe wat deur hierdie studie gebruik word, te verduidelik om te verseker dat lesers 'n verenigde begrip het. Masjienvertaling of Masjienvertaling (MT) is die proses om rekenarsagteware te gebruik om teks van elke brontaal outomaties in die teikentaal te vertaal met min of geen menslike ingryping, deur natuurlike taalverwerking en diepleertegniese te gebruik om die semantiek te verstaan en gepaste vertalings te skep (Vaswani et al., 2017). Formaatbewaring is 'n vermoë van die vertaalstelsel

thuật trong việc duy trì toàn bộ các thành phần trình bày của tài liệu gốc sau khi dịch, bao gồm font chữ, cỡ chữ, màu sắc, căn lề, bảng biểu, đầu mục, đánh số trang, header, footer và các thành phần đồ họa nhúng trong tài liệu (Hassan và cộng sự, 2020). Mô hình ngôn ngữ lớn hay Large Language Model (LLM) là loại mô hình trí tuệ nhân tạo được huấn luyện trên lượng dữ liệu văn bản khổng lồ từ hàng tỷ đến hàng nghìn tỷ từ, có khả năng hiểu ngữ cảnh phức tạp và sinh ra văn bản tự nhiên giống con người, với các đại diện tiêu biểu như GPT-4 của OpenAI, Claude của Anthropic, và Gemini của Google (Sato, 2025).

tegniek in die handhawing van alle aanbiedingselemente van die oorspronklike dokument na vertaling, insluitend lettertipes, lettergroottes, kleure, belyning, tabelle, opskrifte, bladsynommering, koptekste, voettekste en ingebedde grafiese elemente in die dokument (Hassan et al., 2020). Large Language Model of Large Language Model (LLM) is 'n tipe kunsmatige intelligensie-model wat opgelei is op groot hoeveelhede teksdata van biljoene tot triljoene woorde, wat in staat is om komplekse kontekste te verstaan en natuurlike teks soos mense te genereer, met tipiese verteenwoordigers soos OpenAI se GPT-4, Anthropic se Claude, en Google se Gemini (Sato, 2025).

2 Thị Trường Sản Phẩm

2 Produkmark

DeepL Document Translation được ra mắt vào năm 2017 bởi công ty DeepL GmbH có trụ sở tại Cologne, Đức, đánh dấu bước ngoặt quan trọng trong ngành công nghiệp dịch thuật tài liệu tự động khi lần đầu tiên một sản phẩm thương mại cam kết bảo toàn hoàn toàn định dạng gốc của tệp DOCX và PDF sau khi dịch (Hassan và cộng sự, 2020).

DeepL Document Translation is in 2017 bekendgestel deur DeepL GmbH, gebaseer in Keulen, Duitsland, wat 'n belangrike keerpunt in die outomatiese dokumentvertalingsbedryf was toe 'n kommersiële produk vir die eerste keer daartoe verbind is om die oorspronklike formaat van DOCX- en PDF-lêers na vertaling heeltemal te bewaar (Hassan et al., 2020).

Tiếp nối với sự phổ biến của DeepL, Google Cloud Translation API xuất hiện như một giải pháp toàn diện hơn với hơn 500 triệu lượt gọi API mỗi ngày trên toàn cầu, định vị như nền tảng dịch thuật cho các nhà phát triển và doanh nghiệp muốn tích hợp khả năng dịch thuật vào ứng dụng của riêng mình (Hassan và cộng sự, 2020). Điểm khác biệt chính của Google Cloud Translation nằm ở hệ sinh thái tích hợp với các dịch vụ Google khác như Google Docs, Google Drive và Google Workspace, cho phép người dùng dịch tài liệu trực tiếp từ môi trường làm việc quen thuộc mà không cần chuyển đổi định dạng thủ công. Về mặt kỹ thuật, Google Cloud Translation áp dụng kiến trúc ba tầng được tối ưu hóa với tầng giao diện RESTful API và client libraries cho Python, Java, Node.js và nhiều ngôn ngữ lập trình khác (Vaswani và cộng sự, 2017).

Na die gewildheid van DeepL, het Google Cloud Translation API na vore gekom as 'n meer omvattende oplossing met meer as 500 miljoen API-oproepe per dag wêreldwyd, wat dit posisioneer as 'n vertaalinfrastruktuurplatform vir ontwikkelaars en besighede wat vertaalvermoëns in hul eie toepassings wil integreer (Hassan et al., 2020). Die belangrikste verskil van Google Wolk-vertaling lê in sy integrasie-ekosisteem met ander Google-dienste soos Google Docs, Google Drive en Google Workspace, wat gebruikers in staat stel om dokumente direk vanaf bekende werksomgewings te vertaal sonder die behoefte aan handmatige formaat omskakeling.

Tegnies pas Google Cloud Translation 'n geoptimaliseerde drievlak-argitektuur toe met 'n RESTful API-koppelvlaklaag en kliëntbiblioteke vir Python, Java, Node.js en baie ander programmeertale (Vaswani et al., 2017).

Adobe Acrobat AI Translation xuất hiện như một tính năng tích hợp trong bộ sản phẩm Adobe Acrobat, đánh dấu xu hướng tích hợp dịch thuật AI vào công cụ xử lý tài liệu PDF chuyên nghiệp thay vì cung cấp như dịch vụ độc lập (Hassan và cộng sự, 2020). Điểm độc đáo của Adobe Acrobat AI nằm ở cách tiếp cận xử lý tài liệu gốc, trong đó hệ thống có khả năng truy cập trực tiếp vào cấu trúc nội bộ của tệp PDF thông qua các API độc quyền của Adobe, cho phép bảo toàn các thành phần định dạng phức tạp mà các giải pháp bên thứ ba không thể đọc được. Về mặt công nghệ, Adobe Acrobat AI được xây dựng trên nền tảng Adobe Sensei, hệ thống trí tuệ nhân tạo nội bộ của Adobe kết hợp với các API dịch thuật bên ngoài như Microsoft Azure Translator và DeepL thông qua kiến trúc plugin có thể mở rộng (Park và cộng sự, 2021).

Adobe Acrobat AI Translation verskyn as 'n geïntegreerde kenmerk in die Adobe Acrobat-produkreeks, wat die neiging aandui om KI-vertaling in professionele PDF-dokumentverwerkingsnutsmiddels te integreer in plaas daarvan om dit as 'n onafhanklike diens te verskaf (Hassan et al., 2020). Wat uniek is aan Adobe Acrobat AI, lê in sy oorspronklike dokumentverwerkingsbenadering, waar die stelsel direkte toegang het tot die interne struktuur van PDF-lêers deur Adobe se eie API's, wat die behoud van komplekse formaterings-elemente moontlik maak wat nie deur derde party-oplossings gelees kan word nie. Tegnologies is Adobe Acrobat AI gebou op die Adobe Sensei-platform, Adobe se interne kunsmatige intelligensiestelsel gekombineer met eksterne vertaal-API's soos Microsoft Azure Translator en DeepL deur 'n skaalbare inprop-argitektuur (Park et al., 2021).

Translate-toolkit là một trong những dự án mã nguồn mở đầu tiên xuất hiện trên GitHub phục vụ xử lý tệp dịch thuật đa định dạng, đánh dấu sự khởi đầu của phong trào chia sẻ kiến thức về xử lý tài liệu đa ngôn ngữ trong cộng đồng lập trình viên (Smith, 2019). Dự án được phát hành dưới giấy phép GNU GPL v2, cho phép các nhà phát triển khác sử dụng miễn phí, chỉnh sửa và phân phối lại với điều kiện giữ nguyên điều khoản giấy phép. Về kiến trúc, translate-toolkit cung cấp bộ công cụ dòng lệnh

Translate-toolkit is een van die eerste oopbronprojekte wat op GitHub verskyn wat multi-formaat vertaallêerverwerking bedien, wat die begin is van 'n beweging om kennis oor veeltalige dokumentverwerking in die programmeringsgemeenskap te deel (Smith, 2019). Die projek word vrygestel onder die GNU GPL v2-lisensie, wat ander ontwikkelaars toelaat om dit vryelik te gebruik, te verander en te herverdeel, onderhewig aan die lisensiebepalings. Wat argitektuur betref, bied translate-toolkit 'n opdragreël-nutsmiddelstel

Contribution Title (shortened if too long) 3
Bydrae Titel (verkort indien te lank) 3

và thư viện Python để chuyển đổi giữa các định dạng tệp dịch thuật như PO, XLIFF, TMX và các định dạng tài liệu như DOCX, ODT, HTML. Dự án tập trung vào việc trích xuất chuỗi văn bản cần dịch từ tài liệu trong khi bảo toàn toàn bộ cấu trúc markup và metadata của tệp gốc. Phương pháp cài đặt được document chi tiết, yêu cầu người dùng cài đặt Python 3.8 trở lên và các gói phụ thuộc thông qua pip, sau đó có thể sử dụng ngay các công cụ dòng lệnh để xử lý hàng loạt tài liệu (Park và cộng sự, 2021).

en Python-biblioteek om te skakel tussen vertaallêerformate soos PO, XLIFF, TMX en dokumentformate soos DOCX, ODT, HTML. Die projek fokus op die onttrekking van teksstringe wat vertaal moet word uit dokumente, terwyl die hele opmaakstruktuur en metadata van die oorspronklike lêer bewaar word. Die installasiem metode word in die dokument uiteengesit, wat vereis dat gebruikers Python 3.8 of hoër en afhanklike pakkette via pip installeer, en dan onmiddellik opdragreëlnutsgoed kan gebruik om dokumente te bondel te verwerk (Park et al., 2021).

3 Mã Nguồn

3 Bronkode

DeepL là sản phẩm thương mại closed-source, mã nguồn không được công khai trên bất kỳ nền tảng chia sẻ code nào, được bảo vệ nghiêm ngặt như tài sản cốt lõi của công ty theo mô hình Software-as-a-Service (Hassan và cộng sự, 2020). Người dùng có thể tương tác với hệ thống thông qua giao diện web tại deepl.com, ứng dụng desktop chính thức hoặc DeepL API với SDK chính thức cho các ngôn ngữ lập trình phổ biến. Về tính phí, DeepL áp dụng mô hình freemium với giới hạn 500.000 ký tự mỗi tháng cho gói miễn phí, trong khi các gói Pro yêu cầu thanh toán định kỳ để truy cập không giới hạn, xử lý tài liệu DOCX và PDF, và sử dụng API (Smith, 2019). Công cụ cần thiết từ phía người dùng cuối rất đơn giản, chỉ bao gồm trình duyệt web hiện đại hoặc ứng dụng desktop, và kết nối internet ổn định để truyền tải tài liệu lên hệ thống đám mây của DeepL. Người dùng doanh nghiệp tích hợp API cần tài khoản Pro và API key để xác thực, cùng với kiến thức lập trình cơ bản để sử dụng SDK tương ứng.

DeepL is 'n geslote-bron kommersiële produk, die bronkode word nie op enige kodedeelpatform gepubliseer nie, en word streng beskerm as die maatskappy se kernbates volgens die Sagteware-as-'n-diens-model (Hassan et al., 2020). Gebruikers kan slegs met die stelsel interaksie hê deur die webkoppelvlak by deepl.com, die amptelike rekenaartoepassing of die DeepL API met amptelike SDK's vir gewilde programmeertale. Wat pryse betref, pas DeepL 'n freemium-model toe met 'n limiet van 500 000 karakters per maand vir die gratis plan, terwyl Pro-planne herhalende betalings vir onbeperkte toegang, DOCX- en PDF-dokumentverwerking en API-gebruik vereis (Smith, 2019). Die gereedskap wat van die eindgebruiker benodig word, is baie eenvoudig, insluitend slegs 'n moderne webblaaier of rekenaartoepassing, en 'n stabiele internetverbinding om dokumente na DeepL se wolkstelsel op te laai. Besigheidsgebruikers wat API's integreer, benodig 'n Pro-rekening en API-sleutel vir stawing, tesame met basiese programmeringskennis om die ooreenstemmende SDK te gebruik.

Google Cloud Translation tương tự như DeepL, cũng là dịch vụ thương mại với mã nguồn mô hình hoàn toàn đóng, tuy nhiên Google cung cấp các client libraries mã nguồn mở trên GitHub để thuận tiện cho việc tích hợp API (Hassan và cộng sự, 2020). Không có repository mã nguồn nào liên quan đến mô hình dịch thuật cốt lõi được công bố công khai, mặc dù Google có công bố nhiều bài nghiên cứu học thuật mô tả kiến trúc mô hình tổng quát. Về chính sách phí, Google Cloud Translation áp dụng mô hình pay-as-you-go với mức 20 USD cho mỗi triệu ký tự sau khi sử dụng hết hạn mức miễn phí 500.000 ký tự mỗi tháng trong năm đầu tiên (Park và cộng sự, 2021). Quá trình tích hợp yêu cầu tạo dự án trên Google Cloud Platform, kích hoạt Cloud Translation API, tạo service account và tải xuống credentials JSON, sau đó cài đặt client library tương ứng thông qua pip hoặc npm. Công cụ cần thiết bao gồm tài khoản Google Cloud, thiết lập để kích hoạt billing, và môi trường lập trình với ngôn ngữ được Google hỗ trợ SDK chính thức.

Google Cloud Translation is soortgelyk aan DeepL, wat ook 'n kommersiële diens is met 'n heeltemal geslote bronkode model, maar Google verskaf oopbronkliëntbiblioteke op GitHub om API-integrasie te vergemaklik (Hassan et al., 2020). Daar is geen publieke beskikbare bronkode bewaarplek wat verband hou met die kernvertalingsmodel nie, alhoewel Google baie akademiese referate gepubliseer het wat die algemene modelargitektuur beskryf. Wat fooibleid betref, pas Google Cloud Translation 'n betaal-soos-jy-gaan-model toe met 'n koers van 20 USD per miljoen karakters nadat die gratis limiet van 500 000 karakters per maand in die eerste jaar opgebruik is (Park et al., 2021). Die integrasieproses vereis die skep van 'n projek op Google Wolk-platform, die aktivering van die Wolk-vertalings-API, die skep van 'n diensrekening en die aflaai van JSON-geloofsbrief, en installeer dan die ooreenstemmende kliëntbiblioteek via pip of npm. Nodige gereedskap sluit in 'n Google Wolk-rekening, 'n kredietkaart om fakturering te aktiveer, en 'n programmeringsomgewing met 'n taal wat deur die amptelike Google SDK ondersteun word.

4 Dữ Liệu

4 Data

Dữ liệu song ngữ đóng vai trò nền tảng trong việc phát triển và đánh giá các hệ thống dịch thuật AI có khả năng bảo toàn định dạng, bao gồm cả dữ liệu văn bản thuần túy cho huấn luyện mô hình dịch và dữ liệu tài liệu có cấu trúc để kiểm tra khả năng bảo toàn định dạng (Hassan và cộng sự, 2020). Bộ dữ liệu WMT (Workshop on Machine Translation) được tổ chức hàng năm từ năm 2006 là nguồn dữ liệu benchmark phổ biến. Tweetalige data speel 'n fundamentele rol in die ontwikkeling en evalueer van formaatbehoud KI-vertaalstelsels, insluitend beide gewone teksdata vir opleiding van vertaalmodelle en gestruktureerde dokumentdata vir die toets van formaatbehoud (Hassan et al., 2020). Die WMT (Workshop on Machine Translation) dataset, wat jaarliks sedert 2006 gehou word, is 'n gewilde bron van maastafdata.

biến nhất được sử dụng trong đánh giá hệ thống dịch thuật AI hiện đại, với cấu trúc bao gồm hàng triệu cặp câu song ngữ được thu thập từ các nguồn tin tức, tài liệu chính phủ và văn bản pháp lý, chia thành tập huấn luyện, tập validation và tập test chuẩn hóa (Smith, 2019).

mees algemeen gebruik in die evaluerende van moderne KI-vertalingstelsels, met 'n struktuur wat bestaan uit miljoene paar tweetalige sinne versamel uit nuusbronne, regeringsdokumente en regsdokumente, verdeel in opleidingsstelle, valideringsstelle en gestandaardiseerde toetsstelle (Smith, 2019).

Google Cloud Translation phát triển bộ dữ liệu huấn luyện từ nhiều nguồn đa dạng bao gồm Common Crawl được lọc và căn chỉnh song ngữ, các bản dịch chính thức từ tổ chức quốc tế và các kho dữ liệu học thuật công khai như OpenSubtitles và Europarl, với tổng quy mô ước tính hàng trăm tỷ token song ngữ được xử lý qua pipeline cleaning và deduplication phức tạp (Vaswani và cộng sự, 2017). Cấu trúc dữ liệu cho các tác vụ dịch tài liệu được bổ sung thêm các trường như document_id để nhóm các câu thuộc cùng một tài liệu, section_type để phân biệt tiêu đề, nội dung chính và chú thích, và format_tags để mã hóa thông tin định dạng inline như bold và italic.

Google Cloud Translation ontwikkel opleidingsdatastelle van uiteenlopende bronne, insluitend tweetalig gefiltreerde en belynde Common Crawl, amptelike vertalings van internasionale organisasies, en publieke akademiese databewaarplekke soos OpenSubtitles en Europarl, met 'n totale geskatte grootte van honderde biljoene tweetalige tokens wat deur komplekse pyplynskoonmaak en deduplisering verwerk word (Vaswani et al., 2017). Die datastruktuur vir dokumentvertalingstake word aangevul met velde soos document_id om sinne wat aan dieselfde dokument behoort te groepeer, section_type om titels, hoofinhoud en byskrifte te onderskei, en format_tags om inlynformaatinligting soos vet en kursief te enkodeer.

Bảng 1. So sánh cấu trúc dữ liệu các hệ thống dịch tài liệu AI chính

Tabel 1. Vergelyking van datastrukture van groot KI-dokumentvertalingstelsels

Đặc điểm	DeepL DiepL	Google Translate Google Vertaal	Adobe Acrobat Adobe Akrobaat	Mã nguồn mở
Định dạng hỗ trợ Formaat ondersteuning	DOCX, PPTX, PDF	DOCX, PDF, HTML	PDF, DOCX	CSV/JSON/XML
Số ngôn ngữ	31 ngôn ngữ 31 jaar oud	135 ngôn ngữ 135 mense	35 ngôn ngữ 35 jaar oud	10–135 ngôn ngữ 10–135 uur 10-135 uur
Bảo toàn bảng	Đầy đủ	Một phần	Đầy đủ	Một phần
Hỗ trợ OCR	Có (giới hạn)	Có (Document AI)	Có (nâng cao)	Tùy thư viện
Dung lượng tối đa	10 MB/file 10 MB/lêer	20 MB/file 20 MB/lêer 20 MB/leer	500 MB/file 500 MB/lêer 500 MB/leer	Không giới hạn Onbeperk
Cập nhật mô hình Dateer model op	Liên tục Deurlopend	Liên tục Deurlopend	Theo phiên bản	Không đều Ongelyk

Glossary tùy chỉnh	Có Ja	Có (AutoML) Ja (AutoML)	Không Nee	Tùy dự án Hang af van die projek
--------------------	----------	----------------------------	--------------	-------------------------------------

Về phương pháp thu thập và xây dựng dữ liệu tài liệu có định dạng cho hệ thống dịch AI, hầu hết các hệ thống thương mại kết hợp thu thập tự động từ web với quá trình lọc và kiểm tra chất lượng thủ công bởi đội ngũ chuyên gia ngôn ngữ (Park và cộng sự, 2021). DeepL hợp tác với các nhà xuất bản học thuật và cơ quan dịch thuật chuyên nghiệp để có được dữ liệu song ngữ chất lượng cao trong các lĩnh vực chuyên biệt như y tế, pháp lý và kỹ thuật, sau đó xử lý qua pipeline alignment tự động kết hợp với human review để đảm bảo chất lượng cặp câu song ngữ, cuối cùng được augmentation bằng các kỹ thuật back-translation và data synthesis để tăng tính đa dạng (Hassan và cộng sự, 2020). Google sử dụng phương pháp thu thập quy mô lớn từ Common Crawl kết hợp với thuật toán language identification và sentence alignment tự động, nhưng phải xử lý vấn đề nhiễu dữ liệu và các cặp câu không tương đương ngữ nghĩa thông qua các bộ lọc chất lượng phức tạp dựa trên perplexity và cross-lingual similarity (Vaswani và cộng sự, 2017).

Met betrekking tot die metode om geformateerde dokumentdata vir KI-vertaalstelsels in te samel en te bou, kombineer die meeste kommersiële stelsels outomatiese versameling vanaf die web met handmatige filtering en kwaliteitkontrolering deur 'n span taalkundiges (Park et al., 2021). DeepL werk saam met akademiese uitgewers en professionele vertaalagentskappe om tweetalige data van hoë gehalte in gespesialiseerde velde soos medies, reg en ingenieurswese te bekom, en verwerk dit dan deur 'n outomatiese belyningspypplyn gekombineer met menslike hersiening om die kwaliteit van tweetalige sinspare te verseker, en word uiteindelik aangevul met terugvertaling en datasintese-tegnieke om diversiteit te verhoog (H, 2020; et al. 2). Google gebruik grootskaalse versameling van Common Crawl gekombineer met outomatiese taalidentifikasie en sinsbelyningsalgoritmes, maar moet datageraas en semanties ongelykwaardige sinspare hanteer deur komplekse kwaliteitfilters gebaseer op verwarring en kruislinguele ooreenkoms (Vaswani et al., 2017).

Contribution Title (shortened if too long) 5
Bydrae Titel (verkort indien te lank) 5

Bảng 2. So sánh các phương pháp tích hợp dữ liệu Tarot với LLM
Tabel 2. Vergelyking van Tarot-data-integrasiemetodes met LLM

Phương pháp Metode	Chi phí Koste	Độ phức tạp Graad ingewikkeld	Khả năng cập nhật Opdateer vermoë	Chất lượng Kwaliteit
Prompt Engineering Prompt Ingenieurswese	Thấp (\$0.03–0.06/1K tokens) Laag (\$0,03–0,06/1K tekens)	Thấp Laag	Rất dễ (chỉnh sửa prompt) Baie maklik (wysig opdrag)	Tốt cho tài liệu phổ thông
Fine-tuning Fyn instel	Rất cao (\$500–5000/model)	Cao Hoog	Khó (cần retrain)	Tốt nhất cho chuyên ngành Beste vir professionele persone tak
RAG + Translation	Trung bình (\$0.05–0.10/query)	Trung bình Gemiddeld	Dễ (thêm Maklik (meer documents) dokumente)	Rất tốt khi Baie goed wanneer retrieve chính xác hoofherwinning xác liggaam
Hybrid Pipeline Hibried Pyplyn	Trung bình–Cao Medium-Hoog	Cao Hoog	Linh hoạt Buigsaam	Tốt nhất overall

Các thách thức còn tồn tại trong quản lý dữ liệu cho hệ thống dịch tài liệu AI bao gồm vấn đề bản quyền khi sử dụng tài liệu từ nhà xuất bản, thiếu chuẩn hóa trong annotation định dạng giữa các dataset khác nhau gây khó khăn cho việc benchmark thống nhất, nhu cầu cập nhật liên tục để phản ánh sự thay đổi của ngôn ngữ và thuật ngữ chuyên ngành, và sự đánh đổi giữa tính xác thực truyền thống và sự phù hợp hiện đại trong các bản dịch tài liệu lịch sử (Hassan và cộng sự, 2020; Smith, 2019).

Oorblywende uitdaginge in databestuur vir KI-dokumentvertalingstelsels sluit in kopieregkwessies by die gebruik van dokumente van uitgewers, 'n gebrek aan standaardisering in formaataantekeninge oor verskillende datastelle wat konsekwente

maatstawwe moeilik maak, die behoefte aan deurlopende opdatings om veranderinge in taal en gespesialiseerde terminologie te weerspieël, en die afweging tussen tradisionele egtheid en moderne relevansie in historiese dokumentvertalings (Hassan, 220200).

5 Húróng Tiěp Cậń Ngiên Cứu

5 Navorsingsbenaderings

Trong lĩnh vực dịch thuật tài liệu sử dụng trí tuệ nhân tạo với khả năng bảo toàn định dạng, các nghiên cứu và triển khai ứng dụng từ năm 2016 đến nay đã áp dụng ba hướng tiếp cận công nghệ chính với mức độ phức tạp và hiệu quả khác nhau, phản ánh quá trình phát triển nhanh chóng của lĩnh vực xử lý ngôn ngữ tự nhiên và thị giác máy tính (Hassan và cộng sự, 2020; Smith, 2019). Phân tích các tài liệu nghiên cứu cho thấy sự chuyển dịch rõ rệt từ các phương pháp thống kê truyền thống sang các giải pháp dựa trên mạng nơ-ron và mô hình ngôn ngữ lớn, song song với sự phát triển của các kỹ thuật phân tích tài liệu có cấu trúc cho phép xử lý các thành phần định dạng phức tạp một cách tự động và chính xác hơn (Vaswani và cộng sự, 2017; Park và cộng sự, 2021). Điểm khác biệt căn bản so với các hệ thống dịch thuật văn bản thuần túy là bài toán dịch tài liệu có định dạng đòi hỏi giải quyết đồng thời hai vấn đề độc lập nhưng liên quan mật thiết: chất lượng dịch thuật ngữ nghĩa và tính toàn vẹn của cấu trúc trình bày, trong đó việc tối ưu hóa một chiều thường ảnh hưởng đến chiều còn lại (Sato, 2025; Hassan và cộng sự, 2020).

Op die gebied van dokumentvertaling met behulp van kunsmatige intelligensie met formaatbewaringsvermoëns, het navorsing en toepassingsimplementering vanaf 2016 tot nou drie hoof tegnologiese benaderings met verskillende vlakke van kompleksiteit en doeltreffendheid toegepas, wat die vinnige ontwikkeling van die velde van natuurlike taalverwerking en rekenaarvisie weerspieël (Hassan et al., 2020; Smith, 2019). Ontleding van navorsingsdokumente toon 'n duidelike verskuiwing van tradisionele statistiese metodes na oplossings gebaseer op neurale netwerke en groot taalmodelle, parallel met die ontwikkeling van gestruktureerde dokumentontledingstegnieke wat meer akkurate en geoutomatiseerde verwerking van komplekse formateringselemente moontlik maak (Vaswani et al., 2017; Park et al., 2021). Die fundamentele verskil in vergelyking met suiwer teksvertalingstelsels is dat die probleem van die vertaling van geformateerde dokumente vereis dat twee onafhanklike maar nou verwante kwessies gelyktydig opgelos word: semantiese vertalingskwaliteit en die integriteit van die aanbiedingstruktuur, waarin die optimalisering van een dimensie dikwels die ander dimensie beïnvloed (Sato, 2025; Hassan et al., 2020).

Các nghiên cứu đã công bố về hệ thống dịch tài liệu AI được phân loại thành ba nhóm chính dựa trên công nghệ cốt lõi. Hướng tiếp cận dịch máy thống kê (SMT) xuất hiện sớm nhất và hiện còn được sử dụng trong một số hệ thống nhúng có ràng buộc tài nguyên. Hướng tiếp cận dịch máy thần kinh (NMT) dựa trên kiến trúc encoder-decoder với attention mechanism trở thành chuẩn mực từ năm 2017 sau bài báo "Attention Is All You Need" của Vaswani và cộng sự. Hướng tiếp cận dựa trên mô hình ngôn ngữ lớn đang chiếm ưu thế từ năm 2020 khi GPT-3 chứng minh khả năng dịch thuật few-shot mà không cần fine-tuning trên dữ liệu song ngữ chuyên biệt (Vaswani và cộng sự, 2017; Sato, 2025).

Gepubliseerde navorsing oor KI-dokumentvertalingsstelsels word in drie hoofgroepe geklassifiseer gebaseer op die kerntechnologie. Die benadering tot statistiese masjienvertaling (SBS) het die vroegste verskyn en word steeds in sommige hulpbronbeperkte ingebedde stelsels gebruik. Die neurale masjienvertaling (NMT) benadering gebaseer op enkoderder-dekoderder-argitektuur met aandagmeganisme het in 2017 die standaard geword ná die artikel "Attention Is All You Need" deur Vaswani et al. Benaderings gebaseer op groot taalmodelle is dominant sedert 2020 toe GPT-3 die vermoë gedemonstreer het om min-skootvertaling te doen sonder om op gespesialiseerde tweetalige data te verfyn (Vaswani et al., 2017; Sato, 2025).

Hướng tiếp cận dịch máy thống kê (SMT) là phương pháp được sử dụng trước khi kỹ thuật deep learning bắt đầu, dựa trên các mô hình xác suất học từ dữ liệu song ngữ quy mô lớn để tìm ra bản dịch có xác suất cao nhất cho một câu nguồn cho trước (Smith, 2019). Theo cách tiếp cận này, hệ thống được thiết kế để hoạt động bằng cách phân tách câu nguồn thành các đơn vị dịch nhỏ hơn gọi là phrases, tìm kiếm các phrase tương ứng trong phrase table được xây dựng từ dữ liệu song ngữ huấn luyện, và kết hợp chúng thành bản dịch hoàn chỉnh theo mô hình ngôn ngữ đích (Hassan và cộng sự, 2020). Ưu điểm chính của phương pháp này được các nghiên cứu nhấn mạnh là tính minh bạch trong quá trình dịch cho phép kiểm tra và can thiệp thủ công, chi phí tính toán thấp khi inference phù hợp cho môi trường thiếu tài nguyên, khả năng tích hợp trực tiếp các từ điển và quy tắc ngôn ngữ học do chuyên gia xây dựng, và không cần GPU chuyên dụng để triển khai. Tuy nhiên, các nghiên cứu cũng chỉ ra những hạn chế đáng kể bao gồm chất lượng dịch thường kém hơn NMT ở hầu hết cặp ngôn ngữ do không mô hình hóa ngữ cảnh dài, thiếu khả năng xử lý các cấu trúc ngữ pháp phức tạp có sự khác biệt lớn giữa ngôn ngữ nguồn và đích, và đặc biệt không có cơ chế tự nhiên để xử lý thông tin định dạng kèm theo văn bản (Park và cộng sự, 2021). Nghiên cứu của Hassan và cộng sự (2020) cho thấy hệ thống SMT đạt điểm BLEU trung bình thấp hơn 8 đến 12 điểm so với NMT trên các bộ test chuẩn WMT, đồng thời tỷ lệ bảo toàn định dạng chỉ đạt 62% trong thử nghiệm với tài liệu DOCX do thiếu cơ chế ánh xạ giữa đơn vị dịch và thành phần định dạng tương ứng.

Die statistiese masjienvertalingsbenadering (SBS) is 'n metode wat gebruik is voordat die diepleer-era begin het, gebaseer op waarskynlikheidsmodelle wat uit grootskaalse tweetalige data leer om die hoogste waarskynlikheidsvertaling vir 'n gegewe bronsin te vind (Smith, 2019). In hierdie benadering is die stelsel ontwerp om te werk deur die bronsin te ontbind in kleiner vertaaleenhede genaamd frases, te soek vir ooreenstemmende frases in 'n frasetabel wat uit tweetalige opleidingsdata gebou is, en dit te kombineer in 'n volledige vertaling volgens die doeltaalmodel (Hassan et al., 2020). Die belangrikste voordele van hierdie metode wat deur studies uitgelig word, is deursigtigheid in die vertaalproses wat handmatige kontrolering en intervensie moontlik maak, lae berekeningskoste wanneer afleidings geskik is vir hulpbron-arm omgewings, die vermoë om woordeboeke en linguistiese reëls wat deur kundiges gebou is direk te integreer, en geen behoefte aan 'n gespesialiseerde GPU

om te ontplooi nie. Studies wys egter ook beduidende beperkings uit, insluitend vertaalkwaliteit wat in die meeste taalpare dikwels slegter as NGV is as gevolg van nie modellering van lang kontekste nie, gebrek aan vermoë om komplekse grammatikale strukture met groot verskille tussen bron- en teikentale te hanteer, en veral geen natuurlike meganisme om formateringsinligting wat aan die teks geheg is, te verwerk nie (Park et al., 2021). Navorsing deur Hassan et al. (2020) toon dat die SBS-stelsel 'n gemiddelde BLEU-telling van 8 tot 12 punte laer as NGV op die WMT-standaardtoetsuites behaal, en die formaatbehoudsyfer is slegs 62% in toetsing met DOCX-dokumente as gevolg van die gebrek aan 'n karteringmeganisme tussen vertaaleenhede en ooreenstemmende formaatkomponente.

6 ChiSóĐánh Giá

6 Evalueringsaanwysers

Các nghiên cứu hiện có về hệ thống dịch tài liệu AI cho thấy xu hướng xây dựng các khung đánh giá đa chiều, kết hợp phương pháp định lượng và định tính nhằm đo lường đồng thời chất lượng dịch thuật ngữ nghĩa và mức độ bảo toàn định dạng tài liệu gốc, hai khía cạnh không thể tách rời trong đánh giá tổng thể hiệu quả hệ thống (Vaswani và cộng sự, 2017; Hassan và cộng sự, 2020). Tổng hợp tài liệu cho thấy các khung đánh giá thường được hình thành dựa trên năm nhóm chỉ số chính gồm chất lượng dịch thuật ngữ nghĩa, mức độ bảo toàn định dạng, trải nghiệm người dùng, hiệu suất kỹ thuật và tuân thủ đạo đức, trong đó có sự kết hợp giữa các chỉ số chung được sử dụng rộng rãi trong đánh giá hệ thống dịch máy như BLEU Score, TER và METEOR, cùng với các chỉ số đặc thù phản ánh bài toán bảo toàn định dạng tài liệu như Format Preservation Rate, Layout Accuracy và Structure Integrity (Smith, 2019; Park và cộng sự, 2021). Nhóm chỉ số chất lượng dịch thuật được các nghiên cứu sử dụng Bestaande studies oor KI-dokumentvertalingstelsels toon 'n neiging om multidimensionele evalueringsraamwerke te bou, wat kwantitatiewe en kwalitatiewe metodes kombineer om terselfdertyd die kwaliteit van semantiese vertaling en die mate van bewaring van die oorspronklike dokumentformaat te meet, twee onafskeidbare aspekte in die algehele assessering van stelseldoeltreffendheid (Vaswani et al., 2020:7). Literatuuroorsig toon dat evalueringsraamwerke dikwels gevorm word op grond van vyf hoofgroepe aanwysers, insluitend semantiese vertalingskwaliteit, vlak van formaatbewaring, gebruikerservaring, tegniese werkverrigting en etiese nakoming, insluitend 'n kombinasie van algemene aanwysers wat wyd gebruik word in die evaluering van masjienvertalingstelsels soos BLEU Score, TER en METEOR, tesame met spesifieke aanwysers wat die probleem van dokumentbewaring Racury en Laout weerspieël. Strukturele integriteit (Smith, 2019; Park et al., 2021). Groep vertalingskwaliteit-indekse wat deur navorsing gebruik word

Contribution Title (shortened if too long) 7
Bydrae Titel (verkort indien te lank) 7

dụng để đánh giá mức độ tương đương ngữ nghĩa giữa bản dịch tự động và bản dịch tham chiếu, qua đó chứa thách thức cốt lõi trong việc cân bằng giữa tính trung thực với văn bản gốc và tính tự nhiên trong ngôn ngữ đích, đặc biệt quan trọng đối với các tài liệu kỹ thuật đòi hỏi độ chính xác thuật ngữ tuyệt đối (Hassan và cộng sự, 2020; Sato, 2025).

gebruik om die vlak van semantiese ekwivalensie tussen outomatiese vertaling en verwysingsvertaling te evalueer, om sodoende die kernuitdaging uit te wys om getrouheid aan die bronteks en natuurlikheid in die doeltaal te balanseer, veral belangrik vir tegniese dokumente wat absolute terminologiese akkuraatheid vereis (Hassan et al., 2020; Sato, 2025).

7 Kết Luận

7 Gevolgtrekking

Nghiên cứu này đã thực hiện tổng quan toàn diện về các hệ thống dịch văn bản giữ nguyên định dạng sử dụng trí tuệ nhân tạo thông qua phân tích có hệ thống 40 tài liệu nghiên cứu từ năm 2016 đến năm 2025, bao gồm các nghiên cứu học thuật và báo cáo kỹ thuật bằng tiếng Việt và tiếng Anh. Phương pháp nghiên cứu áp dụng là phân loại và so sánh có hệ thống các sản phẩm thương mại, mã nguồn mở, bộ dữ liệu, hướng tiếp cận kỹ thuật và phương pháp đánh giá được đề xuất trong các nghiên cứu trước đây. Kết quả phân tích cho thấy ba xu hướng công nghệ chính trong lĩnh vực này, bao gồm dịch máy thông kê với ưu điểm minh bạch và chi phí thấp nhưng chất lượng hạn chế và thiếu cơ chế bảo toàn định dạng tự nhiên, dịch máy thần kinh với chất lượng ngữ nghĩa vượt trội và hỗ trợ markup-aware translation nhưng vẫn chưa đạt ngưỡng 95% bảo toàn định dạng mà doanh nghiệp yêu cầu, và mô hình ngôn ngữ lớn đang chiếm ưu thế với các sản phẩm thành công như DeepL đạt hơn một triệu người dùng doanh nghiệp, Google Cloud Translation với hàng trăm triệu lượt gọi API mỗi ngày và Adobe Acrobat định vị phân khúc chuyên nghiệp cao cấp.

Hierdie studie het 'n omvattende oorsig van formaatbewarende teksvertalingstelsels deur kunsmatige intelligensie gedoen deur 'n sistematiese ontleding van 40 navorsingsreferate van 2016 tot 2025, insluitend akademiese studies en tegniese verslae in Viëtnamese en Engels. Die toegepaste navorsingsmetode is om kommersiële produkte, oopbronskode, datastelle, tegniese benaderings en evalueringsmetodes wat in vorige studies voorgestel is, sistematies te klassifiseer en te vergelyk. Die ontleding onthul drie groot tegnologiese ontwikkelings in hierdie veld, insluitend statistiese masjienvertaling met die voordele van deursigtigheid en lae koste, maar met beperkte gehalte en gebrek aan inheemse formaatbewaringsmeganismes, neurale masjienvertaling met voortreflike semantiese gehalte en ondersteuning vir opmaakbewuste vertaling, maar wat steeds tekort skiet aan die 95%-formaatbewaringsdrempel wat besighede benodig, en die suksesvolle produkte soos 'n groot besigheidsmodel oorheers. professioneel, Google Wolk-vertaling met honderde miljoene API-oproepe per dag en Adobe Acrobat-posisionering in die hoë- en professionele segment.

Về môi trường sản phẩm và công nghệ triển khai, phân tích cho thấy sự phân tầng rõ rệt giữa các nhóm đối tượng khác nhau với DeepL định vị phân khúc chất lượng cao nhờ pipeline xử lý hai giai đoạn phân tách nội dung khỏi định dạng và hỗ trợ 31 ngôn

ngữ, Google Cloud Translation tập trung vào khả năng mở rộng và tích hợp hệ sinh thái với 135 ngôn ngữ, và Adobe Acrobat nhắm đến người dùng chuyên nghiệp với nhu cầu xử lý PDF phức tạp thông qua tích hợp sâu vào hệ sinh thái Creative Cloud. Sự xuất hiện của các dự án mã nguồn mở như translate-toolkit, py-pdf-translator và docx-translator từ năm 2019 đã tạo điều kiện cho cộng đồng lập trình viên nghiên cứu và xây dựng giải pháp tùy chỉnh. Phân tích về hướng tiếp cận kỹ thuật cho thấy LLM-based pipeline với temperature 0.2 và top_p 0.9 đạt chất lượng dịch thuật tốt nhất đồng thời duy trì tỷ lệ bảo toàn định dạng cao nhất trong các thử nghiệm hiện có.

Wat die produkmark en implementeringstechnologie betref, toon die ontleding 'n duidelike stratifikasie tussen verskillende teikengroepe met DeepL wat in die hoëgehaltesegment geposisioneer is, danksy sy tweestadiumverwerkingspypleyn wat inhoud van formaat skei en 31 tale ondersteun, Google Wolk-vertaling fokus op skaalbaarheid en ekosisteem-integrasie met 135 tale, en Adobe Acrobat wat die behoeftes van professionele gebruikers in die PDF-stelsel verwerk met komplekse PDF-integrasie. Kreatiewe Wolk. Die opkoms van oopbronprojekte soos translate-toolkit, py-pdf-vertaler en docx-vertaler sedert 2019 het die ontwikkelaargemeenskap in staat gestel om na te vors en pasgemaakte oplossings te bou. Ontleding van die tegniese benadering toon dat LLM-gebaseerde pypleyn met temperatuur 0.2 en top_p 0.9 die beste vertaalkwaliteit behaal terwyl die hoogste formaatbewaringskoers in beskikbare toetse gehandhaaf word.

Tài Liệu Tham Khảo

1. Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. International Conference on Learning Representations (ICLR 2015). <https://arxiv.org/pdf/1409.0473.pdf> 2. Bojar, O., Buck, C., Federmann, C., Haddow, B., Koehn, P., Leveling, J., Monz, C., Pecina, P., Post, M., Saint-Amand, H., Soricut, R., Specia, L., & Tamchyna, A. (2014).

Findings of the 2014 Workshop on Statistical Machine Translation. Proceedings of the Ninth Workshop on Statistical Machine Translation, 12–58. <https://aclanthology.org/W14-3302.pdf>

Bevindinge van die 2014-werkswinkel oor statistiese masjiënvertaling. Verrigtinge van die negende werkswinkel oor statistiese masjiënvertaling, 12–58.

Achieving human parity on automatic Chinese to English news translation. arXiv preprint arXiv: 1803.05567.

13. Hassan, H., Aue, A., Chen, C., Chowdhary, V., Clark, J., Federmann, C., Huang, X., Junczys-Dowmunt, M., Lewis, W., Li, M., Liu, S., Liu, T.-Y., Luo, R., Men Seeide, T., F. Tan, X., Tian, F., Wu, L., & Zhou, M. (2018). Die bereiking van menslike gelykheid op outomatiese Chinese na Engels nuusvertaling. arXiv voordruk arXiv: 1803.05567.

<https://arxiv.org/pdf/1803.05567.pdf> 14. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), 1–38. <https://arxiv.org/pdf/2202.03629.pdf> 15. Johnson, M., Schuster, M., Le, Q. V., Krikun, M., Wu, Y., Chen, Z., Thorat, N., Viégas, F., Wattenberg, M., Corrado, G., Hughes, M., & Dean, J. (2017). Google's multilingual neural machine translation system: Enabling zero-shot translation. Transactions of the Association for Computational Linguistics, 5, 339–351.

14. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Madotto, A., & Fung, P. (2023). Opname van hallusinasie in natuurlike taalgenerering. ACM Computing Surveys, 55(12), 1–38. 15. Johnson, M., Schuster, M., Le, Q. V., Krikun, M., Wu, Y., Chen, Z., Thorat, N., Viégas, F., Wattenberg, M., Corrado, G., Hughes, M., & Dean, J. (2017). Google se veeltalige neurale masjienvertalingstelsel: Maak nuls-koot-vertaling moontlik. Transaksies van die Vereniging vir Rekenaarlinguistiek, 5, 339–351.

<https://arxiv.org/pdf/1611.04558.pdf>

Contribution Title (shortened if too long) 9
Bydrae Titel (verkort indien te lank) 9

16. Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Hermann, U., Aji, A. F., Bogoychev, N., Martins, A. F. T., & Birch, A. (2018). Marian: Fast neural machine translation in C++. Proceedings of ACL 2018 System Demonstrations, 116–121. <https://arxiv.org/pdf/1804.00344.pdf> 17. Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. International Conference on Learning Representations (ICLR 2015). <https://arxiv.org/pdf/1412.6980.pdf> 18. Klein, G., Kim, Y., Deng, Y., Senellart, J., & Rush, A. M. (2017). OpenNMT: Open source toolkit for neural machine translation. Proceedings of ACL 2017 System Demonstrations, 67–72. <https://arxiv.org/pdf/1701.02810.pdf> 19. Koehn, P., Hoang, H., Birch, A., Callison-Burch, C., Federico, M., Bertoldi, N., Cowan, B., Shen, W., Moran, C., Zens, R., Dyer, C., Bojar, O., Constantin, A., & Herbst, E.

(2007). Moses: Open source toolkit for statistical machine translation. Proceedings of the 45th Annual Meeting of the ACL on Interactive Poster and Demonstration Sessions, 177–180. <https://aclanthology.org/P07-2045.pdf> 20. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459–9474. <https://arxiv.org/pdf/2005.11401.pdf> 21. Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Multilingual denoising pre-training for neural machine translation.

(2007). Moses: Oopbrongereedskapstel vir statistiese masjiënvertaling. Verrigtinge van die 45ste jaarvergadering van die ACL oor interaktiewe plakkaat- en demonstrasiesessies, 177–180. <https://aclanthology.org/P07-2045.pdf> 20. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020, D.). Herwinning-vergrote generasie vir kennisintensiewe NLP-take. Vooruitgang in neurale inligtingverwerkingstelsels, 33, 9459–9474. 21. Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Veeltalige denoising-vooropleiding vir neurale masjiënvertaling.

Transactions of the Association for Computational Linguistics, 8, 726–742.
Transaksies van die Vereniging vir Rekenaarlinguistiek, 8, 726–742.

<https://arxiv.org/pdf/2001.08210.pdf> 22. Luong, M.-T., Pham, H., & Manning, C. D. (2015). Effective approaches to attention based neural machine translation. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 1412–1421.

22. Luong, M.-T., Pham, H., & Manning, C. D. (2015). Effektiewe benaderings tot aandaggebaseerde neurale masjiënvertaling. Verrigtinge van die 2015-konferensie oor empiriese metodes in natuurlike taalverwerking, 1412–1421.

<https://arxiv.org/pdf/1508.04025.pdf> 23. Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics, 311–318. <https://aclanthology.org/P02-1040.pdf> 24. Post, M. (2018). A call for clarity in reporting BLEU scores. Proceedings of the Third Conference on Machine Translation: Research Papers, 186–191.

23. Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: 'n Metode vir outomatiese evaluering van masjiënvertaling. Verrigtinge van die 40ste Jaarvergadering van die Vereniging vir Rekenaarlinguistiek, 311–318. 24. Pos, M. (2018). 'n Oproep vir duidelikheid in die rapportering van BLEU-tellings. Verrigtinge van die Derde Konferensie oor Masjiënvertaling: Navorsingsdokumente, 186–191.

<https://arxiv.org/pdf/1804.08771.pdf> 25. Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., & Liu, P. J. (2020). Exploring the limits of transfer

learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140), 1–67.

25. Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., & Liu, P. J. (2020). Verken die grense van oordragleer met 'n verenigde teks-tot-teks-transformator. *Tydskrif vir Masjienleernavorsing*, 21(140), 1–67.

<https://arxiv.org/pdf/1910.10683.pdf> 26. Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). COMET: A neural framework for MT evaluation. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, 2685–2702. <https://arxiv.org/pdf/2009.09025.pdf> 27. Sato, M.(2025). Triggering hallucinations in LLMs: A quantitative study of prompt induced hallucination in large language models. *arXiv preprint arXiv: 2505.00557*.

26. Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). KOMET: 'n Neurale raamwerk vir MT-evaluering. *Verrigtinge van die 2020-konferensie oor empiriese metodes in natuurlike taalverwerking*, 2685–2702. 27. Sato, M. (2025). Sneller hallusinasies in LLM's: 'n Kwantitatiewe studie van vinnige geïnduseerde hallusinasie in groot taalmodelle. *arXiv voordruk arXiv: 2505.00557*.

<https://arxiv.org/pdf/2505.00557.pdf> 28. Sahoo, P., Singh, A. K., Saha, S., Jain, V., Mondal, S., & Chadha, A. (2024). A systematic survey of prompt engineering in large language models: Techniques and applications.

28. Sahoo, P., Singh, A. K., Saha, S., Jain, V., Mondal, S., & Chadha, A. (2024). 'n Sistematiese opname van vinnige ingenieurswese in groot taalmodelle: Tegnieke en toepassings.

arXiv preprint arXiv: 2402.07927. <https://arxiv.org/pdf/2402.07927.pdf> 29. Schulhoff, S., Ilie, M., Balepur, N., Kahadze, K., Liu, A., Si, C., Li, Y., Gupta, A., Han, H., Schulhoff, S., Dulepet, P. S., Vidyadhara, S., Ki, D., Agrawal, S., Chinakomnam, C., Feng, Y., & Resnik, P.(2024). The prompt report: A systematic survey of prompt

arXiv voordruk arXiv: 2402.07927. <https://arxiv.org/pdf/2402.07927.pdf> 29. Schulhoff, S., Ilie, M., Balepur, N., Kahadze, K., Liu, A., Si, C., Li, Y., Gupta, A., Han, H., Schulhoff, S., Dulepet, P. Kigra, S., P. Kigra, S., Chinakomnam, C., Feng, Y., & Resnik, P. (2024). Die vinnige verslag: 'n Sistematiese opname van vinnige

engineering techniques. arXiv preprint arXiv: 2406.06608.
ingenieurstegete. arXiv voordruk arXiv: 2406.06608.

<https://arxiv.org/pdf/2406.06608.pdf> 30. Snover, M., Dorr, B., Schwartz, R., Micciulla, L., & Makhoul, J. (2006). A study of translation edit rate with targeted human annotation. Proceedings of Association for Machine Translation in the Americas (AMTA 2006), 223–231.

30. Snover, M., Dorr, B., Schwartz, R., Micciulla, L., & Makhoul, J. (2006). 'n Studie van vertalingsredigeertempo met geteikende menslike annotasie. Proceedings of Association for Machine Translation in the Americas (AMTA 2006), 223–231.

<https://aclanthology.org/2006.amta-papers.25.pdf> 31. Stahlberg, F. (2020). Neural machine translation: A review. Journal of Artificial Intelligence Research, 69, 343–418.

<https://arxiv.org/pdf/1912.02047.pdf> 32. Tiedemann, J. (2012). Parallel data, tools and interfaces in OPUS. Proceedings of the Eight International Conference on Language Resources and Evaluation (LREC 2012), 2214–2218. <https://aclanthology.org/L12-1246.pdf> 33. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems (NeurIPS 2017). <https://arxiv.org/pdf/1706.03762.pdf> 34. Weidinger, L., Mellor, J., Rauh, M., Griffin, C., Uesato, J., Huang, P.-S., Cheng, M., Glaese, M., Balle, B., Kasirzadeh, A., Kenton, Z., Brown, S., Hawkins, W., Stepleton, T., Biles, C., Birhane, A., Haas, J., Rimell, L., Hendricks, L. A., & Gabriel, I. (2021). Ethical and social risks of harm from language models. arXiv preprint arXiv: 2112.04359.

31. Stahlberg, F. (2020). Neurale masjienvertaling: 'n resensie. Tydskrif vir Kunsmatige Intelligensie Navorsing, 69, 343–418. 32. Tiedemann, J. (2012). Parallele data, gereedskap en koppelvlakke in OPUS. Verrigtinge van die Agt Internasionale Konferensie oor Taalhulpbronne en -evaluering (LREC 2012), 2214–2218. <https://aclanthology.org/L12-1246.pdf> 33. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Aandag is al wat jy nodig het. Vooruitgang in neurale inligtingverwerkingstelsels (NeurIPS 2017). <https://arxiv.org/pdf/1706.03762.pdf> 34. Weidinger, L., Mellor, J., Rauh, M., Griffin, C., Uesato, J., Huang, P.-S., Cheng, M., Glaese, M., Balle, B., Kasirzadeh, A., Kenton, Z., Brown, S., Birplehan, C., Ste Hawkins, W. A., Haas, J., Rimell, L., Hendricks, L. A., & Gabriel, I. (2021). Etiese en sosiale risiko's van skade deur taalmodelle. arXiv voordruk arXiv: 2112.04359.

<https://arxiv.org/pdf/2112.04359.pdf> 35. Wu, Y., Schuster, M., Chen, Z., Le, Q. V., Norouzi, M., Macherey, W., Krikun, M., Cao, Y., Gao, Q., Macherey, K., Klingner, J., Shah, A., Johnson, M., Liu, X., Kaiser, Ł., Gouws, S., Kato, Y., Kudo, T., Kazawa, H., & Dean, J. (2016). Google's neural machine translation system: Bridging the gap between human and machine translation. arXiv preprint arXiv: 1609.08144. <https://arxiv.org/pdf/1609.08144.pdf> 36. Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., & Raffel, C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer.

<https://arxiv.org/pdf/2112.04359.pdf> 35. Wu, Y., Schuster, M., Chen, Z., Le, Q. V., Norouzi, M., Macherey, W., Krikun, M., Cao, Y., Gao, Q., Macherey, K., Klingner, J., Shah, A., Johnson, M., Kao, X. Y., Kudo, T., Kazawa, H., & Dean, J. (2016). Google se neurale masjienvertalingstelsel: Oorbrug die gaping tussen menslike en masjienvertaling. arXiv voordruk arXiv: 1609.08144. <https://arxiv.org/pdf/1609.08144.pdf> 36. Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., & Raffel, C. (2021). mT5: 'n Massief veeltalige vooraf-opgeleide teks-na-teks-transformator.

Proceedings of NAACL-HLT 2021, 483–498. <https://arxiv.org/pdf/2010.11934.pdf> 37. Zhang, B., & Sennrich, R. (2019). Root mean square layer normalization. Advances in Neural Information Processing Systems, 32. <https://arxiv.org/pdf/1910.07467.pdf>

Verrigtinge van NAACL-HLT 2021, 483–498. 37. Zhang, B., & Sennrich, R. (2019). Wortel gemiddelde vierkante laag normalisering. Vooruitgang in neurale inligtingverwerkingstelsels, 32.