

TALRAG: 'n Self-lerende tydelike-aanpasbare JOOL-raamwerk

NGUYEN Quoc-Dat 1, Ngo-Ho Anh-Khoa 1, en Ngo-Ho Anh-Khoi 1*

1 Fakulteit Inligtingstechnologie, Nam Can Tho Universiteit, Nguyen Van Custra 168, An Binh Wyk, Can Tho City, {dat223955@student.nctu.edu.vn, , , nhakhoi@nctu.edu

Abstrak. Retrieval-Augmented Generation (RAG) het 'n gewilde metode geword om hallusinasies in groottaalmodelle (LLM's) te verminder. Huidige JOOL-raamwerke maak egter gewoonlik staat op statiese kennisbasisse en basiese semantiese herwinning, wat hul vermoë beperk om domeinspesifieke redenasies te hanteer en met nuwe inligting by te werk. Hierdie beperking is 'n groot kwessie in historiese vraagantwoordstelsels, waar tydelike konteks, oorsaaklike verbande en feitelike betroubaarheid uiters belangrik is. Om dit aan te spreek, stel hierdie vraestel TALRAG voor, 'n selflerende en tydelike aanpasbare JOOL-raamwerk wat spesifiek gebou is vir die beantwoording van Viëtnamese historiese vrae. Die stelsel kombineer aanpasbare herwinning deur gebruik te maak van veelvuldige tellings, selfleer gelei deur vertroue-assessering, en 'n mens-in-die-lus-meganisme in 'n enkele argitektuur om die kennis te laat ontwikkel. Anders as standaard JOOL-modelle, werk TALRAG voortdurend sy kennisbasis op deur 'n leerpylyn wat gelei word deur terugvoer wat webinligting-insameling, betroubaarheidskontrole, gebruikersvalidering en outomatiese vektor-inname behels. Om te verbeter hoe die model oor geskiedenis redeneer, stel ons 'n herwinningmeganisme bekend wat gebaseer is op navraagbedoeling wat semantiese relevansie, tydnabyheid en oorsaaklike verwantskappe dinamies aanteken en kombineer op grond van wat die gebruiker vra. Die hele proses loop deur 'n pylyn met verskeie stadiums, insluitend FAISS-gebaseerde herwinning vanaf veelvuldige vektorwinkels, LLM-gebaseerde dokumentgradering, 'n webterugval vir ontbrekende data en outomatiese kennisverfyning. Boonop laat ons leerbenadering gebaseer op gebruikerterugvoer nuwe eksterne historiese data toe om vertroue vektorgeheue te word sodra dit deur gebruikers bekragtig is, wat toekomstige soekkwaliteit verbeter en hallusinasierisiko's verminder. Ons eksperimentele resultate toon dat TALRAG duidelik beter presteer as tradisionele statiese JOOL-argitekture in herwinningsrobuustheid, antwoordrelevansie en deurlopende kennisaanpassing. Oor die algemeen bied hierdie voorgestelde raamwerk 'n skaalbare en betroubare oplossing vir domeinspesifieke KI-assistente wat betroubare redenasie en die vermoë om mettertyd te leer vereis.

Sleutelwoorde: Retrieval-Augmented Generation(JOOL); Selfleer JOOL; Mens-in-die-lus-leer; Temporele Aanpasbare Herwinning; Historiese Vraag Beantwoording; Kennis Evolusie; Groot taalmodelle.

1 INLEIDING

In onlangse jare het die vinnige groei van Kunsmatige Intelligensie (KI) en digitale inligting die vraag na vraagantwoordstelsels (QA) oor baie domeine laat toeneem. In vergelyking met tradisionele sleutelwoord-gebaseerde soektogte, bied moderne QA-stelsels meer natuurlike en konteksbewuste toegang tot inligting (Riloff & Thelen, 2000). Die ontwikkeling van transformator-gebaseerde modelle (Vaswani et al., 2017), insluitend BERT (Devlin et al., 2019) en GPT-4 (OpenAI, 2023), het natuurlike taalbegrip en -generering verder verbeter.

Ten spyte van hierdie vooruitgang ly groottaalmodelle (LLM's) steeds aan hallusinasie, waar gegenereerde uitsette ongesteunde of verkeerde inligting kan bevat (Ji et al., 2023). Hierdie kwessie is veral krities in historiese vraagbeantwoording omdat historiese antwoorde feitelike akkuraatheid, tydelike konsekwentheid en betroubare kousale interpretasie vereis. Daarom moet 'n historiese QA-stelsel nie net relevante feite ophaal nie, maar ook korrek redeneer oor datums, dinastieë, gebeure en oorsaak-en-gevolg-verwantskappe. Retrieval-Augmented Generation (RAG) verminder hallusinasie deur LLM-reaksies in eksterne kennisbronne te grond eerder as om net op modelparameters staat te maak (Lewis et al., 2020; Gao et al., 2024). Konvensionele JOOL het egter steeds beperkings in historiese QA omdat dit dikwels hoofsaaklik staatmaak op semantiese ooreenkomste, nie eksplisiete tydelike en oorsaaklike redenasies het nie, en gewoonlik op statiese kennisbasisse funksioneer wat nie uit gebruikersterugvoer kan leer nie (Dhingra et al., 2022; Asai et al., 2023; Yan et al., 2024). Om hierdie beperkings aan te spreek, stel hierdie artikel TALRAG bekend, 'n JOOL-raamwerk met selfleer en tydelike aanpassing vir Viëtnamese historiese vraagbeantwoording. Anders as statiese JOOL-modelle, leer TALRAG uit gevalideerde gebruikersterugvoer en werk sy vektorgeheue op deur 'n selfleerpypplyn wat deur vertrouwe-assessering gelei word.

Die res van hierdie vraestel is soos volg georganiseer. Afdeling 2 hersien verwante werk oor JOOL, aanpasbare herwinning en selfleer QA-stelsels. Afdeling 3 bied die voorgestelde TALRAG-raamwerk aan. Afdeling 4 beskryf die eksperimentele opstelling en resultate. Afdeling 5 sluit die vraestel af en bespreek toekomstige werk.

2 VERWANTE WERK

Die ontwikkeling van vraagbeantwoording (QA) stelsels het ontwikkel van reëlgebaseerde metodes tot neurale en herwinning-vergrote benaderings. Vroeë QA-stelsels het hoofsaaklik staatgemaak op handgemaakte reëls en sleutelwoordpassing, wat beheerbaarheid maar beperkte kontekstuele &redenasievermoë verskaf het (Riloff & Thelen, 2000; Lehnert, 1977). Die opkoms van transformator-gebaseerde modelle het natuurlike taalbegrip en generering aansienlik verbeter (Vaswani et al., 2017). Vooraf opgeleide modelle soos BERT en GPT-4 het kontekstuele voorstelling, redenering en gespreksinteraksie verder gevorder (Devlin et al., 2019; OpenAI, 2023). LLM's ly egter steeds aan hallusinasie, waar gegenereerde antwoorde ongesteunde of feitelik verkeerde inligting kan bevat (Ji et al., 2023). Hierdie beperking is veral krities in

historiese QA, waar feitelike akkuraatheid, tydelike konsekwenheid en kousale interpretasie noodsaaklik is.

Retrieval-Augmented Generation (RAG) spreek hallusinasie aan deur LLM-uitsette in eksterne dokumente te grond (Lewis et al., 2020). Digte herwinningsmetodes soos DPR en Sentence-BERT verbeter semantiese soektog, terwyl FAISS doeltreffende vektorherwinning oor grootskaalse dokumentversamelings moontlik maak (Karpukhin et al., 2020; &Reimers&Gurevych, 2019; Johnson et al., 2019). Onlangse opnames toon dat JOOL 'n belangrike benadering vir kennisintensiewe NLP-take geword het (Gao et al., 2024). Nietemin staan konvensionele JOOL-stelsels steeds beperkings in die historiese vraagbeantwoording in die gesig. Hulle vertrou dikwels hoofsaaklik op semantiese ooreenkomste, wat dokumente kan herwin wat linguisties verwant is, maar tydelik of oorsaaklik inkonsekwent is. Vorige werk aan tydbewuste taalmodelle beklemtoon die belangrikheid van temporele redenering vir kennisintensiewe take wat tydlyne en ontwikkelende feite behels (Dhingra et al., 2022).

Verskeie studies het gepoog om herwinningskwaliteit en antwoordbetroubaarheid te verbeter. BERT-gebaseerde herrangskikking verbeter passasierangorde deur die volgorde van herwinnings dokumente te verfyn (Nogueira&Cho, 2019), terwyl BEIR 'n heterogene maatstaf bied vir die evaluering van herwinningsmodelle oor domeine heen (Thakur et al., 2021). Meer onlangse raamwerke soos Self-JOOL en Korrektiewe JOOL stel selfrefleksie- of regstellingmeganismes bekend om generasiekwaliteit te verbeter (Asai et al., 2023; Yan et al., 2024). GraphRAG ondersoek verder grafiekgebaseerde herwinning om globale verhoudings tussen entiteite vas te lê (Edge et al., 2024). Hierdie benaderings spreek egter steeds nie ten volle aan die behoefte aan 'n deursigtige meganisme wat domeinkennis deurlopend opdateer vanaf gevalideerde gebruikerinteraksiegeskiedenis nie.

In die Viëtnamese NLP-domein het Nguyen en Nguyen(2020) PhoNLP bekendgestel, wat Viëtnamese taalverwerking ondersteun en relevant is vir historiese QA omdat Viëtnamese historiese vrae dikwels benoemde entiteite, dinastiese name, tydelike uitdrukkings en kultureel spesifieke terminologie bevat. Vir die historiese QA-basislyn, gebruik hierdie studie ItihashQA. ItihashQA is 'n herwinning-vergrote gespreksvrae-antwoordstelsel wat ontwikkel is vir die Bangladesjse historiese konteks. Die vrygestelde implementering daarvan volg 'n statiese JOOL-argitektuur, waar herwinte historiese kontekste na 'n taalmodel oorgedra word vir reaksiegenerering. Aangesien ItihashQA spesifiek ontwerp is vir historiese vraagbeantwoording, aanvaar hierdie studie dit as die basislynstelsel en pas sy statiese JOOL-pyplyn aan by die Viëtnamese historiese korpus vir beheerde vergelyking. Alhoewel die bewaarplekbeskrywing ook na die stelsel verwys as EkattorQA, gebruik hierdie vraestel konsekvent die naam ItihashQA volgens die bewaarplek en werktitel.

Kommersiële dokument-gegronde QA-nutsgoed soos Google NotebookLM en Gemini Gems demonstreer ook die praktiese waarde van herwinning-gebaseerde assistente vir dokumentbegrip en persoonlike kennistoegang. Hierdie stelsels laat gebruikers toe om bronne te organiseer of pasgemaakte assistente vir spesifieke take te skep. Hul herwinningsmeganismes, evalueringsprosedures en geheue-opdateringstrategieë is egter nie ten volle deursigtig vir navorsingsreproduksie nie. Belangriker nog, hulle verskaf nie 'n eksplisiete selfleerpylyn wat gelei word deur trustassessering, waarin kletsgeskiedenis

deur gebruikers bekragtig word in nuwe vektorgeheue omgeskakel. Daarom, alhoewel hierdie instrumente nuttig is vir dokumentsintese en persoonlike hulp, is hulle nie direk gelykstaande aan TALRAG se kennis-evolusiemeganisme wat deur terugvoer gelei word nie.

Uit die hersiene literatuur bly drie beperkings duidelik. Eerstens maak die meeste JOOL-stelsels swaar op semantiese ooreenkomste staat en optimaliseer nie eksplisiet herwinning vir tydelike en oorsaaklike redenering nie, wat noodsaaklik is in historiese QA. Tweedens verbeter baie aanpasbare JOOL-raamwerke die herwinning of generasiekwaliteit, maar werk steeds op statiese kennisbasisse na ontplooiing. Derdens bied bestaande dokument-gegronde kletsbotstelsels nie 'n deursigtige navorsingsgeoriënteerde meganisme vir die omskakeling van gebruikersterugvoer en kletsgeskiedenis in gevalideerde vektorgeheue nie.

TALRAG spreek hierdie leemtes aan deur herwinning te kombineer gebaseer op navraagbedoeling, tydelike en oorsaaklike telling, dokumentgradering deur 'n LLM, webterugval vir ontbrekende inligting, en selfleer gelei deur terugvoer. Die belangrikste nuwigheid van TALRAG is sy vermoë om uit gebruikerskletsgeskiedenis te leer. Wanneer die stelsel 'n lae selfvertroue of onbeantwoorde navraag teëkom, word die interaksie 'n leerkandidaat. Na eksterne kennisverkryging, betroubaarheidsverifikasie en positiewe gebruikerterugvoer, word die gevalideerde kennis verfyn en in die dinamiese FAISS-vektorstoor ingeneem. Op hierdie manier beantwoord TALRAG nie bloot vrae uit 'n vaste korpus nie; dit ontwikkel voortdurend sy historiese kennisbasis deur kennisvalidering wat deur terugvoer gelei word.

3 VOORGESTELDE TALRAG-RAAMWERK

Die hoofbydrae van TALRAG is 'n selfleerpyplyn wat gelei word deur vertroueassessering wat lae-vertroue of onbeantwoorde navrae omskakel in geleenthede vir kennisuitbreiding. Anders as standaard JOOL-stelsels wat op vaste vektordatabasisse staatmaak, gebruik TALRAG gevalideerde gebruikerterugvoer en kletsgeskiedenis om sy dinamiese vektorgeheue oor tyd op te dateer.




Fig. 1. selfleerpyplyn gelei deur trustassessering van TALRAG.

Om die voorgestelde werkvloei formeel te beskryf, bied Algoritme 1 die belangrikste aan afdelingspyplyn, insluitend bedoelingklassifikasie, tydelike en oorsaaklike herwinning, dokumentgradering en antwoordgenerering. Algoritme 2 beskryf die leer pyplyn gebaseer op gebruiker terugvoer of self leer pyplyn, waar herwinning mislukking word omskep in leerkandidate deur webverkryging, betroubaarheid verifikasie, gebruikerterugvoer en FAISS-inname.

Algoritme 1. TALRAG afdelingspyplyn

Invoer: : Gebruikersvraag q , kletsgeeskiedenis H , betroubare vektorwinkels V , taalmodel LLM

Uitset: Gegenerende reaksie A , herwin kontekste C

1: Bevestig gebruikerversoek

2: Gaan die balans van die gebruikertoken na

3: $voorneme \leftarrow \text{ClassifyQuery}(q)$

4: $tydelike_inligting \leftarrow \text{ExtractTemporalEntities}(q)$

5: $q_norm \leftarrow \text{Normaliseer Vraag}(q)$

6: $candidate_docs \leftarrow \text{MultiBrainFAISSRetrieve}(q_norm, V)$

7: vir elke dokument d in $candidate_docs$ doen

8: $S_sem \leftarrow \text{Semantiese telling}(q_norm, d)$

9: $S_temp \leftarrow \text{Temporale telling}(tydelike_inligting, d)$

10:

$S_oorzaak \leftarrow \text{CausalScore}(q_norm, d)$ 11: $S_totaal \leftarrow \alpha(\text{bedoeling}) \times S_sem$
 $+ \beta(\text{bedoeling}) \times S_temp$
 $+ \gamma(\text{bedoeling}) \times S_oorzaak$

12: einde vir

13: $gerangskik_dokumente \leftarrow \text{Sorteer volgens telling}(kandidaat_dokumente, S_totaal)$

```

14: filtered_docs ← DocumentGrader(q, ranked_docs)
15: as filtered_docs nie leeg is nie
16: C ← filtered_docs
17: A ← GenereerAnswer(LLM, q, C, H)
18: anders
19:
  A, C ← TrustAwareSelfLearning(q)
20: end if
21: Stoor gesprek log
22: Dateer tokenbalans op
23: keer terug A, C

```

Algoritme 2. Vertrouensbewuste selfleerpylyn

Invoer: Gebruikersvraag q , websoekenjin W , taalmodel LLM , hangende kennisbewaarplek P , dinamiese vektorstoor $V_dynamic$, terugvoerdrempel θ
Uitset: Voorlopige antwoord A_web , geverifieerde webkontekste C_web

```

1: web_results ← SearchWeb(W, q)
2: raw_chunks ← CrawlAndExtract(web_results)
3: relevante_brokkies ← FilterRelevante inhoud(q, raw_chunks)
4: C_web, selfvertroue ← VerifyReliability(LLM, q, relevante_brokkies)
5: as selfvertroue dan laag is
6: A_web ← "Onvoldoende bewyse"
7: gee terug A_web,  $\emptyset$ 
8: eindig as
9: A_web ← GenerateWebBasedAnswer(LLM, q, C_web)
10: SaveToPendingKnowledge(P, q, A_web, C_web)
11: Versamel gebruikerterugvoer vir q
12: as Positiewe Terugvoer(q)  $\geq \theta$  dan
13: refined_knowledge ← RefineKnowledge(LLM, q, A_web, C_web)
14: stukkies ← ChunkText(verfynde_kennis)
15: inbeddings ← Genereer inbeddings(stukke)
16: IngestIntoFAISS(V_dynamic, stukkies, inbeddings)
17: MarkKnowledgeAsApproved(P, q)
18: eindig as
19: keer terug A_web, C_web

```

Die TALRAG-werkvloei begin wanneer 'n gebruiker 'n historiese vraag indien. Die stelsel voer eers staving en tokenbalanskontrolering uit om veilige en beheerde toegang te verseker. Die navraag word dan geklassifiseer in bedoelingstipes soos feitelike, tydelike, oorsaaklike of vergelykende vrae. Hierdie klassifikasie lei die herwinningsproses omdat verskillende historiese vrae verskillende bewysprioriteite vereis.

Om historiese redenasie te ondersteun, pas TALRAG 'n ligte tydelike onttrekkingsmeganisme toe om jare, dinastieë, historiese tydperke en ander tydverwante uitdrukkings te identifiseer. Hierdie tydelike seine word gebruik om dokumentherwinning te lei en

rangorde, wat die stelsel help om kontekste te vermy wat semanties soortgelyk is, maar histories verkeerd in lyn is.

Die herwinningskomponent is gebaseer op multi-bron FAISS herwinning. Dit haal kandidaatdokumente uit betroubare historiese bronne, goedgekeurde kennis en dinamies aangeleerde vektorgeheue. In plaas daarvan om dokumente slegs volgens semantiese ooreenkoms te rangskik, bereken TALRAG 'n gekombineerde herwinningtelling: $S_{\text{totaal}} = (\alpha \times S_{\text{semanties}}) + (\beta \times S_{\text{tydelik}}) + (\gamma \times S_{\text{oorsaaklik}})$ waar S semanties semantiese ooreenkoms tussen die vraag en die dokument meet, $S_{\text{temporaal}}$ meet kronologiese konsekwentheid met die kousale belyning meet die kousale belyning. Die gewigte α , β en γ word aangepas volgens die geklassifiseerde navraagvoorneme. Byvoorbeeld, tydelike vrae gee hoër gewig aan S_{tydelik} , terwyl oorsaaklike vrae $S_{\text{oorsaaklik}}$ prioritiseer..

Na herwinning word die gerangorde dokumente verwerk deur 'n LLM-gebaseerde dokumentgraderingsmodule. Hierdie module filtreer raserige, swak verwante of teenstrydige kontekste voor antwoordgenerering. As voldoende betroubare konteks oorbly, genereer die LLM 'n gegronde antwoord deur die gefiltreerde bewyse te gebruik.

As die betroubare herwinningspyplyn nie voldoende betroubare kennis kan vind nie, aktiveer TALRAG die vertrouebewuste selfleerpyplyn. In hierdie stadium soek die stelsel eksterne bronne en onttrek kandidaat-historiese bewyse. Die onttrekte inhoud word gefiltreer vir relevansie en gekontroleer vir betroubaarheid voordat dit gebruik word om 'n voorlopige antwoord te genereer. Dit is belangrik dat kennis wat van die web verkry word nie direk in die vertroude kennisbasis ingevoeg word nie. In plaas daarvan word dit in 'n hangende kennisbewaarplek gestoor totdat dit voldoende positiewe gebruikersterugvoer ontvang.

Die sentrale nuwigheid van hierdie raamwerk is die gebruik van gebruikersinteraksiegeskiedenis as 'n leersein. Wanneer 'n voorlopige antwoord genoeg positiewe terugvoer ontvang, verfyn die outomatiese leermodule die geverifieerde inhoud, verdeel dit in stukke, genereer inbeddings en neem dit in die dinamiese FAISS-vektorstoor in. Gevolglik kan toekomstige soortgelyke vrae hierdie gevalideerde kennis direk uit vektorgeheue haal.

Hierdie ontwerp stel TALRAG in staat om voortdurend sy historiese dekking te verbeter terwyl dit die risiko verminder om die vertroude kennisbasis met onbetroubare inligting te besoedel. Laastens teken die stelsel interaksielogboeke, herwinningspore, terugvoersei en tekengebruik aan vir monitering, hulpbronbestuur en toekomstige ontleding.

4 EKSPERIMENTE

Om die doeltreffendheid van TALRAG te evalueer, het ons 'n RAGAS-gebaseerde vergelykende eksperiment teen die ItiHashQA-basislyn uitgevoer. ItiHashQA is 'n herwinning-aangevulde historiese vraag-antwoordstelsel wat oorspronklik ontwikkel is vir die Bangladesjse historiese konteks. In hierdie studie is sy statiese JOOL-pyplyn aangepas by die Viëtnamese historiese korpus vir beheerde vergelyking. Die basislyn haal die top-k semanties soortgelyke stukke uit die vektordatabasis en stuur dit direk na die taalmodel vir antwoordgenerering.

In teenstelling hiermee brei TALRAG die standaard JOOL-werkvloei uit met bedoelingsklassifikasie, tydelike en oorsaaklike telling, dokumentgradering deur 'n LLM, web




Fig. 2a. Antwoord Relevansievergelyking tussen ItihashQA-basislyn en TALRAG.

Die grootste verbetering verskyn in Antwoordrelevansie. Op maklike vrae verbeter TALRAG van 0.35 tot 0.44. Op Medium vrae styg dit van 0,18 tot 0,79. Op moeilike vrae handhaaf TALRAG 'n telling van 0.70, terwyl die basislyn tot 0.09 daal. Hierdie resultate dui aan dat TALRAG antwoorde genereer wat meer direk in lyn is met gebruikers se historiese vrae, veral namate vraagkompleksiteit toeneem.




Fig. 2b. Getrouheidsvergelyking tussen ItihashQA-basislyn en TALRAG.

Vir Getrouheid vaar TALRAG beter op Medium- en Hardevrae, met tellings van 0.83 en 0.78 in vergelyking met die basislyntellings van onderskeidelik 0.64 en 0.70. Op Maklike vrae kry die basislyn egter 'n hoër Getrouheid-telling van 0.72 in vergelyking met TALRAG se 0.60. Dit dui daarop dat eenvoudige feitevrae nie altyd komplekse aanpasbare herwinning vereis nie, en strenger filtering kan soms nuttige konteks vir eenvoudige soekvrae verwyder.




Fig. 2c. Konteks Presisievergelyking tussen ItihashQA-basislyn en TALRAG.

Wat kontekspresisie betref, verbeter TALRAG oor die basislyn oor alle moeilikheidsvlakke. Op maklike vrae styg die telling van 0,26 tot 0,44. Op Medium vrae neem dit toe van 0,14 tot 0,22. Op moeilike vrae behaal albei stelsels ongeveer 0.25, met TALRAG wat 'n effense verbetering toon. Hierdie resultate toon dat tydelike-oorsaaklike telling en dokumentgradering help om skoner en meer relevante kontekste te verkry.




Fig. 2d. Konteks Herroep vergelyking tussen ItihashQA basislyn en TALRAG.

Vir Konteksherroep verbeter TALRAG oor die basislyn op Maklike en Medium-vrae, wat onderskeidelik van 0.35 tot 0.40 en van 0.24 tot 0.33 toeneem. Op harde vrae kry die basislyn egter 'n hoër telling van 0.45 in vergelyking met TALRAG se 0.35. Dit dui daarop dat die basislyn breër bewyse in sommige moeilike multi-hop vrae kan ophaal, terwyl TALRAG presisie en relevansie deur strenger filtering prioritiseer.

TALRAG behaal hoër gemiddelde tellings as die basislyn op al vier RAGAS-metrieke. Getrouheid verbeter van 0,68 tot 0,73, Antwoordrelevansie verbeter van 0,21 tot 0,64, Kontekspresisie verbeter van 0,22 tot 0,31, en Konteksherroep verbeter van 0,35 tot 0,36. Die grootste wins word waargeneem in Antwoordrelevansie, wat die doeltreffendheid van herwinning toon gebaseer op navraagvoorneme en aanpasbare herrangskikking.

Hierdie resultate bevestig dat TALRAG die algehele kwaliteit van Viëtnamese historiese vraagbeantwoording verbeter in vergelyking met 'n statiese JOOL-basislyn. Die verbetering word hoofsaaklik toegeskryf aan drie komponente: aanpasbare herwinning deur gebruik te maak van veelvuldige tellings, LLM-gebaseerde dokumentgradering, en die selfleerpyplyn gelei deur trustassessering. Terselfdertyd toon die resultate dat TALRAG nie in elke individuele geval beter as die basislyn presteer nie. Veral die laer Easy Faithfulness-telling en laer Hard Context Recall-telling dui daarop dat strenger filtrasie nuttige bewysdekking kan verminder. Toekomstige werk moet aanpasbare drempels, groter top-k-herwinning vir moeilike vrae en beter presisie-herroepbalansering ondersoek.

Die RAGAS-evaluering toon dat TALRAG 'n meer relevante, konteksbewuste en JOOL-argitektuur bied wat met verloop van tyd vir Viëtnamese historiese QA kan verbeter. Deur tydelike en oorsaaklike herwinning, dokumentgradering en vertrouensbewuste selfleer te kombineer, verander TALRAG statiese proses van herwinning en generering in 'n voortdurend ontwikkelende historiese kennisstelsel.

5 GEVOLGTREKKING

Hierdie navorsing het TALRAG bekendgestel, 'n JOOL-raamwerk met selfleer en tydelike aanpassing vir Viëtnamese historiese vraagbeantwoording. Anders as statiese JOOL-stelsels wat hoofsaaklik op semantiese ooreenkomste en vaste vektordatabasisse staatmaak, kombineer TALRAG adaptiewe herwinning, tydelike en oorsaaklike redenering, dokumentgradering en selfleer gelei deur vertrouessessering in 'n verenigde werkvloei.

Die hoofbydrae van TALRAG is sy selfleerpyplyn wat gelei word deur trustassessering. Wanneer betroubare inligting nie van die vertroue vektorstoor verkry kan word nie, verkry die stelsel aanvullende historiese bewyse van eksterne bronne, verifieer die betroubaarheid daarvan, stoor dit as hangende kennis, en gebruik gebruikersterugvoer om te besluit of dit in FAISS ingeneem moet word as herbruikbare vektorgeheue. Hierdie meganisme stel TALRAG in staat om uit gebruikersinteraksiegeskiedenis te leer terwyl dit die risiko verminder om die kennisbasis met onbetroubare inligting te besoedel.

TALRAG demonstreer dat JOOL uitgebrei kan word van 'n statiese proses van herwinning en generering na 'n voortdurend ontwikkelende historiese kennisstelsel. Toekomstige werk sal fokus op die verbetering van herroeping vir multi-hop-vrae, die integrasie van kennisgrafieke om verhoudings tussen historiese entiteite te modelleer, en die ondersoek van multimodale herwinning vir historiese kaarte, geskandeerde dokumente, antieke skrifte en artefakte.

VERWYSINGS

1. Chen, Jiawei, Lin, Hongyu, Han, & Xianpei, & Sun, Le. (2023). Benchmarking Large Language Models in Retrieval-Augmented Generation. arXiv preprint arXiv: 2309.01414.
2. Devlin, Jacob, Chang, Ming-Wei, Lee, & Kenton, & Toutanova, Kristina. (2019). BERT: Vooropleiding van Deep Bidirectional Transformers vir Taalbegrip. In Verrigtinge van die 2019-konferensie van die Noord-Amerikaanse Hoofstuk van die Vereniging vir Rekenaarlinguistiek (NAACL), 4171–4186.
3. Ji, Ziwei, Lee, Nayeon, Frieske, Rita, Yu, Tiezheng, Su, Dan, Xu, Yan, Ishii, Etsuko, Bang, Ye Jin, Madotto, Andrea, & Pascual, Damien. (2023). Opname van hallusinasie in natuurlike taalgenerering. ACM Computing Surveys, 55(12), 1–38.
4. Lewis, Patrick, Perez, Ethan, Piktus, Aleksandra, Petroni, Fabio, Karpukhin, Vladimir, Goyal, Naman, Küttler, Heinrich, Lewis, Mike, Yih, Wen-tau, Rocktäschel, Tim, Riedel, & Sebastian, & Kiela, Douwe. (2020). Retrieval-

- Aanvullende generasie vir kennisintensiewe NLP-take. Vooruitgang in neurale inligtingverwerkingstelsels (NeurIPS), 33, 9459–9474.
5. Nogueira, &Rodrigo,&Cho, Kyunghyun.(2019). Passage Re-ranking with BERT. arXiv preprint arXiv: 1901.04085.
 6. OpenAI. (2023). GPT-4 Technical Report. arXiv preprint arXiv: 2303.08774.
 7. Riloff, &Ellen,&Thelen, June.(2000). A Rule-based Question Answering System for Reading Comprehension Tests. In Proceedings of the ANLP/NAACL Workshop on Reading Comprehension Tests as Evaluation Resources for NLP, 13–21.
 8. Thakur, Nandan, Reimers, Nils, Daxenberger, &Johannes,&Gurevych, Iryna. (2021). BEIR: 'n Heterogene maatstaf vir evaluering van inligtingherwinning. arXiv voordruk arXiv: 2104.08663.
 9. Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, Uszkoreit, Jakob, Jones, Llion, Gomez, Aidan N., Kaiser, &Lukasz,&Polosukhin, Illia.(2017). Attention Is All You Need. In Advances in Neural Information Processing Systems(NeurIPS), 5998–6008.
 10. Himu, A. D., Azad, M. S., Rahman, R., & Hasan, M. R. (2024). Towards Accurate AI-Driven ItihashQA: A Conversational Question Answering System Applied in Bangladeshi Historical Context. GitHub repository. [Online]. Available: <https://github.com/shawmoonazad/ItihashQA>. Accessed: May 14, 2026.
 11. Asai, Akari, Wu, Zeqiu, Wang, Yizhong, Slotnick, Avirup, Sonthalia, & Rishi,& Hajishirzi, Hannaneh.(2023). Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. International Conference on Learning Representations (ICLR).
 12. Yan, Shi-Qi, Gu, Jia-Chen, Zhu, &Yun-Ze,&Ling, Zhen-Hua.(2024). Corrective Retrieval Augmented Generation. arXiv preprint arXiv: 2401.15884.
 13. Gao, Yunfan, Xiong, Yun, Gao, Xinyu, Jia, Kangxiang, Pan, Jinliu, Bi, Yutong, Dai, Yi, Sun, &Jiawei,&Wang, Haofen.(2024). Retrieval-Augmented Generation for Large Language Models: A Survey. arXiv preprint arXiv: 2312.10997.
 14. Nguyen, Dat &Quoc,&Nguyen, Anh Tuan.(2020). PhoNLP: A Joint Overloaded Model for Vietnamese Natural Language Processing. arXiv preprint arXiv: 2011.01544.
 15. Dhingra, Bhuwan, Cole, Jeremy R., Eisenschlos, Julian Martin, Gillick, Daniel, Eisenstein, &Jacob,&Cohen, William W.(2022). Time-Aware Language Models as Temporal Knowledge Bases. Transactions of the Association for Computational Linguistics, 10, 257–273.
 16. Ouyang, Long, Wu, Jeffrey, Jiang, Xu, Almeida, Diogo, Wainwright, Carroll, Mishkin, Pamela, Zhang, Chong, Agarwal, Sandhini, Slama, Katarina, Ray, Alex, Schulman, John, Hilton, Jacob, Kelton, Fraser, Miller, Luke, Simens, Maddie, Askell, Amanda, Welinder, Peter, Christiano, Paul, Leike, &Jan,&Lowe, Ryan. (2022). Opleiding van taalmodelle om instruksies met menslike terugvoer te volg. Vooruitgang in neurale inligtingverwerkingstelsels (NeurIPS).
 17. Karpukhin, Vladimir, Oguz, Barlas, Min, Sewon, Lewis, Patrick, Wu, Ledell, Edunov, Sergey, Chen, &Danqi,&Yih, Wen-tau.(2020). Dense Passage Retrieval

vir Oopdomein-vraag beantwoord. In Verrigtinge van die 2020-konferensie oor empiriese metodes in natuurlike taalverwerking (EMNLP).

18. Reimers, Nils, & Gurevych, Iryna. (2019). Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP).
19. Edge, Darren, Trinh, Ha, Cheng, Newman, Bradley, Joshua, Chao, Shuo, Mody, Apurva, Truitt, & Steven, & Larson, Jonathan. (2024). From Local to Global: A GraphRAG Approach to Query-Focused Summarization. arXiv preprint arXiv: 2404.16130.
20. Johnson, Jeff, Douze, & Matthijs, & Jégou, Hervé. (2019). Billion-scale Similarity Search with GPUs. IEEE Transactions on Big Data, 7(3), 535–547.
21. Zheng, Lianmin, Chiang, Wei-Lin, Sheng, Ying, Zhuang, Siyuan, Wu, Zhanghao, Zhuang, Yonghao, Lin, Zi, Li, Zhuohan, Li, Dacheng, Xing, Eric, Zhang, & Hao, & Stoica, Ion. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arXiv preprint arXiv: 2306.05685.
22. Google. (2023). NotebookLM. [Online]. Available: <https://notebooklm.google/>. Accessed: May 14, 2026.
23. Google. (2024). Gemini Gems. [Online]. Available: <https://gemini.google.com/>. Accessed: May 14, 2026.