

'n KI-gebaseerde dokumentvertaalstelsel met oorspronklike formaatbewaring

Hoang-Phuc Ha 1 Ngo-Ho Anh-Khoa 1 en Ngo-Ho Anh-Khoi 1*

1 Fakulteit Inligtingstechnologie, Nam Can Tho Universiteit, Nguyen Van Custraat 168, An Binh Wyk, Can Tho City, Viëtnam

phuc222683@studentnctu.edu.vn, nhakhoa@nctu.edu.vn,
nhakhoi@nctu.edu.vn

Abstrak.In die konteks van die toenemende vraag na digitale dokumentvertaling, word van moderne vertaalstelsels verwag om nie net die kwaliteit van vertaalde inhoud te verseker nie, maar ook om die oorspronklike formatering van insetdokumente te bewaar. Wanneer struktureel komplekse dokumente soos PDF- en DOCX-lêers vertaal word, ondervind baie stelsels egter steeds probleme soos uitlegvervorming, tabelwanbelyning, beeldverplasing, fontfoute en beperkte ondersteuning vir tweetalige vertoonmodusse. Hierdie studie stel 'n kunsmatige intelligensie-gebaseerde dokumentvertalingstelsel voor wat in staat is om twee algemene dokumentformate, DOCX en PDF te verwerk, terwyl dit drie vertaalmodusse ondersteun: standaardvertaling, tweetalige vertaling langs mekaar en tweetalige lyn-vir-lyn vertaling. Vir DOCX-dokumente verwerk die stelsel dokumentkomponente soos paragrawe, tabelle, kop- en voettekste direk. Vir PDF-dokumente pas die stelsel 'n PDF→DOCX→vertaling→uitlegherstel→PDF-pyplyn toe om formaatbewaring te verbeter. Die stelsel integreer verskeie vertaalverskaffers, insluitend Google Translate, DeepL Translator en Gemini 2.5 Flash, om buigsaamheid in vertalingskwaliteit en verwerkingsopsies te verhoog. Die eksperimentele evaluering word uitgevoer deur gebruik te maak van twee groepe kriteria: formatering bewaring en vertaling kwaliteit gemeet deur BLEU Mean en BLEU Std. Die resultate toon dat die voorgestelde stelsel sterk formaatbewaring vir DOCX-dokumente behaal en belowende prestasie vir akademiese PDF-dokumente.

Sleutelwoorde:Dokumentvertaling, formaatbewaring, kunsmatige intelligensie, PDF, DOCX, tweetalige vertaling, BLEU.

1 Inleiding

Die vinnige ontwikkeling van kunsmatige intelligensie en groot taalmodelle het die veld van natuurlike taalverwerking, veral masjienvertaling, aansienlik bevorder. Moderne vertaalmodelle is nie meer beperk tot die omskakeling van teks van 'n brontaal na 'n doeltaal nie; hulle is ook in staat om konteks, terminologie en skryfstyl meer effektief te hanteer as tradisionele statistiese vertaalbenaderings (Bahdanau et al., 2015; Wu et al., 2016; Koehn, 2020). In die besonder het die Transformer-argitektuur 'n fundamentele grondslag vir baie moderne geword

taalverwerkingsmodelle vanweë die vermoë daarvan om kontekstuele verhoudings doeltreffend in lang teksreekse vas te vang (Vaswani et al., 2017). Daarbenewens het die ontwikkeling van groot taalmodelle soos GPT en verenigde teks-tot-teks-modelle nuwe rigtings vir vertaal-, opsomming- en dokumentverwerkingstake geopen (Brown et al., 2020; Raffel et al., 2020). In praktiese scenario's hoef gebruikers egter nie net gewone sinne of paragrawe te vertaal nie. Hulle moet dikwels volledige geformateerde dokumente vertaal, soos wetenskaplike referate, tegniese verslae, tesse, kontrakte en administratiewe vorms. Hierdie dokumente word gewoonlik in DOCX- of PDF-formate gestoor en bevat verskeie formateringskomponente, insluitend opskrifte, paragrawe, tabelle, prente, kopskrifte, voettekste, lysste en bladsyuitlegte. Dokumentvertaling moet dus nie net as 'n inhoudsvertalingsprobleem beskou word nie, maar ook as 'n formateringsbehoudprobleem.

In baie bestaande dokumentvertalingstelsels bly die behoud van die oorspronklike formaat 'n aansienlike uitdaging. DOCX het 'n relatief gestruktureerde voorstelling waarin inhoud in paragrawe, tabelle, style, kop- en voettekste georganiseer word, wat dit moontlik maak om die dokument direk met behulp van programmeringsinstrumente te verwerk. Daarteenoor is PDF hoofsaaklik ontwerp vir vertoon en druk, en die inhoud daarvan word gewoonlik geberg op grond van bladsykoördinate eerder as 'n logiese dokumentstruktuur. As gevolg hiervan, wanneer vertaalde teks langer of korter as die oorspronklike teks word, kan probleme soos teksoorloop, tabelwanbelyning, oorvleuelende teks en uitlegveranderinge voorkom. Gewilde vertaaldienste soos Google Translate, DeepL, Adobe Acrobat en KI-platforms met lêeroplai-ondersteuning bied gerieflike oplossings, maar hulle het steeds beperkings in terme van pylynaanpassing, tweetalige aanbieding en uitvoerformaatbeheer. Gebaseer op hierdie beperkings, ontwikkel hierdie studie 'n KI-gebaseerde dokumentvertalingstelsel wat die oorspronklike dokumentformaat bewaar en beide DOCX- en PDF-lêers met drie vertaalmodusse ondersteun. Die stelsel gebruik verskillende verwerkingstrategieë vir verskillende dokumenttipes: DOCX-lêers word direk vertaal op grond van hul gestruktureerde paragrawe en tabelle, terwyl PDF-lêers verwerk word deur 'n PDF→DOCX→vertaling→uitlegherstel→PDF-pyplyn te gebruik. Die voorgestelde stelsel word deur twee eksperimentele groepe geëvalueer: formateringsbewaring-evaluering en vertalingskwaliteit-evaluering, ten einde beide visuele struktuur en linguistiese inhoud te assesser.

2 Verwante werk

Op die gebied van dokumentvertaling is baie kommersiële stelsels ontwikkel om gebruikers te help om algemene lêerformate soos DOCX, PDF en PPTX te vertaal. Platforms soos DeepL Document Translation, Google Translate, Google Cloud Translation en Adobe Acrobat bied aanlyn dokumentvertalingskenmerke, wat gebruikers in staat stel om meertalige dokumente vir studie, navorsing en professionele werk te verwerk. Hierdie stelsels bied voordele in terme van verwerkingspoed, vertaalkwaliteit en bruikbaarheid. Die meeste kommersiële platforms is egter geslote stelsels, wat beteken dat gebruikers nie maklik die interne verwerkingspyplyn kan verander, formaatbewaringsmeganismes kan aanpas of tweetalige aanbiedingsmodusse soos sy-aan-sy tweetalige vertaling of lyn-vir-lyn tweetalige vertaling buigsaam kan beheer nie. Vir gebruikers wat met akademiese of tegniese dokumente werk wat komplekse strukture bevat,

om slegs op bestaande kommersiële lêervertaalinstrumente te vertrou, is dalk nie voldoende om formateringsfoute wat tydens die vertaalproses gegenereer word, te beheer nie.

Vanuit 'n akademiese perspektief het masjienvertaling aansienlik ontwikkel van statistiese masjienvertaling na neurale masjienvertaling en groot taalmodelle. Die aandagmeganisme in neurale masjienvertaling het die vermoë verbeter om bron- en teikensinne in lyn te bring (Bahdanau et al., 2015), terwyl Google Neurale Masjienvertaling die doeltreffendheid van neurale netwerke in grootskaalse veeltalige vertaling gedemonstreer het (Wu et al., 2016). Later het die Transformer-argitektuur 'n sleutelgrondslag vir moderne vertalings- en natuurlike taalverwerkingsmodelle geword deur sy selfaandagmeganisme (Vaswani et al., 2017). Resensies van neurale masjienvertaling dui ook aan dat vertalingskwaliteit aansienlik verbeter het, alhoewel daar nog uitdagings is in kontekshantering, domeinspesifieke terminologie en evalueringsmetodologie (Stahlberg, 2020; Koehn, 2020). Boonop het groot taalmodelle soos GPT en verenigde teks-tot-teks-modelle die vermoë uitgebrei om lang teks te verwerk, konteks te verstaan en meer natuurlike uitsette te genereer (Brown et al., 2020; Raffel et al., 2020).

Vir dokumentverwerking het DOCX- en PDF-formate baie verskillende strukturele eienskappe. DOCX is gebaseer op 'n XML-struktuur, waar inhoud in paragrawe, tekslopie, tabelle, style, kop- en voetstukke georganiseer word. Dit laat 'n stelsel toe om deur dokumentkomponente te herhaal, teks te onttrek en te vervang, en die meeste van die oorspronklike formatering te bewaar. Daarteenoor is PDF hoofsaaklik vir vertoon en druk ontwerp, en die teks word dikwels volgens bladsykoördinate gestoor. Dit maak leesvolgorde opsporing, tabelherkenning en uitlegherwinning moeiliker. Studies oor dokumentuitlegontleding, soos PubLayNet, DocBank, FUNSD, DocVQA en LayoutLM, toon dat die begrip van die visuele en strukturele uitleg van dokumente belangrik is vir komplekse dokumentverwerkingstake (Zhong et al., 2019; Li et al., 2020; Jaume et al., 2019; Mathew et al., 2019; Mathew et al., 2020). In die besonder kombineer LayoutLM en LayoutLMv2 tekstuele, posisionele en visuele inligting om dokumentbegrip vir visueel ryk dokumente te verbeter (Xu et al., 2020; Xu et al., 2021).

'n Praktiese benadering vir PDF-verwerking is om PDF-lêers in 'n redigeerbare formaat soos DOCX te omskep, die onttrekte inhoud te vertaal en dan die resultaat terug na PDF uit te voer. Die PDF→DOCX→vertaling→PDF-pyplyn het die voordeel om die buigsame redigeringstruktuur van Word-dokumente te gebruik, wat die stelsel toelaat om teks volgens paragrawe, tabelle en style te verwerk in plaas daarvan om rou PDF-koördinate direk te manipuleer. Hierdie pyplyn het egter ook beperkings omdat die omskakelingsproses intermediêre foute soos saamgevoegde teks, gefragmenteerde paragrawe, verkeerde bespeurde tabelle of gewysigde bladsyuitlegte kan inbring. Daarom, vir hierdie pyplyn om doeltreffend te werk, word voorafverwerking, DOCX-sanering, uitlegherwinning en uitsetkwaliteitskontrolering vereis. Vir geskandeerde dokumente of ingebedde beelde is OCR ook belangrik vir die skep van 'n tekslaag wat verwerk kan word, en Tesseract is een van die mees gebruikte OCR-enjins in beide navorsing en praktiese toepassings (Smith, 2007).

& Masjienvertalingsevalueringstudies gebruik dikwels outomatiese maatstawwe soos BLEU, TER, METEOR en COMET om ooreenkomste tussen masjienvertalings en verwysingsvertalings te meet (Papineni et al., 2002; Snover et al., 2006; Banerjee & Lavie, 2005; Rei et al., 2020). Onder hulle is BLEU 'n wyd gebruikte maatstaf gebaseer op n-gram oorvleueling tussen 'n stelselgegenereerde vertaling en 'n verwysingsvertaling.

(Papineni et al., 2002). BLEU-tellings moet egter duidelik gerapporteer word, want dit kan wissel na gelang van tokenisering, normalisering en berekeninginstellings (Post, 2018). Vir dokumentvertaling met formaatbehoud is vertaalkwaliteit alleen nie voldoende nie. 'n Stelsel kan inhoud korrek vertaal, maar steeds in praktiese gebruik misluk as dit tabelle verloor, beelde verskuif, uitleg verdraai of 'n onleesbare uitvoerdokument produseer. Daarom evalueer hierdie studie die voorgestelde stelsel vanuit twee perspektiewe: formateringbewaring en vertalingskwaliteit.

Op grond van bogenoemde ontleding lê die navorsingsgaping in die kombinasie van drie faktore: vertalingskwaliteit, oorspronklike formaatbewaring en buigsame tweetalige aanbiedingswyses. Bestaande stelsels fokus gewoonlik tot 'n sekere mate op óf inhoudvertaling óf formaatbewaring, maar hulle ondersteun nie standaardvertaling, sy-aan-sy tweetalige vertaling en lyn-vir-lyn tweetalige vertaling binne 'n aanpasbare en uitbreidbare pyplyn nie. Verder, deur gebruikers toe te laat om tussen vertaalverskaffers soos Google Translate, DeepL en Gemini te kies, maak die stelsel meer aanpasbaar by verskillende vereistes in koste, spoed en vertaalkwaliteit. Daarom stel hierdie studie 'n KI-gebaseerde dokumentvertalingstelsel voor wat DOCX-verwerking, 'n PDF→DOCX→vertaling→PDF-pyplyn, spesiale-inhoudbeskerming, uitlegherwinning en eksperimentele evaluering van beide formatering en vertaalkwaliteit kombineer.

3 Stelselontwerp

Die voorgestelde stelsel is ontwerp om die probleem van die vertaling van dokumente op te los, terwyl die oorspronklike formaat vir twee hoofdokumenttipes bewaar word: DOCX en PDF. Die algehele werkvloei begin wanneer 'n gebruiker 'n dokument deur die webkoppelvlak oplaai en die teikentaal, vertaalverskaffer en vertaalmodus kies. Nadat die versoek ontvang is, bevestig die stelsel die lêerformaat, stoor die invoerdokument en skep 'n agtergrondverwerkingstaak. Hierdie asinchroniese verwerkingsontwerp is geskik vir groot dokumente of dokumente wat veelvuldige intermediêre verwerkingstappe vereis, veral PDF-lêers. Tydens vertaling kan die gebruikerskoppelvlak die verwerkingstatus monitor deur 'n posidentifiseerder en die gebruiker toelaat om die uitvoerlêer af te laai wanneer die taak voltooi is.

Die stelselargitektuur bestaan uit verskeie hoofkomponente: die gebruikerskoppelvlak, die versoekhantering-API, die agtergrondwerkbestuurder, die lêerverwerkingsdiens, die vertaalverskaffermodule, die uitlegherwinningsmodule en die uitsetgenereringsmodule. Die gebruikerskoppelvlak stel gebruikers in staat om DOCX- of PDF-lêers op te laai, die teikentaal te kies, 'n vertaalverskaffer soos Google Translate, DeepL of Gemini te kies, en een van drie vertaalmodusse te kies: standaardvertaling, tweetalige vertaling langs mekaar en tweetalige lyn-vir-lyn vertaling. Die API bekragtig die opgelaaide lêer, stoor dit, skep 'n vertaalrekord en inisialiseer 'n agtergrondtaak. Die lêerverwerkingsdiens bepaal dan die dokumenttipe en kies die toepaslike pyplyn. Hierdie argitektuur laat toe dat die stelsel in die toekoms uitgebrei kan word met bykomende vertaalverskaffers of nuwe dokumentformate.




Fig. 1. *Werkvloei van die voorgestelde KI-gebaseerde dokumentvertalingstelsel met oorspronklike formaatbewaring.*

Vir DOCX-dokumente verwerk die stelsel die dokumentstruktuur direk deur paragrawe, tabelle, kopskrifte en voettekste te herhaal. Aangesien DOCX 'n duidelike interne struktuur het, kan die stelsel die meeste style, lettertipes, kantlyne en tabelstrukture bewaar terwyl slegs tekstuele inhoud gewysig word. Voordat teks aan 'n vertaalverskaffer gestuur word, pas die stelsel 'n Translation Guard-meganisme toe om nie-vertaalbare elemente soos URL's, DOI's, e-posadresse, aanhalings, formules, tegniese simbole en kodebrokkies te beskerm. Hierdie meganisme is veral belangrik vir akademiese en tegniese dokumente omdat die verkeerde vertaling van sulke elemente hul oorspronklike betekenis kan verander. Na vertaling word die vertaalde teks teruggeskryf in die dokument volgens die gekose vertaalmodus.

→Vir PDF-dokumente gebruik die stelsel 'n intermediêre omskakelingspylyn: PDF→DOCX→vertaling→uitlegherstel→PDF. Eerstens word die PDF-lêer ontleed om te bepaal of dit 'n tekslaag bevat, of dit 'n geskandeerde dokument is, en of dit tabelle, prente of komplekse bladsyuitlegte insluit. As die lêer geskandeer is of beeldgebaseerde teks bevat, kan OCR toegepas word om 'n verwerkbare tekslaag te skep. Die PDF word dan skoongemaak en in DOCX omgeskakel. Aangesien PDF-na-DOCX-omskakeling probleme kan veroorsaak soos gefragmenteerde paragrawe, saamgevoegde teks, verkeerde tabelbespeuring of abnormale reëlspasiëring, voer die stelsel 'n ontsmettingsstap uit om gefragmenteerde saam te voeg

segmente, normaliseer die uitleg en verminder geraas voor vertaling. Na vertaling word die uitlegherstelmodule gebruik om die dokumentuitleg te herstel voordat die resultaat terug na PDF uitgevoer word.

Die stelsel ondersteun drie vertaalmodusse om aan verskillende gebruikersbehoefte te voldoen. In standaardvertaalmodus word die oorspronklike teks vervang deur die vertaalde teks, wat geskik is wanneer die gebruiker slegs die finale dokument in die doeltaal benodig. In sy-aan-sy tweetalige vertaalmodus hou die stelsel die oorspronklike teks en plaas die vertaalde teks in dieselfde paragraaf, gewoonlik geskei deur die "|" skeidingsteken, wat gebruikers in staat stel om die brontekste te vergelyk. In reël-vir-reël tweetalige vertaalmodus, behou die stelsel die oorspronklike paragraaf en voeg die vertaalde paragraaf onmiddellik daaronder in. Hierdie modus is nuttig vir taalleer, akademiese lees en vertalingskontrole. Aangesien tweetalige modusse die lengte van die dokument vergroot, is die doel van uitlegherwinning nie om die presiese aantal bladsye te bewaar nie, maar om te verseker dat die inhoud leesbaar, korrek georden, volledig en vry van ernstige teksoorvleuelende foute bly.

Algoritme 1

Invoer:

F: invoerdokument (. pdf van . docx)

L: doeltaal

P: vertaalverskaffer (Google Translate, DeepL, Gemini)

M: vertaalmodus (standaard, sy-aan-sy tweetalig, reël-vir-reël tweetalig)

Opt: opsionele instellings soos OCR en skeidingskonfigurasie

Uitset:

F_out: vertaalde dokument met bewaarde formatering

BEGIN

Valideer die invoerdokument F en doeltaal L

AS dies leeruitbreiding van F nie . pdf van . docx

DAN Gee ongesteunde peerformaat terug

EINDE INDIEN

Stoor F om berging op te laai

Skep 'n agtergrondvertaalwerk

Gee job_id en status_url terug na die
kliënt

Stel die werkstatus op in_progress

AS F 'n PDF-dokument DAN is
Ontleed die PDF-struktuur, insluitend tekslaag, geskandeerde bladsye,
tabelle en beelde

AS die PDF DAN geskandeer word
Pas OCR toe om 'n soekbare PDF te
skep AS OCR DAN in streng modus
misluk

Stel die
taakstatus op misluk

Terugkeer fout
EINDE INDIEN
EINDE INDIEN

Maak die PDF-dokument skoon
Skakel die PDF-dokument om na DOCX
Maak die omgeskakelde DOCX-
dokument skoon

Onttrek paragrawe, tabelle, kop- en voettekste uit die DOCX-dokument
Pas vertaalwag toe om URL's, DOI's, aanhalings, formules en spesiale
simbole te beskerm

Vertaal die onttrekte inhoud deur verskaffer P en modus M te gebruik
Herwin die dokumentuitleg na vertaling

AS M standaardvertaling DAN is
Pas die finale uitlegverfyningsstap
EINDE IF toe

Skakel die vertaalde DOCX-dokument terug na PDF
Voer kwaliteitskontrole uit op die uitvoer PDF

ANDERS AS F DAN 'n DOCX-dokument is

Maak die DOCX-dokument direk oop
Onttrek paragrawe, tabelle, kop- en voettekste
Pas vertaalwag toe om spesiale inhoud te beskerm
Vertaal die DOCX-inhoud deur verskaffer P en modus M
te gebruik Behou die oorspronklike style en
dokumentstruktuur
EINDE INDIEN

Stoor die vertaalde dokument om berging af te laai
Stel die taakstatus op voltooi

Keer die afluipad van F_out terug

INDIEN enige fout DAN voorkom
Stel die taakstatus op misluk met die
foutboodskap END IF

Die kliënt kontroleer periodiek
status_url AS die posstatus DAN
voltooi is Laai die vertaalde
dokument af EINDE INDIEN

EINDE

Die pseudokode beskryf die algehele verwerkingswervloei van die voorgestelde stelsel. Vir DOCX-dokumente verwerk die stelsel paragrawe, tabelle, opskrifte en

voettekste om tekstuele inhoud te vertaal terwyl die oorspronklike formatering behoue bly. Vir PDF-dokumente gebruik die stelsel DOCX as 'n intermediêre redigeerbare formaat deur die PDF in DOCX om te skakel, die onttrekte inhoud te vertaal, die uitleg te herstel en die resultaat terug na PDF uit te voer. Tydens vertaling ondersteun die stelsel drie modusse: standaardvertaling, sy-aan-sy tweetalige vertaling en reël-vir-lyn tweetalige vertaling. Daarbenewens word spesiale elemente soos URL's, DOI's, aanhalings, formules en tegniese simbole beskerm om verkeerde vertaling van nie-vertaalbare inhoud te voorkom.

Nadat vertaling en uitlegherwinning voltooi is, voer die stelsel die uitvoerlêer uit volgens die oorspronklike dokumenttipe. As die invoerlêer DOCX is, gee die stelsel 'n vertaalde DOCX-lêer terug. As die invoerlêer PDF is, skakel die stelsel die vertaalde DOCX terug na PDF en voer die kwaliteit kontrolering uit. Hierdie nagaanstap het ten doel om ernstige foute op te spoor soos ontbrekende inhoud, ontbrekende tabelle, ontbrekende beelde of uitlegprobleme wat leesbaarheid beïnvloed. Die finale lêer word in die aflaaigids gestoor, en die aflaaipad word aan die gebruiker teruggestuur nadat die taakstatus na voltooi verander het.

4 Eksperimente

Die eksperimente is uitgevoer om die stelsel vanuit twee hoofperspektiewe te evalueer: formateringbewaring na vertaling en vertalinginhoudkwaliteit. Die skeiding van hierdie twee evalueringsgroepe is nodig omdat dokumentvertaling nie net afhang van linguistiese kwaliteit nie, maar ook van die vermoë om die oorspronklike visuele struktuur van die dokument te bewaar. 'n Vertaling kan semanties korrek wees, maar misluk steeds in die praktyk as dit tabelle verloor, die uitleg verander of 'n onleesbare uitvoerlêer produseer. Omgekeerd kan 'n dokument sy formatering goed bewaar, maar die vertaling kan steeds onvoldoende wees as dit onnatuurlik is of verkeerde terminologie gebruik.

Die eksperimente is uitgevoer op 'n Acer Nitro AN515-45 rekenaar met Microsoft Windows 11 Home Single Language 64-bis. Die masjien gebruik 'n AMD Ryzen 55600H met Radeon Graphics-verwerker, met 12 logiese verwerkers teen ongeveer 3.3 GHz, op 'n x64-gebaseerde rekenaarargitektuur. Die stelsel is toegerus met 8 GB RAM en DirectX 12. Die ontwikkelingsomgewing gebruik Python saam met die FastAPI-raamwerk op die agterkant vir die ontvangs van dokumentvertalingsversoeke, die bestuur van agtergrondverwerkingstake en die terugstuur van uitvoerlêers aan gebruikers. Die gebruikerskoppelvlak word geïmplementeer met behulp van HTML, CSS en JavaScript. Vir dokumentverwerking gebruik die stelsel pdf2docx vir PDF-na-DOCX-omskakeling, DOCX-verwerkingsbiblioteke vir die hantering van paragrawe, tabelle, kop- en voettekste, Tesseract OCR vir geskandeerde dokumente of ingebedde beelde, en 'n DOCX-na-PDF-omskakelingsinstrument vir die generering van die finale vertaalde PDF-uitset. Die vertaalverskaffers wat in die eksperimente gebruik is, sluit in Google Translate, DeepL Translator en Gemini 2.5 Flash.

Die eksperimentele dokumente is versamel en voorberei uit publiek beskikbare akademiese artikels en tegniese dokumente wat verband hou met kunsmatige intelligensie, masjienvertaling, OCR en dokumentuitlegontleding. Die brondokumente is gekies uit ooptoegang akademiese bewaarplekke en publiek toeganklike PDF-bronne, soos arXiv en ACL Anthology. Sommige PDF-dokumente is direk gebruik, terwyl sommige

Tabel 1. Formatering van bewaringsevaluering van vertaalde dokumente.

Dokument tipe	Vertaalmodus	Opskrif (%teks/styl (%))	Tabel (%)	Verduideliking (%)	Geen oorloop (%)	AVG (%)
Woord	Standaard	100.00	100.00	100.00	100.00	100,00
Woord		100.00	100.00	100.00	100.00	100,00
Woord		100.00	99,92	100.00	100.00	99,98
PDF	Vertaling Side-by-side	100.00	83,33	100.00	80.00	100.00
PDF	Tweetalig Vertaling	100.00	66,67	100.00	60.00	99,14
PDF	Reël-vir-reël Tweetalig	100.00	93,13	100.00	66,67	100.00
	Vertaling Standaard					
	Vertaling Side-by-side					
	Tweetalig					
	Vertaling Reël-vir-reël					92,67
	Tweetalig					
	Vertaling					85,16
						91,96

Die resultate in Tabel 1 toon dat Word-dokumente 'n formateringbehoudtelling van 100% behaal het in standaardvertaling en sy-aan-sy tweetalige vertaalmodus, terwyl die lyn-vir-lyn tweetalige vertaalmodus 99,98% behaal het. Dit stem ooreen met die gestruktureerde aard van DOCX, wat die stelsel toelaat om paragrawe, tabelle en style direk te verwerk. In standaardvertaalmodus vervang die stelsel slegs die oorspronklike teks met die vertaalde teks terwyl formateringskomponente behoue bly. In sy-aan-sy en reël-vir-reël tweetalige modusse kan die dokumentlengte toeneem, maar die buigsame struktuur van DOCX laat opskrifte, paragrawe, tabelle en uitleglesbaarheid toe om stabiel te bly.

Vir PDF-dokumente is die resultate laer as dié van DOCX, maar steeds belowend. Die standaardvertaalmodus het 'n AVG-telling van 92.67% behaal, wat aandui dat die PDF→DOCX→vertaling→PDF-pyplyn die meeste van die dokumentstruktuur kan bewaar. Die sy-aan-sy tweetalige modus het 'n AVG-telling van 85.16% behaal, wat laer is as die ander twee modusse omdat die plasing van bron- en vertaalde teks in dieselfde paragraaf teksdigtheid verhoog en meer uitlegdruk skep. Die reël-vir-reël tweetalige modus het 'n AVG-telling van 91.96% behaal, wat hoër is as die sy-aan-sy-modus omdat die plasing van die vertaling onder die bronparagraaf leesbaarheid verbeter en die risiko verminder dat teks in dieselfde reël oorvleuel.

Die tweede eksperiment evalueer vertalingskwaliteit deur drie vertaalverskaffers te gebruik: Google Translate, Gemini 2.5 Flash en DeepL Translator. Die evalueringdata bestaan uit 84 tekssegmente wat uit die DOCX-toetsdokument onttrek is. BLEU word gebruik om die ooreenkoms tussen vertalings op dieselfde toetsstel te evalueer. BLEU word wyd gebruik in masjienvertalingsevaluering om n-gram-oorvleueling tussen stelseluitset en verwysingsvertaling te meet (Papineni et al., 2002). BLEU-verslaggewing moet egter duidelik beskryf word om verwarring tussen standaard BLEU met menslike verwysingsvertalings en relatiewe evalueringsvariante oor veelvuldige masjienvertalingsuitsette te voorkom (Post, 2018). In hierdie studie, omdat 'n volledige handmatig hersiene verwysingsvertalingsdatastel nog nie

saamgestel is nie, word BLEU in 'n kruisuitsetopstelling gebruik om die ooreenkoms tussen vertalings wat deur Google Translate, DeepL Translator en Gemini 2.5 Flash op dieselfde toetssegmente gegenereer word, te vergelyk.

moet nie as 'n formateringsfout beskou word nie, solank die dokument leesbaar, volledig en vry van ernstige teksoorvleueling bly.

& Ten spyte van die resultate wat verkry is, het die stelsel steeds verskeie beperkings wat verdere verbetering benodig. Die PDF→DOCX→vertaling→PDF-pyplyn kan nie perfekte formatering vir alle soorte PDF-dokumente waarborg nie, veral dokumente met multi-kolom-uitlegte, komplekse tabelle, wiskundige formules of professionele desktop-publiserings-ontwerpe. Boonop hang geskandeerde PDF's baie af van OCR-kwaliteit; as beelde vaag, skeef, raserig is of ongewone lettertipes gebruik, kan OCR-foute die vertaalkwaliteit beïnvloed. Aangesien BLEU in hierdie studie in 'n kruisuitsetopstelling gebruik word as gevolg van die afwesigheid van 'n volledige handmatig hersiene verwysingsvertalingsdatastel, behoort toekomstige werk 'n verwysingsdatastel te konstrueer en addisionele maatstawwe soos METEOR, TER en COMET te kombineer vir 'n meer omvattende evaluering (Banerjee & Lavie, 2005; Snover et al.06, 20).

5 Gevolgtrekking

Hierdie studie het 'n KI-gebaseerde dokumentvertalingstelsel met oorspronklike formaatbewaring voorgestel en ontwikkel vir twee hoofdokumentformate: DOCX en PDF. Die stelsel ondersteun drie vertaalmodusse: standaardvertaling, sy-aan-sy tweetalige vertaling en reël-vir-lyn tweetalige vertaling. Dit stel gebruikers ook in staat om verskillende vertaalverskaffers te kies, insluitend Google Translate, DeepL Translator en Gemini 2.5 Flash. Vir DOCX-dokumente verwerk die stelsel gestruktureerde komponente soos paragrawe, tabelle, kop- en voettekste direk. Vir PDF-dokumente gebruik die stelsel 'n PDF→DOCX→vertaling→uitleggherstel→PDF-pyplyn om voordeel te trek uit DOCX-redigeerbaarheid en formaatbewaring te verbeter.

Die eksperimentele resultate toon dat die stelsel baie sterk formaatbewaring vir Word-dokumente behaal en belowende resultate vir PDF-dokumente. Die tweetalige vertaalmodusse is nuttig om gebruikers te help om die oorspronklike inhoud met die vertaalde inhoud te vergelyk, veral in leer, navorsing en terminologiekontrolle. Wat vertalingskwaliteit betref, toon BLEU Mean en BLEU Std dat die vertaalverskaffers relatief goeie resultate op die toetsdatastel behaal het, met Gemini 2.5 Flash wat die hoogste telling in die kruisuitset BLEU-eksperiment behaal het. Om vertalingskwaliteit meer akkuraat te evalueer, moet toekomstige navorsing egter handmatig hersiene verwysingsvertalings saamstel en bykomende evalueringsmaatstawwe kombineer.

In toekomstige werk kan die stelsel in verskeie rigtings verbeter word. Eerstens kan PDF-verwerking verbeter word deur uitlegontleding, tabelherkenning en na-vertaling-uitleggherwinning te verbeter. Tweedens, OCR-kwaliteit moet verbeter word vir geskandeerde PDF's en ingebedde beelde. Derdens kan 'n domeinspesifieke woordelys bygevoeg word om terminologiekonsekwentheid in akademiese en tegniese dokumente te verseker. Laastens kan ondersteuning vir bykomende formate soos PPTX, XLSX en HTML ontwikkel word om die praktiese toepaslikheid van die stelsel te verbreed.

Verwysings

- &1. Bahdanau, D., Cho, K.,&Bengio, Y.(2015). Neural machine translation by jointly learning to align and translateInternational Conference on Learning Representations.

<https://arxiv.org/pdf/1409.0473>

2. Banerjee, S., &Lavie, A.(2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgmentsProceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization, 65–72. <https://aclanthology.org/W05-0909.pdf>
3. Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C.,Amodei, D.(2020).

Taalmodelle is min-skoot-leerders Vooruitgang in neurale inligtingverwerking Systems, 33, 1877–1901. <https://arxiv.org/pdf/2005.14165>

4. Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Gonzalez, G. M., Hansanti, P., Hoffman, J., . Wang, J. (2022).

&

&

& Geen taal agtergelaat nie: skaal mensgesentreerde masjienvertalingarXiv-voordruk arXiv: 2207.04672. <https://arxiv.org/pdf/2207.04672>

5. Devlin, J., Chang, M.-W., Lee, K.,&Toutanova, K.(2019). BERT: Pre-training of deep bidirectional transformers for language understandingProceedings of NAACL-HLT, 4171–4186. <https://aclanthology.org/N19-1423.pdf>
6. Jaume, G., Ekenel, H. K.,&Thiran, J.-P.(2019). FUNSD: A dataset for form understanding in noisy scanned documentsInternational Conference on Document Analysis and Recognition Workshops. <https://arxiv.org/pdf/1905.13538>
7. Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Hermann, U., Aji, A. F., Bogoychev, N., Martins, A. F. T.,& Birch, A.(2018). Marian: Fast neural machine translation in C++Proceedings of ACL System Demonstrations, 116–121. <https://aclanthology.org/P18-4020.pdf>
8. Koehn, P. (2020). Neural machine translation Cambridge University Press.

& <https://arxiv.org/pdf/1709.07809>

&

9. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S.,&Kiela, D.(2020). Retrieval-augmented generation for knowledge-intensive NLP tasksAdvances in Neural Information Processing Systems, 33, 9459–9474. <https://arxiv.org/pdf/2005.11401>

10. Li, M., Xu, Y., Cui, L., Huang, S., Wei, F., Li, Z.,&Zhou, M.(2020). DocBank: A benchmark dataset for document layout analysisProceedings of the 28th International Conference on Computational Linguistics, 949–960. <https://aclanthology.org/2020.coling-main.82.pdf>

11. Lin, C.-Y.(2004). ROUGE: A package for automatic evaluation of summaries

Verrigtinge van die werkswinkel oor teksopsomming

takke uit, 74–81.

<https://aclanthology.org/W04-1013.pdf>

&

12. Mathew, M., Karatzas, D., & Jawahar, C. V. (2021). DocVQA: A dataset for VQA on document images. *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2200–2209.
https://openaccess.thecvf.com/content/WACV2021/papers/Mathew_DocVQA_A_Dataset_for_VQA_on_Document_Imagespaper.pdf
13. Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. *Proceedings of the 40th Annual Meeting of the*

Vereniging vir Rekenaarlinguistiek, 311–318. <https://aclanthology.org/P02-1040.pdf>

14. Post, M.(2018). A call for clarity in reporting BLEU scoresProceedings of the Third Conference on Machine Translation, 186–191. <https://aclanthology.org/W18-6319.pdf> 15. Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., & Liu, P. J.(2020). Exploring the limits of transfer learning with a unified text-to-text transformer Journal of Machine Learning Research, 21(140), 1–67. <https://jmlr.org/vraestelle/volume21/20-074/20-074.pdf>

16. Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). COMET: A neural framework for machine translation evaluationProceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, 2685–2702. <https://aclanthology.org/2020.emnlp-hoof.213.pdf>

17. Smith, R.(2007). An overview of the Tesseract OCR engineProceedings of the International Conference on Document Analysis and Recognition, 629–633.

&

<https://research.google.com/pubs/archive/33418.pdf>

18. Snover, M., Dorr, B., Schwartz, R., Micciulla, L., & Makhoul, J.(2006). A study of translation edit rate with targeted human annotationProceedings of the Association for Machine Translation in the Americas, 223–231. <https://aclanthology.org/2006.amta-papers.25.pdf>

19. Stahlberg, F.(2020). Neural machine translation: A reviewJournal of Artificial Intelligence Research, 69, 343–418. <https://arxiv.org/pdf/1912.02047>

20. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I.(2017). Attention is all you needAdvances in Neural Information Processing Systems, 30. <https://arxiv.org/pdf/1706.03762>

21. Wu, Y., Schuster, M., Chen, Z., Le, Q. V., Norouzi, M., Macherey, W., Krikun, M., Cao, Y., Gao, Q., Macherey, K., Klingner, J., Shah, A., Johnson, M., Liu, X., Kaiser, Ł., Gouws, S., Kato, Y., Kudo, T., Kazawa, H., Dean, J.(2016). Google's neural machine translation system: Bridging the gap between human and machine translationarXiv preprint arXiv: 1609.08144. <https://arxiv.org/pdf/1609.08144>

22. Xu, Y., Li, M., Cui, L., Huang, S., Wei, F., & Zhou, M. (2020). LayoutLM: Pre-training of text and layout for document image understandingProceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1192–1200.

&

<https://arxiv.org/pdf/1912.13318>

23. Xu, Y., Xu, Y., Lv, T., Cui, L., Wei, F., Wang, G., Lu, Y., Florencio, D., Zhang, C., Che, W., Zhang, M., Zhou, L., Huang, Q., & Zhou, M. (2021). LayoutLMv2: Multi-modal pre-training for visually-rich document understandingProceedings of the Annual Meeting of the Association for Computational Linguistics. <https://aclanthology.org/2021.acl-long.201.pdf>

24. Zhong, X., Tang, J., & Yepes, A. J. (2019). PubLayNet: Largest dataset ever for document layout analysisProceedings of the International Conference on Document Analysis and Recognition, 1015–1022. <https://arxiv.org/pdf/1908.07836>