

Automatic Text-to-Speech System for Vietnamese Using | Hệ thống chuyển văn bản thành giọng nói tự động cho người Việt sử dụng Artificial Intelligence | Trí tuệ nhân tạo

Thanh-Danh Vo¹, Ngo-Ho Anh-Khoa¹ and Ngo-Ho Anh-Khoi^{1*} | Thành-Danh Võ¹, Ngô-Hồ Anh-Khoa¹ và
Ngô-Hồ Anh-Khôi^{1*}

¹ Faculty of Information Technology, Nam Can Tho University, 168 Nguyen Van Cu Street, An | ¹ FACULTY OF INFORMATION

TECHNOLOGY, Đại học Nam Cần Thơ, 168 Nguyễn Văn Cừ, An

Binh Ward, Can Tho City | , Vietnam Phường Bình, Thành phố Cần Thơ

danh223566@studentnctu.edu.vn, nhakhoa@nctu.edu.vn, | __ GIỮ_0__, ,

nhakhoi@nctu.edu.vn

Abstract. In the context of digital transformation and the rapid advancement of | **Trình tự.** Trong bối cảnh chuyển đổi
kỹ thuật số và sự tiến bộ nhanh chóng của
artificial intelligence, the demand for Text-to-Speech(TTS) systems has | trí tuệ nhân tạo, nhu cầu về hệ thống Chuyển
văn bản thành giọng nói (TTS) ngày càng tăng
become increasingly critical across domains such as virtual assistants, | ngày càng trở nên quan trọng trên các lĩnh vực
như trợ lý ảo,
education, automatic call centers, and accessibility tools for the visually | giáo dục, trung tâm cuộc gọi tự động và các
công cụ trợ năng dành cho người dùng trực quan
impaired. However, generating natural, context-aware, and prosodically | bị suy yếu. Tuy
nhiên, tạo ra sự tự nhiên, nhận biết theo ngữ cảnh và một cách có nhịp điệu
appropriate speech remains a significant challenge, particularly for | phù hợp lời
nói vẫn là một ý nghĩa quan trọng thử thách, cụ thể vì
Vietnamese—a tonal language with complex pitch contours and regional | Tiếng Việt—một ngôn ngữ thanh điệu với
cao độ phức tạp và
diversity. This research proposes and develops a Vietnamese TTS system built | đa dạng. Nghiên cứu này đề xuất và
phát triển hệ thống TTS Việt Nam được xây dựng
upon modern deep learning models to overcome the limitations of traditional | dựa trên các mô hình học sâu hiện đại
để khắc phục những hạn chế của phương pháp truyền thống
methods. The system leverages state-of-the-art architectures including | phương pháp. các
hệ thống đòn bẩy những kiến trúc tân tiến bao gồm
Tacotron, FastSpeech, and VITS, combined with machine learning techniques | Tacotron, FastSpeech và VITS, kết hợp
với kỹ thuật học máy
to enhance synthesis quality. Construction and evaluation are performed on a | để nâng cao chất lượng tổng hợp. Việc
xây dựng và đánh giá được thực hiện một cách
diverse Vietnamese dataset, ensuring adaptability to multiple real-world | bộ dữ liệu tiếng Việt đa dạng, đảm bảo khả
năng thích ứng với nhiều thể giới thực
contexts. Results demonstrate that the system achieves natural, clear, highly | bối cảnh. Kết quả chứng minh hệ thống
đạt được độ tự nhiên, rõ nét, cao
flexible speech output with broad potential for deployment in digital platforms | đầu ra giọng nói linh hoạt với tiềm
năng triển khai rộng rãi trên nền tảng kỹ thuật số
and intelligent services. | và các dịch vụ thông minh.

Keywords: Text-to-Speech (TTS), Artificial Intelligence (AI), Deep Learning, | **Từ khóa:** Chuyển
văn bản thành giọng nói (TTS), Trí tuệ nhân tạo (AI), Học sâu,

1 Introduction | 1 Giới thiệu

Driven by digital transformation and the progress of artificial intelligence, the need to | Được thúc đẩy bởi sự chuyển đổi kỹ thuật số và sự tiến bộ của trí tuệ nhân tạo, nhu cầu build Text-to-Speech(TTS) systems is becoming ever more important in areas such | xây dựng hệ thống Chuyển văn bản thành giọng nói (TTS) ngày càng trở nên quan trọng hơn trong các lĩnh vực như as virtual assistants, education, automatic call centers, and support for the visually | như trợ lý ảo, giáo dục, trung tâm cuộc gọi tự động và hỗ trợ trực quan impaired. The TTS problem, however, extends beyond simply converting text into | bị suy yếu. Tuy nhiên, vấn đề TTS không chỉ dừng lại ở việc chuyển đổi văn bản thành audio; it demands that the synthesized voice be natural, carry appropriate intonation, | âm thanh; đòi hỏi giọng nói tổng hợp phải tự nhiên, có ngữ điệu phù hợp, and fit the given context—a particularly difficult task for Vietnamese, a language with | và phù hợp với bối cảnh nhất định—một nhiệm vụ đặc biệt khó khăn đối với tiếng Việt, một ngôn ngữ có a complex tone system and substantial regional variation (Do, 2026). | một hệ thống âm sắc phức tạp và sự khác biệt đáng kể theo vùng (Do, 2026).

Traditional concatenative and formant-based TTS methods(Zen et al., 2019) and | Các phương pháp TTS dựa trên định dạng và nổi truyền thống (Zen và cộng sự, 2019) và Hidden Markov Model(HMM)-based synthesis(Zen et al., 2019) exhibit limitations | Tổng hợp dựa trên Mô hình Markov ẩn (HMM) (Zen và cộng sự, 2019) bộc lộ những hạn chế in flexibility, naturalness, and scalability. In response, modern deep learning models | về tính linh hoạt, tự nhiên và khả năng mở rộng. Đáp lại, các mô hình học sâu hiện đại such as Tacotron (Wang et al., 2017), Tacotron 2 (Shen et al., 2018), FastSpeech (Ren | chẳng hạn như Tacotron (Wang và cộng sự, 2017), Tacotron 2 (Shen và cộng sự, 2018), FastSpeech (Ren

et al., 2019,2020), and VITS(Kim et al., 2021) have opened more effective avenues by learning directly from data. Building on these advances, this study focuses on the research and development of a Vietnamese TTS system aimed at improving voice quality and practical applicability. | et al., 2019,2020) và VITS(Kim et al., 2021) đã mở ra những con đường hiệu quả hơn bằng cách học trực tiếp từ dữ liệu. Dựa trên những tiến bộ này, nghiên cứu này tập trung vào nghiên cứu và phát triển hệ thống TTS của Việt Nam nhằm cải thiện chất lượng giọng nói và khả năng ứng dụng thực tế.

2 Related Work | 2 công việc liên quan

The Vietnamese TTS market features several prominent domestic platforms alongside international solutions. FPT Smart Cloud Text to Speech, developed by FPT Corporation, delivers a high-quality Vietnamese TTS service through a commercial API(Vu et al., 2025; Nguyen, 2023). It applies deep learning architectures such as Tacotron(Wang et al., 2017) and Transformer variants(Vaswani et al., 2017) together with vocoders like WaveNet(Oord et al., 2016) and HiFi-GAN(Kong et al., 2020) to produce natural, region-diverse voices with controllable speed, pitch, and pausing. The system is extensively used in interactive voice response(IVR), audiobooks, virtual assistants, and online education (Do, 2026). Viettel AI Text-to-Speech offers a SaaS-based solution optimized for Vietnamese(Vu et al., 2025; Nguyen, 2023), employing advanced neural models trained on large-scale, Vietnamese-specific speech corpora to ensure accurate pronunciation, natural breaks, and expressive output(Do, 2026; Oord et al., 2016; Kong et al., 2020). Zalo AI Text to Speech, a product of VNG Corporation, integrates deep NLP models like PhoBERT(Nguyen&Tuan, 2020) and BERT-style pre-training(Devlin et al., 2019) with synthesis architectures including Tacotron, FastSpeech, and VITS(Wang et al., 2017; Ren et al., 2019; Kim et al., 2021), leveraging massive user data to support multiple speaking styles(Vu et al., 2025). Voice.vn specializes in speech synthesis and voice cloning(Vu et al., 2025) using end-to-end models like VITS(Kim et al., 2021) and voice conversion techniques(Casanova et al., 2022; Chen et al., 2022), enabling high-fidelity voice cloning and customization for advertising, podcasting, and gaming. Google AI Studio provides a cloud-based environment for TTS via the Gemini family and Google Cloud Text-to-Speech(Vaswani et al., 2017; Ren et al., 2019), featuring multi-lingual, natural, and context-adaptive voice generation (Casanova et al., 2022; Shen et al., 2018). EventLab offers TTS and voice cloning tools built on end-to-end TTS(Wang et al., 2017) and speaker embedding models (Chen et al., 2022; Kim et al., 2021; Casanova et al., 2022). Overall, the market is shifting from simple text-reading systems toward intelligent communication platforms, with strong trends in voice cloning (Jia et al., 2018) and multimodal AI. | Thị trường TTS Việt Nam có một số nền tảng nội địa nổi bật bên cạnh các giải pháp quốc tế. FPT Smart Cloud Text to Speech do Tập đoàn FPT phát triển, cung cấp dịch vụ TTS tiếng Việt chất lượng cao thông qua API thương mại (Vũ và cộng sự, 2025; Nguyễn, 2023). Nó áp dụng các kiến trúc học sâu như Tacotron(Wang và cộng sự, 2017) và các biến thể Transformer (Vaswani và cộng sự, 2017) cùng với các bộ phát âm như WaveNet(Oord và cộng sự, 2016) và HiFi-GAN(Kong và cộng sự, 2020) để tạo ra giọng nói tự nhiên, đa dạng theo vùng với tốc độ, cao độ và tạm dừng có thể kiểm soát được. Hệ thống này được sử dụng rộng rãi trong phản hồi bằng giọng nói

tương tác (IVR), sách nói, trợ lý ảo và giáo dục trực tuyến (Đỗ, 2026). Viettel AI Text-to-Speech cung cấp giải pháp dựa trên SaaS được tối ưu hóa cho tiếng Việt (Vu và cộng sự, 2025; Nguyễn, 2023), sử dụng các mô hình thần kinh tiên tiến được đào tạo trên tập hợp giọng nói dành riêng cho tiếng Việt trên quy mô lớn để đảm bảo phát âm chính xác, ngắt quãng tự nhiên và đầu ra biểu cảm (Do, 2026; Oord và cộng sự, 2016; Kong và cộng sự, 2020). Zalo AI Text to Speech, một sản phẩm của VNG Corporation, tích hợp các mô hình NLP chuyên sâu như PhoBERT (Nguyễn & Tuan, 2020) và đào tạo trước kiểu BERT (Devlin et al., 2019) với các kiến trúc tổng hợp bao gồm Tacotron, FastSpeech và VITS (Wang et al., 2017; Ren et al., 2019; Kim et al., 2021), tận dụng dữ liệu người dùng khổng lồ để hỗ trợ nhiều phong cách nói (Vu và cộng sự, 2025). Voice.vn chuyên về tổng hợp giọng nói và sao chép giọng nói (Vu và cộng sự, 2025) sử dụng các mô hình đầu cuối như VITS (Kim và cộng sự, 2021) và các kỹ thuật chuyển đổi giọng nói (Casanova và cộng sự, 2022; Chen và cộng sự, 2022), cho phép nhân bản và tùy chỉnh giọng nói có độ trung thực cao cho quảng cáo, podcasting và chơi game. Google AI Studio cung cấp môi trường dựa trên đám mây cho TTS thông qua dòng Gemini và Google Cloud Text-to-Speech (Vaswani và cộng sự, 2017; Ren và cộng sự, 2019), có tính năng tạo giọng nói đa ngôn ngữ, tự nhiên và thích ứng với ngữ cảnh (Casanova và cộng sự, 2022; Shen và cộng sự, 2018). EventLab cung cấp TTS và các công cụ sao chép giọng nói được xây dựng trên TTS đầu cuối (Wang và cộng sự, 2017) và mô hình nhúng loa (Chen và cộng sự, 2022; Kim và cộng sự, 2021; Casanova và cộng sự, 2022). Nhìn chung, thị trường đang chuyển dần từ đơn giản đọc văn bản hệ thống theo hướng thông minh nền tảng truyền thông, với xu hướng mạnh mẽ về nhân bản giọng nói (Jia và cộng sự, 2018) và AI đa phương thức.

The open-source community has contributed a range of Vietnamese TTS models. VietTTS is a representative system built with encoder-decoder or Transformer architectures (Wang et al., 2017; Vaswani et al., 2017; Ren et al., 2019), trained on carefully normalized Vietnamese data (Do, 2026) to handle tones, compound words, and sentence structures, offering near-real-time latency suitable for virtual assistants, e-learning, and audiobook production (Nguyễn, 2023; Vu et al., 2025). NeuTTS-Air focuses on lightweight, efficient inference, balancing voice quality and speed to operate on CPUs or low-resource devices (Ren et al., 2019, 2020; Kim et al., 2021), | Cộng đồng nguồn mở đã đóng góp nhiều mô hình TTS Việt Nam. VietTTS là một hệ thống đại diện được xây dựng với kiến trúc bộ mã hóa-giải mã hoặc kiến trúc Transformer (Wang và cộng sự, 2017; Vaswani và cộng sự, 2017; Ren và cộng sự, 2019), được đào tạo về dữ liệu tiếng Việt được chuẩn hóa cẩn thận (Do, 2026) để xử lý các âm, từ ghép và cấu trúc câu, cung cấp độ trễ gần như thời gian thực phù hợp cho trợ lý ảo, học tập điện tử và sản xuất sách nói (Nguyễn, 2023; Vũ và cộng sự, 2025). NeuTTS-Air tập trung vào suy luận nhẹ nhàng, hiệu quả, cân bằng giữa chất lượng giọng nói và tốc độ để hoạt động trên CPU hoặc các thiết bị có nguồn tài nguyên thấp (Ren và cộng sự, 2019, 2020; Kim và cộng sự, 2021),

optimized for chatbots, IVR, and IoT applications (Ping et al., 2017; Kalchbrenner et al., 2018). Kani-TTS is a large-scale model with approximately 370 million parameters, aiming for high expressiveness and professional audio quality (Kim et al., 2021; Casanova et al., 2022), excelling in audiobook and media production but requiring powerful GPUs for deployment (Ren et al., 2019; Ping et al., 2017; Kalchbrenner et al., 2018). VieNeu-TTS combines TTS with voice cloning, extracting speaker characteristics via techniques like AutoVC (Qian et al., 2019) and StarGAN-VC (Kameoka et al., 2018) and applying them to synthesized speech (Casanova et al., 2022; Jia et al., 2018), enabling strong personalization but also raising ethical and security concerns. ViXTTS serves as a demonstration project for voice cloning, illustrating the technology for rapid experimentation (Thinh, 2024; Kim et al., 2021). Valtec-TTS is a compact model optimized for extremely resource-constrained environments such as embedded devices and IoT (Ren et al., 2019, 2020; Ping et al., 2017; Kalchbrenner et al., 2018), delivering adequate clarity for simple notification and guidance applications. Collectively, these models illustrate the maturation of Vietnamese TTS, with specialized branches ranging from high-quality synthesis to lightweight deployment and voice personalization. | được tối ưu hóa cho các ứng dụng chatbot, IVR và IoT (Ping và cộng sự, 2017; Kalchbrenner và cộng sự, 2018). Kani-TTS là mô hình quy mô lớn với khoảng 370 triệu thông số, hướng tới tính biểu cảm cao và chất lượng âm thanh chuyên nghiệp (Kim và cộng sự, 2021; Casanova và cộng sự, 2022), vượt trội trong sản xuất sách nói và phương tiện truyền thông nhưng yêu cầu GPU mạnh mẽ để triển khai (Ren và cộng sự, 2019; Ping và cộng sự, 2017; Kalchbrenner và cộng sự, 2018). VieNeu-TTS kết hợp TTS với nhân bản giọng nói, trích xuất các đặc điểm của người nói thông qua các kỹ thuật như AutoVC (Qian et al., 2019) và StarGAN-VC (Kameoka et al., 2018) và áp dụng chúng vào giọng nói tổng hợp (Casanova et al., 2022; Jia et al., 2018), cho phép cá nhân hóa mạnh mẽ nhưng cũng gây ra những lo ngại về đạo đức và bảo mật. ViXTTS đóng vai trò là một dự án trình diễn nhân bản giọng nói, minh họa công nghệ thử nghiệm nhanh (Thinh, 2024; Kim và cộng sự, 2021). Valtec-TTS là một mô hình nhỏ gọn được tối ưu hóa cho các môi trường cực kỳ hạn chế về tài nguyên như thiết bị nhúng và IoT (Ren và cộng sự, 2019, 2020; Ping và cộng sự, 2017; Kalchbrenner và cộng sự, 2018), mang lại sự rõ ràng đầy đủ cho các ứng dụng hướng dẫn và thông báo đơn giản. Nhìn chung, các mô hình này minh họa sự trưởng thành của TTS Việt Nam, với các nhánh chuyên biệt từ tổng hợp chất lượng cao đến triển khai đơn giản và cá nhân hóa giọng nói.

Data quality is foundational for TTS. The VLSP Speech Corpus is a large, academically oriented dataset with multi-speaker recordings in controlled conditions (Ardila et al., 2020; Vu et al., 2025), richly annotated with phonetic and regional information (Yamagishi et al., 2019; Do, 2026). VIVOS is a smaller open-source corpus (around 10–20 hours) of clean read speech (Ardila et al., 2020; Ito & Johnson, 2017), widely used for initial modeling despite limited emotional and real-world diversity (Do, 2026). Commercial datasets from FPT Corporation, Viettel Group, and VNG Corporation are far larger and more detailed. FPT's dataset comprises hundreds to thousands of hours of studio-quality recordings with exhaustive annotations (Vu et al., 2025; Do, 2026; Oord et al., 2016; Kong et al., 2020). Viettel's data blends studio and real-world recordings covering diverse accents (Vu et al., 2025; Yamagishi et al., 2019; Jia et al., 2018; Do, 2026). Zalo's data benefits from its broad user ecosystem, incorporating contemporary language use (Vu et al., 2025; Nguyen & Tuan, 2020; Devlin et

al., 2019; Kim et al., 2021). Additionally, VietTTS provides a basic open dataset with text–audio pairs sufficient for small-scale experiments(Nguyen, 2023; Ito&Johnson, 2017; Vu et al., 2025). Overall, dataset scale, diversity, annotation depth, and realism directly determine TTS performance. | Chất lượng dữ liệu là nền tảng cho TTS. VLSP Speech Corpus là một tập dữ liệu lớn, mang tính học thuật với các bản ghi âm nhiều người nói trong điều kiện được kiểm soát (Ardila và cộng sự, 2020; Vu và cộng sự, 2025), được chú thích phong phú với thông tin về ngữ âm và khu vực (Yamagishi và cộng sự, 2019; Do, 2026). VIVOS là một kho ngữ liệu nguồn mở nhỏ hơn (khoảng 10–20 giờ) chứa lời nói đọc rõ ràng (Ardila và cộng sự, 2020; Ito & Johnson, 2017), được sử dụng rộng rãi để lập mô hình ban đầu mặc dù có hạn chế về tính đa dạng về cảm xúc và thể giới thực (Do, 2026). Bộ dữ liệu thương mại từ Tập đoàn FPT, Tập đoàn Viễn thông và Tập đoàn VNG lớn hơn và chi tiết hơn nhiều. Bộ dữ liệu của FPT bao gồm hàng trăm đến hàng nghìn giờ ghi âm chất lượng phòng thu với các chú thích đầy đủ (Vu và cộng sự, 2025; Đỗ, 2026; Oord và cộng sự, 2016; Kong và cộng sự, 2020). Dữ liệu của Viettel kết hợp các bản ghi âm trong phòng thu và thể giới thực với nhiều chất giọng khác nhau (Vu và cộng sự, 2025; Yamagishi và cộng sự, 2019; Jia và cộng sự, 2018; Do, 2026). Dữ liệu của Zalo được hưởng lợi từ hệ sinh thái người dùng rộng lớn, kết hợp việc sử dụng ngôn ngữ đương đại (Vũ và cộng sự, 2025; Nguyễn&Tuấn, 2020; Devlin và cộng sự, 2019; Kim và cộng sự, 2021). Ngoài ra, VietTTS còn cung cấp bộ dữ liệu mở cơ bản với các cặp văn bản-âm thanh đủ cho các thử nghiệm quy mô nhỏ (Nguyen, 2023; Ito&Johnson, 2017; Vu et al., 2025). Nhìn chung, quy mô tập dữ liệu, tính đa dạng, độ sâu chú thích và tính hiện thực trực tiếp xác định hiệu suất TTS.


3 System Design | 3 Thiết kế hệ thống

Early TTS systems relied on concatenative and formant-based methods, which assemble or mathematically model speech units but suffer from inflexibility, high database costs, and unnatural prosody(Zen et al., 2019). Statistical parametric synthesis using Hidden Markov Models(HMM) improved flexibility but still produced monotonous, less natural output(Zen et al., 2019). The advent of deep learning brought end-to-end models such as Tacotron and Tacotron 2, which employ encoder–decoder architectures with attention to directly map text to | Các hệ thống TTS ban đầu dựa vào các phương pháp nối và dựa trên định dạng, tập hợp hoặc lập mô hình toán học cho các đơn vị lời nói nhưng có tính không linh hoạt, chi phí cơ sở dữ liệu cao và ngữ điệu không tự nhiên (Zen và cộng sự, 2019). Tổng hợp tham số thống kê bằng Mô hình Markov ẩn (HMM) đã cải thiện tính linh hoạt nhưng vẫn tạo ra kết quả đơn điệu, kém tự nhiên (Zen và cộng sự, 2019). Sự ra đời của học sâu đã mang đến các mô hình đầu cuối như Tacotron và Tacotron 2, sử dụng bộ mã hóa-giải mã kiến trúc với chú ý ĐẾN trực tiếp bản đồ chữ ĐẾN

mel-spectrograms, followed by vocoders like WaveNet(Oord et al., 2016) or WaveGlow(Prenger et al., 2019) to generate waveforms(Wang et al., 2017; Shen et al., 2018; Vaswani et al., 2017). These models automatically learn phonetic and prosodic features, yielding significantly more natural speech, but have limitations in inference speed and attention errors. FastSpeech and FastSpeech 2 addressed these issues by removing attention during inference and using duration, pitch, and energy predictors, achieving faster and more stable synthesis with explicit prosody control (Ren et al., 2019,2020; Vaswani et al., 2017). The latest leap, VITS, integrates a variational autoencoder(Kingma&Welling, 2014) with a generative adversarial network(Goodfellow et al., 2014) to directly generate waveforms from text in a single end-to-end framework, eliminating a separate vocoder and further boosting quality and efficiency(Kim et al., 2021; Casanova et al., 2022). Voice cloning and multi-speaker synthesis have also advanced, using speaker embeddings and style tokens to enable personalization and zero-shot adaptation(Jia et al., 2018; Casanova et al., 2022; Chen et al., 2022; Wang et al., 2018). Additionally, transfer and self-supervised learning methods(Baevski et al., 2020; Hsu et al., 2021; Radford et al., 2022) mitigate data scarcity for Vietnamese by pretraining on large multilingual corpora. A modern TTS pipeline typically includes data collection and preprocessing, text normalization (Do, 2026), model training, and waveform generation (Wang et al., 2017; Kim et al., 2021). | mel-spectrogram, theo sau là các bộ phát âm như WaveNet(Oord và cộng sự, 2016) hoặc WaveGlow(Prenger và cộng sự, 2019) để tạo ra dạng sóng (Wang và cộng sự, 2017; Shen và cộng sự, 2018; Vaswani và cộng sự, 2017). Những mô hình này tự động học các đặc điểm ngữ âm và ngữ điệu, mang lại lời nói tự nhiên hơn đáng kể nhưng có những hạn chế về tốc độ suy luận và lỗi chú ý. FastSpeech và FastSpeech 2 đã giải quyết những vấn đề này bằng cách loại bỏ sự chú ý trong quá trình suy luận và sử dụng các yếu tố dự đoán thời lượng, cường độ và năng lượng, đạt được sự tổng hợp nhanh hơn và ổn định hơn với khả năng kiểm soát ngữ điệu rõ ràng (Ren và cộng sự, 2019,2020; Vaswani và cộng sự, 2017). Bước nhảy vọt mới nhất, VITS, tích hợp bộ mã hóa tự động biến thiên (Kingma&Welling, 2014) với mạng đối nghịch tổng hợp (Goodfellow và cộng sự, 2014) để trực tiếp tạo ra dạng sóng từ văn bản trong một khung đầu cuối duy nhất, loại bỏ bộ mã hóa riêng biệt và nâng cao hơn nữa chất lượng và hiệu quả (Kim và cộng sự, 2021; Casanova và cộng sự, 2022). Nhân bản giọng nói và tổng hợp nhiều loa cũng đã được nâng cao, sử dụng tính năng nhúng loa và mã thông báo kiểu để cho phép cá nhân hóa và điều chỉnh không phát âm (Jia và cộng sự, 2018; Casanova và cộng sự, 2022; Chen và cộng sự, 2022; Wang và cộng sự, 2018). Ngoài ra, các phương pháp học tập chuyển giao và tự giám sát (Baevski và cộng sự, 2020; Hsu và cộng sự, 2021; Radford và cộng sự, 2022) giảm thiểu tình trạng khan hiếm dữ liệu cho tiếng Việt bằng cách đào tạo trước trên khối ngữ liệu đa ngôn ngữ lớn. Quy trình TTS hiện đại thường bao gồm thu thập và xử lý trước dữ liệu, chuẩn hóa văn bản (Do, 2026), đào tạo mô hình và tạo dạng sóng (Wang và cộng sự, 2017; Kim và cộng sự, 2021).


The proposed system implements an emotional TTS pipeline: input text containing emotion tags is segmented by emotion, each segment is synthesized via viXTTS, and the resulting waveforms are concatenated with silence gaps to produce the final audio file | Hệ thống được đề xuất triển khai quy trình TTS cảm xúc: văn bản đầu vào chứa thẻ cảm xúc được phân đoạn theo cảm xúc, mỗi phân đoạn được tổng hợp thông qua viXTTS và các dạng sóng thu được được nối với các khoảng im lặng để tạo ra tệp âm thanh cuối cùng

Fig. 1. Work



Hệ thống tổng

reference file per emotion (e.g., neutral → base_voice.wav, cheerful → cheerful_ref.wav). To maintain consistent speaker identity, latent speaker embeddings are extracted once from a user-provided voice sample and reused across all chunks (Jia et al., 2018; Casanova et al., 2022). The synthesis produces a waveform for each chunk (e.g., cheerful_ref.wav). Để duy trì nhận dạng người nói nhất quán, phần nhúng của người nói tiềm ẩn được trích xuất một lần từ mẫu giọng nói do người dùng cung cấp và sử dụng lại trên tất cả các đoạn (Jia và cộng sự, 2018; Casanova và cộng sự, 2022). Sự tổng hợp tạo ra một dạng sóng cho mỗi



[REDACTED]

[REDACTED]

chunk, as formalized in the following algorithm | chunk, như được chính thức hóa trong thuật toán sau

In the third layer, the generated waveforms are concatenated sequentially with 300 ms of silence inserted to separate emotional turns and avoid abrupt cuts. The final output is saved as a WAV file. This design effectively combines keyword-based emotion classification with conditional TTS and audio post-processing, enabling tag-driven, expressive speech synthesis using a unified voice identity. | Ở lớp thứ ba, các dạng sóng được tạo ra được nối tuần tự với khoảng im lặng 300 mili giây được chèn vào để tách các bước chuyển cảm xúc và tránh bị cắt đột ngột. Đầu ra cuối cùng được lưu dưới dạng tệp WAV. Thiết kế này kết hợp hiệu quả việc phân loại cảm xúc dựa trên từ khóa với TTS có điều kiện và xử lý hậu kỳ âm thanh, cho phép tổng hợp giọng nói biểu cảm, dựa trên thẻ bằng cách sử dụng nhận dạng giọng nói thống nhất.

4 Evaluation Metrics | 4 thước đo đánh giá

To comprehensively assess the text-to-speech and voice cloning system, two complementary deep-learning-based metrics are employed: speaker similarity via Resemblyzer, and perceived speech quality via DNSMOS. | Để đánh giá toàn diện hệ thống sao chép giọng nói và chuyển văn bản thành giọng nói, hai chỉ số dựa trên học sâu bổ sung được sử dụng: độ tương tự của người nói qua Resemblyzer và chất lượng giọng nói được cảm nhận qua DNSMOS.

Resemblyzer is a neural network-based tool for speaker verification and voice similarity measurement (Mishra et al., 2023). At its core, it employs a speaker verification encoder trained with a generalized end-to-end loss (Wan et al., 2018). The operational principle is as follows: first, an input utterance—either the original reference voice or the synthesized cloned voice—is processed by a deep neural network that extracts a fixed-dimensional embedding vector (often referred to as a d-vector or speaker embedding). This vector is designed to capture the unique vocal identity of the speaker, including characteristics such as timbre, pitch contour, and speaking style, while being largely invariant to the linguistic content or the specific words spoken. In other words, regardless of what the person says, the embedding should remain consistent for the same speaker and distinctly different for different speakers (Wan et al., 2018). | Resemblyzer là một công cụ dựa trên mạng thần kinh để xác minh người nói và đo độ giống nhau của giọng nói (Mishra và cộng sự, 2023). Về cốt lõi, nó sử dụng một bộ mã hóa xác minh loa được đào tạo với tổn thất tổng quát từ đầu đến cuối (Wan và cộng sự, 2018). Nguyên tắc hoạt động như sau: đầu tiên, một cách phát âm đầu vào—giọng nói tham chiếu ban đầu hoặc giọng nói nhân bản tổng hợp—được xử lý bởi mạng thần kinh sâu trích xuất vector nhúng có chiều cố định (thường được gọi là vector d hoặc nhúng loa). Vector này được thiết kế để ghi lại đặc điểm nhận dạng giọng nói độc đáo của người nói, bao gồm các đặc điểm như âm sắc, cao độ và phong cách nói, trong khi hầu như không thay đổi đối với nội dung ngôn ngữ hoặc các từ cụ thể được nói. Nói cách khác, bất kể người đó nói gì, việc nhúng phải nhất quán đối với cùng một người nói và khác biệt rõ ràng đối với những người nói khác nhau (Wan và cộng sự, 2018).

Once the embedding vectors are obtained for both the reference audio A (the original speaker's voice) and the synthesized audio B (the cloned voice), their similarity is quantified using the cosine similarity metric: | Sau khi thu được các vector

nhúng cho cả âm thanh tham chiếu A (giọng nói của người nói gốc) và âm thanh tổng hợp B (giọng nói nhân bản), độ tương tự của chúng được định lượng bằng cách sử dụng thước đo độ tương tự cosine:

$$\text{Cosine Similarity } A, B = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}}$$

2 trang

The cosine similarity measures the angle between the two vectors in the high-dimensional embedding space. A value close to 1 indicates that the vectors point in nearly the same direction, meaning the two voices are perceived as highly similar or almost identical in terms of speaker identity (Jia et al., 2018; Wan et al., 2018). Conversely, a value close to 0 or negative would suggest dissimilar speakers. Thus, Resemblyzer provides an objective, automatic, and reproducible metric for evaluating how faithfully a voice cloning system preserves the original speaker's vocal characteristics. | Các biện pháp tương tự cosin góc giữa hai vectơ trong không gian nhúng chiều cao. Giá trị gần bằng 1 cho biết các vectơ hướng gần như cùng một hướng, nghĩa là hai giọng nói được coi là rất giống nhau hoặc gần giống nhau về mặt nhận dạng người nói (Jia và cộng sự, 2018; Wan và cộng sự, 2018). Ngược lại, giá trị gần bằng 0 hoặc âm sẽ gợi ý những người nói khác nhau. Do đó, Resemblyzer cung cấp số liệu khách quan, tự động và có thể tái tạo để đánh giá mức độ trung thực của hệ thống nhân bản giọng nói bảo tồn các đặc điểm giọng hát của người nói ban đầu.

DNSMOS (Deep Noise Suppression Mean Opinion Score) is a non-intrusive, deep learning-based metric designed to estimate the perceptual quality of speech signals without requiring a clean reference audio signal (Reddy et al., 2021). This makes it | DNSMOS (Điểm ý kiến trung bình hạn chế tiếng ồn sâu) là một chỉ số dựa trên công nghệ học sâu, không xâm phạm, được thiết kế để ước tính chất lượng cảm nhận của tín hiệu giọng nói mà không yêu cầu tín hiệu âm thanh tham chiếu rõ ràng (Reddy và cộng sự, 2021). Điều này làm cho nó

5 Experiments and Results | 5 thí nghiệm và kết quả

Training Dataset. The system was trained and evaluated using the viVoice corpus (Le, 2024), the first publicly available large-scale Vietnamese speech dataset designed for multi-speaker text-to-speech. viVoice comprises over 1,000 hours of cleaned audio and accompanying transcriptions sourced from 186 YouTube channels. All audio samples are provided at a 24 kHz sampling rate in WAV format, with background music and noise removed to ensure clean training data. The dataset covers a wide variety of speakers, accents (Northern, Central, Southern), and speaking styles, making it particularly suitable for training robust multi-speaker Vietnamese TTS models such as XTTS-v2. viVoice is released under the CC BY-NC-SA 4.0 license. | Tập dữ liệu huấn luyện. Hệ thống được đào tạo và đánh giá bằng viVoice corpus (Le, 2024), bộ dữ liệu giọng nói tiếng Việt quy mô lớn đầu tiên được công bố rộng rãi, được thiết kế cho chuyển văn bản thành giọng nói của nhiều người nói. viVoice bao gồm hơn 1.000 giờ âm thanh được làm sạch và các bản ghi âm đi kèm có nguồn gốc từ 186 kênh YouTube. Tất cả các mẫu âm thanh đều được cung cấp ở tốc độ lấy mẫu 24 kHz ở định dạng WAV, loại bỏ nhạc nền và tiếng ồn để đảm bảo dữ liệu đào tạo sạch sẽ. Bộ dữ liệu bao gồm nhiều loại người nói, giọng (Bắc, Trung, Nam) và phong cách nói, khiến nó đặc biệt phù hợp để đào tạo các mô hình TTS tiếng Việt nhiều người nói mạnh mẽ như XTTS-v2. viVoice được phát hành theo giấy phép CC BY-NC-SA 4.0.

The preprocessing pipeline was designed to eliminate variability that could degrade speaker similarity. Steps included:(i) manual verification of transcript accuracy to ensure perfect alignment;(ii) text normalization using VietNormalizer(Do, 2026) to expand abbreviations, convert numbers to words, and standardize punctuation;(iii) phonetic alignment with a forced aligner trained on Vietnamese, yielding frame-level phoneme boundaries;(iv) energy-based silence stripping at the beginning and end of utterances to remove leading/trailing silence; and(v) loudness normalization to−23 LUFS to maintain consistent perceived volume across speakers. Crucially, for each speaker a high-quality speaker embedding was extracted using the Resemblyzer encoder and stored as a reference vector. Conditioning the generative model on these embeddings during training encourages the decoder to preserve speaker identity, which directly contributed to the high cosine similarity scores (0.90+) observed in the experiments. | Quy trình tiền xử lý được thiết kế để loại bỏ những biến đổi có thể làm giảm độ tương tự của loa. Các bước bao gồm: (i) xác minh thủ công độ chính xác của bản ghi để đảm bảo căn chỉnh hoàn hảo; (ii) chuẩn hóa văn bản bằng VietNormalizer(Do, 2026) để mở rộng chữ viết tắt, chuyển đổi số thành từ và chuẩn hóa dấu câu; (iii) căn chỉnh ngữ âm bằng căn chỉnh bắt buộc được huấn luyện trên tiếng Việt, tạo ra ranh giới âm vị ở cấp khung; (iv) loại bỏ khoảng lặng dựa trên năng lượng ở đầu và cuối câu để loại bỏ khoảng lặng đầu/cuối; và (v) chuẩn hóa âm lượng thành −23 LUFS để duy trì âm lượng cảm nhận nhất quán trên các loa. Điều quan trọng là đối với mỗi loa, phần nhúng loa chất lượng cao được trích xuất bằng bộ mã hóa Resemblyzer và được lưu trữ dưới dạng vector tham chiếu. Việc điều chỉnh mô hình tổng quát trên các phần nhúng này trong quá trình đào tạo sẽ khuyến khích bộ giải mã bảo toàn danh tính người nói, điều này góp phần trực tiếp vào điểm tương đồng cosine cao (0,90+) được quan sát thấy trong các thử nghiệm.

Experimental Setup. The evaluation was conducted on a GIGABYTE G5 GD laptop, a gaming-oriented notebook whose specifications are listed in Table 1. Notably, the system features a dedicated NVIDIA GeForce RTX GPU(Ampere architecture, discrete) alongside an integrated Intel UHD Graphics

adapter. However, the PyTorch environment used for inference was a CPU-only build, meaning all synthesis operations ran on the Intel Core i5-11400H CPU without GPU acceleration. This configuration reflects a common deployment scenario where CUDA drivers or libraries are not installed, or where the system prioritizes compatibility over maximum speed. | **Thiết lập thử nghiệm.** Quá trình đánh giá được thực hiện trên máy tính xách tay GIGABYTE G5 GD, máy tính xách tay định hướng chơi game có thông số kỹ thuật được liệt kê trong Bảng 1. Đáng chú ý, hệ thống này có GPU NVIDIA GeForce RTX chuyên dụng (kiến trúc Ampere, rời) cùng với bộ điều hợp Đồ họa Intel UHD tích hợp. Tuy nhiên, môi trường PyTorch được sử dụng để suy luận là bản dựng chỉ dành cho CPU, nghĩa là tất cả các hoạt động tổng hợp đều chạy trên CPU Intel Core i5-11400H mà không cần tăng tốc GPU. Cấu hình này phản ánh một kịch bản triển khai phổ biến trong đó trình điều khiển hoặc thư viện CUDA chưa được cài đặt hoặc khi hệ thống ưu tiên khả năng tương thích hơn tốc độ tối đa.

Table 1. System configuration of the test platform. | Bảng 1. Cấu hình hệ thống của nền tảng thử nghiệm.

Component	Specification
Model	GIGABYTE G5 GD
CPU	Intel Core i5-11400H (8 cores, 12 threads, 2.70 GHz base)
RAM	16 GB DDR4 (15.8 GB usable)
GPU	Intel UHD Graphics (integrated)
Discrete GPU	NVIDIA GeForce RTX (Ampere, dedicated)
OS Model	Windows 11 Home Single Language
CPU	GIGABYTE G5 GD
ĐẬP	Intel Core i5-11400H (8 lõi, 12 luồng, tốc độ cơ bản 2,70 GHz)
GPU	16 GB DDR4 (có thể sử dụng 15,8 GB)
Hệ điều hành	Đồ họa Intel UHD (tích hợp)
GPU rời	NVIDIA GeForce RTX (Ampe, chuyên dụng)
	Ngôn ngữ đơn Windows 11 Home

(Build 26200) | (Bản dựng 26200)

Inference BackendPyTorch CPU-only, 4 threads

Voice Similarity and Speech Quality. The system was evaluated by comparing original and synthesized(cloned) speech samples from four speakers. Each sample pair consisted of a reference.wav file and its clone. Two assessment methods were applied: Resemblyzer for voice similarity (Wan et al., 2018; Mishra et al., 2023), and DNSMOS for perceived audio quality(Reddy et al., 2021). Voice similarity results are presented in Table 2. All pairs achieve a cosine similarity of approximately 0.90 (ranging from 0.9013 to 0.9346), confirming that the VITS model, despite running on the CPU, preserves vocal timbre and speaker identity remarkably well(Jia et al., 2018). | Độ tương tự giọng nói và chất lượng giọng nói. Hệ thống được đánh giá bằng cách so sánh các mẫu giọng nói gốc và tổng hợp (nhân bản) từ bốn diễn giả. Mỗi cặp mẫu bao gồm một tệp reference.wav và bản sao của nó. Hai phương pháp đánh giá đã được áp dụng: Resemblyzer về độ giống nhau của giọng nói (Wan và cộng sự, 2018; Mishra và cộng sự, 2023) và DNSMOS cho chất lượng âm thanh cảm nhận được (Reddy và cộng sự, 2021). Kết quả về độ giống nhau của giọng nói được trình bày trong Bảng 2. Tất cả các cặp đều đạt được độ tương tự cosin xấp xỉ 0,90 (dao động từ 0,9013 đến 0,9346), xác nhận rằng mô hình VITS, mặc dù chạy trên CPU, vẫn duy trì âm sắc giọng hát và nhận dạng người nói rất tốt (Jia và cộng sự, 2018).

Voice similarity results for the viXTTS model are presented in Table 2. All pairs achieve a cosine similarity of approximately 0.90(ranging from 0.9013 to 0.9346), confirming that the model preserves vocal timbre and speaker identity remarkably well(Jia et al., 2018). Speaker similarity for other engines was not measured in this evaluation run, as most of them do not natively support voice cloning or require a separate reference embedding extraction step. | Kết quả về độ tương tự giọng nói cho mô hình viXTTS được trình bày trong Bảng 2. Tất cả các cặp đều đạt độ tương tự cosine xấp xỉ 0,90 (trong khoảng từ 0,9013 đến 0,9346), xác nhận rằng mô hình duy trì âm sắc giọng hát và nhận dạng người nói rất tốt (Jia và cộng sự, 2018). Độ tương tự của loa đối với các công cụ khác không được đo lường trong lần đánh giá này vì hầu hết chúng không hỗ trợ nhân bản giọng nói hoặc yêu cầu bước trích xuất nhúng tham chiếu riêng.

Table 2. Voice similarity between original and cloned speech. | Bảng 2. Độ tương tự của giọng nói giữa lời nói gốc và lời nói nhân bản.

Cặp audio	Similarity
giong_goc và giong_clone	0.9038
Danh_1 và Danh_clone	0.9019
Khang1 và Khang_clone	0.9346
Ngoc1 và Ngoc_clone	0.9013
	0,9038
	0,9019
	0,9346
	0,9013

Speech quality results from DNSMOS across all seven evaluated engines are summarized in Table 3. Four metrics were recorded: OVRL(overall quality), SIG (speech quality), BAK (background noise intrusiveness), and the supplementary P808 score (an overall listening quality estimator aligned with ITU-T P.808). Scores are on the standard 1–5 Mean Opinion Score scale, where higher values indicate better perceptual quality. | Kết quả chất lượng giọng nói từ DNSMOS trên tất cả bảy công cụ được đánh giá được tóm tắt trong Bảng 3. Bốn chỉ số đã được ghi lại: OVRL(chất lượng tổng thể), SIG (chất lượng giọng nói), BAK (độ xâm nhập tiếng ồn nền) và điểm P808 bổ sung (công cụ ước tính chất lượng nghe tổng thể phù hợp với ITU-T P.808). Điểm số nằm trên thang Điểm ý kiến trung bình tiêu chuẩn 1–5, trong đó giá trị cao hơn cho thấy chất lượng nhận thức tốt hơn.

Table 3. DNSMOS evaluation of synthesized Vietnamese speech quality.. | Bảng 3. Đánh giá DNSMOS chất lượng giọng nói tiếng Việt tổng hợp..

Model	File audio	OVRL MOS	SIG MOS	BAK MOS	P808 MOS
Proposed viXTTS-based Đề xuất dựa trên viXTTS Voice Cloning System Hệ thống nhân bản giọng nói	giong_clone.wav	3.38 3,38	3.60 3,60	4.14	4.03
Piper Vietnamese TTS Piper Việt TTS	Piper_Vietnamese_TTS Piper_Tiếng Việt_TTS	3.00 3,00	3.40 3,40	3.81 3,81	3.15 3,15
Valtec Vietnamese TTS Valtec Việt TTS v2	Valtec Vietnamese Valtec Tiếng Việt TTS_ver2.wav	3.07	3.34 3,34	4.04	3.95 3,95
VietnameseTTS Tiếng ViệtTTS	VietnameseTTS.wav Tiếng ViệtTTS.wav	2.07	2.75 2,75	2.86 2,86	2.73 2,73
Valtec Vietnamese TTS Valtec Việt TTS	Valtec_Vietnamese.wav Valtec_Tiếng Việt.wav	3.37 3,37 3,37 3,37	3.58 3,58	4.16	4.21
VietTTS	VietTTS.wav	3.05	3.25 3,25	4.15	3.64 3,64
VieNeu-TTS	VietNeu_TTS.wav	3.31 3,31	3.54 3,54	4.16	3.68 3,68

The DNSMOS evaluation results show noticeable differences in synthesized Vietnamese speech quality among the evaluated TTS systems. Overall, the proposed viXTTS-based voice cloning system, represented by `giong_clone.wav`, achieves the highest OVRL MOS score of 3.38 and the highest SIG MOS score of 3.60. These results indicate that the proposed system produces speech with strong overall perceptual quality and clear speech signals. The high BAK MOS score of 4.14 also suggests that the generated audio contains very little background noise. Therefore, the viXTTS-based model demonstrates strong performance in both speech clarity and noise suppression. | Kết quả đánh giá DNSMOS cho thấy sự khác biệt rõ rệt về chất lượng giọng nói tiếng Việt tổng hợp giữa các hệ thống TTS được đánh giá. Nhìn chung, hệ thống nhân bản giọng nói dựa trên viXTTS được đề xuất, do `giong_clone.wav` đại diện, đạt được điểm OVRL MOS cao nhất là 3,38 và điểm SIG MOS cao nhất là 3,60. Những kết quả này chỉ ra rằng hệ thống được đề xuất tạo ra giọng nói có chất lượng cảm nhận tổng thể tốt và tín hiệu giọng nói rõ ràng. Điểm BAK MOS cao là 4,14 cũng cho thấy âm thanh được tạo ra có rất ít tiếng ồn xung quanh. Do đó, mô hình dựa trên viXTTS thể hiện hiệu suất mạnh mẽ cả về độ rõ của giọng nói và khả năng khử tiếng ồn.

Among the compared systems, `Valtec_Vietnamese.wav` also performs competitively, with an OVRL MOS of 3.37 and a SIG MOS of 3.58, which are very close to the proposed system. In addition, this model obtains the highest P808 MOS score of 4.21, suggesting that listeners may perceive its overall audio quality favorably. However, the proposed `giong_clone.wav` still slightly outperforms it in the two main DNSMOS indicators, OVRL and SIG. This suggests that the proposed model has a small but measurable advantage in terms of overall speech quality and signal clarity. | Trong số các hệ thống được so sánh, `Valtec_Tiếng Việt.wav` Mà còn hoạt động mang tính cạnh tranh, với OVRL MOS là 3,37 và SIG MOS là 3,58, rất gần với hệ thống được đề xuất. Ngoài ra, model này đạt điểm P808 MOS cao nhất là 4,21, cho thấy người nghe có thể cảm nhận chất lượng âm thanh tổng thể của nó một cách tích cực. Tuy nhiên, `giong_clone.wav` được đề xuất vẫn vượt trội hơn một chút ở hai chỉ số DNSMOS chính là OVRL và SIG. Điều này cho thấy mô hình đề xuất có một lợi thế nhỏ nhưng có thể đo lường được về chất lượng giọng nói tổng thể và độ rõ của tín hiệu.

The `VietNeu_TTS.wav` model also achieves strong results, with an OVRL MOS of 3.31, SIG MOS of 3.54, BAK MOS of 4.16, and P808 MOS of 3.68. These scores place it in the high-performing group, especially in terms of background noise suppression. Its BAK score is among the highest in the comparison, showing that the generated audio is clean and stable. Although its overall and signal quality scores are slightly lower than those of `giong_clone.wav` and `Valtec_Vietnamese.wav`, it remains a reliable model for Vietnamese speech synthesis. | Mô hình `VietNeu_TTS.wav` cũng đạt được kết quả cao với OVRL MOS là 3,31, SIG MOS là 3,54, BAK MOS là 4,16 và P808 MOS là 3,68. Những điểm số này xếp nó vào nhóm hiệu suất cao, đặc biệt là về khả năng khử tiếng ồn xung quanh. Điểm BAK của nó nằm trong số cao nhất trong so sánh, cho thấy âm thanh được tạo ra sạch và ổn định. Mặc dù điểm tổng thể và chất lượng tín hiệu của nó thấp hơn một chút so với `giong_clone.wav` và `Valtec_English.wav`, nhưng nó vẫn là một mô hình đáng tin cậy để tổng hợp giọng nói tiếng Việt.

The middle-performing group includes `Valtec_Vietnamese_TTS_ver2.wav`, `VietTTS.wav`, and `Piper_Vietnamese_TTS`. These models obtain OVRL MOS scores ranging from 3.00 to 3.07, indicating acceptable but not outstanding synthesized speech quality. Their SIG MOS scores, ranging from 3.25 to 3.40,

suggest that the speech signal is reasonably clear but still less natural or less detailed than the top-performing systems. Notably, VietTTS.wav achieves a high BAK MOS score of 4.15, showing that its audio output is relatively clean. However, its lower OVRL and SIG scores indicate that background cleanliness alone is not sufficient to ensure high overall speech quality. | Nhóm có thành tích trung bình bao gồm Valtec Tiếng Việt TTS_ver2.wav, VietTTS.wav và Piper_Việt_TTS. Những mô hình này đạt được điểm OVRL MOS trong khoảng từ 3,00 đến 3,07, cho thấy chất lượng giọng nói tổng hợp ở mức chấp nhận được nhưng không vượt trội. Điểm SIG MOS của họ, dao động từ 3,25 đến 3,40, cho thấy tín hiệu giọng nói khá rõ ràng nhưng vẫn kém tự nhiên hoặc kém chi tiết hơn so với các hệ thống hoạt động tốt nhất. Đáng chú ý, VietTTS.wav đạt điểm BAK MOS cao 4,15, cho thấy âm thanh phát ra tương đối sạch. Tuy nhiên, điểm OVRL và SIG thấp hơn cho thấy rằng chỉ độ sạch nền là không đủ để đảm bảo chất lượng giọng nói tổng thể cao.

The lowest-performing system is VietnameseTTS.wav, which obtains an OVRL MOS of 2.07, SIG MOS of 2.75, BAK MOS of 2.86, and P808 MOS of 2.73. These scores are substantially lower than those of the other models. In particular, the low OVRL and SIG scores suggest that the synthesized speech may contain noticeable artifacts, reduced naturalness, or unclear pronunciation. The low BAK score also indicates that the audio may include more background interference or noise compared with the other systems. | Hệ thống có hiệu suất thấp nhất là VietnameseTTS.wav, có OVRL MOS là 2,07, SIG MOS là 2,75, BAK MOS là 2,86 và P808 MOS là 2,73. Những điểm số này thấp hơn đáng kể so với các mô hình khác. Đặc biệt, điểm OVRL và SIG thấp cho thấy giọng nói tổng hợp có thể chứa các thành phần giả đáng chú ý, độ tự nhiên giảm hoặc cách phát âm không rõ ràng. Điểm BAK thấp cũng cho thấy âm thanh có thể có nhiều nhiễu hoặc nhiễu nền hơn so với các hệ thống khác.

A general trend can be observed across the stronger models: most systems achieve high BAK MOS scores above 4.0, which means that modern Vietnamese TTS models are generally effective at producing clean audio with limited background noise. However, differences in OVRL and SIG scores show that clean audio does not always | Có thể nhận thấy xu hướng chung trên các mẫu máy mạnh hơn: hầu hết các hệ thống đều đạt điểm BAK MOS cao trên 4.0, điều đó có nghĩa là các mẫu TTS hiện đại của Việt Nam nhìn chung có hiệu quả trong việc tạo ra âm thanh trong trẻo với tiếng ồn xung quanh hạn chế. Tuy nhiên, sự khác biệt về điểm OVRL và SIG cho thấy âm thanh sạch không phải lúc nào cũng

guarantee natural and intelligible speech. Speech naturalness, clarity, and signal quality remain important factors in distinguishing the best-performing models. | đảm bảo lời nói tự nhiên và dễ hiểu. Độ tự nhiên, rõ ràng và chất lượng tín hiệu của giọng nói vẫn là những yếu tố quan trọng để phân biệt các mô hình hoạt động tốt nhất.

In summary, the proposed viXTTS-based voice cloning model `giong_clone.wav` achieves the best overall performance in terms of OVRL and SIG MOS, making it the strongest system in this comparison. `Valtec_Vietnamese.wav` and `VietNeu_TTS.wav` also demonstrate competitive performance and can be considered strong alternatives. Meanwhile, `VietnameseTTS.wav` shows the weakest results and may require further optimization to improve speech naturalness, clarity, and background noise control. | Tóm lại, mô hình nhân bản giọng nói dựa trên viXTTS `giong_clone.wav` được đề xuất đạt được hiệu suất tổng thể tốt nhất về OVRL và SIG MOS, khiến nó trở thành hệ thống mạnh nhất trong cuộc so sánh này. `Valtec_vietnamese.wav` và `VietNeu_TTS.wav` cũng thể hiện hiệu suất cạnh tranh và có thể được coi là những lựa chọn thay thế mạnh mẽ. Trong khi đó, `VietnameseTTS.wav` cho kết quả yếu nhất và có thể cần tối ưu hóa hơn nữa để cải thiện độ tự nhiên của giọng nói, độ rõ và kiểm soát tiếng ồn xung quanh.

Real-Time Performance and Latency Analysis: The most critical performance metric of the current prototype is the end-to-end synthesis latency. For a typical input text of 750 characters (equivalent to approximately 50 seconds of generated audio at a standard Vietnamese speaking rate of about 900 characters per minute), the system requires roughly 2 minutes and 50 seconds (170 seconds) to produce the final WAV file. This yields a Real-Time Factor (RTF) of approximately 3.4, well above the real-time threshold of 1.0. The latency is not fixed, however; it varies measurably depending on the linguistic complexity of the input text. Two factors dominate the additional processing overhead:

❑ Emotion tags. Each emotional boundary forces a new synthesis chunk with a separate viXTTS inference call, leading to multiple context switch and model loading overheads. More tags increase the number of chunks and the cumulative pause insertion time. | Phân tích độ trễ và hiệu suất theo thời gian thực: Chỉ số hiệu suất quan trọng nhất của nguyên mẫu hiện tại là độ trễ tổng hợp từ đầu đến cuối. Đối với một văn bản đầu vào thông thường gồm 750 ký tự (tương đương với khoảng 50 giây âm thanh được tạo ra với tốc độ nói tiếng Việt tiêu chuẩn khoảng 900 ký tự mỗi phút), hệ thống cần khoảng 2 phút 50 giây (170 giây) để tạo ra tệp WAV cuối cùng. Điều này mang lại Hệ số thời gian thực (RTF) xấp xỉ 3,4, cao hơn nhiều so với ngưỡng thời gian thực là 1,0. Tuy nhiên, độ trễ không cố định; nó thay đổi có thể đo lường được tùy thuộc vào độ phức tạp ngôn ngữ của văn bản đầu vào. Hai yếu tố chi phối chi phí xử lý bổ sung:

❑ Thẻ cảm xúc. Mỗi ranh giới cảm xúc buộc phải có một đoạn tổng hợp mới với lệnh gọi suy luận viXTTS riêng biệt, dẫn đến chuyển đổi nhiều ngữ cảnh và chi phí tải mô hình. Nhiều thẻ hơn sẽ tăng số lượng khối và thời gian chèn tạm dừng tích lũy.

❑ English words and non Vietnamese segments. These require extra grapheme to phoneme steps within the text normalization layer (Do, 2026), and may introduce attention errors that force the decoder to retry alignment, adding to the total runtime. | Từ tiếng Anh và các đoạn không phải tiếng Việt. Những điều này yêu cầu các bước biểu đồ bổ sung cho âm vị trong lớp chuẩn hóa văn bản (Do, 2026) và có thể gây ra lỗi chú ý buộc bộ giải mã phải thử căn chỉnh lại, làm tăng thêm tổng thời gian chạy.

The observed latency stems from running the full VITS pipeline on the CPU without utilizing the available RTX GPU. The CPU-only PyTorch build cannot exploit the massive parallelism of the GPU's tensor cores, leaving matrix multiplications and convolutions to be computed sequentially. Despite this, the system remains acceptable for near-line content creation tasks such as podcast dubbing, educational narration, or voicemail generation—applications where a few minutes of rendering time are tolerated in exchange for high-quality, emotionally expressive output. | Độ trễ quan sát được bắt nguồn từ việc chạy toàn bộ quy trình VITS trên CPU mà không sử dụng GPU RTX có sẵn. Bản dựng PyTorch chỉ dành cho CPU không thể khai thác tính song song lớn của các lõi tensor của GPU, khiến các phép nhân và tích chập ma trận phải được tính toán tuần tự. Mặc dù vậy, hệ thống vẫn có thể chấp nhận được đối với các tác vụ tạo nội dung gần như lồng tiếng podcast, tường thuật mang tính giáo dục hoặc tạo thư thoại—các ứng dụng trong đó cho phép một vài phút thời gian kết xuất để đổi lấy đầu ra có chất lượng cao, biểu đạt cảm xúc.

Critically, the machine is equipped with an NVIDIA GeForce RTX GPU, which is fully capable of accelerating the inference. Moving to a CUDA-enabled PyTorch installation would reduce the RTF to well below 0.1 (based on typical GPU benchmarks for VITS), enabling real-time streaming synthesis. In addition, model quantization to FP16 or INT8, and switching to optimized inference engines like ONNX Runtime with OpenVINO, could further halve latency while preserving the high similarity and MOS scores. | Điều quan trọng là máy được trang bị GPU NVIDIA GeForce RTX, hoàn toàn có khả năng tăng tốc suy luận. Việc chuyển sang cài đặt PyTorch hỗ trợ CUDA sẽ giảm RTF xuống dưới 0,1 (dựa trên GPU thông thường điểm chuẩn cho VITS), cho phép tổng hợp phát trực tuyến theo thời gian thực. Ngoài ra, lượng tử hóa mô hình thành FP16 hoặc INT8 và chuyển sang các công cụ suy luận được tối ưu hóa như ONNX Runtime với OpenVINO, có thể giảm một nửa độ trễ trong khi vẫn duy trì độ tương tự cao và điểm MOS.

6 Conclusion | 6 Kết luận

In this research, a Vietnamese text-to-speech system based on artificial intelligence and deep learning was thoroughly designed, implemented, and evaluated.

The system | Trong nghiên cứu này, hệ thống chuyển văn bản sang giọng nói tiếng Việt dựa trên trí tuệ nhân tạo và deep learning đã được thiết kế, triển khai và đánh giá kỹ lưỡng, hệ thống

exploits modern models such as Tacotron, FastSpeech, and VITS to automatically convert text into natural speech signals, learning the unique phonetic and prosodic features of Vietnamese. Experimental outcomes show that the proposed model generates clear, natural speech with appropriate intonation and maintains stable performance across various conditions and contexts. | khai thác các mô hình hiện đại như Tacotron, FastSpeech, VITS để tự động chuyển đổi văn bản thành tín hiệu giọng nói tự nhiên, học các đặc điểm ngữ âm và ngữ điệu độc đáo của tiếng Việt. Kết quả thử nghiệm cho thấy mô hình đề xuất tạo ra lời nói rõ ràng, tự nhiên với ngữ điệu phù hợp và duy trì hiệu suất ổn định trong nhiều điều kiện và bối cảnh khác nhau.

The achieved results not only validate the effectiveness of deep learning in Vietnamese speech synthesis but also highlight the system's broad applicability in practice, notably in virtual assistants, education, automatic call centers, and assistive tools for the visually impaired. Future work may focus on expanding and enriching the speech dataset, improving regional naturalness, optimizing models for resource-constrained devices, and integrating the system into real-world platforms to enhance feasibility and usability. | Kết quả đạt được không chỉ khẳng định tính hiệu quả của deep learning trong tổng hợp giọng nói tiếng Việt mà còn nêu bật khả năng ứng dụng rộng rãi của hệ thống trong thực tế, nổi bật là trợ lý ảo, giáo dục, tổng đài tự động và các công cụ hỗ trợ người khiếm thị. Công việc trong tương lai có thể tập trung vào việc mở rộng và làm phong phú thêm tập dữ liệu giọng nói, cải thiện khu vực sự tự nhiên, tối ưu hóa mô hình dành cho các thiết bị có hạn chế về tài nguyên và tích hợp hệ thống vào các nền tảng trong thế giới thực để nâng cao tính khả thi và khả năng sử dụng.

References | Tài liệu tham khảo

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. M., & Weber, G. (2020). Common Voice: A massively-multilingual speech corpus. arXiv. <https://arxiv.org/abs/1912.06670>
2. Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, E., & Ponti, M. A. (2022). YourTTS: Towards zero-shot multi-speaker TTS and zero-shot voice conversion for everyone. arXiv. <https://arxiv.org/abs/2112.02418> | YourTTS: Hướng tới TTS nhiều loa không tiếng vang và chuyển đổi giọng nói không tiếng động cho mọi người. arXiv. [GIỮ_0__](https://arxiv.org/abs/2112.02418)
4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Pratap, V., Conneau, A., Collobert, R., Synnaeve, G., & Auli, M. (2022). WavLM: Large-scale self-supervised pre-training for full stack speech processing. arXiv. <https://arxiv.org/abs/2110.13900>
5. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. arXiv. <https://arxiv.org/abs/1810.04805>
6. Do, N. (2026). VietNormalizer: An open-source, dependency-free Python library for Vietnamese text normalization in TTS and NLP applications. arXiv. <https://arxiv.org/abs/2603.04145>
7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative adversarial networks. arXiv.

<https://arxiv.org/abs/1406.2661>

8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhota, K., Salakhutdinov, R., & Mohamed, A.

(2021). HuBERT: Self-supervised speech representation learning by masked prediction of hidden units. arXiv. <https://arxiv.org/abs/2104.05136> | (2021). HuBERT: Học cách biểu diễn giọng nói tự giám sát bằng dự đoán ẩn của các đơn vị ẩn arXiv. __ GIỮ_0__

9. Ito, K., & Johnson, L. (2017). The LJ Speech Dataset. <https://keithito.com/LJ-Speech-Dataset/>

10. Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, X., Chen, Z., Nguyen, P., Pang, R.,

Moreno, I. L., & Wu, Y. (2018). Transfer learning from speaker verification to multispeaker text-to-speech synthesis. Advances in Neural Information Processing Systems, 31.

<https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Efficient neural audio synthesis. arXiv. <https://arxiv.org/abs/1802.08435>
12. Kameoka, H., Kaneko, T., Tanaka, K., & Hojo, N. (2018). StarGAN-VC: Non-parallel many-to-many voice conversion using star generative adversarial networks. arXiv. <https://arxiv.org/abs/1806.02169>
13. Kim, J., Kong, J., & Son, J. (2021). Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech. arXiv. <https://arxiv.org/abs/2106.06103>
14. Kingma, D. P., & Welling, M. (2014). Auto-encoding variational bayes. arXiv. <https://arxiv.org/abs/1312.6114>
15. Kong, J., Kim, J., & Bae, J. (2020). HiFi-GAN: Generative adversarial networks for efficient and high fidelity speech synthesis. arXiv. <https://arxiv.org/abs/2010.05646>
16. Mishra, P., Choudhury, J. A., Kho, E., Basu, B., & Nandi, A. (2023). Speaker identification, differentiation and verification using deep learning for human machine interface. In 2023 Photonics & Electromagnetics Research Symposium (PIERS) (pp. 861–870). IEEE. <https://ieeexplore.ieee.org/document/10221344>
17. Nguyen, D. Q., & Tuan, N. D. (2020). PhoBERT: Pre-trained language models for Vietnamese. arXiv. <https://arxiv.org/abs/2003.00744>
18. Nguyen, N. (2023). VietTTS: Vietnamese text to speech library. GitHub. <https://github.com/NTT123/vietTTS>
19. Oord, A. van den, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). WaveNet: A generative model for raw audio. arXiv. <https://arxiv.org/abs/1609.03499>
20. Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Raiman, J., Miller, J., & Sengupta, S. (2017). Deep Voice 3: Scaling text-to-speech with convolutional sequence learning. arXiv. <https://arxiv.org/abs/1710.07654>
21. Prenger, R., Valle, R., & Catanzaro, B. (2019). WaveGlow: A flow-based generative network for speech synthesis. arXiv. <https://arxiv.org/abs/1811.00002>
22. Qian, K., Zhang, Y., Chang, S., Yang, X., & Hasegawa-Johnson, M. (2019). AutoVC: Zero-shot voice style transfer with only autoencoder loss. arXiv. <https://arxiv.org/abs/1905.05879>
23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022). Robust speech recognition via large-scale weak supervision. arXiv. | Nhận dạng giọng nói mạnh mẽ thông qua giám sát yếu trên quy mô lớn. arXiv. <https://arxiv.org/abs/2212.04356>
24. Reddy, C. K., Gopal, V., & Cutler, R. (2021). DNSMOS: A non-intrusive perceptual objective speech quality metric to evaluate noise suppressors. In ICASSP 2021–2021 IEEE International Conference on Acoustics, Speech and Signal Processing (pp. 6493–6497). IEEE. <https://arxiv.org/abs/2010.15258> | IEEE. __ GIỮ_0__
25. Ren, Y., Ruan, Y., Chen, X., Qin, T., Zhao, S., & Liu, T. (2019). FastSpeech: Fast, robust and controllable text to speech. arXiv. <https://arxiv.org/abs/1905.09263>
26. Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T. (2020). FastSpeech 2: Fast and high-quality end-to-end text to speech. arXiv. <https://arxiv.org/abs/2006.04558>
27. Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyriannakis, Y., & Wu, Y. (2018). Natural TTS synthesis by conditioning WaveNet on mel spectrogram predictions. arXiv. | Tổng hợp TTS tự nhiên bằng cách điều chỉnh WaveNet trên các dự đoán phổ mel. arXiv. <https://arxiv.org/abs/1712.05884>
28. Thinh, L. (2024). viXTTS: A Vietnamese voice cloning text-to-speech model. GitHub. <https://github.com/thinhlpg/vixtts-demo>

29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. arXiv. <https://arxiv.org/abs/1706.03762> | Polosukhin, I. (2017). Sự chú ý là tất cả những gì bạn cần. arXiv. __ GIỮ_0__
30. Vu, T., Nguyen, L. T., & Nguyen, D. Q. (2025). Zero-shot text-to-speech for Vietnamese. arXiv. <https://arxiv.org/abs/2506.01322> | arXiv. __ GIỮ_0__
31. Wan, L., Wang, Q., Papir, A., & Moreno, I. L. (2018). Generalized end-to-end loss for speaker verification. In 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) (pp. 4879–4883). IEEE. | Xử lý tín hiệu (ICASSP) (trang 4879–4883). IEEE. <https://ieeexplore.ieee.org/abstract/document/8462665>
32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Ajiomyrgiannakis, Y., Clark, R., & Saurous, R. A. | Y., Chen, Z., Bengio, S., Le, Q., Ajiomyrgiannakis, Y., Clark, R., & Saurous, R. A. (2017). Tacotron: Towards end-to-end speech synthesis. arXiv. | (2017). Tacotron: Hướng tới tổng hợp giọng nói từ đầu đến cuối. arXiv. <https://arxiv.org/abs/1703.10132>
33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R. J., Battenberg, E., Shor, J., Xiao, Y., Jia, Y., Ren, F., & Saurous, R. A. (2018). Style tokens: Unsupervised style modeling. | Jia, Y., Ren, F., & Saurous, R. A. (2018). Mã thông báo kiểu: Lập mô hình kiểu không giám sát, control and transfer in end-to-end speech synthesis. arXiv. | điều khiển và chuyển giao trong quá trình tổng hợp tiếng nói từ đầu đến cuối. arXiv. <https://arxiv.org/abs/1803.09017>
34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: English multi-speaker corpus for CSTR voice cloning toolkit (Version 0.92). University of Edinburgh. | ngữ liệu loa cho bộ công cụ nhân bản giọng nói CSTR (Phiên bản 0.92). Đại học Edinburgh. <https://datashare.ed.ac.uk/handle/10283/3443>
35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R. J., Jia, Y., Chen, Z., & Wu, Y. (2019). LibriTTS: A corpus derived from LibriSpeech for text-to-speech. arXiv. | LibriTTS: Một kho văn bản có nguồn gốc từ LibriSpeech để chuyển văn bản thành giọng nói. arXiv. <https://arxiv.org/abs/1904.02882>
36. Le, T. (2024). viVoice: A large-scale multi-speaker Vietnamese speech dataset for text-to-speech. Hugging Face. <https://huggingface.co/datasets/capleaf/viVoice> | bài phát biểu. Ôm Mặt. __ GIỮ_0__