

Hệ thống chuyển văn bản thành giọng nói tự động cho người Việt sử dụng Trí tuệ nhân tạo

Thành-Danh võ1, Ngô-Hồ Anh-Khoa1and Ngô-Hồ Anh-Khoi1*

¹FACULTY OF INFORMATION TECHNOLOGY, Đại học Nam Cần Thơ, 168 Nguyễn Văn Cừ, An
Phường Bình, Thành phố Cần Thơ, Vietnam

GIỮ_0
nhakhoi@nctu.edu.vn

Trừu tượng. Trong bối cảnh chuyển đổi kỹ thuật số và sự tiến bộ nhanh chóng của trí tuệ nhân tạo, nhu cầu về hệ thống chuyển văn bản thành giọng nói (TTS) ngày càng trở nên quan trọng trên nhiều lĩnh vực như trợ lý ảo, giáo dục, trung tâm cuộc gọi tự động và các công cụ hỗ trợ tiếp cận một cách trực quan bị suy yếu. Tuy nhiên, tạo ra sự tự nhiên, nhận biết theo ngữ cảnh và một cách có nhịp điệu

phù hợp lời nói vẫn là một ý nghĩa quan trọng thử thách, cụ thể vì

Tiếng Việt—ngôn ngữ không đồng nhất với cao độ phức tạp và khu vực sự đa dạng. Nghiên cứu này đề xuất và phát triển hệ thống TTS của Việt Nam được xây dựng dựa trên các mô hình deep learning hiện đại khác phục được hạn chế phần mềm truyền thống phương pháp. các hệ thống đơn giản những kiến trúc tiên tiến bao gồm

Tacotron, FastSpeech và VITS, kết hợp với kỹ thuật học máy để nâng cao chất lượng tổng hợp. Xây dựng và đánh giá được thực hiện Bộ dữ liệu tiếng Việt đa dạng, đảm bảo khả năng thích ứng với nhiều thể giới thực bối cảnh. Kết quả chứng minh rằng hệ thống đạt được sự tự nhiên, rõ ràng, cao đầu ra lời nói linh hoạt với tiềm năng rộng rãi để triển khai trong nền tảng kỹ thuật số và các dịch vụ thông minh.

Từ khóa: Chuyển văn bản thành giọng nói (TTS), Trí tuệ nhân tạo (AI), Học sâu, Xử lý ngôn ngữ tự nhiên (NLP), Tổng hợp giọng nói.

1 Giới thiệu

Được thúc đẩy bởi sự chuyển đổi kỹ thuật số và sự tiến bộ của trí tuệ nhân tạo, nhu cầu hệ thống xây dựng văn bản thành giọng nói (TTS) ngày càng trở nên quan trọng hơn trong các lĩnh vực như trợ lý ảo, giáo dục, trung tâm cuộc gọi tự động và hỗ trợ trực quan bị suy yếu. Tuy nhiên, vấn đề TT không chỉ đơn giản là chuyển đổi văn bản thành âm thanh; nó đòi hỏi giọng nói tổng hợp phải tự nhiên, mang ngữ điệu phù hợp, và phù hợp với bối cảnh nhất định—một nhiệm vụ đặc biệt khó khăn đối với tiếng Việt, một ngôn ngữ có một hệ thống âm sắc phức tạp và sự khác biệt đáng kể theo vùng (Do, 2026).

Các phương pháp TTS dựa trên kết nối và định dạng truyền thống (Zenetal., 2019) và Triển lãm dựa trên tổng hợp Hidden Markov Model (HMM) (Zenetal., 2019) tính không linh hoạt, tính tự nhiên và khả năng mở rộng. Phản hồi, mô hình deep learning hiện đại chẳng hạn như Tacotron (Wang và cộng sự, 2017), Tacotron 2 (Shen và cộng sự, 2018), FastSpeech (Ren

2 F. Tác giả và S. Tác giả

etal.,2019,2020), và VITS(Kimetal.,2021) đã mở ra những con đường hiệu quả hơn bằng cách học trực tiếp từ dữ liệu. Dựa trên những tiến bộ, nghiên cứu này tập trung vào nghiên cứu và phát triển hệ thống TTS của Việt Nam nhằm mục đích cải thiện chất lượng giọng nói và khả năng ứng dụng thực tế.

2 công việc liên quan

Thị trường TTS Việt Nam có một số nền tảng nội địa nổi bật cùng với các giải pháp quốc tế. FPT Smart Cloud Text-to-Speech, do Tập đoàn FPT phát triển, cung cấp dịch vụ TTS tiếng Việt chất lượng cao thông qua API thương mại (Vu et al., 2025; Nguyen, 2023). Ứng dụng các kiến trúc deep learning như Tacotron (Wang et al., 2017) và Transformer variants (Vaswani et al., 2017) cùng với các nhà phát âm như WaveNet (Oord và cộng sự, 2016) và HiFi-GAN (Kong và cộng sự, 2020) để tạo ra giọng nói tự nhiên, đa dạng theo khu vực với tốc độ, cao độ và tạm dừng có thể kiểm soát được. Hệ thống được sử dụng rộng rãi trong phản hồi giọng nói tương tác (IVR), sách nói, trợ lý ảo và giáo dục trực tuyến (Do, 2026). TTS AI Text-to-Speech offer giải pháp dựa trên SaaS được tối ưu hóa cho người Việt (Vu et al., 2025; Nguyen, 2023), sử dụng các mô hình thần kinh nâng cao được đào tạo trên quy mô lớn, giọng nói cụ thể của tiếng Việt, đảm bảo phát âm chính xác, ngắt quãng tự nhiên và đầu ra biểu cảm (Do, 2026; Oord et al., 2016; Kong et al., 2020). Zalo AI Text to Speech, sản phẩm của Tập đoàn VNG, tích hợp các mô hình NLP sâu như PhoBERT (Nguyen & Tuan, 2020) và đào tạo trước phong cách BERT (Devlin et al., 2019) với các kiến trúc tổng hợp bao gồm Tacotron, FastSpeech và VITS (Wang et al., 2017; Ren et al., 2019; Kim et al., 2021), tận dụng dữ liệu người dùng khổng lồ để hỗ trợ đa phong cách nói (Vu et al., 2025). Voice.vn chuyên tổng hợp giọng nói và nhân bản giọng nói (Vu et al., 2025) sử dụng các mô hình đầu cuối như VITS (Kim et al., 2021) và kỹ thuật chuyển đổi giọng nói (Casanova et al., 2022; Chen et al., 2022), cho phép nhân bản và tùy chỉnh giọng nói có độ trung thực cao để quảng cáo, podcast và chơi game. Google AI Studio cung cấp môi trường dựa trên đám mây cho TTS thông qua Gemini family và Google Cloud Text-to-Speech (Vaswani et al., 2017; Ren et al., 2019), bao gồm tính năng tạo giọng nói đa ngôn ngữ, tự nhiên và thích ứng với ngữ cảnh (Casanova et al., 2022; Shen et al., 2018). Event Lab offers TTS và các công cụ nhân bản giọng nói được xây dựng từ đầu đến cuối TTS (Wang et al., 2017) và các mô hình nhúng loa (Chen et al., 2022; Kim et al., 2021; Casanova et al., 2022). Nhìn chung, thị trường đang chuyển từ đơn giản đọc văn bản hệ thống theo hướng thông minh nền tảng truyền thông, với xu hướng mạnh mẽ về nhân bản giọng nói (Jia và cộng sự, 2018) và AI đa phương thức.

Cộng đồng nguồn mở đã đóng góp một loạt các mô hình TTS của Việt Nam. VietTTS là hệ thống đại diện được xây dựng với bộ mã hóa-giải mã hoặc Kiến trúc biến áp (Wang et al., 2017; Vaswani et al., 2017; Ren et al., 2019), được đào tạo về dữ liệu tiếng Việt được chuẩn hóa cẩn thận (Do, 2026) để xử lý âm, từ ghép và cấu trúc câu, cung cấp độ trễ gần thời gian thực phù hợp cho trợ lý ảo, học tập điện tử và sản xuất sách nói (Nguyen, 2023; Vu et al., 2025). NeuTTS-Air tập trung vào suy luận nhẹ, hiệu quả, cân bằng chất lượng giọng nói và tốc độ vận hành trên CPU hoặc thiết bị có nguồn tài nguyên thấp (Ren et al., 2019, 2020; Kim et al., 2021),

được tối ưu hóa cho các ứng dụng chatbot, IVR và IoT (Pingetal.,2017;Kalchbrenneret al.,2018).Kani-TTSlà một mô hình quy mô lớn với khoảng 370 triệu thông số, hướng tới tính biểu cảm cao và chất lượng âm thanh chuyên nghiệp (Kim và cộng sự, 2021;Casanovaetal.,2022), xuất sắc trong sách nói và sản xuất phương tiện truyền thôngnhưng yêu cầu triển khai GPU mạnh mẽ(Renetal.,2019;Pingetal.,2017; Kalchbrenner và cộng sự, 2018). VieNeu-TTS kết hợp TTS với nhân bản giọng nói, trích xuất các đặc tính của loa thông qua các kỹ thuật như AutoVC(Qianetal.,2019) và StarGAN-VC(Kameokaetal.,2018)và áp dụng chúng để tổng hợp giọng nói có kích thước (Casanovaetal.,2022;Jiaetal.,2018), cho phép cá nhân hóa mạnh mẽnhưng cũng nâng cao các mối quan ngại về đạo đức và an ninh.ViXTTS phục vụ như một dự án trình diễn nhân bản giọng nói, minh họa công nghệ cho thử nghiệm nhanh (Thịnh, 2024; Kimetal., 2021).Valtec-TTSisacompactmô hình được tối ưu hóa cho các môi trường cực kỳ hạn chế về tài nguyên nhưcác thiết bị nhúng vàIoT(Renetal., 2019,2020;Pingetal.,2017;Kalchbrenneretal.,2018), cung cấp sự rõ ràng đầy đủ cho các ứng dụng hướng dẫn và thông báo đơn giản. Nói chung, các mô hình này minh họa sự trưởng thành của TTS Việt Nam, với các nhánh chuyên biệt, từ tổng hợp chất lượng cao đến triển khai nhẹ nhàng và cá nhân hóa giọng nói.

Chất lượng dữ liệu là nền tảng cho TTS.VLSPSpeechCorpus là một tập dữ liệu lớn, có định hướng học thuật với bản ghi đa người nói trong các điều kiện được kiểm soát (Ardilaetal.,2020;Vuetal.,2025), được chú thích phong phú với ngữ âm và thông tin khu vực (Yamagishietal.,2019;Do,2026).VIVOS là một kho ngữ liệu nguồn mở nhỏ hơn (khoảng 10–20 giờ) bài phát biểu rõ ràng (Ardila và cộng sự, 2020; Ito & Johnson, 2017), được sử dụng rộng rãi cho mô hình hóa ban đầu mặc dù cảm xúc và sự đa dạng của thể giới thực bị hạn chế (Do, 2026). Các bộ dữ liệu thương mại từ Tập đoàn FPT, Tập đoàn Viễn thông và Tập đoàn VNG lớn hơn và chi tiết hơn nhiều. Bộ dữ liệu của FPT bao gồm hàng trăm đến hàng nghìn giờ ghi âm chất lượng phòng thu với các chú thích đầy đủ (Vu và cộng sự, 2025; Đỗ, 2026; Oord và cộng sự, 2016; Kong và cộng sự, 2020). Dữ liệu của Viettel kết hợp các bản ghi âm trong phòng thu và trong thể giới thực bao gồm các giọng điệu đa dạng (Vu và cộng sự, 2025; Yamagishi và cộng sự, 2019;Jiaetal.,2018;Do,2026).Dữ liệu của Zalo mang lại lợi ích từ hệ thống người dùng rộng rãi, kết hợp việc sử dụng ngôn ngữ đương đại &(Vuetal.,2025;Nguyen&Tuan,2020; Devlinetal.,2019;Kimetal.,2021).Ngoài ra, VietTTSung cấp cơ sở dữ liệu mở với cặp văn bản–âm thanh đủ cho các thử nghiệm quy mô nhỏ (Nguyen,2023; &Ito&Johnson,2017;Vuetal.,2025). Nhìn chung, quy mô tập dữ liệu, tính đa dạng, độ sâu chú thích và tính hiện thực trực tiếp xác định hiệu suất TTS.

3 Thiết kế hệ thống


Các hệ thống TTS ban đầu dựa trên các phương pháp dựa trên kết nối và biểu mẫu, lắp ráp các mô hình toán học theo mô hình ngôn ngữ nhưng có tính không linh hoạt, chi phí cơ sở dữ liệu cao và tiến trình không tự nhiên (Zenetal.,2019). học tập mang lại các mô hình từ đầu đến cuối như Tacotron và Tacotron2, sử dụng bộ mã hóa-giải mã

kiến trúc	với	chú ý	ĐẾN	trực tiếp
bản đồ	chữ	ĐẾN		

mel-Spectrogram, tiếp theo là các bộ phát âm như WaveNet(Oordetal.,2016) hoặc WaveGlow(Prengeretal.,2019) để tạo ra dạng sóng(Wangetal.,2017;Shenet al.,2018;Vaswanietal.,2017).Các mô hình nàytự độnghọcngữ âm và các tính năng phát âm, mang lại lời nói tự nhiên hơn đáng kể, nhưng có những hạn chế về tốc độ suy luận và lỗi chú ý. Lời nói nhanh và Lời nói nhanh2 đã giải quyết những vấn đề này bằng cách loại bỏ sự chú ý trong quá trình suy luận và sử dụng thời lượng, cao độ và các yếu tố dự đoán năng lượng, đạt được tốc độ tổng hợp nhanh hơn và ổn định hơn với sự kiểm soát diễn đạt rõ ràng (Renetal.,2019,2020;Vaswanietal.,2017).Thelatestleap,VITS,tích hợp một bộ mã &hóa tự động biến thiên(Kingma&Welling,2014)với mạng đối thủ tổng hợp(Goodfellowetal.,2014) để trực tiếp tạo ra các dạng sóng từ khung văn bản từ đầu đến cuối, loại bỏ bộ mã hóa paratevocoder và tăng cường hơn nữa chất lượng và hiệu quả(Kimetal.,2021;Casanovaetal.,2022).Nhân bản giọng nói và tổng hợp nhiều loa cũng đã được nâng cao, sử dụng tính năng nhúng loa và mã thông báo kiểu để kích hoạt cá nhân hóa và thích ứng không bản (Jiaetal.,2018;Casanova etal.,2022;Chenetal.,2022;Wangetal.,2018).Ngoài ra, chuyển giao và các phương pháp học tập tự giám sát(Baevskietal.,2020;Hsuetal.,2021;Radfordet al.,2022) giảm thiểu sự khan hiếm dữ liệu cho người Việt Nam bằng cách đào tạo trước trên các tập đoàn đa ngôn ngữ lớn. Quy trình TTS hiện đại thường bao gồm thu thập và xử lý trước dữ liệu, chuẩn hóa văn bản (Do, 2026), đào tạo mô hình và tạo dạng sóng (Wang và cộng sự, 2017; Kim và cộng sự, 2021).

Hệ thống được đề xuất triển khai quy trình TTS cảm xúc: văn bản đầu vào chứa các thẻ cảm xúc được phân đoạn theo cảm xúc, mỗi phân đoạn được tổng hợp thông quaaviXTTS và các dạng sóng thu được được nối với các khoảng im lặng để tạo ra tệp âm thanh cuối cùng

Tiêu đề đóng góp (rút ngắn nếu dài quá) 5



6 F. Tác giả và S. Tác giả

chunk, như được chính thức hóa trong thuật toán sau

Ở lớp thứ ba, các dạng sóng được tạo ra được nối tuần tự với 300 mili giây im lặng được chèn vào để phân tách các chuyển biến cảm xúc và tránh bị cắt đột ngột. Đầu ra cuối cùng được lưu trữ dưới dạng tệp WAV. Thiết kế này kết hợp hiệu quả phân loại cảm xúc dựa trên từ khóa với quá trình xử lý hậu kỳ TTS và âm thanh có điều kiện, cho phép tổng hợp giọng nói biểu cảm, dựa trên thẻ bằng cách sử dụng nhận dạng giọng nói thống nhất.

4 thước đo đánh giá

Để đánh giá toàn diện hệ thống sao chép văn bản sang giọng nói và giọng nói, hai chỉ số dựa trên học sâu bổ sung được sử dụng: độ tương tự của loa qua Resemblyzer và chất lượng giọng nói được cảm nhận qua DNSMOS.

Resemblyzerisanaturalnetworkcông cụ để xác minh loa và đo lường độ tương tự giọng nói (Mishraetal.,2023).Atitscore,itemploysa bộ mã hóa xác minh loa được đào tạo với suy hao từ đầu đến cuối tổng quát (Wan và cộng sự, 2018). Nguyên tắc hoạt động như sau: đầu tiên, một lời nói đầu vào—hoặc tham chiếu ban đầu hoặc giọng nói nhân bản tổng hợp—được xử lý bởi một mạng lưới thần kinh sâu trích xuất một vector nhúng có chiều cố định (thường được gọi là vector d-vector hoặc nhúng loa). Vector này được thiết kế để nắm bắt nhận dạng giọng nói duy nhất của người nói, bao gồm các đặc điểm như âm sắc, cao độ, và phong cách nói, trong khi phần lớn không thay đổi đối với nội dung ngôn ngữ hoặc các từ cụ thể được nói. Nói cách khác, bất kể người đó nói gì, cách lồng ghép phải nhất quán đối với cùng một người nói và khác biệt rõ ràng đối với những người nói khác nhau (Wan và cộng sự, 2018).

Sau khi thu được các vector nhúng cho cả hai âm thanh tham chiếuA(giọng nói của người nói gốc) và âm thanh tổng hợpB(giọng nói nhân bản), độ tương tự của chúng được định lượng bằng cách sử dụng thước đo độ tương tự cosine:

$$\text{Cosine S\ddot{u}r tương đ\ddot{o}ng} \left(\mathbf{A}, \mathbf{B} \right) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}} \quad (2P)$$

Các phép đo độ tương tự cosine góc giữa hai người vector trong không gian nhúng chiều cao. Giá trị gần bằng 1 cho biết các vector chỉ về cùng một hướng, nghĩa là hai giọng nói được nhận biết có tính chất bằng miệng rất giống nhau và đặc tính của người nói (Jiaetal.,2018;Wanetal.,2018). Ngược lại, giá trị gần0 hoặc âm sẽ gợi ý những người nói không giống nhau. Do đó, Resemblyzer cung cấp thước đo khách quan, tự động và có thể tái tạo để đánh giá mức độ trung thực của hệ thống nhân bản giọng nói bảo tồn các đặc điểm giọng nói của người nói ban đầu.

DNSMOS (Điểm ý kiến trung bình hạn chế tiếng ồn sâu) là một số liệu dựa trên học tập sâu, không xâm phạm, được thiết kế để ước tính chất lượng cảm nhận của tín hiệu giọng nói mà không yêu cầu tín hiệu âm thanh tham chiếu sạch (Reddyetal.,2021).

5 thí nghiệm và kết quả

Tập dữ liệu đào tạo. Hệ thống đã được đào tạo và đánh giá bằng cách sử dụng theviVoicecorpus (Le, 2024), tập dữ liệu giọng nói tiếng Việt quy mô lớn đầu tiên được công bố rộng rãi được thiết kế cho nhiều người nói chuyển văn bản thành giọng nói.viVoice bao gồm hơn 1.000 giờ âm thanh được làm sạch và phiên âm đi kèm có nguồn gốc từ 186 kênh YouTube. Tất cả các mẫu âm thanh được cung cấp dữ liệu tốc độ lấy mẫu 24kHz ở định dạng WAV, với nhạc nền và tiếng ồn đã được loại bỏ để đảm bảo dữ liệu đào tạo sạch. Bộ dữ liệu bao gồm nhiều loại người nói, giọng (Miền Bắc, Miền Trung, Miền Nam) và phong cách nói, khiến nó đặc biệt phù hợp để đào tạo mạnh mẽ nhiều người nói. Các mẫu TTS tiếng Việt như XTTS-v2.vi Giọng nói được phát hành theo giấy phép CCBY-NC-SA4.0.

Quy trình tiền xử lý được thiết kế để loại bỏ những biến đổi có thể làm giảm độ tương tự của người nói. Các bước bao gồm: (i)xác minh thủ công độ chính xác của bản ghi để đảm bảo căn chỉnh hoàn hảo;(ii)chuẩn hóa văn bản bằng cách sử dụng VietNormalizer(Do,2026)để mở rộng chữ viết tắt, chuyển đổi số thành từ và chuẩn hóa dấu câu;(iii) căn chỉnh ngữ âm với bộ căn chỉnh bắt buộc được đào tạo trên tiếng Việt, mang lại cấp độ khung hình ranh giới âm vị;(iv)sự im lặng dựa trên năng lượng loại bỏ ở phần đầu và phần cuối của phát ngôn cửa hàngdi chuyển đầu/cuối im lặng;và (v)chuẩn hóa âm lượng thành-23 LUFSđể duy trì sự nhất quán được cảm nhận âm lượng trên các loa. Điều quan trọng là, đối với mỗi loa, việc nhúng loa chất lượng cao đã được trích xuất bằng cách sử dụng bộ mã hóa Resemblyzer và vectơ tham chiếu được lưu trữ. nhúng trong quá trình đào tạo khuyến khích bộ giải mã bảo tồn danh tính của người nói, góp phần trực tiếp vào điểm tương đồng cosine cao (0,90+) được quan sát thấy trong các thí nghiệm.

Thiết lập thử nghiệm.Đánh giá được tiến hành trên máy tính xách tay GIGABYTEG5GD, máy tính xách tay định hướng chơi game có thông số kỹ thuật được liệt kê trong Bảng 1. Đáng chú ý là hệ thống có các tính năng chuyên dụngNVIDIA GeForce RTXGPU(Ampe architecture, rời) cùng với bộ điều hợp IntelUHDGraphics tích hợp. Tuy nhiên, môi trường PyTorchen được sử dụng cho suy luận là bản dựng chỉ dành cho CPU, nghĩa là tất cả các hoạt động tổng hợp đều chạy trên CPU Intel Core i5-11400H mà không cần tăng tốc GPU. Cấu hình này phản ánh một kịch bản triển khai chung trong đó các thư viện trình điều khiển CUDA không được cài đặt hoặc trong đó hệ thống ưu tiên khả năng tương thích trên tốc độ tối đa.

Bảng 1. Cấu hình hệ thống của nền tảng thử nghiệm.

Component	Specification
Model	GIGABYTE G5 GD
CPU	Intel Core i5-11400H (8 lõi, 12 luồng, tốc độ cơ bản 2,70 GHz)
ĐẬP	16 GB DDR4 (có thể sử dụng 15,8 GB)
GPU	Đồ họa Intel UHD (tích hợp)
Hệ điều hành	NVIDIA GeForce RTX (Ampe, chuyên dụng)
GPU rời	Ngôn ngữ đơn Windows 11 Home

(Bản dựng 26200)

Inference Backend PyTorch CPU-only, 4 threads

Giọng nói tương tự và chất lượng .giọng nói. Hệ thống được đánh giá bằng cách so sánh các mẫu giọng nói gốc và tổng hợp (nhân bản) từ bốn người nói. Mỗi cặp mẫu bao gồm tham chiếu.wavfileanditsclone. Phương pháp đánh giá hai đã được áp dụng: Resemblyzer để đảm bảo độ giống nhau của giọng nói (Wan và cộng sự, 2018; Mishra và cộng sự, 2023) và DNSMOSforperceivedaudioquality(Reddyetal.,2021).Kết quả về độ tương tự giọng nói được trình bày trongBảng2.Allpairsachieveacosinesimilarityofapproximately0,90 (dao động từ 0,9013 đến 0,9346), xác nhận rằng mô hình VITS, mặc dù chạy trên CPU, vẫn bảo toàn được âm sắc và nhận dạng loa rất tốt (Jiaetal., 2018).

Kết quả về độ tương tự giọng nói của mô hình viXTTS được trình bày trong Bảng 2. Tất cả các cặp đều đạt được độ tương tự acosine xấp xỉ 0,90 (trong khoảng từ 0,9013 đến 0,9346), xác nhận rằng mô hình bảo tồn âm sắc giọng nói và nhận dạng loa rất tốt (Jiaetal.,2018). Độ tương tự của loa đối với các động cơ khác không được đo lường trong phần này chạy đánh giá, hầu hết chúng không hỗ trợ nhân bản giọng nói hoặc yêu cầu bước trích xuất nhúng tham chiếu riêng.

Bảng 2. Độ tương tự của giọng nói giữa lời nói gốc và lời nói nhân bản.

Cập audio	Similarity
giọng_goc và giọng_clone	0,9038
Danh_1 và Danh_clone	0,9019
Khang1 và Khang_clone	0,9346
Ngoc1 và Ngoc_clone	0,9013

Chất lượng giọng nói kết quả từDNSMOStrên tất cả bảy công cụ được đánh giá được tóm tắt trong Bảng 3. Bốn số liệu được ghi lại:OVRL(chất lượng tổng thể),SIG (chất lượng giọng nói), BAK (độ xâm nhập của tiếng ồn nền) và điểm P808 bổ sung (công cụ ước tính chất lượng nghe tổng thể phù hợp với ITU-T P.808). Điểm số nằm trên thang điểm tiêu chuẩn1–5Ý kiến trung bình, trong đó giá trị cao hơn biểu thị chất lượng nhận thức tốt hơn.

Bảng 3. Đánh giá DNSMOS chất lượng giọng nói tiếng Việt tổng hợp..

Model	File audio	OVRL MOS	SIG MOS	BAK MOS	P808 MOS
Đề xuất dựa trên viXTTS					
Hệ thống nhân bản giọng nói	giọng_clone.wav	3,38	3,60	4.14	4.03
Piper Việt TTS	Piper_Tiếng Việt_TTS	3,00	3,40	3,81	3,15
Valtec Việt TTS v2	Valtec Tiếng Việt TTS_ver2.wav	3.07	3,34	4.04	3,95
Tiếng ViệtTTS	Tiếng ViệtTTS.wav	2.07	2,75	2,86	2,73
Valtec Việt TTS	Valtec_Tiếng Việt.wav	3,37	3,58	4.16	4.21
VietTTS	VietTTS.wav	3.05	3,25	4.15	3,64
VieNeu-TTS	VietNeu_TTS.wav	3,31	3,54	4.16	3,68

Các kết quả đánh giá DNSMOS cho thấy sự khác biệt đáng chú ý trong chất lượng giọng nói tiếng Việt được tổng hợp trong số các hệ thống TTS được đánh giá. Nhìn chung, hệ thống nhân bản giọng nói dựa trên viXTTS được đề xuất, được đại diện bởi giọng_clone.wav, đạt được điểm OVRLMOS cao nhất là 3,38 và điểm SIGMOS cao nhất là 3,60. Những kết quả này kết quả chỉ ra rằng hệ thống được đề xuất tạo ra giọng nói với chất lượng nhận thức tổng thể mạnh mẽ và tín hiệu giọng nói rõ ràng. Điểm BAKMOS cao là 4,14 cũng cho thấy rằng âm thanh được tạo ra có rất ít tiếng ồn xung quanh. Do đó, mô hình dựa trên viXTTS thể hiện hiệu suất mạnh mẽ cả về độ rõ của giọng nói và khả năng khử tiếng ồn.

Trong số các hệ thống được so sánh, Valtec_Tiếng Việt.wav Mà còn hoạt động một cách cạnh tranh, với OVRLMOS của 3,37 và SIGMOS ở mức 3,58, gần với hệ thống được đề xuất. Ngoài ra, mô hình này đạt được điểm P808MOS cao nhất là 4,21, cho thấy rằng người nghe có thể cảm nhận chất lượng âm thanh tổng thể của nó một cách thuận lợi. Tuy nhiên, giọng_clone.wav được đề xuất vẫn hoạt động tốt hơn một chút so với hai chỉ báo DNS MO chính, OVRLandSIG. Điều này cho thấy rằng mô hình được đề xuất có lợi thế nhỏ nhưng có thể đo lường được về chất lượng giọng nói tổng thể và độ rõ của tín hiệu.

Mô hình VietNeu TTS.wav cũng đạt được kết quả cao, với OVRL MOS là 3,31, SIGMOSof3,54, BAKMOSof4,16 và P808MOSof3,68. Các điểm số này được xếp vào nhóm có hiệu suất cao, đặc biệt là mức khử nhiễu nền. Điểm BAK của nó nằm trong số các điểm cao nhất trong so sánh, cho thấy âm thanh được tạo ra sạch và ổn định. điểm chất lượng tín hiệu tổng thể của nó thấp hơn một chút so với giọng_clone.wav và Valtec_vietnamese.wav, nó vẫn là một mô hình đáng tin cậy để tổng hợp giọng nói tiếng Việt.

Nhóm có thành tích trung bình bao gồm Valtec Tiếng Việt TTS_ver2.wav, VietTTS.wav và Piper_English_TTS. Các mô hình này đạt được điểm OVRLMOS trong khoảng từ 3,00 đến 3,07, cho thấy chất lượng giọng nói tổng hợp có thể chấp nhận được nhưng không vượt trội. Điểm SIGMOS của họ, dao động từ 3,25 đến 3,40, cho thấy rằng tín hiệu giọng nói ở mức hợp lý rõ ràng nhưng vẫn thiếu tự nhiên hoặc thiếu chi tiết so với các hệ thống hoạt động hàng đầu. Đáng chú ý, VietTTS.wav đạt được số điểm BAK MOS cao là 4,15, cho thấy đầu ra âm thanh của nó tương đối sạch. Tuy nhiên, điểm OVRLandSIG thấp hơn cho thấy chỉ riêng độ sạch của nền là chưa đủ để đảm bảo chất lượng giọng nói tổng thể cao.

Hệ thống có hiệu suất thấp nhất là tiếng ViệtTTS.wav, đạt được OVRL MOSof2,07, SIGMOSof2,75, BAKMOSof2,86 và P808MOSof2,73. Các điểm số này thấp hơn đáng kể so với các điểm số của các mô hình khác. Đặc biệt, điểm số OVRLandSIG thấp gợi ý rằng lời nói tổng hợp có thể chứa đựng sự chú ý tạo tác, giảm độ tự nhiên, hoặc phát âm không rõ ràng. Điểm BAK thấp cũng chỉ ra rằng âm thanh có thể có nhiều nhiễu hoặc nhiễu nền hơn so với các hệ thống khác.

Có thể nhận thấy xu hướng chung trên các mô hình mạnh hơn: hầu hết các hệ thống đều đạt điểm BAK MOS cao trên 4,0, điều đó có nghĩa là các mô hình TTS hiện đại của Việt Nam nhìn chung có hiệu quả trong việc tạo ra âm thanh sạch với tiếng ồn nền hạn chế. Tuy nhiên, sự khác biệt về điểm OVRL và SIG cho thấy âm thanh sạch không phải lúc nào cũng

đảm bảo lời nói tự nhiên và dễ hiểu. Tính tự nhiên, rõ ràng và chất lượng tín hiệu vẫn là những yếu tố quan trọng trong việc phân biệt các mô hình hoạt động tốt nhất.

Tóm lại, mô hình nhân bản giọng nói dựa trên viXTTS được đề xuất `giọng_clone.wav` đạt được hiệu suất tổng thể tốt nhất về OVRL và SIG MOS, khiến nó trở thành hệ thống mạnh nhất trong so sánh này. `Valtec_Việt.wav` và `VietNeu_TTS.wav` cũng thể hiện hiệu suất cạnh tranh và có thể được coi là các lựa chọn thay thế mạnh mẽ. Trong khi đó, `TTS.wav` tiếng Việt cho thấy kết quả yếu và có thể cần tối ưu hóa hơn nữa để cải thiện độ tự nhiên của giọng nói, độ rõ và kiểm soát tiếng ồn xung quanh.

Phân tích hiệu suất và độ trễ theo thời gian thực: Chỉ số hiệu suất quan trọng nhất của nguyên mẫu hiện tại là độ trễ tổng hợp từ đầu đến cuối. Đối với một văn bản đầu vào thông thường có 750 ký tự (tương đương với khoảng 50 giây âm thanh được tạo ra ở tốc độ nói tiếng Việt tiêu chuẩn khoảng 900 ký tự mỗi phút), hệ thống cần khoảng 2 phút và 50 giây (170 giây) để tạo ra WAV cuối cùng file. Điều này mang lại hệ số thời gian thực (RTF) khoảng 3,4, cao hơn ngưỡng thời gian thực của 1.0. Tuy nhiên, độ trễ không cố định; nó thay đổi có thể đo lường được tùy thuộc vào độ phức tạp ngôn ngữ của văn bản đầu vào. Hai yếu tố chi phối chi phí xử lý bổ sung:

▣ Thẻ cảm xúc. Mỗi ranh giới cảm xúc buộc phải có một đoạn tổng hợp mới với lệnh gọi suy luận viXTTS riêng biệt, dẫn đến chuyển đổi nhiều ngữ cảnh và chi phí tài mô hình. Nhiều thẻ hơn sẽ tăng số lượng khối và thời gian chèn tạm dừng tích lũy.

▣ Từ tiếng Anh và các đoạn không phải tiếng Việt. Những điều này đòi hỏi thêm các bước từ grapheme đến âm vị trong lớp chuẩn hóa văn bản (Do, 2026) và có thể gây ra lỗi chú ý buộc bộ giải mã phải thử lại cần chỉnh, thêm vào tổng thời gian chạy.

Độ trễ quan sát được bắt nguồn từ việc chạy toàn bộ quy trình VITS trên CPU mà không sử dụng GPU RTX có sẵn. Bản dựng PyTorch chỉ dành cho CPU không thể khai thác tính song song lớn của các lõi tensor của GPU, khiến các phép nhân và tích chập ma trận phải được tính toán tuần tự. Mặc dù vậy, hệ thống vẫn có thể chấp nhận được đối với các tác vụ tạo nội dung gần như lồng tiếng podcast, tường thuật mang tính giáo dục hoặc tạo thư thoại—các ứng dụng trong đó cho phép một vài phút thời gian kết xuất để đổi lấy đầu ra có chất lượng cao, biểu đạt cảm xúc.

Điều quan trọng là máy được trang bị GPU NVIDIA GeForce RTX, hoàn toàn có khả năng tăng tốc suy luận. Việc chuyển sang cài đặt PyTorch hỗ trợ CUDA sẽ giảm RTF xuống dưới 0,1 (dựa trên GPU thông thường điểm chuẩn cho VITS), cho phép tổng hợp phát trực tuyến theo thời gian thực. Ngoài ra, lượng tử hóa mô hình thành FP16 hoặc INT8 và chuyển sang các công cụ suy luận được tối ưu hóa như ONNX Runtime với OpenVINO, có thể giảm một nửa độ trễ trong khi vẫn duy trì độ tương tự cao và điểm MOS.

6 Kết luận

Trong nghiên cứu này, một hệ thống chuyển văn bản sang giọng nói tiếng Việt dựa trên trí tuệ nhân tạo và học sâu đã được thiết kế, triển khai và đánh giá kỹ lưỡng. Hệ thống

khai thác các mô hình hiện đại như Tacotron, FastSpeech và VITS để tự động chuyển đổi văn bản thành tín hiệu lời nói tự nhiên, tìm hiểu các đặc điểm ngữ âm và ngữ điệu độc đáo của tiếng Việt. Kết quả thử nghiệm cho thấy mô hình đề xuất tạo ra giọng nói rõ ràng, tự nhiên với ngữ điệu phù hợp và duy trì hiệu suất ổn định trong nhiều điều kiện và ngữ cảnh khác nhau.

Các kết quả đạt được không chỉ xác nhận tính hiệu quả của deep learning trong tổng hợp giọng nói tiếng Việt mà còn nêu bật khả năng ứng dụng rộng rãi của hệ thống trong thực tế, đặc biệt là trợ lý ảo, giáo dục, tổng đài tự động và các công cụ hỗ trợ dành cho người khiếm thị. Futurework có thể tập trung vào việc mở rộng và làm phong phú thêm tập dữ liệu giọng nói, cải thiện khu vực sự tự nhiên, tối ưu hóa mô hình dành cho các thiết bị có hạn chế về tài nguyên và tích hợp hệ thống vào các nền tảng trong thế giới thực để nâng cao tính khả thi và khả năng sử dụng.

Tài liệu tham khảo

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. M., & Weber, G. (2020). CommonVoice: A massively-multilingual speech corpus. arXiv. [GIỮ_0](#)
2. Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). wav2vec2.0: A framework for self-supervised learning of representations. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, E., & Ponti, M. A. (2022). TTS của bạn: Hướng tới chuyển đổi giọng nói đa loa TTS and zero-shot cho mọi người. arXiv. [GIỮ_0](#)
4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Prasad, V., Conneau, A., Collobert, R., Synnaeve, G., & Auli, M. (2022). WavLM: Large-scale self-supervised pre-training for full spectrum audio processing. arXiv. [GIỮ_0](#)
5. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. arXiv. <https://arxiv.org/abs/1810.04805>
6. Do, N. (2026). VietNormalizer: Thư viện Python mã nguồn mở, không phụ thuộc cho Tiếng Việt chữ bình thường hóa TRONG TTS và NLP ứng dụng. arXiv. <https://arxiv.org/abs/2603.04145>
7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, M., & Bengio, Y. (2014). Generative adversarial nets. arXiv. <https://arxiv.org/abs/1406.2661>
8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhotia, K., Salakhutdinov, R., & Mohamed, A. (2021). HuBERT: Self-supervised learning of representations from unlabeled audio. arXiv. [GIỮ_0](#)
9. Nădejde, K., & Johnson, L. (2017). The LJSpeech Dataset. <https://keithito.com/LJ-Speech-Dataset/>
10. Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, X., Chen, Z., Nguyen, P., Pang, R., Moreno, I. L., & Wu, Y. (2018). Chuyển học từ xác minh người nói sang tổng hợp chuyển văn bản thành giọng nói đa loa. Advances in Neural Information Processing Systems, 31. <https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Tổng hợp âm thanh thần kinh hiệu quả. arXiv. __ GIỮ_0__
StarGAN-VC: Chuyển đổi giọng nói nhiều thành nhiều không song song bằng cách sử dụng stargenerativeadversarialnetworks. arXiv.
<https://arxiv.org/abs/1806.02169>
- & 13. Kim, J., Kong, J., & Son, J. (2021). Biến đổi tự động có điều kiện với phương pháp học đối nghịch để chuyển văn bản thành giọng nói từ đầu đến cuối. arXiv. __ GIỮ_0__
- & 14. Kingma, D. P., & Welling, M. (2014). Auto-encoding variational bayes. arXiv.
<https://arxiv.org/abs/1312.6114>
15. Kong, J., Kim, J., & Bae, J. (2020). HiFi-GAN: Mạng đối thủ sáng tạo để tổng hợp giọng nói có độ trung thực cao và hiệu quả. arXiv. <https://arxiv.org/abs/2010.05646>
16. Mishra, P., Choudhury, J. A., Kho, E., Basu, B., & Nandi, A. (2023). Nhận dạng, phân biệt và xác minh người nói bằng cách sử dụng deep learning cho giao diện người máy. Hội nghị chuyên đề nghiên cứu Quang tử & Điện tử (PIERS) năm 2023 (trang 861–870). IEEE. __ GIỮ_0__
17. Nguyễn, Đ. Q., & Tuan, N. D. (2020). PhoBERT: Các mô hình ngôn ngữ được đào tạo trước cho tiếng Việt. arXiv. __ GIỮ_0__
18. Nguyễn, N. (2023). VietTTS: Tiếng Việt chữ phát biểu thư viện. GitHub.
<https://github.com/NTT123/vietTTS>
19. Oord, A. vanden, Dieleman, S., Zen, H., Simonyan, K., Vijals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). WaveNet: A generative model cho âm thanh thô. arXiv. __ GIỮ_0__
20. Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Rayman, J., Miller, J., & Sengupta, S. (2017). DeepVoice3: Chuyển đổi tỷ lệ văn bản thành giọng nói bằng cách học theo trình tự tích chập. arXiv. __ GIỮ_0__
21. Prenger, R., Valle, R., & Catanzaro, B. (2019). WaveGlow: Mạng tạo dựa trên dòng chảy để tổng hợp giọng nói. arXiv. __ GIỮ_0__
22. Qian, K., Zhang, Y., Chang, S., Yang, X., & Hasegawa-Johnson, M. (2019). AutoVC: Bán không tiếng nói phong cách chuyển chỉ với bộ mã hóa tự động sự mất mát. arXiv.
<https://arxiv.org/abs/1905.05879>
23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022). Nhận dạng giọng nói mạnh mẽ thông qua giám sát yếu trên quy mô lớn. arXiv.
<https://arxiv.org/abs/2212.04356>
24. Reddy, C. K., Gopal, V., & Cutler, R. (2021). DNSMOS: Chỉ số chất lượng giọng nói khách quan mang tính nhận thức không xâm phạm để đánh giá các bộ giảm tiếng ồn. Trong ICASSP 2021–2021 Hội nghị quốc tế IEEE về Âm thanh, Xử lý tín hiệu phát biểu (trang 6493–6497). IEEE. __ GIỮ_0__
25. Ren, Y., Ruan, Y., Chen, X., Qin, T., Zhao, S., & Liu, T. (2019). FastSpeech: Chuyển văn bản thành giọng nói nhanh, mạnh mẽ và có thể kiểm soát. arXiv. __ GIỮ_0__
26. Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T. (2020). FastSpeech 2: Chuyển văn bản thành giọng nói nhanh và chất lượng cao. arXiv.
<https://arxiv.org/abs/2006.04558>
27. Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyrigiannakis, Y., & Wu, Y. (2018). NaturalTTS tổng hợp by ConditionWaveNet on mel spectrogram predictions. arXiv.
<https://arxiv.org/abs/1712.05884>
28. Thinh, L. (2024). viXTTS: Tiếng Việt nhân bản văn bản thành giọng nói model. GitHub.
<https://github.com/thinhlp/vixtts-demo>

29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Sự chú ý là tất cả những gì bạn cần. arXiv. __ GIỮ_0__
30. Vu, T., Nguyen, L.T., & Nguyen, D.Q. (2025). Chuyển văn bản thành giọng nói nhanh chóng cho người Việt. arXiv. __ GIỮ_0__
31. Wan, L., Wang, Q., Papir, A., & Moreno, I.L. (2018). Tổng & quát hóa từ đầu đến cuối cho xác minh loa. In 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) (trang 4879–4883). IEEE.
- <https://ieeexplore.ieee.org/abstract/document/8462665>
32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Agiomyrgiannakis, Y., Clark, R., & Saurous, R.A. (2017). Tacotron: Hướng tới tổng hợp giọng nói từ đầu đến cuối. arXiv.
- <https://arxiv.org/abs/1703.10132>
33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R.J., Battenberg, E., Shor, J., Xiao, Y., Jia, Y., Ren, F., & Saurous, R.A. (2018). Styletokens: Tạo mô hình phong cách không giám sát, điều khiển và chuyển giao trong quá trình tổng hợp tiếng nói từ đầu đến cuối. arXiv.
- <https://arxiv.org/abs/1803.09017>
34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: English multi-talker speech corpus for the community. Đại học Edinburgh. <https://datashare.ed.ac.uk/handle/10283/3443>
35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R.J., Jia, Y., Chen, Z., & Wu, Y. (2019). LibriTTS: Một kho văn bản có nguồn gốc từ LibriSpeech để chuyển văn bản thành giọng nói. arXiv.
- <https://arxiv.org/abs/1904.02882>
36. Lê, T. (2024). viVoice: Bộ dữ liệu giọng nói tiếng Việt đa người nói quy mô lớn dành cho chuyển văn bản thành bài phát biểu. Ôm Mặt. __ GIỮ_0__