

Hệ thống dịch tài liệu dựa trên AI với khả năng giữ nguyên định dạng gốc

Hoàng-Phúc Hà 1 Ngô-Hồ Anh-Khoa 1 và Ngô-Hồ Anh-Khôi 1*

1 Khoa Công nghệ Thông tin, Đại học Nam Cần Thơ, 168 Nguyễn Văn Cừ, Phường An Bình, Thành phố Cần Thơ, Việt Nam

phuc222683@studentnctu.edu.vn, nhakhoa@nctu.edu.vn,
nhakhoi@nctu.edu.vn

Trừu tượng. Trong bối cảnh nhu cầu dịch thuật tài liệu số ngày càng tăng, các hệ thống dịch thuật hiện đại được kỳ vọng không chỉ đảm bảo chất lượng nội dung dịch mà còn giữ nguyên định dạng ban đầu của tài liệu đầu vào. Tuy nhiên, khi dịch các tài liệu có cấu trúc phức tạp như file PDF, DOCX, nhiều hệ thống vẫn gặp phải các vấn đề như méo bố cục, lệch bảng, dịch chuyển hình ảnh, lỗi font chữ và hạn chế hỗ trợ chế độ hiển thị song ngữ. Nghiên cứu này đề xuất hệ thống dịch tài liệu dựa trên trí tuệ nhân tạo có khả năng xử lý hai định dạng tài liệu phổ biến là DOCX và PDF, đồng thời hỗ trợ ba chế độ dịch: dịch tiêu chuẩn, dịch song ngữ song ngữ và dịch song ngữ từng dòng. Đối với tài liệu DOCX, hệ thống xử lý trực tiếp các thành phần tài liệu như đoạn văn, bảng biểu, đầu trang, chân trang. Đối với các tài liệu PDF, hệ thống áp dụng quy trình PDF→DOCX→dịch→khôi phục bố cục→PDF để cải thiện việc bảo toàn định dạng. Hệ thống tích hợp một số nhà cung cấp dịch thuật, bao gồm Google Translate, DeepL Translator và Gemini 2.5 Flash, để tăng tính linh hoạt về chất lượng dịch và các tùy chọn xử lý. Việc đánh giá thử nghiệm được tiến hành bằng hai nhóm tiêu chí: bảo toàn định dạng và chất lượng dịch thuật được đo bằng BLEU Mean và BLEU Std. Kết quả cho thấy hệ thống được đề xuất đạt được khả năng bảo toàn định dạng mạnh mẽ cho các tài liệu DOCX và hiệu suất đầy hứa hẹn cho các tài liệu PDF học thuật.

Từ khóa: Dịch tài liệu, bảo quản định dạng, trí tuệ nhân tạo, PDF, DOCX, dịch song ngữ, BLEU.

1 Giới thiệu

Sự phát triển nhanh chóng của trí tuệ nhân tạo và các mô hình ngôn ngữ lớn đã thúc đẩy đáng kể lĩnh vực xử lý ngôn ngữ tự nhiên, đặc biệt là dịch máy. Các mô hình dịch thuật hiện đại không còn bị giới hạn trong việc chuyển đổi văn bản từ ngôn ngữ nguồn sang ngôn ngữ đích; chúng cũng có khả năng xử lý ngữ cảnh, thuật ngữ và phong cách viết hiệu quả hơn các phương pháp dịch thống kê truyền thống (Bahdanau và cộng sự, 2015; Wuet cộng sự, 2016; Koehn, 2020). Đặc biệt, kiến trúc Transformer đã trở thành nền tảng cơ bản cho nhiều công nghệ hiện đại.

mô hình xử lý ngôn ngữ nhờ khả năng nắm bắt các mối quan hệ theo ngữ cảnh một cách hiệu quả trong các chuỗi văn bản dài (Vaswani và cộng sự, 2017). Ngoài ra, sự phát triển của các mô hình ngôn ngữ lớn như GPT và các mô hình chuyển văn bản thành văn bản hợp nhất đã mở ra những hướng đi mới cho các tác vụ dịch thuật, tóm tắt và xử lý tài liệu (Brown và cộng sự, 2020; Raffel và cộng sự, 2020). Tuy nhiên, trong các tình huống thực tế, người dùng không chỉ cần dịch các câu hoặc đoạn văn đơn giản. Họ thường có nhu cầu dịch toàn bộ các tài liệu có định dạng như bài báo khoa học, báo cáo kỹ thuật, luận văn, hợp đồng, biểu mẫu hành chính. Những tài liệu này thường được lưu trữ ở định dạng DOCX hoặc PDF và chứa nhiều thành phần định dạng khác nhau, bao gồm tiêu đề, đoạn văn, bảng, hình ảnh, đầu trang, chân trang, danh sách và bố cục trang. Vì vậy, không nên coi việc dịch tài liệu chỉ là vấn đề dịch nội dung mà còn là vấn đề bảo toàn định dạng.

Trong nhiều hệ thống dịch tài liệu hiện có, việc giữ nguyên định dạng gốc vẫn là một thách thức đáng kể. DOCX có cách trình bày có cấu trúc tương đối, trong đó nội dung được sắp xếp thành các đoạn, bảng, kiểu, đầu trang và chân trang, giúp bạn có thể xử lý tài liệu trực tiếp bằng các công cụ lập trình. Ngược lại, PDF được thiết kế chủ yếu để hiển thị và in ấn và nội dung của nó thường được lưu trữ dựa trên tọa độ trang thay vì cấu trúc tài liệu logic. Kết quả là, khi văn bản dịch trở nên dài hơn hoặc ngắn hơn văn bản gốc, có thể xảy ra các vấn đề như tràn văn bản, căn chỉnh bảng, chồng chéo văn bản và thay đổi bố cục. Các dịch vụ dịch thuật phổ biến như Google Translate, DeepL, Adobe Acrobat và nền tảng AI có hỗ trợ tải tệp lên cung cấp các giải pháp tiện lợi nhưng vẫn có những hạn chế về tùy chỉnh quy trình, trình bày song ngữ và kiểm soát định dạng đầu ra. Dựa trên những hạn chế này, nghiên cứu này phát triển hệ thống dịch tài liệu dựa trên AI, giữ nguyên định dạng tài liệu gốc và hỗ trợ cả tệp DOCX và PDF với ba chế độ dịch. Hệ thống sử dụng các chiến lược xử lý khác nhau cho các loại tài liệu khác nhau: tệp DOCX được dịch trực tiếp dựa trên các đoạn và bảng có cấu trúc của chúng, trong khi tệp PDF được xử lý bằng cách sử dụng đường dẫn $\text{PDF} \rightarrow \text{DOCX} \rightarrow \text{translation} \rightarrow \text{layout recovery} \rightarrow \text{PDF}$. Hệ thống đề xuất được đánh giá thông qua hai nhóm thực nghiệm: đánh giá bảo toàn định dạng và đánh giá chất lượng dịch thuật, nhằm đánh giá cả cấu trúc hình ảnh và nội dung ngôn ngữ.

2 công việc liên quan

Trong lĩnh vực dịch thuật tài liệu, nhiều hệ thống thương mại đã được phát triển để giúp người dùng dịch các định dạng tệp phổ biến như DOCX, PDF và PPTX. Các nền tảng như DeepL Document Translation, Google Translate, Google Cloud Translation và Adobe Acrobat cung cấp các tính năng dịch tài liệu trực tuyến, cho phép người dùng xử lý các tài liệu đa ngôn ngữ phục vụ học tập, nghiên cứu và làm việc chuyên môn. Các hệ thống này mang lại lợi thế về tốc độ xử lý, chất lượng dịch thuật và khả năng sử dụng. Tuy nhiên, hầu hết các nền tảng thương mại đều là hệ thống khép kín, nghĩa là người dùng không thể dễ dàng sửa đổi quy trình xử lý nội bộ, tùy chỉnh cơ chế bảo toàn định dạng hoặc kiểm soát linh hoạt các chế độ trình bày song ngữ như dịch song ngữ song ngữ hoặc dịch song ngữ từng dòng. Đối với người dùng làm việc với các tài liệu học thuật hoặc kỹ thuật có chứa cấu trúc phức tạp,

chỉ dựa vào các công cụ dịch tệp thương mại hiện có có thể không đủ để kiểm soát các lỗi định dạng phát sinh trong quá trình dịch.

Từ góc độ học thuật, dịch máy đã phát triển đáng kể từ dịch máy thống kê sang dịch máy thần kinh và các mô hình ngôn ngữ lớn. Cơ chế chú ý trong dịch máy thần kinh đã cải thiện khả năng căn chỉnh câu nguồn và câu đích (Bahdanau và cộng sự, 2015), trong khi Dịch máy thần kinh của Google đã chứng minh tính hiệu quả của mạng thần kinh trong bản dịch đa ngôn ngữ quy mô lớn (Wu và cộng sự, 2016). Sau này, kiến trúc Transformer trở thành nền tảng chính cho các mô hình dịch thuật và xử lý ngôn ngữ tự nhiên hiện đại thông qua cơ chế tự chú ý (Vaswani et al., 2017). Các đánh giá về dịch máy thần kinh cũng chỉ ra rằng chất lượng dịch đã được cải thiện đáng kể, mặc dù vẫn còn những thách thức trong việc xử lý ngữ cảnh, thuật ngữ dành riêng cho từng miền và phương pháp đánh giá (Stahlberg, 2020; Koehn, 2020). Ngoài ra, các mô hình ngôn ngữ lớn như GPT và mô hình chuyển văn bản thành văn bản hợp nhất đã mở rộng khả năng xử lý văn bản dài, hiểu ngữ cảnh và tạo ra kết quả đầu ra tự nhiên hơn (Brown và cộng sự, 2020; Raffel và cộng sự, 2020).

Để xử lý tài liệu, định dạng DOCX và PDF có các đặc điểm cấu trúc rất khác nhau. DOCX dựa trên cấu trúc XML, trong đó nội dung được tổ chức thành các đoạn văn, dòng văn bản, bảng, kiểu, đầu trang và chân trang. Điều này cho phép hệ thống lặp qua các thành phần tài liệu, trích xuất và thay thế văn bản cũng như giữ nguyên hầu hết định dạng ban đầu. Ngược lại, PDF được thiết kế chủ yếu để hiển thị và in ấn, văn bản của nó thường được lưu trữ theo tọa độ trang. Điều này làm cho việc phát hiện thứ tự đọc, nhận dạng bảng và khôi phục bố cục trở nên khó khăn hơn. Các nghiên cứu về phân tích bố cục tài liệu, chẳng hạn như PubLayNet, DocBank, FUNSD, DocVQA và LayoutLM, cho thấy rằng việc hiểu bố cục cấu trúc và hình ảnh của tài liệu rất quan trọng đối với các tác vụ xử lý tài liệu phức tạp (Zhong và cộng sự, 2019; Li và cộng sự, 2020; Jaume và cộng sự, 2019; Mathew và cộng sự, 2021; Xu et cộng sự, 2020). Đặc biệt, LayoutLM và LayoutLMv2 kết hợp thông tin văn bản, vị trí và hình ảnh để cải thiện khả năng hiểu tài liệu cho các tài liệu có hình ảnh phong phú (Xu và cộng sự, 2020; Xu và cộng sự, 2021).

Một cách tiếp cận thực tế để xử lý PDF là chuyển đổi các tệp PDF thành định dạng có thể chỉnh sửa như DOCX, dịch nội dung được trích xuất và sau đó xuất kết quả trở lại PDF. Đường dẫn PDF→DOCX→translation→PDF có ưu điểm là sử dụng cấu trúc chỉnh sửa linh hoạt của tài liệu Word, cho phép hệ thống xử lý văn bản theo đoạn văn, bảng và kiểu thay vì thao tác trực tiếp tọa độ rawPDF. Tuy nhiên, quy trình này cũng có những hạn chế vì quá trình chuyển đổi có thể gây ra các lỗi trung gian như văn bản được hợp nhất, các đoạn văn bị phân mảnh, bảng được phát hiện không chính xác hoặc bố cục trang bị sửa đổi. Do đó, để quy trình này hoạt động hiệu quả, cần phải xử lý trước, dọn dẹp DOCX, khôi phục bố cục và kiểm tra chất lượng đầu ra. Đối với các tài liệu được quét hoặc hình ảnh được nhúng, OCR cũng rất quan trọng để tạo lớp văn bản có thể được xử lý và Tesseract là một trong những công cụ OCR được sử dụng rộng rãi nhất trong cả ứng dụng nghiên cứu và thực tế (Smith, 2007).

& Các nghiên cứu đánh giá dịch máy thường sử dụng các số liệu tự động như BLEU, TER, METEOR và COMET để đo lường sự tương đồng giữa bản dịch máy và bản dịch tham chiếu (Papineni và cộng sự, 2002; Snover và cộng sự, 2006; Banerjee & Lavie, 2005; Rei và cộng sự, 2020). Trong số đó, BLEU là thước đo được sử dụng rộng rãi dựa trên sự chồng chéo n-gram giữa bản dịch do hệ thống tạo và bản dịch tham chiếu.


(Papineni và cộng sự, 2002). Tuy nhiên, điểm BLEU phải được báo cáo rõ ràng vì chúng có thể thay đổi tùy thuộc vào cài đặt mã thông báo, chuẩn hóa và tính toán (Bài đăng, 2018). Đối với dịch tài liệu có bảo toàn định dạng, chỉ chất lượng dịch là không đủ. Một hệ thống có thể dịch nội dung chính xác nhưng vẫn không sử dụng được trong thực tế nếu nó bị mất bảng, dịch chuyển hình ảnh, làm sai bố cục hoặc tạo ra tài liệu đầu ra không thể đọc được. Vì vậy, nghiên cứu này đánh giá hệ thống được đề xuất từ hai góc độ: bảo tồn định dạng và chất lượng dịch thuật.

Dựa trên những phân tích trên, khoảng trống nghiên cứu nằm ở việc kết hợp ba yếu tố: chất lượng dịch thuật, bảo tồn định dạng gốc và chế độ trình bày song ngữ linh hoạt. Các hệ thống hiện tại thường tập trung vào dịch nội dung hoặc bảo toàn định dạng ở một mức độ nhất định, nhưng chúng không hỗ trợ đầy đủ dịch tiêu chuẩn, dịch song ngữ song ngữ và dịch song ngữ từng dòng trong một quy trình có thể tùy chỉnh và mở rộng. Hơn nữa, việc cho phép người dùng lựa chọn trong số các nhà cung cấp dịch thuật như Google Translate, DeepL và Gemini giúp hệ thống thích ứng hơn với các yêu cầu khác nhau về chi phí, tốc độ và chất lượng dịch thuật. Do đó, nghiên cứu này đề xuất một hệ thống dịch tài liệu dựa trên AI kết hợp xử lý DOCX, quy trình aPDF→DOCX→translation→PDF, bảo vệ nội dung đặc biệt, khôi phục bố cục và đánh giá thử nghiệm cả định dạng và chất lượng dịch thuật.

3 Thiết kế hệ thống

Hệ thống được đề xuất được thiết kế để giải quyết vấn đề dịch tài liệu trong khi vẫn giữ nguyên định dạng gốc cho hai loại tài liệu chính: DOCX và PDF. Quy trình làm việc tổng thể bắt đầu khi người dùng tải tài liệu lên thông qua giao diện web và chọn ngôn ngữ đích, nhà cung cấp dịch vụ dịch thuật và chế độ dịch thuật. Sau khi nhận được yêu cầu, hệ thống xác thực định dạng tệp, lưu trữ tài liệu đầu vào và tạo công việc xử lý nền. Thiết kế xử lý không đồng bộ này phù hợp với những tài liệu có kích thước lớn hoặc những tài liệu yêu cầu nhiều bước xử lý trung gian, đặc biệt là các file PDF. Trong quá trình dịch, giao diện người dùng có thể theo dõi trạng thái xử lý thông qua mã định danh công việc và cho phép người dùng tải xuống tệp đầu ra khi công việc hoàn thành.

Kiến trúc hệ thống bao gồm một số thành phần chính: giao diện người dùng, API xử lý yêu cầu, trình quản lý công việc nền, dịch vụ xử lý tệp, mô-đun nhà cung cấp dịch thuật, mô-đun khôi phục bố cục và mô-đun tạo đầu ra. Giao diện người dùng cho phép người dùng tải lên các tệp DOCX hoặc PDF, chọn ngôn ngữ đích, chọn nhà cung cấp dịch thuật như Google Translate, DeepL hoặc Gemini và chọn một trong ba chế độ dịch: dịch tiêu chuẩn, dịch song ngữ song ngữ và dịch song ngữ từng dòng. API xác thực tệp đã tải lên, lưu trữ tệp, tạo bản ghi dịch và khởi tạo tác vụ nền. Sau đó, dịch vụ xử lý tệp sẽ xác định loại tài liệu và chọn đường dẫn thích hợp. Kiến trúc này cho phép hệ thống được mở rộng với các nhà cung cấp dịch thuật bổ sung hoặc các định dạng tài liệu mới trong tương lai.



Hình 1. Quy trình làm việc của hệ thống dịch tài liệu dựa trên AI được đề xuất với việc giữ nguyên định dạng gốc.

Đối với tài liệu DOCX, hệ thống trực tiếp xử lý cấu trúc tài liệu bằng cách lặp lại thông qua các đoạn văn, bảng biểu, đầu trang và chân trang. Vì DOCX có cấu trúc bên trong rõ ràng nên hệ thống có thể giữ nguyên hầu hết các kiểu, phong chữ, lề và cấu trúc bảng trong khi chỉ sửa đổi nội dung văn bản. Trước khi gửi văn bản đến nhà cung cấp dịch thuật, hệ thống sẽ áp dụng cơ chế Translation Guard để bảo vệ các thành phần không thể dịch được như URL, DOI, địa chỉ email, trích dẫn, công thức, ký hiệu kỹ thuật và đoạn mã. Cơ chế này đặc biệt quan trọng đối với các tài liệu học thuật và kỹ thuật vì việc dịch sai các yếu tố đó có thể làm thay đổi ý nghĩa ban đầu của chúng. Sau khi dịch, văn bản đã dịch được ghi lại vào tài liệu theo chế độ dịch đã chọn.

→Đối với tài liệu PDF, hệ thống sử dụng quy trình chuyển đổi trung gian: PDF→DOCX→dịch→phục hồi bố cục→PDF. Đầu tiên, tệp PDF được phân tích để xác định xem nó có chứa lớp văn bản hay không, liệu đó có phải là tài liệu được quét hay không và liệu nó có bao gồm bảng, hình ảnh hoặc bố cục trang phức tạp hay không. Nếu tệp được quét hoặc chứa văn bản dựa trên hình ảnh, OCR có thể được áp dụng để tạo lớp văn bản có thể xử lý. Sau đó, tệp PDF sẽ được làm sạch và chuyển đổi thành DOCX. Vì quá trình chuyển đổi PDF sang DOCX có thể tạo ra các vấn đề như đoạn văn bị phân mảnh, văn bản được hợp nhất, phát hiện bảng không chính xác hoặc giãn cách dòng bất thường nên hệ thống sẽ thực hiện bước dọn dẹp để hợp nhất các đoạn bị phân mảnh.

phân đoạn, bình thường hóa bố cục và giảm tiếng ồn trước khi dịch. Sau khi dịch, mô-đun Khôi phục bố cục được sử dụng để khôi phục bố cục tài liệu trước khi xuất kết quả trở lại PDF.

Hệ thống hỗ trợ ba chế độ dịch để đáp ứng các nhu cầu khác nhau của người dùng. Ở chế độ dịch tiêu chuẩn, văn bản gốc được thay thế bằng văn bản dịch, phù hợp khi người dùng chỉ cần tài liệu cuối cùng bằng ngôn ngữ đích. Ở chế độ dịch song ngữ song ngữ, hệ thống giữ nguyên văn bản gốc và đặt văn bản dịch vào cùng một đoạn văn, thường cách nhau bằng dấu “|” dấu phân cách, cho phép người dùng so sánh nhanh văn bản nguồn và văn bản đích. Ở chế độ dịch song ngữ từng dòng, hệ thống giữ lại đoạn văn gốc và chèn đoạn văn đã dịch ngay bên dưới. Chế độ này hữu ích cho việc học ngôn ngữ, đọc học thuật và kiểm tra bản dịch. Vì chế độ song ngữ làm tăng độ dài của tài liệu nên mục tiêu của việc khôi phục bố cục không phải là giữ nguyên số trang chính xác mà là đảm bảo rằng nội dung vẫn có thể đọc được, được sắp xếp chính xác, đầy đủ và không mắc các lỗi chồng chéo văn bản nghiêm trọng.

Thuật toán 1

đầu vào:

F: tài liệu đầu vào (. pdf hoặc . docx)

L: ngôn ngữ đích

P: nhà cung cấp dịch thuật (Google Translate, DeepL, Gemini)

M: chế độ dịch (chuẩn, song ngữ song ngữ, song ngữ từng dòng)

Tùy chọn: cài đặt tùy chọn như cấu hình OCR và dấu phân cách

Đầu ra:

F_out: tài liệu đã dịch với định dạng được giữ nguyên

BẮT ĐẦU

Xác thực tài liệu đầu vào F và ngôn ngữ đích L

NẾU phần mở rộng tệp của F không phải là . pdf
hoặc . docx THÌ Trả về lỗi định dạng tệp không
được hỗ trợ

KẾT THÚC NẾU

Lưu F để tải lên bộ nhớ
Tạo một công việc dịch nền
Trả lại job_id và status_url cho khách
hàng

Đặt trạng thái công việc thành in_progress

NẾU F là một tài liệu PDF THÌ
Phân tích cấu trúc PDF, bao gồm lớp văn bản, trang được quét, bảng và
hình ảnh

NẾU PDF được quét THÌ
Áp dụng OCR để tạo tệp PDF có thể
tìm kiếm NẾU OCR không thành công
ở chế độ nghiêm ngặt THÌ

Đặt trạng
thái công việc thành thất bại

Lỗi trả về
KẾT THÚC NẾU
KẾT THÚC NẾU

Làm sạch tài liệu PDF
Chuyển đổi tài liệu PDF sang DOCX Vệ
sinh tài liệu DOCX đã chuyển đổi

Trích xuất các đoạn văn, bảng, đầu trang và chân trang từ tài liệu DOCX
Áp dụng trình bảo vệ dịch thuật để bảo vệ URL, DOI, trích dẫn, công thức
và ký hiệu đặc biệt

Dịch nội dung trích xuất bằng nhà cung cấp P và chế độ M
Khôi phục bố cục tài liệu sau khi dịch

NẾU M là bản dịch chuẩn THÌ
Áp dụng bước sàng lọc bố cục cuối
cùng END IF

Chuyển đổi tài liệu DOCX đã dịch trở lại thành PDF
Thực hiện kiểm tra chất lượng trên bản PDF đầu ra

ELSE NẾU F là tài liệu DOCX THÌ

Mở tài liệu DOCX trực tiếp
Trích xuất các đoạn văn, bảng, đầu trang và chân trang
Áp dụng bảo vệ dịch thuật để bảo vệ nội dung đặc biệt
Dịch nội dung DOCX bằng nhà cung cấp P và chế độ M
Giữ nguyên kiểu dáng và cấu trúc tài liệu gốc
KẾT THÚC NẾU

Lưu tài liệu đã dịch để tải xuống bộ lưu trữ Đặt
trạng thái công việc thành đã hoàn thành

Trả về đường dẫn tải của F_out

NẾU có lỗi xảy ra THÌ
Đặt trạng thái công việc thành không thành công
với thông báo lỗi END IF

Khách hàng kiểm tra định kỳ

status_url	NẾU trạng thái công việc đã
hoàn thành THÌ	Tải tài
liệu đã dịch	KẾT THÚC NẾU

KẾT THÚC

Mã giả mô tả quy trình xử lý tổng thể của hệ thống được đề xuất. Đối với tài liệu DOCX, hệ thống xử lý trực tiếp các đoạn văn, bảng biểu, tiêu đề và

chân trang để dịch nội dung văn bản trong khi vẫn giữ nguyên định dạng ban đầu. Đối với tài liệu PDF, hệ thống sử dụng DOCX làm định dạng có thể chỉnh sửa trung gian bằng cách chuyển đổi PDF thành DOCX, dịch nội dung được trích xuất, khôi phục bố cục và xuất kết quả trở lại PDF. Trong quá trình dịch, hệ thống hỗ trợ 3 chế độ: dịch tiêu chuẩn, dịch song ngữ song ngữ và dịch song ngữ từng dòng. Ngoài ra, các yếu tố đặc biệt như URL, DOI, trích dẫn, công thức và ký hiệu kỹ thuật được bảo vệ để ngăn chặn việc dịch sai nội dung không thể dịch được.

Sau khi hoàn tất dịch và khôi phục bố cục, hệ thống xuất tệp đầu ra theo loại tài liệu gốc. Nếu tệp đầu vào là DOCX, hệ thống sẽ trả về tệp DOCX đã dịch. Nếu tệp đầu vào là PDF, hệ thống sẽ chuyển đổi DOCX đã dịch trở lại PDF và thực hiện kiểm tra chất lượng đầu ra. Bước kiểm tra này nhằm mục đích phát hiện các lỗi nghiêm trọng như thiếu nội dung, thiếu bảng, thiếu hình ảnh hoặc các vấn đề về bố cục ảnh hưởng đến khả năng đọc. Tệp cuối cùng được lưu trong thư mục tải xuống và đường dẫn tải xuống sẽ được trả lại cho người dùng sau khi trạng thái công việc thay đổi thành hoàn thành.

4 thí nghiệm

Các thử nghiệm được thực hiện nhằm đánh giá hệ thống từ hai góc độ chính: bảo toàn định dạng sau dịch và chất lượng nội dung dịch. Việc tách biệt hai nhóm đánh giá này là cần thiết bởi việc dịch tài liệu không chỉ phụ thuộc vào chất lượng ngôn ngữ mà còn phụ thuộc vào khả năng bảo toàn cấu trúc hình ảnh nguyên bản của tài liệu. Bản dịch có thể đúng về mặt ngữ nghĩa nhưng vẫn thất bại trong thực tế nếu nó làm mất bảng, thay đổi bố cục hoặc tạo ra tệp đầu ra không thể đọc được. Ngược lại, một tài liệu có thể giữ nguyên định dạng tốt nhưng bản dịch vẫn có thể không đầy đủ nếu nó không tự nhiên hoặc sử dụng thuật ngữ không chính xác.

Thí nghiệm được tiến hành trên máy tính Acer Nitro AN515-45 chạy Microsoft Windows 11 Home Single Language 64-bit. Máy sử dụng vi xử lý AMD Ryzen 55600H với bộ xử lý Radeon Graphics, với 12 bộ xử lý logic tốc độ xấp xỉ 3,3 GHz, trên kiến trúc PC dựa trên x64. Hệ thống được trang bị 8GB RAM và DirectX 12. Môi trường phát triển sử dụng Python cùng với khung FastAPI ở phần phụ trợ để nhận yêu cầu dịch tài liệu, quản lý công việc xử lý nền và trả về tệp đầu ra cho người dùng. Giao diện người dùng được triển khai bằng HTML, CSS và JavaScript. Để xử lý tài liệu, hệ thống sử dụng pdf2docx để chuyển đổi PDF sang DOCX, thư viện xử lý DOCX để xử lý đoạn văn, bảng, đầu trang và chân trang, Tesseract OCR cho tài liệu được quét hoặc hình ảnh nhúng và công cụ chuyển đổi DOCX sang PDF để tạo bản dịch PDF đầu ra cuối cùng. Các nhà cung cấp dịch vụ dịch thuật được sử dụng trong thử nghiệm bao gồm Google Translate, DeepL Translator và Gemini 2.5 Flash.

Dữ liệu thử nghiệm bao gồm các tài liệu học thuật DOCX và PDF chứa các tiêu đề, đoạn văn, bảng, hình ảnh và bố cục trang. Các tài liệu này được xử lý bằng ba chế độ dịch: dịch tiêu chuẩn, dịch song ngữ song ngữ và dịch song ngữ từng dòng. Để đánh giá định dạng, hệ thống xem xét các tiêu chí sau: Tiêu đề, Văn bản/Phong cách, Bảng, Bố cục và Không

Tiêu đề đóng góp (rút ngắn nếu dài quá) 9

tràn. Các thước đo tiêu đề xem tiêu đề và phân cấp phần có được giữ nguyên hay không. Văn bản/Phong cách đánh giá xem phông chữ, đoạn văn và cách trình bày văn bản có còn đọc được hay không. Bảng đo xem cấu trúc bảng có được bảo tồn hay không. Bố cục phản ánh tổ chức trang tổng thể. No Overflow đo lường xem tài liệu đầu ra có tránh được tình trạng tràn hoặc chồng chéo văn bản nghiêm trọng hay không. Các lỗi nhỏ có thể được sửa theo cách thủ công, chẳng hạn như dịch chuyển dòng nhẹ hoặc tăng trang tự nhiên do văn bản dịch dài hơn gây ra, không được coi là lỗi nghiêm trọng nếu chúng không ảnh hưởng đến khả năng đọc.

Điểm AVG được tính bằng giá trị trung bình số học của năm tiêu chí đánh giá định dạng: Tiêu đề, Văn bản/Phong cách, Bảng, Bố cục và Không tràn. Giá trị AVG cao hơn cho thấy khả năng bảo toàn định dạng và khả năng đọc đầu ra tốt hơn.

so sánh tương đối giữa các kết quả dịch máy hơn là kết luận tuyệt đối về chất lượng bản dịch.

Nhìn chung, kết quả thử nghiệm cho thấy hệ thống đề xuất hoạt động tốt đối với tài liệu DOCX và đạt được kết quả đầy hứa hẹn đối với tài liệu PDF. Sự khác biệt giữa hiệu suất DOCX và PDF đến từ đặc điểm cấu trúc của từng định dạng. DOCX cho phép xử lý trực tiếp các thành phần văn bản và định dạng, trong khi PDF yêu cầu một số bước chuyển đổi trung gian, điều này làm tăng khả năng xảy ra lỗi định dạng. Đối với chế độ dịch song ngữ, độ dài tài liệu và số trang có thể tăng lên do cả nguồn và văn bản dịch đều được giữ lại. Đây không được coi là lỗi định dạng miễn là tài liệu vẫn có thể đọc được, đầy đủ và không bị chùng chéo văn bản nghiêm trọng.

& Bên cạnh những kết quả đạt được, hệ thống vẫn còn một số hạn chế cần được cải thiện thêm. Đường dẫn PDF→DOCX→dịch→PDF không thể đảm bảo định dạng hoàn hảo cho tất cả các loại tài liệu PDF, đặc biệt là các tài liệu có bố cục nhiều cột, bảng phức tạp, công thức toán học hoặc thiết kế xuất bản trên máy tính để bàn chuyên nghiệp. Ngoài ra, các tệp PDF được quét phụ thuộc rất nhiều vào chất lượng OCR; nếu hình ảnh bị mờ, lệch, nhiễu hoặc sử dụng phông chữ không bình thường, lỗi OCR có thể ảnh hưởng đến chất lượng bản dịch. Vì BLEU trong nghiên cứu này được sử dụng trong cài đặt đầu ra chéo do không có tập dữ liệu dịch tham chiếu được xem xét thủ công hoàn chỉnh nên công việc trong tương lai nên xây dựng tập dữ liệu tham chiếu và kết hợp các số liệu bổ sung như METEOR, TER và COMET để đánh giá toàn diện hơn (Banerjee & Lavie, 2005; Snover và cộng sự, 2006; Rei và cộng sự, 2020).

5 Kết luận

Nghiên cứu này đề xuất và phát triển hệ thống dịch tài liệu dựa trên AI với tính năng giữ nguyên định dạng gốc cho hai định dạng tài liệu chính là DOCX và PDF. Hệ thống hỗ trợ 3 chế độ dịch: dịch tiêu chuẩn, dịch song ngữ song ngữ và dịch song ngữ từng dòng. Nó cũng cho phép người dùng chọn các nhà cung cấp dịch thuật khác nhau, bao gồm Google Translate, DeepL Translator và Gemini 2.5 Flash. Đối với tài liệu DOCX, hệ thống xử lý trực tiếp các thành phần có cấu trúc như đoạn văn, bảng, đầu trang và chân trang. Đối với tài liệu PDF, hệ thống sử dụng quy trình aPDF→DOCX→translation→layout recovery→PDF để tận dụng khả năng chỉnh sửa DOCX và cải thiện việc bảo toàn định dạng.

Kết quả thử nghiệm cho thấy hệ thống đạt được khả năng bảo toàn định dạng rất mạnh cho tài liệu Word và mang lại kết quả đầy hứa hẹn cho tài liệu PDF. Các chế độ dịch song ngữ rất hữu ích giúp người dùng so sánh nội dung gốc với nội dung dịch, đặc biệt trong học tập, nghiên cứu, kiểm tra thuật ngữ. Về chất lượng dịch thuật, BLEU Mean và BLEUStd cho thấy các nhà cung cấp dịch thuật đã đạt được kết quả tương đối gần nhau trên tập dữ liệu thử nghiệm, trong đó Gemini 2.5 Flash đạt điểm cao nhất trong thử nghiệm BLEU đầu ra chéo. Tuy nhiên, để đánh giá chất lượng bản dịch chính xác hơn, nghiên cứu trong tương lai nên xây dựng các bản dịch tham chiếu được xem xét thủ công và kết hợp các thước đo đánh giá bổ sung.

Trong công việc tương lai, hệ thống có thể được cải thiện theo nhiều hướng. Đầu tiên, quá trình xử lý PDF có thể được nâng cao bằng cách cải thiện khả năng phân tích bố cục, nhận dạng bảng và khôi phục bố cục sau dịch. Thứ hai, chất lượng OCR cần được cải thiện để quét

PDFs and embedded images. Third, a domain-specific glossary can be added to ensure terminology consistency in academic and technical documents. Finally, support for additional formats such as PPTX, XLSX, and HTML can be developed to broaden the practical applicability of the system.

References

- &1. Bahdanau, D., Cho, K.,&Bengio, Y.(2015). *Neural machine translationbyjointly learning to align and translate*International Conference on Learning Representations. <https://arxiv.org/pdf/1409.0473>
2. Banerjee, S., &Lavie, A.(2005). *METEOR: An automatic metric forMTEvaluation with improved correlation with human judgments*Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization, 65–72. <https://aclanthology.org/W05-0909.pdf>
3. Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C.,Amodei, D.(2020). *Language models are few-shot learners*Advances in Neural Information Processing Systems, 33, 1877–1901. <https://arxiv.org/pdf/2005.14165>
4. Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Gonzalez, G. M., Hansanti, P., Hoffman, J., . Wang, J. (2022). *No language left behind: Scaling human-centered machine translation*arXiv preprint arXiv: 2207.04672. <https://arxiv.org/pdf/2207.04672>
- &5. Devlin, J., Chang, M.-W., Lee, K.,&Toutanova, K.(2019). *BERT: Pre-training of deep bidirectional transformers for language understanding*Proceedings of NAACL-HLT, 4171–4186. <https://aclanthology.org/N19-1423.pdf>
- &6. Jaume, G., Ekenel, H. K.,&Thiran, J.-P.(2019). *FUNSD: A dataset for form understanding in noisy scanned documents*International Conference on Document Analysis and Recognition Workshops. <https://arxiv.org/pdf/1905.13538>
7. Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Hermann, U., Aji, A. F., Bogoychev, N., Martins, A. F. T.,&&Bach duong, A.(2018). *Marian: Dịch máy thần kinh nhanh trong Kỹ yếu C++ của ACL*Trình diễn hệ thống, 116–121. <https://aclanthology.org/P18-4020.pdf>
8. Koehn, P. (2020). *Neural machine translation* Cambridge University Press. <https://arxiv.org/pdf/1709.07809>
9. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, &M., Yih, W., Rocktäschel, T., Riedel, S.,&Kiela, D.(2020). *Tăng cường truy xuất tạo ra các nhiệm vụ NLP chuyên sâu về kiến thức. Những tiến bộ trong Thông tin thần kinh* Hệ thống xử lý, 33, 9459–9474. <https://arxiv.org/pdf/2005.11401>
- &10. Li, M., Xu, Y., Cui, L., Huang, S., Wei, F., Li, Z.,&Zhou, M.(2020). *DocBank: A tập dữ liệu chuẩn để phân tích bố cục tài liệu Kỹ yếu của Quốc tế lần thứ 28* Hội thảo về Ngôn ngữ học tính toán, 949–960. <https://aclanthology.org/2020.coling-chinh.82.pdf>
11. Lin, C.-Y.(2004). *ROUGE: A package for automatic evaluation of summaries* Kỹ yếu Hội thảo về Tóm tắt văn bản Branches Out, 74–81. <https://aclanthology.org/W04-1013.pdf>

&12. Mathew, M., Karatzas, D.,&Jawahar, C. V.(2021). DocVQA: A dataset for VQA on document imagesProceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2200–2209.

&

https://openaccess.thecvf.com/content/WACV2021/papers/Mathew_DocVQA_A_Dataset_for_VQA_on_Document_Imagespaper.pdf

13. Papineni, K., Roukos, S., Ward, T.,&Zhu, W.-J.(2002). BLEU: A method for automatic evaluation of machine translationProceedings of the 40th Annual Meeting of the Association for Computational Linguistics, 311–318. <https://aclanthology.org/P02-1040.pdf>

14. Post, M.(2018). A call for clarity in reporting BLEU scoresProceedings of the Third Conference on Machine Translation, 186–191. <https://aclanthology.org/W18-6319.pdf>

15. Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., & Liu, P. J.(2020). Exploring the limits of transfer learning with a unified text-to-text transformer Journal of Machine Learning Research, 21(140), 1–67.

<https://jmlr.org/papers/volume21/20-074/20-074.pdf>

16. Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). COMET: A neural framework for machine translation evaluationProceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, 2685–2702.

<https://aclanthology.org/2020.emnlp-main.213.pdf>

17. Smith, R.(2007). An overview of the Tesseract OCR engineProceedings of the International Conference on Document Analysis and Recognition, 629–633.

&

<https://research.google.com/pub/archive/33418.pdf>

18. Snover, M., Dorr, B., Schwartz, R., Micciulla, L.,&Makhoul, J.(2006). A study of translation edit rate with targeted human annotationProceedings of the Association for Machine Translation in the Americas, 223–231. <https://aclanthology.org/2006.amta-papers.25.pdf>

19. Stahlberg, F.(2020). Neural machine translation: A reviewJournal of Artificial Intelligence Research, 69, 343–418. <https://arxiv.org/pdf/1912.02047>

20. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I.(2017). Attention is all you needAdvances in Neural Information Processing Systems, 30. <https://arxiv.org/pdf/1706.03762>

21. Wu, Y., Schuster, M., Chen, Z., Le, Q. V., Norouzi, M., Macherey, W., Krikun, M., Cao, Y., Gao, Q., Macherey, K., Klingner, J., Shah, A., Johnson, M., Liu, X., Kaiser, Ł., Gouws, S., Kato, Y., Kudo, T., Kazawa, H.,Dean, J.(2016). Google’s neural machine translation system: Bridging the gap between human and machine translationarXiv preprint arXiv: 1609.08144. <https://arxiv.org/pdf/1609.08144>

22. Xu, Y., Li, M., Cui, L., Huang, S., Wei, F., & Zhou, M. (2020). LayoutLM: Pre-training of text and layout for document image understandingProceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1192–1200.

&

<https://arxiv.org/pdf/1912.13318>

23. Xu, Y., Xu, Y., Lv, T., Cui, L., Wei, F., Wang, G., Lu, Y., Florencio, D., Zhang, C., Che, W., Zhang, M., Zhou, L., Huang, Q.,&Zhou, M. (2021). LayoutLMv2: Multi-modal pre-training for visually-rich document understandingProceedings of the Annual Meeting of the Association for Computational Linguistics. <https://aclanthology.org/2021.acl-long.201.pdf>

24. Zhong, X., Tang, J., & Yepes, A. J. (2019). PubLayNet: Largest dataset ever for document

layout analysisProceedings of the International Conference on Document Analysis and Recognition, 1015–1022. <https://arxiv.org/pdf/1908.07836>