

DSC2F: Hệ thống phát hiện hình ảnh đa phương thức do AI tạo ra sử dụng mạng thần kinh tích chập luồng kép với khả năng biến đổi Fourier nhanh

Trí-Vinh Nguyen<sup>1</sup>, Ngô-Hồ Anh-Khoa<sup>1</sup>, và Ngô-Hồ Anh-Khoi<sup>1\*</sup>

<sup>1</sup> FACULTY OF INFORMATION TECHNOLOGY, Đại học Nam Cần Thơ,  
168 Nguyễn Văn Cừ, Phường An Bình, Thành phố Cần Thơ, Việt Nam  
vinh225312@nctu.edu.vn, nhakhoa@nctu.edu.vn,  
nhakhoi@nctu.edu.vn

Trừu tượng. Sự tiến bộ nhanh chóng của các mô hình tổng quát, bao gồm GAN và kiến trúc dựa trên khuếch tán, đã khiến hình ảnh do AI tạo ra ngày càng không thể phân biệt được với ảnh thật, đặt ra những thách thức quan trọng đối với pháp y kỹ thuật số và xác minh phương tiện truyền thông. Bài báo này đề xuất một hệ thống phát hiện CNN Dual-Stream, được gọi là DualStreamCNNEnhanced hoặc DSCNNE, xử lý hình ảnh thông qua hai nhánh song song: Luồng không gian phân tích các tính năng RGB và Luồng tần số phân tích phổ biên độ FFT. Cơ chế Chú ý đa phương thức kết hợp hai vectơ đặc trưng 512 chiều trước khi bộ phân loại Entropy chéo nhị phân tạo ra dự đoán cuối cùng. Mô hình nâng cao tích hợp 30 bộ lọc thông cao SRM, mô-đun chú ý CBAM, Khối SE và đường trục kiểu ResNet, tổng cộng khoảng 7,8 triệu tham số.

Cả đường cơ sở (DualStreamCNN, thông số 3,7M) và mô hình đề xuất đều được đào tạo trên CIFAKE (120.000 hình ảnh) và đánh giá ảnh không chụp trên tập dữ liệu ArtiFact (20.000 hình ảnh, hơn 13 trình tạo). Đánh giá không bắt cho thấy hiệu suất gần như có thể xảy ra trên tất cả các kiểu máy (độ chính xác 49–51%), cho thấy mức độ nghiêm trọng

khoảng cách khái quát hóa từ đào tạo máy phát điện đơn đến đánh giá nhiều máy phát điện. Thuật toán của chúng tôi đạt được dự đoán cân bằng nhất với AccF = 53,75% và AUC = 51,01%, đồng thời giảm cảnh

báo sai trên hình ảnh thực so với đường cơ sở. Những kết quả này nêu bật tầm quan trọng đặc biệt của việc đào tạo nhiều máy phát điện để triển khai mạnh mẽ trong thế giới thực và thúc đẩy công việc đào tạo trong tương lai với các bộ dữ liệu đa dạng như ArtiFact và GenImage.

Từ khóa: Phát hiện hình ảnh AI, CNN luồng kép, Phân tích tần số, Cơ chế chú ý, Pháp y kỹ thuật số.

## GIỚI THIỆU

Sự tiến bộ nhanh chóng của các mô hình tổng hợp hình ảnh dựa trên Mạng đối thủ sáng tạo (GAN) và Mô hình khuếch tán, bao gồm ProGAN, StyleGAN, Stable Diffusion, DALL-E 3 và Midjourney, đã tạo ra những thách thức nghiêm trọng trong việc xác minh tính xác thực của hình ảnh kỹ thuật số. Chất lượng của AI tổng hợp hình ảnh hiện đã vượt quá ngưỡng phân biệt thị giác của con người, tạo ra nhu cầu cấp thiết về các công cụ phát hiện đáng tin cậy trong bối cảnh truyền thông, pháp lý và an ninh quốc gia.

Phương pháp phát hiện thụ động, phân tích trực tiếp nội dung pixel mà không dựa vào siêu dữ liệu hình ảnh, mang lại những lợi thế đáng kể về tính độc lập và khả năng triển khai ngoại tuyến. Thuật toán của chúng tôi được đề xuất kế thừa có chọn lọc từ bốn hướng nghiên cứu (miền không gian, miền tần số, cơ chế chú ý, kiến trúc xương sống) và bổ sung chiến lược đánh giá zero-shot trên tập dữ liệu ArtiFact, thể hiện kịch bản thực tế và thách thức nhất để phát hiện nội dung AI trên nhiều trình tạo khác nhau.

Kiến trúc luồng kép với sự chú ý đa phương thức: Chúng tôi đề xuất DSCNNE, một khung phát hiện nâng cao có hiệu quả tích hợp các tính năng cấp pixel không gian với miền tần số tạo tác (phổ biên độ FFT). Cơ chế Chú ý đa phương thức hai chiều được giới thiệu để tự động kết hợp các tính năng từ cả hai luồng, cho phép mô hình tập trung vào nhiều nhất tín hiệu phân biệt để phát hiện AI. Tích hợp SRM và Mô-đun chú ý: Chúng tôi nâng cao xương sống CNN tiêu chuẩn bằng cách kết hợp 30 bộ lọc thông cao Mô hình phong phú Steganalysis (SRM) để khuếch đại các mẫu nhiễu vi mô và Mô-đun chú ý khối tích chập (CBAM) để tinh chỉnh tính năng không gian và kênh thông minh đại diện. Sự kết hợp này cải thiện đáng kể

phát hiện GAN tinh vi và các tạo tác dựa trên khuếch tán.

Phân tích tổng quát và đánh giá thực nghiệm mạnh mẽ: Chúng tôi cung cấp đánh giá không bias toàn diện trên điểm chuẩn ArtiFact (Awsaf và cộng sự, 2023), một tập dữ liệu quy mô lớn bao gồm 13 trình tạo trở lên trong năm danh mục ngữ nghĩa. Tất cả các mô hình đều đạt được hiệu suất gần như ngẫu nhiên (độ chính xác 49–51%), bộc lộ khoảng cách khái quát hóa quan trọng từ đào tạo CIFAKE một máy phát điện đến đa dạng

máy phát điện trong thế giới thực. Bản thân kết quả tiêu cực này là một đóng góp có ý nghĩa, nêu bật những hạn chế của các phương pháp phát hiện hiện tại. Phân tích khoảng cách khái quát hóa trong thế giới thực: Không giống như nhiều nghiên cứu hiện có đánh giá về cùng một phân phối như đào tạo, chúng tôi thử nghiệm zero-shot trên ArtiFact, chứa các hình ảnh từ

máy phát điện không được nhìn thấy trong quá trình đào tạo. AUC gần như có khả năng xảy ra trên tất cả các mô hình (49–51%) xác nhận rằng việc đào tạo lại các bộ dữ liệu nhiều máy phát điện là điều cần thiết để triển khai thực tế.

## CÔNG VIỆC LIÊN QUAN

Lĩnh vực phát hiện hình ảnh do AI tạo ra đã phát triển song song với tốc độ phát triển mô hình tổng hợp hình ảnh. Hai

phương pháp tiếp cận cơ bản tồn tại: phát hiện thụ động và tích cực xác minh xuất xứ. Về mặt phát hiện thụ động, các công cụ SaaS thương mại như Hype Lense, AI or Not, Illuminarty và Hive Moderation phân tích trực tiếp nội dung pixel hình ảnh. Về mặt tích cực, Adobe triển khai Sáng kiến xác thực nội dung (CAI)

tuân theo tiêu chuẩn C2PA để nhúng siêu dữ liệu được ký bằng mật mã vào tệp hình ảnh, trong khi Google SynthID nhúng hình mờ kỹ thuật số vào pixel của hình ảnh do Imagen tạo ra một cách vô hình.

Vương và cộng sự. (2020) đã thiết lập nền tảng quan trọng nhất để phát hiện hình ảnh GAN: một bộ phân loại nhị phân CNN đơn giản, được đào tạo riêng về hình ảnh ProGAN, tổng quát hóa đáng kể cho hàng chục kiến trúc GAN chưa được nhìn thấy (StyleGAN, BigGAN, CycleGAN,

StarGAN) với AUC trung bình vượt quá 99%, nhờ vào dữ liệu chiến lược tăng cường kết hợp làm mờ Gaussian và nén JPEG ngẫu nhiên. Zhang và cộng sự. (2019) đề xuất AutoGAN để mô phỏng và phát hiện đặc điểm giả tạo của GAN tiêu chuẩn

đường ống, chứng minh rằng một máy dò có mục đích chung có thể được chế tạo bằng cách khai thác các tính năng chung của quy trình tổng hợp AI thay vì xây dựng các máy dò dành riêng cho máy phát điện.

Frank và cộng sự. (2020) đã ảnh hưởng trực tiếp đến thiết kế của Luồng Tần số. Các tác giả đã phát hiện ra rằng hình ảnh GAN chứa các thành phần giả rõ ràng trong miền tần số mà mắt người không nhìn thấy được: phép toán tích chập chuyển vị, được sử dụng rộng rãi trong bộ giải mã GAN để lấy mẫu lại, tạo ra mẫu bàn cờ trong phổ tần số ở dạng các đỉnh năng lượng cách đều nhau theo chu kỳ, trong khi thực

hình ảnh thể hiện phổ giảm dần từ trung tâm đến ngoại vi. Frank và cộng sự. (2020) đã xây dựng bộ phân loại chỉ dựa trên phổ FFT và đạt được AUC cao trên nhiều GAN kiến trúc, chứng minh rằng miền tần số cung cấp các tín hiệu phân biệt bổ sung và độc lập với miền không gian, tạo thành cơ sở lý thuyết trực tiếp cho các công thức biến đổi FFT trong hệ thống đề xuất.

Qian và cộng sự. (2020) đã mở rộng phân tích miền tần số để đối mặt với khả năng phát hiện deepfake trong Suy nghĩ theo tần số. Các tác giả đã đề xuất mô-đun F3Net, sử dụng Biến đổi Cosine rời rạc (DCT) thay vì FFT, khai thác hai loại tính năng: thành phần hình ảnh phân rã nhận biết tần số và thống kê tần số cục bộ, kết hợp thông qua cơ chế chú ý chéo để phát hiện các vùng khuôn mặt bị thao túng. Nataraj và cộng sự. (2019) đã đề xuất một cách tiếp cận khác biệt: sử dụng ma trận xuất hiện trực tiếp trên các kênh pixel RGB để nắm bắt mối tương quan thống kê giữa các pixel lân cận, khai thác sự khác biệt về cấu trúc tương quan pixel giữa ảnh thật và ảnh GAN do quá trình tổng hợp GAN có xu hướng tạo ra các mẫu tương quan pixel không tự nhiên so với ảnh thật.

Sự xuất hiện của Mô hình xác suất khuếch tán khử nhiễu hoặc DDPM (Ho và cộng sự, 2020) và các biến thể cải tiến của chúng (Dhariwal & Nichol, 2021; Rombach và cộng sự, 2022; Song và cộng sự, 2021) đã đã làm gián đoạn toàn bộ lĩnh vực phát hiện hình ảnh AI. Không giống như GAN để lại các mẫu bàn cờ rõ ràng trong miền tần số, mô hình khuếch tán tổng hợp hình ảnh thông qua quá trình khử nhiễu lặp đi lặp lại, tạo ra phổ tần số tự nhiên hơn và khó phân biệt hơn đáng kể. Hồ và cộng sự. (2020) giới thiệu DDPM với cơ chế khuếch tán thuận và ngược; Bài hát và cộng sự. (2021) đề xuất DDIM cho phép tổng hợp nhanh hơn mà không làm giảm chất lượng; và Rombach và cộng sự. (2022) nâng cao hơn nữa các mô hình khuếch tán với Mô hình khuếch tán tiềm ẩn, cơ sở kỹ thuật của Ổn định Khuếch tán, cho phép tổng hợp hình ảnh có độ phân giải cao với chi

phí tính toán hợp lý.

Anh ấy và cộng sự. (2016) đã giải quyết vấn đề suy giảm độ chính xác bằng cách tăng độ sâu mạng thông qua việc bỏ qua các kết nối trong ResNet, cho phép đào tạo mạng sâu hàng trăm lớp. Woo và cộng sự. (2018) đề xuất CBAM, một mô-đun chú ý nhẹ có thể chèn được



vào bất kỳ kiến trúc CNN nào, hoạt động theo hai giai đoạn tuần tự: sự chú ý của kênh xác định các kênh tính năng quan trọng nhất bằng cách kết hợp Nhóm trung bình toàn cầu và Nhóm tối đa toàn cầu thông qua MLP; tiếp theo là sự chú ý về không gian nhằm xác định các vùng không gian cần tập trung bằng cách kết hợp hai hoạt động gộp kênh thông minh.

Hệ thống CNN detect kế thừa có chọn lọc cả 4 hướng nghiên cứu: kiến trúc luồng kép kết hợp phân tích không gian (Wang và cộng sự, 2020) với phân tích tần số (Frank và cộng sự, 2020); Bộ lọc SRM để phát hiện tạo tác ở cấp độ pixel; CBAM (Woo

et al., 2018) để tập trung vào kênh và không gian; và Chú ý đa phương thức để hợp nhất thông tin đa phương thức. Điểm khác biệt chính là chiến lược đánh giá bổ sung trên hình ảnh CIFAR-10 hoàn toàn thực để đo FPR trong kịch bản triển khai thực tế nhất.

## Thuật toán đề xuất

Các thuật toán của chúng tôi, được gọi là DualStreamCNNEnhanced hoặc DSCNNE, được xây dựng trên kiến trúc CNN Dòng kép, xử lý hình ảnh song song thông qua hai nhánh độc lập: Luồng không gian phân tích các đặc điểm không gian RGB và Luồng tần số phân tích phổ biên độ FFT. Hai vector đặc trưng 512 chiều được hợp nhất thông qua Chú ý chéo phương thức trước bộ phân loại MLP. thuật toán của chúng tôi bổ sung thêm trên đường cơ sở: 30 bộ lọc thông cao SRM, mô-đun CBAM, Khối SE bên trong EnhanceResidualBlocks và đường trục được tăng cường ResNet, tổng cộng ~ 7,8 triệu tham số.

Hình 1. Sơ đồ kiến trúc tổng quan của thuật toán của chúng tôi.

Hình 1 minh họa quy trình xử lý tổng thể của thuật toán của chúng tôi. Hình ảnh đầu vào trước tiên được chuyển đổi sang thang độ xám và được xử lý bằng 30 bộ lọc thông cao SRM (Mô hình phong phú

Steganalysis) để trích xuất dư lượng nhiễu. Đồng thời, Biến đổi Fourier nhanh 2D (FFT) tạo ra phổ biên độ miền tần số. Luồng không gian (nhánh trái) cung cấp các tính năng RGB và SRM thông qua xương sống EnhanceResidualBlock với sự chú ý của CBAM, tạo ra

một vectơ đặc trưng không gian 512 chiều. các

Luồng tần số (nhánh phải) xử lý FFT thang đo log biên độ thông qua đường trục CNN song song, cũng mang lại vectơ đặc trưng tần số 512 chiều. Sau đó, mô-đun Chú ý đa phương thức hai chiều sẽ kết hợp cả hai luồng, cho phép mỗi nhánh cân nhắc có chọn lọc các tín hiệu mang tính thông tin nhất từ nhánh kia. Hai vectơ tham dự 512 chiều được ghép nối thành một biểu diễn khớp 1024 chiều, được đưa đến bộ phân loại MLP đưa ra dự đoán nhị phân: thực (0) hoặc giả do AI tạo ra (1).

Chuyển đổi thang độ xám.

$$G = 0,299 \cdot R + 0,587 \cdot G + 0,114 \cdot B \quad (1)$$

trong đó G là đầu ra thang độ xám; R, G, B là các giá trị pixel kênh màu đỏ, xanh lục và xanh lam; các hệ số 0,299, 0,587 và 0,114 là trọng số độ chói tiêu chuẩn (ITU-R BT.601).

Biến đổi Fourier rời rạc 2D.

$$F_{u,v} = xyl(x,y) \cdot \exp\left\{j2\pi\left(-i2x(uxW+vyH)\right)\right\} \quad (2)$$

Phổ biên độ quy mô log.

$$M = \log(1+|F|) \quad (3)$$

trong đó  $A(u,v)$  là biên độ thang log ở tần số  $(u,v)$ ;  $F(u,v)$  là hệ số DFT phức; hoạt động nhật ký (1+) nén phạm vi động, làm cho các thành phần giả tần số cao tinh vi trở nên rõ ràng hơn đối với trình trích xuất tính năng CNN tiếp theo.

Luồng không gian (EnhancedSpatialStream) xử lý đầu vào RGB thông qua Khối gốc (Conv 7×7/stride=2, BN, ReLU, MaxPool) sau đó thông qua ba EnhanceResidualBlocks với mức tăng dần số kênh là 64→128→256→512, theo sau là CBAM. Mỗi EnhanceResidualBlock tích hợp một Khối SE (reduction=16) sau lần

tích chập thứ hai, với kết nối bỏ qua Chuyển đổi  $1 \times 1$  khi kích thước thay đổi. Đầu ra:  $F_{\text{spatial}} \in \mathbb{R}^{(B \times 512)}$  thông qua Global Average Pooling và Flatten.

Luồng tần số (Luồng tần số nâng cao) trích xuất các tính năng đa quy mô từ phổ FFT kênh đơn thông qua ba nhánh song song: Chuyển đổi  $7 \times 7$  (tần số thấp, tạo tác toàn cầu), Chuyển đổi  $5 \times 5$  (tần số trung bình) và Chuyển đổi  $3 \times 3$  (tần số cao, chi tiết cục bộ), mỗi kênh tạo ra 32 kênh. Ba đầu ra được nối thành 96 kênh, sau đó được xử lý qua ba Khối chuyển đổi  $\rightarrow$  BN  $\rightarrow$  ReLU  $\rightarrow$  CBAM ( $96 \rightarrow 128 \rightarrow 256 \rightarrow 512$ ). Thiết kế đa quy mô này đồng thời nắm bắt được toàn cầu và địa phương cấu trúc tần số Đầu ra:  $F_{freq} \in \mathbb{R}(B \times 512)$ .

Sự chú ý đến kênh sẽ hiệu chỉnh lại  $X$  dọc theo thứ nguyên kênh:

$$\alpha = \text{SigmoidFC2ReLUFC1AgvPoolX} + \text{FC2ReLUFC1MaxPoolX} \quad (4)$$

trong đó  $\alpha \in \mathbb{R}^C$  là vector chú ý của kênh;  $z_{avg}$  và  $z_{max}$  là các vector đặc trưng được gộp trung bình và tối đa toàn cầu trên các kích thước không gian;  $FC_1$  và  $FC_2$  là các lớp được kết nối đầy đủ với bottleneck reduction ratio  $r=16$ ; ReLU is the activation; and  $\sigma$  is the sigmoid function.

Chú ý không gian sẽ hiệu chỉnh lại  $X$  dọc theo các vị trí không gian:

$$\beta = \text{SigmoidConv7} \times 7 \text{MeanChannelX; MaxChannelX} \quad (5)$$

trong đó  $\beta \in \mathbb{R}^{(H \times W)}$  là bản đồ chú ý không gian; MeanChannel và MaxChannel áp dụng tổng hợp trung bình và tối đa theo kênh cho produce two spatial maps;  $\text{Conv}_{7 \times 7}$  is a  $7 \times 7$  convolution; and  $\sigma$  is the sigmoid function. The output  $X_{out} = \beta \otimes X$  recalibrates each spatial location.

Không gian tham dự tần số:

$Q_s = F$  không gian tuyến tính,  $K_f = F_{freq}$  tuyến tính,  $V_f = F_{freq}$  tuyến tính

$$\text{attn} = \text{Sigmoid}Q_s \times K_f 512 \quad F_{spatial\_enh} = F_{spatial} + \text{attn} \times V_f \quad (6)$$

trong đó  $Q_s$ ,  $K_f$ ,  $V_f$  là các phép chiếu truy vấn, khóa và giá trị của các đặc tính không gian và tần số thông qua các lớp tuyến tính đã học;  $d_k$

là thứ nguyên chính được sử dụng để chia tỷ lệ;  $\text{softmax}(\cdot)$  tạo ra trọng số chú ý trên chuỗi tính năng tần số; và  $\text{Fspatial\_enhis}$  tăng cường sự thể hiện không gian sau sự chú ý đa phương thức.

Tần số tham dự vào không gian một cách đối xứng. Các kết nối còn lại đảm bảo sự ổn định trong quá trình luyện tập. Hai vectơ tăng cường là nối.

$$F_{\text{combined}} = [F_{\text{spatial\_enh}}; F_{\text{freq\_enh}}] \in \mathbb{R}^{B \times 1024} \quad (7)$$

where  $F_{\text{spatial\_enh}}$  and  $F_{\text{freq\_enh}}$  are the cross-attention-enhanced spatial and frequency representations (each  $\in \mathbb{R}^{B \times 512}$ );  $[\cdot; \cdot]$  denotes channel-wise concatenation; and  $F_{\text{combined}} \in \mathbb{R}^{B \times 1024}$  is the joint multimodal representation fed to the MLP classifier.

Trình phân loại MLP xử lý  $F_{\text{combined}}$  thông qua các lớp sau.

$$\text{Tuyến tính}(1024 \rightarrow 1024) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0,5)$$

(8) Lớp nén đầu tiên.

$$\text{Tuyến tính}(1024 \rightarrow 512) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0,5) \quad (9)$$

Lớp nén thứ hai.

$$\text{Tuyến tính}(512 \rightarrow 256) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0,25)$$

(10) Lớp đầu ra.

$$\text{Tuyến tính}(256 \rightarrow 1) \rightarrow \text{logit } Y \quad (11)$$

Tại suy luận.

$$\text{Sigmoid}(Y) \rightarrow P(\text{FAKE}) \in [0,1] \quad (12)$$

where  $\hat{y} = \sigma(Y)$  is the predicted probability;  $Y$  is the raw logit output of the classifier;  $\sigma$  is the sigmoid function; and the threshold 0.5 maps probabilities to binary labels (1 = AI-generated fake, 0 = real).

The loss function for optimization is Binary Cross-Entropy.

$$LBCE = -\frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(y_i) + (1 - y_i) \cdot \log(1 - y_i)] \quad (13)$$



trong đó  $L_{BCE}$  là tổn thất Entropy chéo nhị phân;  $N$  là số lượng mẫu huấn luyện;  $y_i \in \{0,1\}$  là nhãn sự thật cơ bản (0 = thật, 1 = giả);  $y_i = \sigma(y_i) \in (0,1)$  là xác suất dự đoán sau khi kích hoạt sigmoid; và  $\log(\cdot)$  là logarit tự nhiên.

Mã giả của thuật toán của chúng tôi, được gọi là thuật toán của chúng tôi (DSCNNE), được mô tả dưới đây:

ALGORITHM thuật toán của chúng tôi( $X_{rgb}$ ,  $X_{fft}$ )

Đầu vào:  $X_{rgb}$  in  $\mathbb{R}^{(B \times 3 \times 224 \times 224)}$  -- Hình ảnh RGB

$X_{fft}$  trong  $\mathbb{R}^{(B \times 1 \times 224 \times 224)}$  -- Phổ FFT (từ

Tính toánFFTSpectrum)

Đầu ra:  $Y$  in  $\mathbb{R}^{(B \times 1)}$  -- Logit (Real=1 / Fake=0)

**BẮT ĐẦU**

// Bước 1: Ngân hàng bộ lọc SRM (30 bộ lọc thông cao)

$X_{srm} \leftarrow \text{ApplySRMFilters}(X_{rgb}, k=30)$  //  $\mathbb{R}^{(B \times 30 \times H \times W)}$   $X_{in} \leftarrow$

$\text{Concat}([X_{rgb}, X_{srm}], \text{dim}=\text{channel})$  //  $\mathbb{R}^{(B \times 33 \times H \times W)}$

// Bước 2: Trích xuất tính năng luồng kép

F\_spatial <- EnhanceSpatialStream(X\_in) //  $R^{(B \times 512)}$

F\_freq <- EnhanceFrequencyStream(X\_fft) //  $R^{(B \times 512)}$

// Bước 3: Chú ý đa phương thức (hai chiều)

Q\_s <- Linear\_Qs(F\_spatial); K\_f <- Tuyến Tính\_Kf(F\_freq); V\_f  
<- Linear\_Vf(F\_freq)

attn\_s <- Sigmoid(Sum(Q\_s \* K\_f, dim=-1) / sqrt(512))

F\_spatial\_e <- F\_spatial + attn\_s \* V\_f // dư

```
Q_f <- Tuyến tính_Qf(F_freq); K_s <- Linear_Ks(F_spatial); V_s <-  
Linear_Vs(F_spatial)
```

```
attn_f <- Sigmoid(Sum(Q_f * K_s, dim=-1) / sqrt(512))
```

```
F_freq_e <- F_freq + attn_f * V_s // dư
```

```
// Bước 4: Hợp nhất tính năng
```

```
F_combined <- Concat([F_spatial_e, F_freq_e], dim=1) //  $R^{(B \times 1024)}$ 
```

```
// Bước 5: Trình phân loại MLP
```

```
Z <- Bỏ học (ReLU(BN(Tuyến tính(1024->1024)(F_combined))),  
p=0,50)
```

```
Z <- Bỏ học(ReLU(BN(Tuyến tính(1024->512 )(Z))), p=0,50)
```

```
Z <- Dropout(ReLU(BN(Tuyến tính(512 ->256 )(Z))), p=0,25)
```

```
Y <- Tuyến tính(256->1)(Z)
```

```
RETURN Y // Sigmoid(Y) khi suy luận -> P(FAKE) trong [0,1]
```

KẾT THÚC

THÍ NGHIỆM

Điểm chuẩn. Sau khi đào tạo, khái quát hóa về việc không bắt  
Quá trình đánh giá được thực hiện trên tập dữ liệu ArtiFact (Awsaf và  
cộng sự, 2023), một điểm chuẩn quy mô lớn chứa các hình ảnh được  
tạo bởi 13 trình tạo trở lên thuộc 5 danh mục ngữ nghĩa (Con  
người/Khuôn mặt, Động vật, Địa điểm, Phương tiện và Nghệ thuật),  
ban đầu được sử dụng trong IEEE VIP Cup tại ICIP 2022. Một tập hợp

con cân bằng gồm 20.000 hình ảnh (10.000 hình ảnh thực, 10.000 do AI tạo) đã được sử dụng.

Thiết lập thử nghiệm. Để đánh giá kiến trúc đề xuất, các thử nghiệm đã được tiến hành trên máy trạm Windows 11

được trang bị CPU Intel Core i7-11800H, RAM DDR4 16 GB và GPU NVIDIA RTX 3050Ti (VRAM 4 GB), sử dụng Python 3.10, PyTorch 2.0.1 và CUDA 11.7. Cả mô hình cơ sở và đề xuất đều được đào tạo từ đầu trên tập dữ liệu CIFAKE (Bird & Lotfi, 2024), bao gồm 120.000 bức ảnh CIFAR-10 thực và hình ảnh do AI tạo ra từ Stable Diffusion v1.4. Trước khi đào tạo, hình ảnh đầu vào được xử lý trước thông qua cắt xén trung tâm  $224 \times 224$  và chuẩn hóa ImageNet tiêu chuẩn ( $\mu = [0,485, 0,456, 0,406]$ ,  $\sigma = [0,229, 0,224, 0,225]$ ). Quá trình tối ưu hóa sử dụng trình tối ưu hóa Adam ( $\text{lr} = 0,0001$ ,  $\beta_1 = 0,9$ ,  $\beta_2 = 0,999$ ) với kích thước lô là 16. Để đảm bảo sự hội tụ tối ưu và ngăn chặn tình trạng trang bị quá mức, chúng tôi đã kết hợp bộ lập lịch GiảmLRonPlateau (hệ số = 0,1, kiên nhẫn = 5 kỷ nguyên) cùng với cơ chế Dừng sớm (kiên nhẫn = 10 kỷ nguyên). Tất cả các đánh giá đều được thực hiện trên CPU để đảm bảo so sánh tốc độ công bằng và không phụ thuộc vào phần cứng.

The primary evaluation metric is Average Precision (AP), which is threshold-independent and robust to class imbalance. Models were also assessed on overall accuracy (Acc), accuracy on real (AccR) and fake (AccF) images, F1 score on fake images, and total thời gian đánh giá. Định nghĩa số liệu: AP (Độ chính xác trung bình) measures the area under the precision-recall curve, summarizing detection quality independently of any fixed threshold; Acc (Overall Accuracy) is the fraction of all predictions that are correct; AccR (Accuracy on Real) is the fraction of real images correctly classified as real (true-negative rate); AccF (Accuracy on Fake) is the fraction of fake images correctly classified as fake (true-positive rate); F1 is the harmonic mean of precision and recall on the fake class.

Kết quả và thảo luận. Bảng 1 trình bày kết quả đánh giá không bias của cả ba mô hình trên bộ dữ liệu ArtiFact 20.000 hình ảnh (10.000 thực, 10.000 do AI tạo ra từ hơn 13 trình tạo). Cả ba mô hình đều hoạt động gần mức cơ hội, với độ chính xác dao động từ 48,74% đến 50,91%, cho thấy khả năng khái quát hóa kém đối với điểm chuẩn ngoài phân phối rất đa dạng này.

Bảng 1. So sánh tất cả các mô hình trên tập dữ liệu ArtiFact (20.000 hình ảnh, không ảnh).

Số liệu

Vương và cộng sự.

(2020)

(Đường cơ sở)

Thuật toán của chúng

tôi

AP (Độ chính xác trung

bình)

50,32%

51,01%

Acc (Độ chính xác tổng

thể)

48,74%

50,91%

AccR (Độ chính xác trên

thực tế)

18,61%

48,08%

AccF (Độ chính xác trên  
hàng giả)

78,88%

53,75%

AUC (ROC-AUC)

49,13%

51,01%

F1 (Lớp giả)



60,61%

52,27%

Thời gian đánh giá (20.000 hình ảnh)

49,1 giây

52,4 giây

Số lượng thông số

3,7M

7,8 triệu

Định nghĩa số liệu AP (Độ chính xác trung bình): vùng dưới đường cong thu hồi độ chính xác, không phụ thuộc vào ngưỡng; Acc (Độ chính xác tổng thể):

một phần của tất cả các dự đoán là đúng; AccR (Độ chính xác trên thực): tỷ lệ hình ảnh thực được phân loại chính xác là thực (tỷ lệ âm tính thực); AccF (Độ chính xác trên giả): tỷ lệ hình ảnh giả được phân loại chính xác là giả (tỷ lệ dương tính thật); AUC (ROC-AUC): diện tích dưới đường cong đặc tính vận hành máy thu; F1 (Lớp giả):

harmonic mean of precision and recall for the fake class; Evaluation Time: total CPU inference time on 20,000 images; Parameter Count: total trainable model parameters.

Trên điểm chuẩn ArtiFact, cả ba mô hình đều có cơ hội gần như ngẫu nhiên. Thuật toán của chúng tôi đạt được độ chính xác cao nhất (50,91%) và AUC (0,51), vượt trội hơn một chút so với DualStreamCNN (48,74%) và FFTOnlyCNNEnhanced (49,60%), nhưng sự khác biệt là không đáng kể.

Hiệu suất gần như ngẫu nhiên này trên tất cả các mô hình cho thấy rằng các tính năng học được từ CIFAKE (hình ảnh Khuếch tán ổn định v1.4 ở độ phân giải  $32 \times 32$ ) không khái quát cho sự đa dạng, đa dạng. trình tạo, nội dung có độ phân giải cao của ArtiFact. Kết quả này nêu bật một hạn chế quan trọng của việc đào tạo trên bộ dữ liệu một trình tạo để triển khai trong thế giới thực.

Đáng chú ý, ba mô hình cho thấy những sai lệch phân loại khác nhau về

ArtiFact. DualStreamCNN thể hiện xu hướng FAKE mạnh mẽ: AccR = 18,61% so với AccF = 78,88%, cho thấy nó phân loại hầu hết các hình ảnh là giả bất kể nội dung. Thuật toán của chúng tôi hiển thị nhiều hơn sự phân chia cân bằng (AccR = 48,08%, AccF = 53,75%), cho thấy CBAM và sự chú ý đa phương thức của nó mang lại một số lợi ích tổng quát. Bảng 2 so sánh ba mô hình về sự đánh đổi giữa AccR và AccF này.

Bảng 2. Sự đánh đổi giữa AccR (ảnh thật) và AccF (ảnh giả) trên ArtiFact (zero-shot).

Người mẫu

AccR (Thực)

AccF (Giả mạo)

Tổng tài khoản

AP

Vương và cộng sự.

(2020)

18,61%

78,88%

48,74%

50,32%

Thuật toán của

chúng tôi

48,08%

53,75%

50,91%

51,01%

thuật toán của chúng tôi đẩy độ lệch FAKE hơn nữa: AccR tăng từ 18,61% lên 48,08%, trong khi AccF giảm từ 78,88% xuống 53,75%. Điều này cho thấy các cơ chế chú ý trong Thuật toán của chúng tôi làm giảm độ lệch FAKE cực cao của đường cơ sở, tạo ra một máy dò được hiệu chỉnh tốt hơn - mặc dù cả hai mô hình vẫn hoạt động gần như ngẫu nhiên về tổng thể, phản ánh khoảng cách tổng quát từ đào tạo CIFAKE một máy phát điện đến đánh giá ArtiFact đa máy phát điện.

Bảng 3 cung cấp bản tóm tắt đầy đủ về cả ba biến thể mô hình được đánh giá dựa trên điểm chuẩn ArtiFact, bao gồm cả thời gian đánh giá. Mô hình FFTOnlyCNNEnhanced, chỉ sử dụng luồng tần số, mất ít thời gian nhất (41,5 giây) nhưng không có độ chính xác lợi thế so với các mô hình luồng kép, xác nhận rằng chỉ riêng các tính năng tần số là không đủ để khái quát hóa trên các trình tạo và danh mục hình ảnh đa dạng trong ArtiFact.

Bảng 3. So sánh đầy đủ cả ba biến thể mô hình trên ArtiFact (20.000 hình ảnh, không ảnh).

Người mẫu

Tích lũy (%)

AUC

AP (%)

F1 (%)

Tiền (%)

Ghi lại (%)

(các) thời gian

Vương và cộng sự.

(2020)

48,74

49,13

50,32

60,61

49,22

78,88

49,1

Các thuật toán của chúng tôi (FFT đơn  
phương thức)

49,60

50,25

50,66

57,72

49,71

68,79

41,5

Thuật toán của chúng tôi (FFT & CNN đa  
phương thức) 50.91

51.01

51.01

52,27

50,87

53,75

52,4





Bảng 4 cung cấp bảng phân tích ma trận nhầm lẫn cho cả ba mô hình trên bộ dữ liệu ArtiFact, hiển thị số lượng True Âm bản (TN, hình ảnh thật được phân loại chính xác), Dương tính giả (FP, hình ảnh thật bị gán cờ sai là giả), Âm tính giả (FN, hình ảnh giả bị bỏ sót) và Dương tính thật (TP, hình ảnh giả được phát hiện chính xác). DualStreamCNN có số lượng TP cao nhất nhưng phải trả giá bằng nhiều lỗi FP trên hình ảnh thực, trong khi Thuật toán của chúng tôi đạt được dự đoán cân bằng nhất trên cả hai loại.

Bảng 4. Phân tích ma trận nhầm lẫn trên ArtiFact (10.000 ảnh thật + 10.000 ảnh giả).

Người mẫu

TN (Thực sự chính  
xác)

FP (Thật sự sai)

FN (Giả Lỡ)

TP (Giả Đúng)

DualStreamCNN

1,861

8,139

2.112

7,888

Thuật toán của

chúng tôi

4,808

5.192

4.625

5.375

FFTOnlyCNNNâng cao

3.042

6,958

3.121

6,879

Như được hiển thị trong ma trận nhầm lẫn, thuật toán của chúng tôi phân loại chính xác 4.808 hình ảnh thực (TN) so với chỉ 1.861 của DualStreamCNN, tăng thêm 2.947 hình ảnh thực được phân loại chính xác, với cái giá là số lượng TP cân bằng hơn nhưng thấp hơn (5.375 so với 7.888). Sự đánh đổi này phản ánh tác động của CBAM và Sự chú ý đa phương thức trong việc giảm xu hướng FAKE mạnh mẽ hiện có trong đường cơ sở. Mặc dù không có mô hình nào khái quát tốt về độ chính xác tổng thể cho các trình tạo đa dạng của ArtiFact, nhưng Thuật toán của chúng tôi tạo ra các dự đoán cân bằng nhất, khiến mô hình này phù hợp hơn với các tình huống trong đó cảnh báo sai trên hình ảnh thực sẽ gây tổn kém..

Khoảng cách khái quát được quan sát trên ArtiFact cho thấy một hạn chế quan trọng của việc đào tạo một máy phát điện. Bộ lọc SRM khuếch đại nhiều vi mô ở cấp độ pixel và tạo phẩm trên bảng kiểm tra GAN (Frank và cộng sự, 2020), trong khi CBAM (Woo và cộng sự, 2018) hướng sự chú ý của mô hình đến các vùng có nhiều tạo tác. Các thành phần này có hiệu quả để phát hiện Ổn định

Các tạo phẩm khuếch tán v1.4 (bản phân phối đào tạo CIFAKE), nhưng hình ảnh ArtiFact từ 13 trình tạo trở lên giới thiệu các dấu hiệu tạo tác đa dạng mà các mô hình chưa gặp phải trong quá trình đào tạo. AUC

gần như có khả năng xảy ra (49–51%) trên tất cả các mô hình xác nhận đây là sự cố dịch chuyển phân phối chứ không phải là vấn đề về năng lực mô hình, thúc đẩy việc đào tạo lại trong tương lai về các bộ dữ liệu nhiều máy phát điện như chính GenImage hoặc ArtiFact, làm cho thuật toán của chúng tôi vừa chính xác hơn vừa phù hợp hơn cho việc triển khai sản xuất.

## KẾT LUẬN

Bài viết này đã trình bày Thuật toán của chúng tôi (DSCNNE), kiến trúc CNN luồng kép kết hợp phân tích không gian (RGB và SRM) với phân tích tần số (FFT), kết hợp Cross-Modal

Cơ chế chú ý và bộ phân loại Entropy chéo nhị phân. Cả hai mô hình đều được đào tạo về CIFAKE và đánh giá không ảnh trên điểm chuẩn ArtiFact (20.000 hình ảnh, hơn 13 trình tạo). Tất cả các mô hình đều thực hiện mức độ cơ hội gần như trên ArtiFact (độ chính xác 49–51%), cho thấy khoảng cách khái quát hóa đáng kể khi chuyển từ đánh giá một máy phát sang nhiều máy phát. Thuật toán của chúng tôi đạt được các dự đoán cân bằng nhất ( $\text{AccF} = 53,75\%$ ,  $\text{AUC} = 51,01\%$ ) với ít cảnh báo sai trên hình ảnh thực hơn so với đường cơ sở. Những kết quả này cho thấy sự cần thiết phải đào tạo nhiều máy phát điện để đạt được khả năng triển khai trong thế giới thực một cách đáng tin cậy.

Ba hướng cải tiến được đề xuất cho giai đoạn tiếp theo. Đầu tiên là đào tạo lại các bộ dữ liệu nhiều trình tạo như ArtiFact hoặc GenImage (Zhu và cộng sự, 2023), bao gồm các trình tạo và danh mục hình ảnh khác nhau, giải quyết trực tiếp khoảng cách khái quát hóa được xác định trong đánh giá này. Thứ hai là tích hợp DIRE (Wang và cộng sự, 2023) như luồng thứ ba trong kiến trúc, khai thác lỗi tái tạo mô hình khuếch tán để cung cấp các tín hiệu phát hiện hiện không được các luồng RGB và FFT thu được. Thứ ba là áp dụng các kỹ thuật học tập liên tục hoặc chụp vài lần để cho phép mô hình thích ứng dần dần khi các trình tạo hình ảnh AI mới xuất hiện mà không yêu cầu thu hồi toàn bộ dữ liệu., kết hợp với một cơ chế học tập liên tục để cho phép mô hình tự động cập nhật khi các trình tạo hình ảnh AI mới tiếp tục xuất hiện.

Tài liệu tham khảo

Awsaf, M., và cộng sự. (2023). ArtiFact: Một tập dữ liệu quy mô lớn với hình ảnh nhân tạo và thực tế để phát hiện hình ảnh tổng hợp mạnh mẽ và khái quát. Hội nghị quốc tế IEEE về hình ảnh Đang xử lý (ICIP 2023). \_\_ GIỮ\_0\_\_

Bird, J. J., & Lotfi, A. (2024). CIFAKE: Phân loại hình ảnh và nhận dạng có thể giải thích được của hình ảnh tổng hợp do AI tạo ra. Truy cập IEEE, 12, 15642–15650. `

Dhariwal, P., & Nichol, A. (2021). Các mô hình khuếch tán đánh bại GAN về tổng hợp hình ảnh. Những tiến bộ trong Hệ thống xử lý thông tin thần kinh (NeurIPS 2021), 34, 8780–8794. [https://www.semanticscholar.org/đầu\\_đọc/64ea8f180d0682e6c18d1eb688afdb2027c02794](https://www.semanticscholar.org/đầu_đọc/64ea8f180d0682e6c18d1eb688afdb2027c02794)

Frank, J., Eisenhofer, T., Schönherr, L., Fischer, A., Kolossa, D., & Holz, T. (2020). Tận dụng phân tích tần số để nhận dạng hình ảnh giả sâu. Kỷ yếu của Hội nghị quốc tế về học máy lần thứ 37 (ICML 2020), 119, 3247–3258. [https://thủ\\_tục\\_tổ\\_tụng.mlr.press/v119/frank20a.html](https://thủ_tục_tổ_tụng.mlr.press/v119/frank20a.html)

Anh ấy, K., Zhang, X., Ren, S., & Sun, J. (2016). Học dư sâu để nhận dạng hình ảnh. Hội nghị IEEE về Thị giác máy tính và Nhận dạng mẫu (CVPR 2016), 770–778. \_GIỮ\_0\_ pdf/1512.03385

Ho, J., Jain, A., & Abbeel, P. (2020). Khuếch tán khử nhiễu các mô hình xác suất. Những tiến bộ trong Hệ thống xử lý thông tin thần kinh (NeurIPS 2020), 33, 6840–6851. <https://arxiv.org/pdf/2006.11239>

Marra, F., Gragnaniello, D., Verdoliva, L., & Poggi, G. (2019). GAN có để lại dấu vân tay nhân tạo không? Hội nghị IEEE về Xử lý và Truy xuất Thông tin Đa phương tiện (MIPR 2019), 506–511. <https://arxiv.org/pdf/1812.11842>

Nataraj, L., Mohammed, T. M., Manjunath, B. S., và những người khác. (2019). Phát hiện hình ảnh giả được tạo bởi GAN bằng cách sử dụng ma trận xuất hiện đồng thời. Hình ảnh Điện tử, 2019(5), 532-1–532-7.

Qian, Y., Yin, G., Sheng, L., Chen, Z., & Shao, J. (2020). Suy nghĩ về tần số: Phát hiện giả mạo khuôn mặt bằng cách khai thác các manh mối nhận



biết tần số. Hội nghị Châu Âu về Thị giác Máy tính (ECCV 2020), 12357, 86–103. \_\_ GIỮ\_1\_\_

Rombach, R., Blattmann, A., Lorenz, D., Esser, P., & Ommer, B. (2022). Tổng hợp hình ảnh có độ phân giải cao với các mô hình khuếch tán tiềm ẩn. Hội nghị IEEE về Thị giác máy tính và Nhận dạng mẫu (CVPR 2022), 10684–10695. \_\_ GIỮ\_0\_\_

pdf/2112.10752

Song, J., Meng, C., & Ermon, S. (2021). Các mô hình tiềm ẩn khuếch tán khử nhiễu. Hội nghị quốc tế về đại diện học tập (ICLR 2021). \_\_ GIỮ\_0\_\_

Wang, S.-Y., Wang, O., Zhang, R., Owens, A., & Efros, A. A. (2020). Hình ảnh do CNN tạo ra dễ dàng được phát hiện một cách đáng ngạc nhiên...bây giờ.

CVPR 2020, 8695–8704. \_\_ GIỮ\_0\_\_

Wang, Z., Bao, J., Chu, W., và những người khác. (2023). DIRE để phát hiện hình ảnh do khuếch tán. ICCV 2023, 22445–22455.

<https://openaccess.thecvf.com/content/ICCV2023/papers/>

Wang\_DIRE\_for\_Diffusion-

Đã tạo\_Image\_Detection\_ICCV\_2023\_paper.pdf

Woo, S., Park, J., Lee, J.-Y., & Kweon, I. S. (2018). CBAM:

Mô-đun chú ý khối tích chập. ECCV 2018, 3–19. [https://](https://doi.org/10.1007/978-3-030-01234-2_1)

[doi.org/10.1007/978-3-030-01234-2\\_1](https://doi.org/10.1007/978-3-030-01234-2_1)

Yu, N., Davis, L. S., & Fritz, M. (2019). Quy kết hình ảnh giả cho GAN: Tìm hiểu và phân tích dấu vân tay GAN. IEEE/CVF

Hội nghị quốc tế về Thị giác máy tính (ICCV 2019), 7556–7566. \_\_

GIỮ\_0\_\_

Zhang, X., Karaman, S., & Chang, S.-F. (2019). Phát hiện và mô phỏng các tạo tác trong hình ảnh giả mạo GAN. IEEE quốc tế Hội thảo về Pháp y và An ninh thông tin (WIFS 2019), 1–6.

<https://arxiv.org/pdf/1907.06515>

Zhu, J.-Y., Park, T., Isola, P., & Efros, A. A. (2017). Dịch thuật từ hình ảnh sang hình ảnh không ghép đôi bằng cách sử dụng mạng đối thủ nhất quán theo chu kỳ. Hội nghị quốc tế của IEEE về Thị giác máy tính (ICCV 2017), 2223–2232. \_\_ GIỮ\_\_

Zhu, M., Chen, H., Yan, Q., Huang, X., Lin, G., Li, W., Tu, Z., Hu, H., & Wang, Z. (2023). GenImage: Điểm chuẩn quy mô hàng triệu cho phát hiện hình ảnh do AI tạo ra. Những tiến bộ trong Hệ thống xử lý thông tin thần kinh (NeurIPS 2023), 36. <https://arxiv.org/pdf/2306.08571>