

Sistemi automatik i tekstit në të folur për përdorim vietnamez

Inteligjenca Artificiale

Thanh-Danh Vo 1, Ngo-Ho Anh-Khoa 1 dhe Ngo-Ho Anh-Khoi 1*

1 Fakulteti i Teknologjisë së Informacionit, Universiteti Nam Can Tho, Rruga Nguyen Van Cu 168, An Binh Ward, Can Tho City, Vietnam

__MBAJ_0__, , ,
nhakhoi@nctu.edu.vn

Abstrakt. Në kontekstin e transformimit dixhital dhe avancimit të shpejtë të inteligjenca artificiale, kërkesa për sistemet Text-to-Speech (TTS) ka bërë gjithnjë e më kritike në fusha të tilla si asistentët virtualë, edukimi, qendrat automatike të thirrjeve dhe mjetet e aksesueshmërisë për vizualisht i dëmtuar. Megjithatë, duke gjeneruar të natyrshme, të vetëdijshme për kontekstin dhe në mënyrë prozodike fjalimi i duhur mbetet një sfidë e rëndësishme, veçanërisht për Vietnamisht - një gjuhë tone me konturet komplekse të zërit dhe rajonal diversiteti. Ky hulumtim propozon dhe zhvillon një sistem vietnamez TTS të ndërtuar mbi modelet moderne të të mësuarit të thellë për të kapërcyer kufizimet e tradicionales metodat. Sistemi shfrytëzon arkitekturat më të fundit, duke përfshirë Tacotron, FastSpeech dhe VITS, të kombinuara me teknikat e mësimit të makinerive për të rritur cilësinë e sintezës. Ndërtimi dhe vlerësimi kryhen në a Të dhëna të ndryshme vietnameze, duke siguruar përshtatshmëri me botën e shumfshistë reale kontekstet. Rezultatet tregojnë se sistemi arrin të natyrshme, të qartë, shumë prodhim fleksibël të të folurit me potencial të gjerë për vendosje në platformat dixhitale dhe shërbime inteligjente.

Fjalët kyçe: Tekst në të folur (TTS), Inteligjenca Artificiale (AI), Mësim i thellë, Përpunimi i gjuhës natyrore (NLP), Sinteza e të folurit.

1 Hyrje

E nxitur nga transformimi dixhital dhe progresi i inteligjencës artificiale, nevoja për të ndërtimi i sistemeve Text-to-Speech (TTS) po bëhet gjithnjë e më e rëndësishme në fusha të tilla si asistentët virtualë, edukim, qendra telefonike automatike dhe mbështetje për vizualisht i dëmtuar. Problemi TTS, megjithatë, shtrihet përtej thjesht konvertimit të tekstit në audio; kërkon që zëri i sintetizuar të jetë i natyrshëm, të ketë intonacion të përshtatshëm, dhe përshtaten me kontekstin e dhënë - një detyrë veçanërisht e vështirë për vietnamezisht, një gjuhë me një sistem kompleks tonesh dhe një ndryshim thelbësor rajonal (Do, 2026).

Metodat tradicionale të bashkimit dhe të bazuara në formant TTS (Zen et al., 2019) dhe Sinteza e bazuar në modelin e fshehur Markov (HMM) (Zen et al., 2019) shfaq kufizime në fleksibilitet, natyrshmëri dhe shkallëzim. Si përgjigje, modele moderne të të mësuarit të thellë të tilla si Tacotron (Wang et al., 2017), Tacotron 2 (Shen et al., 2018), FastSpeech (Ren

et al., 2019,2020) dhe VITS (Kim et al., 2021) kanë hapur rrugë më efektive duke mësuar drejtpërdrejt nga të dhënat. Duke u mbështetur në këto përparime, ky studim fokusohet në kërkimin dhe zhvillimin e një sistemi vietnamez TTS që synon përmirësimin e cilësisë së zërit dhe zbatueshmërisë praktike.

2 Punë të ngjashme

Tregu Vietnamez TTS përmban disa platforma të spikatura vendase së bashku me zgjidhjet ndërkombëtare. FPT Smart Cloud Text to Speech, i zhvilluar nga FPT Corporation, ofron një shërbim vietnamez TTS me cilësi të lartë përmes një API komerciale (Vu et al., 2025; Nguyen, 2023). Ai zbaton arkitekturat e të mësuarit të thellë si Tacotron (Wang et al., 2017) dhe variantet e Transformer (Vaswani et al., 2017) së bashku me koduesit e zërit si WaveNet (Oord et al., 2016) dhe HiFi-GAN (Kong et al., 2020 me shpejtësi të natyrshme, rajone dhe kontrolle të ndryshme të zërit. duke ndaluar. Sistemi përdoret gjerësisht në përgjigjen interaktive të zërit (IVR), libra audio, asistentë virtualë dhe edukimin në internet (Do, 2026). Viettel AI Text-to-Speech ofron një zgjidhje të bazuar në SaaS të optimizuar për vietnamezët (Vu et al., 2025; Nguyen, 2023), duke përdorur modele nervore të avancuara të trajnuara në shkallë të gjerë, trupa të të folurit specifike vietnameze për të siguruar shqiptim të saktë të fjalës²⁰, shqiptim të saktë²⁰ dhe shprehje natyrale. et al., 2016; Kong et al., 2020). Zalo AI Text to Speech, një produkt i VNG Corporation, integron modele të thella NLP si &PhoBERT (Nguyen&Tuan, 2020) dhe trajnimin paraprak të stilit BERT (Devlin et al., 2019) me arkitektura sinteze duke përfshirë Tacotron; al., 2019; Kim et al., 2021), duke përdorur të dhëna masive të përdoruesve për të mbështetur stile të shumta të të folurit (Vu et al., 2025). Voice.vn specializohet në sintezën e të folurit dhe klonimin e zërit (Vu et al., 2025) duke përdorur modele nga skaji në fund si VITS (Kim et al., 2021) dhe teknikat e konvertimit të zërit (Casanova et al., 2022; Chen et al., 2022 me cilësi të lartë të personalizimit të zërit). podcasting dhe lojëra. Google AI Studio ofron një mjedis të bazuar në renë kompjuterike për TTS nëpërmjet familjes Gemini dhe Google Cloud Text-to-Speech (Vaswani et al., 2017; Ren et al., 2019), duke shfaqur gjenerimin e zërit shumëgjuhësh, natyral dhe kontekstual 2et al., 2et al., Shenova 2. 2018). EventLab ofron TTS dhe mjete për klonimin e zërit të ndërtuara në TTS nga skaji në skaj (Wang et al., 2017) dhe modele të ngulitjes së altoparlantëve (Chen et al., 2022; Kim et al., 2021; Casanova et al., 2022). Në përgjithësi, tregu po zhvendoset nga sistemet e thjeshta të leximit të tekstit drejt platformave inteligjente të komunikimit, me tendenca të forta në klonimin e zërit (Jia et al., 2018) dhe AI multimodale.

Komuniteti me burim të hapur ka kontribuar me një sërë modelesh vietnameze TTS. VietTTS është një sistem përfaqësues i ndërtuar me arkitekturë enkoder-dekoder ose transformator (Wang et al., 2017; Vaswani et al., 2017; Ren et al., 2019), i trajnuar mbi të dhënat vietnameze të normalizuara me kujdes (Do, 2026) për të trajtuar tonet, strukturën e përshtatshme, fjalët e përbëra afër kohës dhe ofertën e përshtatshme të fjalive. për asistentët virtualë, mësimin elektronik dhe prodhimin e librave audio (Nguyen, 2023; Vu et al., 2025). NeuTTS-Air fokusohet në konkluzionet e lehta, efikase, balancimin e cilësisë dhe shpejtësisë së zërit për të operuar në CPU ose pajisje me burime të ulëta (Ren et al., 2019,2020; Kim et al., 2021),

optimizuar për chatbot, IVR dhe aplikacione IoT (Ping et al., 2017; Kalchbrenner et al., 2018). Kani-TTS është një model në shkallë të gjerë me përafërsisht 370 milionë parametra, që synon ekspresivitet të lartë dhe cilësi profesionale audio (Kim et al., 2021; Casanova et al., 2022), duke shkëlqyer në prodhimin e audiolibrave dhe mediave, por që kërkon GPU të fuqishme për vendosje (Ren et al., 19, 20; Kalchbrenner et al., 2018). VieNeu-TTS kombinon TTS me klonimin e zërit, duke nxjerrë karakteristikat e altoparlantëve nëpërmjet teknikave si AutoVC (Qian et al., 2019) dhe StarGAN-VC (Kameoka et al., 2018) dhe duke i zbatuar ato në të folurit e sintetizuar (Casanova et al., 2001, personalizimi i fortë, Jiabet al., 2002; duke ngritur gjithashtu shqetësime etike dhe sigurie. ViXTTS shërben si një projekt demonstrues për klonimin e zërit, duke ilustruar teknologjinë për eksperimentim të shpejtë (Thinh, 2024; Kim et al., 2021). Valtec-TTS është një model kompakt i optimizuar për mjedise jashtëzakonisht të kufizuara nga burimet, si pajisjet e ngulitura dhe IoT (Ren et al., 2019,2020; Ping et al., 2017; Kalchbrenner et al., 2018), duke ofruar qartësi të thjeshta të mosnjohjes dhe qartësi të aplikimit. Së bashku, këto modele ilustrojnë maturimin e TTS vietnameze, me degë të specializuara që variojnë nga sinteza me cilësi të lartë deri te vendosja e lehtë dhe personalizimi i zërit.

Cilësia e të dhënave është themelore për TTS. Korpusi i të folurit VLSP është një grup të dhënash i madh, i orientuar akademikisht, me regjistrime me shumë altoparlantë në kushte të kontrolluara (Ardila et al., 2020; Vu et al., 2025), me shënime të pasura me informacion fonetik dhe rajonal (Yamagishi et al., 2019; Do, 2). VIVOS është një korpus më i vogël me burim të hapur (rreth 10-20 orë) të të folurit të pastër të lexuar (Ardila et al., 2020; Ito & Johnson, 2017), i përdorur gjerësisht për modelimin fillestar pavarësisht diversitetit të kufizuar emocional dhe të botës reale (Do, 2026). Të dhënat komerciale nga FPT Corporation, Viettel Group dhe VNG Corporation janë shumë më të mëdha dhe më të detajuara. Të dhënat e FPT-së përfshijnë qindra deri në mijëra orë regjistrime të cilësisë së studios me shënime shteruese (Vu et al., 2025; Do, 2026; Oord et al., 2016; Kong et al., 2020). Të dhënat e Viettel ndërthurin regjistrimet në studio dhe ato të botës reale që mbulojnë thekse të ndryshme (Vu et al., 2025; Yamagishi et al., 2019; Jia et al., 2018; Do, 2026). Të dhënat e Zalo përfitojnë nga ekosistemi i tij i gjerë i përdoruesve, duke përfshirë përdorimin bashkëkohor të gjuhës (Vu et al., 2025; &Nguyen&Tuan, 2020; Devlin et al., 2019; Kim et al., 2021). Për më tepër, VietTTS ofron një bazë të dhënash të hapur me çifte tekst-audio të mjaftueshme për eksperimente në shkallë të vogël (Nguyen, 2023; Ito&Johnson, &2017; Vu et al., 2025). Në përgjithësi, shkalla e të dhënave, diversiteti, thellësia e shënimit dhe realizmi përcaktojnë drejtpërdrejt performancën e TTS.

3 Projektimi i sistemit

Sistemet e hershme TTS mbështeteshin në metodat e bashkuara dhe të bazuara në formant, të cilat mbledhin ose modelojnë matematikisht njësitë e të folurit, por vuajnë nga papërkulshmëria, kostot e larta të bazës së të dhënave dhe prozodia e panatyrshme (Zen et al., 2019). Sinteza parametrike statistikore duke përdorur Hidden Markov Models (HMM) përmirësoi fleksibilitetin, por gjithsesi prodhoi rezultat monoton, më pak natyror (Zen et al., 2019). Ardhja e të mësuarit të thellë solli modele nga fundi në fund si Tacotron dhe Tacotron 2, të cilat përdorin arkitekturat kodues-dekoder me vëmendje për të hartuar drejtpërdrejt tekstin në

mel-spektrograme, të ndjekura nga vokodues si WaveNet (Oord et al., 2016) ose WaveGlow (Prenger et al., 2019) për të gjeneruar forma valore (Wang et al., 2017; Shen et al., 2018; Vaswani et al., 2001). Këto modele mësojnë automatikisht veçori fonetike dhe prozodike, duke dhënë të folur dukshëm më të natyrshëm, por kanë kufizime në shpejtësinë e përfundimit dhe gabimet e vëmendjes. FastSpeech dhe FastSpeech 2 trajtuan këto çështje duke hequr vëmendjen gjatë konkluzionit dhe duke përdorur parashikuesit e kohëzgjatjes, lartësisë dhe energjisë, duke arritur sintezë më të shpejtë dhe më të qëndrueshme me kontrollin e qartë të prozodisë (Ren et al., 2019, 2020; Vaswani et al., 2017). Kërcimi i fundit, VITS, integron një kodues automatik variacional (Kingma&Welling, 2014) me një &rrjet kundërshtar gjenerues (Goodfellow et al., 2014) për të gjeneruar drejtpërdrejt forma vale nga teksti në një kornizë të vetme nga fundi në skaj, duke eliminuar një vokoder të veçantë dhe një cilësi të mëtejshme të rritjes së efikasitetit al20;im. Casanova et al., 2022). Klonimi i zërit dhe sinteza me shumë altoparlantë kanë avancuar gjithashtu, duke përdorur ngulitje të altoparlantëve dhe shenja stili për të mundësuar personalizimin dhe përshtatjen me zero (Jia et al., 2018; Casanova et al., 2022; Chen et al., 2022; Wang et al., 2022; Wang et al.). Për më tepër, transferimi dhe metodat e të mësuarit të vetë-mbikëqyrura (Baevski et al., 2020; Hsu et al., 2021; Radford et al., 2022) zbusin mungesën e të dhënave për vietnamezët duke u trajnuar paraprakisht në korpora të mëdha shumëgjuhëshe. Një tubacion modern TTS zakonisht përfshin mbledhjen dhe përpunimin e të dhënave, normalizimin e tekstit (Do, 2026), trajnimin e modelit dhe gjenerimin e formës së valës (Wang et al., 2017; Kim et al., 2021).

Sistemi i propozuar zbaton një tubacion emocional TTS: teksti hyrës që përmban etiketa emocionale segmentohet sipas emocioneve, secili segment sintetizohet nëpërmjet viXTTS dhe format e valëve që rezultojnë janë të lidhura me boshllëqet e heshtjes për të prodhuar skedarin audio përfundimtar.




Fig. 1. Rrjedha e punës e sistemit të propozuar të sintezës së të folurit të bazuar në emocione

Në shtresën e parë, teksti skanohet rresht pas rreshti. Kur një rresht përmban një etiketë emocionale në kllapa, sistemi e vendos atë në një etiketë emocionale duke përdorur një fjalor të fjalëve kyçe vietnameze. Linjat e njëpasnjëshme që ndajnë të njëjtin emocion grupohen në një pjesë (teksti, emocion). Përpara sintezës, teksti pastrohet duke hequr përmbajtjen e etiketave, duke normalizuar hapësirat dhe duke standardizuar ortografinë vietnameze. Në shtresën e dytë, çdo pjesë i kalohet motorit të konkluzionit viXTTS së bashku me karakteristikat e altoparlantëve të nxjerra nga një skedar audio referencë. Një hartë emocionale cakton një referencë dosje për emocion (p.sh., neutrale → zëri_bazë.wav, i gëzuar → i gëzuar_ref.wav). Për të ruajtur identitetin e qëndrueshëm të altoparlantit, futjet latente të altoparlantëve nxirren një herë nga një mostër zanore e ofruar nga përdoruesi dhe ripërdoren në të gjitha pjesët (Jia et al., 2018; Casanova et al., 2022). Sintetza prodhon një formë vale për secilën



copë, siç është formalizuar në algoritmin e mëposhtëm

Në shtresën e tretë, format e valëve të krijuara janë të lidhura në mënyrë sekuenciale me 300 ms heshtje të futur për të ndarë kthesat emocionale dhe për të shmangur prerjet e papritura. Dalja përfundimtare ruhet si skedar WAV. Ky dizajn kombinon në mënyrë efektive klasifikimin e emocioneve të bazuara në fjalë kyçe me TTS të kushtëzuar dhe pas përpunimit audio, duke mundësuar sintezën shprehëse të të folurit të drejtuar nga etiketat duke përdorur një identitet të unifikuar zanor.

4 Metrikat e vlerësimit

Për të vlerësuar në mënyrë gjithëpërfshirëse sistemin e klonimit të tekstit në të folur dhe zërit, përdoren dy metrika plotësuese të bazuara në të mësuarit e thellë: ngjashmëria e altoparlantit nëpërmjet Resemblyzer dhe cilësia e perceptuar e të folurit nëpërmjet DNSMOS.

Resemblyzer është një mjet i bazuar në rrjetin nervor për verifikimin e altoparlantëve dhe matjen e ngjashmërisë së zërit (Mishra et al., 2023). Në thelbin e tij, ai përdor një kodues verifikimi të altoparlantëve të trajnuar me një humbje të përgjithësuar nga fundi në fund (Wan et al., 2018). Parimi operacional është si vijon: së pari, një thënie hyrëse - qoftë zëri origjinal i referencës ose zëri i klonuar i sintetizuar - përpunohet nga një rrjet nervor i thellë që nxjerr një vektor ngulitjeje me dimensione fikse (shpesh i referuar si një d-vektor ose ngulitje e altoparlantit). Ky vektor është krijuar për të kapur identitetin unik vokal të folësit, duke përfshirë karakteristika të tilla si timbri, kontura e zërit dhe stili i të folurit, ndërkohë që është kryesisht i pandryshueshëm ndaj përmbajtjes gjuhësore ose fjalëve specifike të folura. Me fjalë të tjera, pavarësisht se çfarë thotë personi, përfshirja duhet të mbetet e qëndrueshme për të njëjtin folës dhe dukshëm e ndryshme për folës të ndryshëm (Wan et al., 2018).

Pasi të merren vektorët e ngulitjes si për audion e referencës A (zëri i folësit origjinal) dhe për audion e sintetizuar B (zëri i klonuar), ngjashmëria e tyre përcaktohet duke përdorur metrikën e ngjashmërisë së kosinusit:

$$\text{CosineNgjashmëria} = \frac{A \cdot B}{\|A\| \cdot \|B\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}}$$

d

Ngjashmëria e kosinusit mat këndin midis dy vektorëve në hapësirën e ngulitjes me dimensione të larta. Një vlerë afër 1 tregon se vektorët drejtohen pothuajse në të njëjtin drejtim, që do të thotë se dy zërat perceptohen si shumë të ngjashëm ose pothuajse identikë për sa i përket identitetit të folësit (Jia et al., 2018; Wan et al., 2018). Në të kundërt, një vlerë afër 0 ose negative do të sugjeronte folës të ndryshëm. Kështu, Resemblyzer ofron një metrikë objektive, automatike dhe të riprodhueshme për të vlerësuar se sa besnikërisht një sistem i klonimit të zërit ruan karakteristikat vokale origjinale të folësit.

DNSMOS (Deep Noise Suppression Mean Poinion Score) është një metrikë jo ndërhyrëse, e bazuar në të mësuarit e thellë, e krijuar për të vlerësuar cilësinë perceptuese të sinjaleve të të folurit pa kërkuar një sinjal audio referimi të pastër (Reddy et al., 2021). Kjo e bën atë

5 Eksperimentet dhe rezultatet

Të dhënat e trajnimit. Sistemi u trajnua dhe u vlerësua duke përdorur korpusin viVoice (Le, 2024), grupi i parë i të dhënave të folurit vietnamez në shkallë të gjerë të disponueshëm publikisht, i krijuar për tekst në të folur me shumë altoparlantë. viVoice përfshin mbi 1000 orë audio të pastruar dhe transkriptime shoqëruese të marra nga 186 kanale në YouTube. Të gjitha mostrat e audios ofrohen me një shpejtësi kampionimi 24 kHz në formatin WAV, me muzikë në sfond dhe zhurmë të hequr për të siguruar të dhëna të pastra të trajnimit. Të dhënat e të dhënave mbulojnë një shumëllojshmëri të gjerë altoparlantësh, theksesh (Veriore, Qendrore, Jugore) dhe stile të folurit, duke e bërë atë veçanërisht të përshtatshëm për trajnimin e modeleve të fuqishme vietnameze TTS me shumë altoparlantë si XTTS-v2. viVoice lëshohet nën licencën CC BY-NC-SA 4.0.

Tubacioni i parapërpunimit u krijua për të eliminuar ndryshueshmërinë që mund të degradojë ngjashmërinë e altoparlantëve. Hapat përfshinin: (i) verifikimin manual të saktësisë së transkriptit për të siguruar një shtrirje të përsosur; (ii) normalizimin e tekstit duke përdorur VietNormalizer (Do, 2026) për të zgjeruar shkurtesat, për të kthyer numrat në fjalë dhe për të standardizuar shenjat e pikësimit; (iii) përafrimi fonetik me një rreshtues të detyruar të trajnuar në vietnameze, me korniza telefonike me nivel të lartë energjie. zhveshja e heshtjes në fillim dhe në fund të thënieve për të hequr heshtjen kryesore/pasuese; dhe (v) normalizimi i zërit në -23 LUFs për të mbajtur volumin e perceptuar të qëndrueshëm nëpër altoparlantë. Më e rëndësishmja, për secilin altoparlant u nxor një futje e altoparlantëve me cilësi të lartë duke përdorur koduesin Resemblyzer dhe u ruajt si një vektor referimi. Kushtëzimi i modelit gjenerues në këto ngulitje gjatë trajnimit inkurajon dekoderin të ruajë identitetin e altoparlantit, gjë që kontribuoi drejtpërdrejt në rezultatet e larta të ngjashmërisë së kosinusit (0,90+) të vëzhguara në eksperimente.

Konfigurimi eksperimental. Vlerësimi u krye në një laptop GIGABYTE G5 GD, një laptop i orientuar nga lojërat, specifikimet e të cilit janë renditur në tabelën 1. Veçanërisht, sistemi përmban një GPU të dedikuar NVIDIA GeForce RTX (arkitekturë Ampere, diskrete) së bashku me një përshtatës të integruar grafikë Intel UHD. Sidoqoftë, mjedisi PyTorch i përdorur për konkluzione ishte një ndërtim vetëm nga CPU, që do të thotë se të gjitha operacionet e sintezës ekzekutoheshin në CPU Intel Core i5-11400H pa përrshpejtim të GPU-së. Ky konfigurim pasqyron një skenar të përbashkët vendosjeje ku drejtuesit ose bibliotekat CUDA nuk janë instaluar, ose ku sistemi i jep përparësi përputhshmërisë mbi shpejtësinë maksimale.

Tabela 1. Konfigurimi i sistemit të platformës së testimit.

Komponentët	Specifikimi
Model	GIGABYTE G5 GD
CPU	Intel Core i5-11400H (8 bërthama, 12 fije, baza 2,70 GHz)
RAM	16 GB DDR4 (15,8 GB i përdorshëm)
GPU	Intel UHD Graphics (të integruara)
OS diskrete	NVIDIA GeForce RTX (Amper, i dedikuar)
GPU	Windows 11 Home Single Language

Mbështetja e
përfundimit

PyTorch vetëm për CPU, 4 tema

Ngjashmëria e zërit dhe cilësia e të folurit. Sistemi u vlerësua duke krahasuar mostrat origjinale dhe të sintetizuara (klonuara) të të folurit nga katër folës. Çdo çift mostër përbëhej nga një skedar reference.wav dhe klon i tij. U aplikuan dy metoda vlerësimi: Resemblyzer për ngjashmërinë e zërit (Wan et al., 2018; Mishra et al., 2023) dhe DNSMOS për cilësinë e perceptuar të audios (Reddy et al., 2021). Rezultatet e ngjashmërisë së zërit janë paraqitur në tabelën 2. Të gjitha çiftet arrijnë një ngjashmëri të kosinusit prej afërsisht 0,90 (duke filluar nga 0,9013 në 0,9346), duke konfirmuar se modeli VITS, pavarësisht se funksionon në CPU, ruan jashtëzakonisht mirë timbrin vokal dhe identitetin e folësit (Jia et al., 2018).

Rezultatet e ngjashmërisë së zërit për modelin viXTTS janë paraqitur në tabelën 2. Të gjitha çiftet arrijnë një ngjashmëri të kosinusit prej afërsisht 0,90 (duke filluar nga 0,9013 në 0,9346), duke konfirmuar se modeli ruan jashtëzakonisht mirë timbrin vokal dhe identitetin e folësit (Jia et al., 2018). Ngjashmëria e altoparlantëve për motorët e tjerë nuk u mat në këtë test vlerësimi, pasi shumica e tyre nuk e mbështesin në mënyrë të pavarur klonimin e zërit ose kërkojnë një hap të veçantë të nxjerrjes së përfshirjes së referencës.

Tabela 2. Ngjashmëria e zërit midis të folurit origjinal dhe të klonuar.

Kap audio	Ngjashmëria
giong_goc dhe	0,9038
giong_clone Danh_1 dhe	0,9019
Danh_clone	0,9346
Khang1 dhe Khang_clone	0,9013
Ngoc1 dhe Ngoc_clone	

Rezultatet e cilësisë së të folurit nga DNSMOS në të shtatë motorët e vlerësuar përmbliken në tabelën 3. Janë regjistruar katër metrikë: OVRL (cilësia e përgjithshme), SIG (cilësia e të folurit), BAK (ndërhyrja e zhurmës së sfondit) dhe rezultati shtesë P808 (një vlerësues i përgjithshëm i cilësisë së dëgjimit i përafëruar me ITU808-T). Rezultatet janë në shkallën standarde 1–5 të rezultatit mesatar të opinionit, ku vlerat më të larta tregojnë cilësi më të mirë perceptuese.

Tabela 3. Vlerësimi DNSMOS i cilësisë së të folurit vietnamez të sintetizuar.

Model	Audio me lugë	OVRL MOS	SIG MOS	BAK MOS	P808 MOS
Propozuar bazuar në viXTTS	giong_kloni.wav	3.38	3.60	4.14	4.03
Sistemi i klonimit të zërit					
Piper Vietnamese TTS	Piper_Vietnamese_TTS	3.00	3.40	3.81	3.15
TTS vietnameze Valtec v2	Vietnamese Valtec TTS_ver2.wav	3.07	3.34	4.04	3.95
VietnameseTTS	vietnamezeTTS.wav	2.07	2.75	2.86	2.73
TTS vietnameze Valtec	Valtec_Vietnamese.wav	3.37	3.58	4.16	4.21

VietTTS				4.15	3.64
	VietTTS.wav	3.05	3.25		
VieNeu-TTS	VietNeu_TTS.wav	3.31	3.54	4.16	3.68

Rezultatet e vlerësimit të DNSMOS tregojnë ndryshime të dukshme në cilësinë e sintetizuar të të folurit vietnamez midis sistemeve të vlerësuara TTS. Në përgjithësi, sistemi i propozuar i klonimit të zërit i bazuar në viXTTS, i përfaqësuar nga giong_clone.wav, arrin rezultatin më të lartë OVRL MOS prej 3,38 dhe rezultatin më të lartë SIG MOS prej 3,60. Këto rezultate tregojnë se sistemi i propozuar prodhon të folur me cilësi të përgjithshme perceptuese të fortë dhe sinjale të qarta të të folurit. Rezultati i lartë BAK MOS prej 4.14 sugjeron gjithashtu që audioja e krijuar përmban shumë pak zhurmë në sfond. Prandaj, modeli i bazuar në viXTTS demonstroi performancë të fortë si në qartësinë e të folurit ashtu edhe në shtypjen e zhurmës.

Ndër sistemet e krahasuara, Valtec_Vietnamese.wav performon gjithashtu në mënyrë konkurruese, me një OVRL MOS prej 3.37 dhe një SIG MOS prej 3.58, të cilat janë shumë afër sistemit të propozuar. Përveç kësaj, ky model merr rezultatin më të lartë P808 MOS prej 4,21, duke sugjeruar që dëgjuesit mund ta perceptojnë cilësinë e tij të përgjithshme audio në mënyrë të favorshme. Megjithatë, giong_clone.wav i propozuar ende e tejkalon pak atë në dy treguesit kryesorë të DNSMOS, OVRL dhe SIG. Kjo sugjeron që modeli i propozuar ka një avantazh të vogël por të matshëm për sa i përket cilësisë së përgjithshme të të folurit dhe qartësisë së sinjalit.

Modeli VietNeu_TTS.wav gjithashtu arrin rezultate të forta, me një OVRL MOS prej 3.31, SIG MOS prej 3.54, BAK MOS prej 4.16 dhe P808 MOS prej 3.68. Këto rezultate e vendosin atë në grupin me performancë të lartë, veçanërisht për sa i përket shtypjes së zhurmës në sfond. Rezultati i tij BAK është ndër më të lartat në krahasim, duke treguar se audioja e krijuar është e pastër dhe e qëndrueshme. Megjithëse rezultatet e tij të përgjithshme dhe të cilësisë së sinjalit janë pak më të ulëta se ato të giong_clone.wav dhe Valtec_Vietnamese.wav, ai mbetet një model i besueshëm për sintezën vietnameze të të folurit.

Grupi me performancë mesatare përfshin Valtec Vietnamese TTS_ver2.wav, VietTTS.wav dhe Piper_Vietnamese_TTS. Këto modele marrin rezultate OVRL MOS që variojnë nga 3,00 në 3,07, që tregojnë cilësi të pranueshme, por jo të jashtëzakonshme të sintetizimit të të folurit. Rezultatet e tyre SIG MOS, që variojnë nga 3,25 në 3,40, sugjerojnë që sinjali i të folurit është mjaft i qartë, por ende më pak i natyrshëm ose më pak i detajuar se sistemet me performancë të lartë. Veçanërisht, VietTTS.wav arrin një rezultat të lartë BAK MOS prej 4.15, duke treguar se prodhimi i tij audio është relativisht i pastër. Megjithatë, rezultatet e tij më të ulëta OVRL dhe SIG tregojnë se vetëm pastërtia e sfondit nuk është e mjaftueshme për të siguruar cilësi të lartë të përgjithshme të të folurit.

Sistemi me performancën më të ulët është VietnameseTTS.wav, i cili merr një OVRL MOS prej 2.07, SIG MOS prej 2.75, BAK MOS prej 2.86 dhe P808 MOS prej 2.73. Këto rezultate janë dukshëm më të ulëta se ato të modeleve të tjera. Në veçanti, rezultatet e ulëta të OVRL dhe SIG sugjerojnë se fjalimi i sintetizuar mund të përmbajë artefakte të dukshme, natyralitet të reduktuar ose shqiptim të paqartë. Rezultati i ulët BAK tregon gjithashtu se audio mund të përfshijë më shumë ndërhyrje ose zhurmë në sfond në krahasim me sistemet e tjera.

Një prirje e përgjithshme mund të vërehet në modelet më të forta: shumica e sistemeve arrijnë rezultate të larta BAK MOS mbi 4.0, që do të thotë se modelet moderne vietnameze TTS janë përgjithësisht efektive në prodhimin e audios së pastër me zhurmë të kufizuar të sfondit. Megjithatë, dallimet në rezultatet OVRL dhe SIG tregojnë se audio e pastër jo gjithmonë

garantojnë të folur të natyrshëm dhe të kuptueshëm. Natyraliteti i të folurit, qartësia dhe cilësia e sinjalit mbeten faktorë të rëndësishëm në dallimin e modeleve me performancën më të mirë.

Si përmbledhje, modeli i propozuar i klonimit të zërit me bazë viXTTS giong_clone.wav arrin performancën më të mirë të përgjithshme për sa i përket OVRL dhe SIG MOS, duke e bërë atë sistemin më të fortë në këtë krahasim. Valtec_Vietnamese.wav dhe VietNeu_TTS.wav gjithashtu demonstrojnë performancë konkurruese dhe mund të konsiderohen alternativa të forta. Ndërkohë, VietnameseTTS.wav tregon rezultatet më të dobëta dhe mund të kërkojë optimizim të mëtejshëm për të përmirësuar natyrshmërinë e të folurit, qartësinë dhe kontrollin e zhurmës në sfond.

Analiza e performancës dhe vonesës në kohë : reale: Metrika më kritike e performancës së prototipit aktual është vonesa e sintezës nga fundi në fund. Për një tekst të zakonshëm hyrës prej 750 karakteresh (ekuivalente me afërsisht 50 sekonda audio të gjeneruar me një shpejtësi standarde të të folurit vietnamez prej rreth 900 karaktere në minutë), sistemi kërkon afërsisht 2 minuta e 50 sekonda (170 sekonda) për të prodhuar skedarin përfundimtar WAV. Kjo jep një faktor në kohë reale (RTF) prej afërsisht 3.4, shumë mbi pragun në kohë reale prej 1.0. Megjithatë, vonesa nuk është fikse; ai ndryshon në mënyrë të matshme në varësi të kompleksitetit gjuhësor të tekstit hyrës. Dy faktorë dominojnë shpenzimet e përpunimit shtesë: □ Etiketat e emocioneve. Çdo kufi emocional detyron një pjesë të re □ sinteze me një thirrje konkluzionesh të veçantë viXTTS, që çon në ndërrim të shumëfishhtë të kontekstit dhe shpenzime të përgjithshme të ngarkimit të modelit. Më shumë etiketa rrisin numrin e pjesëve dhe kohën kumulative të futjes së pauzës.

□ □ Fjalët angleze dhe segmentet jo vietnameze. Këto kërkojnë hapa shtesë grafemë ndaj fonemës brenda shtresës së normalizimit të tekstit (Do, 2026) dhe mund të sjellin gabime të vëmendjes që e detyrojnë dekoderin të riprovojë shtrirjen, duke shtuar kohëzgjatjen totale.

Vonesa e vëzhguar rrjedh nga ekzekutimi i tubacionit të plotë VITS në CPU pa përdorur GPU-në e disponueshme RTX. Ndërtimi i PyTorch vetëm për CPU-në nuk mund të shfrytëzojë paralelizmin masiv të bërthamave tensore të GPU-së, duke lënë që shumëzimet dhe konvolucionet e matricës të llogariten në mënyrë sekuenciale. Pavarësisht kësaj, sistemi mbetet i pranueshëm për detyrat e krijimit të përmbajtjes afër linjës, si dublimi i podkastit, rrëfimi edukativ ose gjenerimi i postës zanore - aplikacione ku tolerohen disa minuta kohë përthimi në këmbim të një produkti me cilësi të lartë dhe emocionalisht shprehës.

Në mënyrë kritike, makina është e pajisur me një GPU NVIDIA GeForce RTX, e cila është plotësisht e aftë të përshpejtojë përfundimin. Kalimi në një instalim PyTorch të aktivizuar nga CUDA do të reduktonte RTF në shumë më poshtë 0.1 (bazuar në standardet tipike të GPU për VITS), duke mundësuar sintezën e transmetimit në kohë reale. Për më tepër, kuantizimi i modelit në FP16 ose INT8 dhe kalimi në motorët e optimizuar të përfundimeve si ONNX Runtime me OpenVINO, mund të përgjysmojë më tej vonesën duke ruajtur ngjashmërinë e lartë dhe rezultatet MOS.

6 Përfundim

Në këtë hulumtim, një sistem vietnamez tekst-në-fjalë i bazuar në inteligjencën artificiale dhe mësimin e thellë u projektua, u zbatua dhe u vlerësua tërësisht. Sistemi

shfrytëzon modelet moderne si Tacotron, FastSpeech dhe VITS për të kthyer automatikisht tekstin në sinjale natyrale të folurit, duke mësuar veçoritë unike fonetike dhe prozodike të Vietnamishtes. Rezultatet eksperimentale tregojnë se modeli i propozuar gjeneron të folur të qartë, të natyrshëm me intonacion të përshtatshëm dhe ruan performancë të qëndrueshme në kushte dhe kontekste të ndryshme.

Rezultatet e arritura jo vetëm që vërtetojnë efektivitetin e të mësuarit të thellë në sintezën e të folurit vietnamez, por gjithashtu theksojnë zbatueshmërinë e gjerë të sistemit në praktikë, veçanërisht në asistentët virtualë, arsimin, qendrat automatike të thirrjeve dhe mjetet ndihmëse për personat me shikim të dëmtuar. Puna e ardhshme mund të përqendrohet në zgjerimin dhe pasurimin e të dhënave të folurit, përmirësimin e natyralitetit rajonal, optimizimin e modeleve për pajisjet me burime të kufizuara dhe integrimin e sistemit në platformat e botës reale për të rritur fizibilitetin dhe përdorshmërinë.

Referencat

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. & M., & Weber, G. (2020). Common Voice: A massively- multilingual speech corpus. arXiv. <https://arxiv.org/abs/1912.06670>
2. Baevski, A., Zhou, Y., Mohamed, & A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, & E., & Ponti, M. A. (2022). YourTTS: Drejt TTS me shumë altoparlantë me zero dhe konvertim zëri me zero për të gjithë. arXiv. __MBAJ_0__
4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Pratap, V., Conneau, A., Collobert, R., Synnaeve, G., & Auli, M. (2022). WavLM: Trajnim paraprak i vetë-mbikëqyrur në shkallë të gjerë për përpunimin e të folurit në grup të plotë. arXiv. __MBAJ_1__
5. Devlin, J., Chang, M. W., Lee, & K., & Toutanova, K. (2019). BERT: Trajnim paraprak i transformatorëve dydrejtues të thellë për të kuptuar gjuhën. arXiv. __MBAJ_0__
6. Do, N. (2026). VietNormalizer: Një bibliotekë Python me burim të hapur, pa varësi për normalizimin e tekstit vietnamez në aplikacionet TTS dhe NLP. arXiv. __MBAJ_0__
7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, & Y. (2014). Rrjetet gjeneruese kundërshtare. arXiv. __MBAJ_0__
8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhota, K., Salakhutdinov, R., & Mohamed, A. (2021). HuBERT: Mësimi i përfaqësimit të të folurit i vetë-mbikëqyrur nga parashikimi i maskuar i njësive të fshehura. arXiv. __MBAJ_0__
9. Ito, K., & Johnson, L. & (2017). Grupi i të dhënave të të folurit LJ. <https://keithito.com/LJ-Speech-> Grupi i të dhënave/
10. Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, X., Chen, Z., Nguyen, P., Pang, R., Moreno, I. L., & Wu, & Y. (2018). Transferoni mësimin nga verifikimi i altoparlantit në sintezën e tekstit në të folur me shumë altoparlantë. Përparimet në Sistemet e Përpunimit të Informacionit Neural, 31. <https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Efficient neural audio synthesis. arXiv. <https://arxiv.org/abs/1802.08435>
12. Kameoka, H., Kaneko, T., Tanaka, &K.,&Hojo, N.(2018). StarGAN-VC: Non-parallel many-to-many voice conversion using star generative adversarial networks. arXiv.
__MBAJ_0__
13. Kim, J., Kong, J., & Son, J. (2021). &Autoenkoder variacional i kushtëzuar me mësim kundërshtar për transmetimin tekst-në-fjalë nga fundi në fund. arXiv. __MBAJ_1__
14. Kingma, D. P., & Welling, &M. (2014). Fushat variacionale me kodim automatik. arXiv.
__MBAJ_0__
15. Kong, J., Kim, J., & Bae, J. (2020). & HiFi-GAN: Rrjete kundërshtar gjeneruese për sintezë efikase dhe me besnikëri të lartë të të folurit. arXiv. <https://arxiv.org/abs/2010.05646>
16. Mishra, P., Choudhury, J. A., Kho, E., Basu, B., & &Nandi, A. (2023). Identifikimi, diferencimi dhe verifikimi i altoparlantëve duke përdorur mësimin e thellë për ndërfaqen e makinës njerëzore. Në vitin 2023 Simpoziumi i Kërkimeve Fotonike dhe Elektromagnetike (PIERS) (fq. 861–870). IEEE. __MBAJ_2__
17. Nguyen, D. &Q.,&Tuan, N. D. (2020). PhoBERT: Modele gjuhësore të para-trajnuara për Vietnamisht. arXiv. __MBAJ_3__
18. Nguyen, N. (2023). VietTTS: Biblioteka vietnameze tekst në të folur. GitHub.
__MBAJ_0__
19. Oord, A. van den, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A.,&Kavukcuoglu, K.(2016). &WaveNet: Një model gjenerues për audio të papërpunuar. arXiv. __MBAJ_1__
20. Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Raiman, J., Miller, J.,&Sengupta, S.(2017). & Deep Voice 3: Shkallëzimi i tekstit në të folur me mësimin e sekuencës konvolucionale. arXiv. __MBAJ_2__
21. Prenger, R., Valle, R., & Catanzaro, B. (2019). & WaveGlow: Një rrjet gjenerues i bazuar në rrjedhë për sintezën e të folurit. arXiv. __MBAJ_3__
22. Qian, K., Zhang, Y., Chang, S., Yang, X.,&Hasegawa-Johnson, &M.(2019). AutoVC: Transferimi i stilit të zërit me zero me humbje vetëm të kodifikuesit automatik. arXiv.
__MBAJ_0__
23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & &Sutskever, I. (2022). Njohje e fortë e të folurit nëpërmjet mbikëqyrjes së dobët në shkallë të gjerë. arXiv.
__MBAJ_0__
24. Reddy, C. K., Gopal, V., & Cutler, R. (2021). &DNSMOS: Një metrikë e cilësisë së të folurit objektiv perceptues jo ndërhyrës për të vlerësuar shtypësit e zhurmës. Në Konferencën Ndërkombëtare të ICASSP 2021–2021 IEEE mbi Akustikën, Përpunimin e të folurit dhe të Sinjalit (fq. 6493–6497). IEEE. __MBAJ_0__
25. Ren, Y., Ruan, Y., Chen, X., Qin, T., Zhao, S., & Liu, T. (2019). FastSpeech: Tekst në të folur i shpejtë, i fuqishëm dhe i kontrollueshëm. arXiv. __MBAJ_1__
26. Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T. (2020). FastSpeech 2: Tekst në të folur i shpejtë dhe me cilësi të lartë. arXiv. <https://arxiv.org/abs/2006.04558>
27. Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., &Agimonyri, 1.8.
Sintezë natyrore e TTS duke e kushtëzuar WaveNet në parashikimet e spektrogramit mel. arXiv.
__MBAJ_0__
28. Thinh, L. (2024). viXTTS: Një model vietnamez i klonimit të zërit të tekstit në të folur. GitHub.

<https://github.com/thinhlpg/vixtts-demo>

29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Vëmendja është gjithçka që ju nevojitet. arXiv. __MBAJ_0__
30. Vu, T., Nguyen, L. T., & Nguyen, D. Q. (2025). Zero-shot text-to-speech for Vietnamese. arXiv. __MBAJ_0__
31. Wan, L., Wang, Q., Papir, & A., & Moreno, I. L. (2018). Generalized end-to-end loss for verifikimi i folësit. Në 2018 Konferenca Ndërkombëtare IEEE mbi Akustikën, Fjalimin dhe Përpunimi i sinjalit (ICASSP) (fq. 4879–4883). IEEE.
<https://ieeexplore.ieee.org/abstract/document/8462665>
32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Agiomyrgiannakis, Y., Clark, R., & Saurous, R. A. (2017). Tacotron: Drejt sintezës së të folurit nga fundi në fund. arXiv.
<https://arxiv.org/abs/1703.10132>
33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R. J., Battenberg, E., Shor, J., Xiao, Y., Jia, Y., Ren, F., & Saurous, R. A. (2018). Shenjat e stilit: Modelimi i stilit të pambikëqyrur, kontrolli dhe transferimi në sintezën e të folurit nga fundi në fund. arXiv.
<https://arxiv.org/abs/1803.09017>
34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: English multi-korpasi i altoparlantëve për paketën e veglave të klonimit të zërit CSTR (Versioni 0.92). Universiteti i Edinburgut.
<https://datashare.ed.ac.uk/handle/10283/3443>
35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R. J., Jia, Y., Chen, Z., & Wu, Y. (2019). LibriTTS: Një korpus që rrjedh nga LibriSpeech për tekst në fjalim. arXiv.
<https://arxiv.org/abs/1904.02882>
36. Le, T. (2024). viVoice: A large-scale multi-speaker Vietnamese speech dataset for text-to-të folurit. Fytyrë e përqafuar. __MBAJ_0__