

Teksvertaalstelsel handhaaf oorspronklike formaat deur kunsmatige intelligensie te gebruik

Ha Hoang-Phuc ¹ en Tweede skrywer ²[1111-2222-3333-4444]

¹ Fakulteit Inligtingstechnologie, Southern Can Tho Universiteit, Viëtnam

² Springer Heidelberg, Tiergartenstr. 17, 69121 Heidelberg, Duitsland

__HOU__0__

Opsomming. In die konteks van vertaalstelsels wat kunsmatige intelligensie gebruik wat vinnig ontwikkel sedert 2016, het die gebrek aan sistematiese navorsing oor tegnologie, metodes en standaarde vir die evaluering van die vermoë om dokumentformate te behou 'n groot leemte in hierdie veld geskep. Hierdie studie gee 'n omvattende oorsig van KI-teksvertalingstelsels wat in staat is om die oorspronklike formaat te behou deur die ontleding van 40 navorsingsdokumente van 2016 tot 2025, insluitend Viëtnamese en Engels, met behulp van 'n sistematiese klassifikasie- en vergelykingsmetode volgens vyf hoofgroepe insluitend kommersiële produkte, oopbronskode, datastelle, tegniese benaderings en evalueringmetodes. Die ontledingsresultate toon dat drie hooftegnologieneigings reëlgebaseerde vertaalstelsels insluit met die voordeel van eenvoud maar gebrek aan buigsaamheid, masjienvertaling neurale netwerke met beter konteksverwerkingsvermoëns maar groot data benodig, en groot taalmodelle wat vandag oorheers met produkte soos DeepL wat meer as een miljoen ondernemingsgebruikers bereik, Google Translate API met honderde miljoene oproepe per dag, en Adobe Acrobat wat hoofsaaklik die professionele AI-segment gebruik. GPT-4 en gespesialiseerde modelle met vinnige ingenieurstechnieke gekombineer met dokumentstruktuuranalise.

Sleutelwoorde: neurale masjienvertaling, formaatbewaring, PDF-verwerking, DOCX-verwerking, groot taalmodelle, vertaling API.

1 Inleiding

Saam met die sterk ontwikkeling van groot taalmodelle soos GPT-3, GPT-4 en Claude vanaf 2019, het die toepassing van kunsmatige intelligensie op die gebied van die vertaling van dokumente met komplekse strukture begin verskyn deur outomatiese vertaalstelsels wat in staat is om die oorspronklike formaat te behou.

Voordat jy in gedetailleerde ontleding gaan, is dit nodig om 'n paar sleuteltermen en -begrippe wat deur hierdie studie gebruik word, te verduidelik om te verseker dat lesers 'n verenigde begrip het. Masjienvertaling of Masjienvertaling (MT) is die proses om rekenaarsagteware te gebruik om teks van elke brontaal outomaties in die teikentaal te vertaal met min of geen menslike ingryping, deur natuurlike taalverwerking en diepleertegniese te gebruik om die semantiek te verstaan en gepaste vertalings te skep (Vaswani et al., 2017). Formaatbewaring is 'n vermoë van die vertaalstelsel

2 F. Skrywer en S. Skrywer

tegniek in die handhawing van alle aanbiedingselemente van die oorspronklike dokument na vertaling, insluitend lettertipes, lettergroottes, kleure, belyning, tabelle, opskrifte, bladsynommering, koptekste, voettekste en ingebedde grafiese elemente in die dokument (Hassan et al., 2020). Large Language Model of Large Language Model (LLM) is 'n tipe kunsmatige intelligensie-model wat opgelei is op groot hoeveelhede teksdata van biljoene tot triljoene woorde, wat in staat is om komplekse kontekste te verstaan en natuurlike teks soos mense te genereer, met tipiese verteenwoordigers soos OpenAI se GPT-4, Anthropic se Claude, en Google se Gemini (Sato, 202).

2 Produkmark

DeepL Document Translation is in 2017 bekendgestel deur DeepL GmbH, gebaseer in Keulen, Duitsland, wat 'n belangrike keerpunt in die outomatiese dokumentvertalingsbedryf was toe 'n kommersiële produk vir die eerste keer daartoe verbind is om die oorspronklike formaat van DOCX- en PDF-lêers na vertaling heeltemal te bewaar (Hassan et al., 2020).

Na die gewildheid van DeepL, het Google Cloud Translation API na vore gekom as 'n meer omvattende oplossing met meer as 500 miljoen API-oproepe per dag wêreldwyd, wat dit posisioneer as 'n vertaalinfrastruktuurplatform vir ontwikkelaars en besighede wat vertaalvermoëns in hul eie toepassings wil integreer (Hassan et al., 2020). Die belangrikste verskil van Google Wolk-vertaling lê in sy integrasie-ekosisteem met ander Google-dienste soos Google Docs, Google Drive en Google Workspace, wat gebruikers in staat stel om dokumente direk vanaf bekende werksomgewings te vertaal sonder die behoefte aan handmatige formaatomskakeling. Tegnies pas Google Cloud Translation 'n geoptimaliseerde drievlak-argitektuur toe met 'n RESTful API-koppelvlaklaag en kliëntbiblioteke vir Python, Java, Node.js en baie ander programmeertale (Vaswani et al., 2017).

Adobe Acrobat AI Translation verskyn as 'n geïntegreerde kenmerk in die Adobe Acrobat-produkreeks, wat die neiging aandui om KI-vertaling in professionele PDF-dokumentverwerkingsnutsmiddels te integreer in plaas daarvan om dit as 'n onafhanklike diens te verskaf (Hassan et al., 2020). Wat uniek is aan Adobe Acrobat AI, lê in sy oorspronklike dokumentverwerkingsbenadering, waar die stelsel direkte toegang het tot die interne struktuur van PDF-lêers deur Adobe se eie API's, wat die behoud van komplekse formateringselemente moontlik maak wat nie deur derdeparty-oplossings gelees kan word nie. Tegnologies is Adobe Acrobat AI gebou op die Adobe Sensei-platform, Adobe se interne kunsmatige intelligensiestelsel gekombineer met eksterne vertaal-API's soos Microsoft Azure Translator en DeepL deur 'n skaalbare inprop-argitektuur (Park et al., 2021).

Translate-toolkit is een van die eerste oopbronprojekte wat op GitHub verskyn wat multi-formaat vertaallêerverwerking bedien, wat die begin is van 'n beweging om kennis oor veeltalige dokumentverwerking in die programmeringsgemeenskap te deel (Smith, 2019). Die projek word vrygestel onder die GNU GPL v2-lisensie, wat ander ontwikkelaars toelaat om dit vryelik te gebruik, te verander en te herverdeel, onderhewig aan die lisensiebepalings. Wat argitektuur betref, bied translate-toolkit 'n opdragreël-nutsmiddelstel

en Python-biblioteek om te skakel tussen vertaallêerformate soos PO, XLIFF, TMX en dokumentformate soos DOCX, ODT, HTML. Die projek fokus op die onttrekking van teksstringe wat vertaal moet word uit dokumente, terwyl die hele opmaakstruktuur en metadata van die oorspronklike lêer bewaar word. Die installasiemethode word in die dokument uiteengesit, wat vereis dat gebruikers Python 3.8 of hoër en afhanklike pakkette via pip installeer, en dan onmiddellik opdragreëlnutsgoed kan gebruik om dokumente te bondel te verwerk (Park et al., 2021).

3 Bronkode

DeepL is 'n geslote-bron kommersiële produk, die bronkode word nie op enige kodedeelpatform gepubliseer nie, en word streng beskerm as die maatskappy se kernbates volgens die Sigteware-as-'n-diens-model (Hassan et al., 2020). Gebruikers kan slegs met die stelsel interaksie hê deur die webkoppelvlak by deepl.com, die amptelike rekenaartoepassing of die DeepL API met amptelike SDK's vir gewilde programmeertale. Wat pryse betref, pas DeepL 'n freemium-model toe met 'n limiet van 500 000 karakters per maand vir die gratis plan, terwyl Pro-planne herhalende betalings vir onbeperkte toegang, DOCX- en PDF-dokumentverwerking en API-gebruik vereis (Smith, 2019). Die gereedskap wat van die eindgebruiker benodig word, is baie eenvoudig, insluitend slegs 'n moderne webblaaier of rekenaartoepassing, en 'n stabiele internetverbinding om dokumente na DeepL se wolkstelsel op te laai. Besigheidsgebruikers wat API's integreer, benodig 'n Pro-rekening en API-sleutel vir staving, tesame met basiese programmeringskennis om die ooreenstemmende SDK te gebruik.

Google Cloud Translation is soortgelyk aan DeepL, wat ook 'n kommersiële diens is met 'n heeltemal geslote bronkodemodel, maar Google verskaf oopbronskliëntbiblioteke op GitHub om API-integrasie te vergemaklik (Hassan et al., 2020). Daar is geen publieke beskikbare bronkodebewaarplek wat verband hou met die kernvertalingsmodel nie, alhoewel Google baie akademiese referate gepubliseer het wat die algemene modelargitektuur beskryf. Wat fooibeleid betref, pas Google Cloud Translation 'n betaal-soos-jy-gaan-model toe met 'n koers van 20 USD per miljoen karakters nadat die gratis limiet van 500 000 karakters per maand in die eerste jaar opgebruik is (Park et al., 2021). Die integrasieproses vereis die skep van 'n projek op Google Wolk-platform, die aktivering van die Wolk-vertalings-API, die skep van 'n diensrekening en die aflaai van JSON-geloofsbriewe, en installeer dan die ooreenstemmende kliëntbiblioteek via pip of npm. Nodige gereedskap sluit in 'n Google Wolk-rekening, 'n kredietkaart om fakturering te aktiveer, en 'n programmeringsomgewing met 'n taal wat deur die amptelike Google SDK ondersteun word.

4 Data

Tweetalige data speel 'n fundamentele rol in die ontwikkeling en evaluering van formaatbehoud KI-vertaalstelsels, insluitend beide gewone teksdata vir opleiding van vertaalmodelle en gestruktureerde dokumentdata vir die toets van formaatbehoud (Hassan et al., 2020). Die WMT (Workshop on Machine Translation) dataset, wat jaarliks sedert 2006 gehou word, is 'n gewilde bron van maatstafdata.

4 F. Skrywer en S. Skrywer

mees algemeen gebruik in die evaluering van moderne KI-vertalingstelsels, met 'n struktuur wat bestaan uit miljoene pare tweetalige sinne versamel uit nuusbronne, regeringsdokumente en regsdokumente, verdeel in opleidingsstelle, valideringsstelle en gestandaardiseerde toetsstelle (Smith, 2019).

Google Cloud Translation ontwikkel opleidingsdatastelle van uiteenlopende bronne, insluitend tweetalig gefiltreerde en belynde Common Crawl, amptelike vertalings van internasionale organisasies, en publieke akademiese databewaarplekke soos OpenSubtitles en Europarl, met 'n totale geskatte grootte van honderde biljoene tweetalige tokens wat deur komplekse pyplynskoonmaak en deduplisering verwerk word (Vaswani et al., 2017). Die datastruktuur vir dokumentvertalingstake word aangevul met velde soos document_id om sinne wat aan dieselfde dokument behoort te groepeer, section_type om titels, hoofinhoud en byskrifte te onderskei, en format_tags om inlynformaatinsligting soos vet en kursief te enkodeer.

Tabel 1. Vergelyking van datastrukture van groot KI-dokumentvertalingstelsels

Đặc điểm	DeepL	Google Vertaal	Adobe Akrobaat	Mã nguồn mở
Định dạng hỗ trợ	DOCX, PPTX, PDF	DOCX, PDF, HTML	PDF, DOCX	CSV/JSON/XML
Sốngôn ngữ	31 jaar oud	135 mense	35 jaar oud	10–135 uur
Bảo toàn bản	Đầy đủ	Một phần	Đầy đủ	Một phần
Hỗ trợ OCR	Có (giới hạn)	Có (Document AI)	Có (nâng cao)	Tùy thư viện
Dung lượng tối đa	10 MB/leer	20 MB/leer	500 MB/lêer	Onbeperk
Dateer model op	Deurlopend	Deurlopend	Theo phiên bản	Ongelyk
Glossary tùy chỉnh	En	Ja (AutoML)	Nee	Hang af van die projek

Met betrekking tot die metode om geformateerde dokumentdata vir KI-vertaalstelsels in te samel en te bou, kombineer die meeste kommersiële stelsels outomatiese versameling vanaf die web met handmatige filtering en kwaliteitkontrolering deur 'n span taalkundiges (Park et al., 2021). DeepL werk saam met akademiese uitgewers en professionele vertaalagentskappe om tweetalige data van hoë gehalte in gespesialiseerde velde soos medias, reg en ingenieurswese te bekom, en verwerk dit dan deur 'n outomatiese belyningspyplyn gekombineer met menslike hersiening om die kwaliteit van tweetalige sinne te verseker, en word uiteindelik aangevul met terugvertaling en datasintese-tegnieke om diversiteit te verhoog (H, 20an et al.2). Google gebruik grootskaalse versameling van Common Crawl gekombineer met outomatiese taalidentifikasie en sinsbelyningsalgoritmes, maar moet datageraas en semanties ongelykwaardige sinne hanteer deur komplekse kwaliteitfilters gebaseer op verwardheid en kruistalige ooreenkoms (Vaswani et al., 2017).

Tabel 2. Vergelyking van Tarot-data-integrasiemetodes met LLM

Metode	Koste	Graad ingewikkeld	Oupdateer vermoë	Kwaliteit
Prompt Ingenieurswese	Laag (\$0,03–0,06/1K tekens)	Laag	Baie maklik (wysig opdrag)	Tốt cho tài liệu phổ thông
Fyn afstemming	Rất cao (\$500–5000/model)	Hoog	Khó (cần retrain)	Beste vir professionele persone tak
RAG + Translation	Trung bình (\$0.05–0.10/query)	Gemiddeld	Maklik (meer dokumente)	Baie goed wanneer hoofherwinning liggaam
Hibried Pyplyn	Medium – Hoog	Hoog	Buigsaam	Tốt nhất overall

Oorblywende uitdagings in databestuur vir KI-dokumentvertalingstelsels sluit in kopieregkwessies by die gebruik van dokumente van uitgewers, 'n gebrek aan standaardisering in formaataantekeninge oor verskillende datastelle wat konsekwente maatsstawwe moeilik maak, die behoefte aan deurlopende opdaterings om veranderinge in taal en gespesialiseerde terminologie te weerspieël, en die afweging tussen tradisionele egtheid en moderne relevansie in historiese dokumentvertalings (Hassan, 220200).

5 Navorsingsbenaderings

Op die gebied van dokumentvertaling met behulp van kunsmatige intelligensie met formaatbewaringsvermoëns, het navorsing en toepassingsimplementering vanaf 2016 tot nou drie hoof tegnologiese benaderings met verskillende vlakke van kompleksiteit en doeltreffendheid toegepas, wat die vinnige ontwikkeling van die velde van natuurlike taalverwerking en rekenaarvisie weerspieël (Hassan et al., 2020; Smith, 2019). Ontleding van navorsingsdokumente toon 'n duidelike verskuiwing van tradisionele statistiese metodes na oplossings gebaseer op neurale netwerke en groot taalmodelle, parallel met die ontwikkeling van gestruktureerde dokumentontledingstegnieke wat meer akkurate en geoutomatiseerde verwerking van komplekse formateringselemente moontlik maak (Vaswani et al., 2017; Park et al., 2021). Die fundamentele verskil in vergelyking met suiwer teksvertalingstelsels is dat die probleem van die vertaling van geformateerde dokumente vereis dat twee onafhanklike maar nou verwante kwessies gelyktydig opgelos word: semantiese vertalingskwaliteit en die integriteit van die aanbiedingstruktuur, waarin die optimalisering van een dimensie dikwels die ander dimensie beïnvloed (Sato, 2025; Hassan et al., 2020).

6 F. Skrywer en S. Skrywer

Gepubliseerde navorsing oor KI-dokumentvertalingstelsels word in drie hoofgroepe geklassifiseer gebaseer op die kerntegnologie. Die benadering tot statistiese masjienvertaling (SBS) het die vroegste verskyn en word steeds in sommige hulpbronbeperkte ingebedde stelsels gebruik. Die neurale masjienvertaling (NMT) benadering gebaseer op enkodeerder-dekodeerder-argitektuur met aandagmeganisme het in 2017 die standaard geword ná die artikel "Attention Is All You Need" deur Vaswani et al. Benaderings gebaseer op groot taalmodelle is dominant sedert 2020 toe GPT-3 die vermoë gedemonstreer het om 'n paar skootvertaling te doen sonder om op gespesialiseerde tweetalige data te verfyn (Vaswani et al., 2017; Sato, 2025).

Die statistiese masjienvertalingsbenadering (SBS) is 'n metode wat gebruik is voordat die diepleer-era begin het, gebaseer op waarskynlikheidsmodelle wat uit grootskaalse tweetalige data leer om die hoogste waarskynlikheidsvertaling vir 'n gegewe bronsin te vind (Smith, 2019). In hierdie benadering is die stelsel ontwerp om te werk deur die bronsin te ontbind in kleiner vertaaleenhede genaamd frases, te soek vir ooreenstemmende frases in 'n frasetabel wat uit tweetalige opleidingsdata gebou is, en dit te kombineer in 'n volledige vertaling volgens die doeltaalmodel (Hassan et al., 2020). Die belangrikste voordele van hierdie metode wat deur studies uitgelig word, is deursigtigheid in die vertaalproses wat handmatige kontrolering en intervensie moontlik maak, lae berekeningskoste wanneer afleidings geskik is vir hulpbron-arm omgewings, die vermoë om woordeboeke en linguistiese reëls wat deur kundiges gebou is direk te integreer, en geen behoefte aan 'n gespesialiseerde GPU om te ontplooi nie. Studies wys egter ook beduidende beperkings uit, insluitend vertaalkwaliteit wat in die meeste taalpare dikwels slegter as NGV is as gevolg van nie modellering van lang kontekste nie, gebrek aan vermoë om komplekse grammatikale strukture met groot verskille tussen bron- en teikentale te hanteer, en veral geen natuurlike meganisme om formateringsinligting wat aan die teks geheg is, te verwerk nie (Park et al., 2021). Navorsing deur Hassan et al. (2020) toon dat die SBS-stelsel 'n gemiddelde BLEU-telling van 8 tot 12 punte laer as NGV op die WMT-standaardtoetsuites behaal, en die formaatbehoudsyfer is slegs 62% in toetsing met DOCX-dokumente as gevolg van die gebrek aan 'n karteringmeganisme tussen vertaaleenhede en ooreenstemmende formaatkomponente.

6 Evalueringsaanwysers

Bestaande studies oor KI-dokumentvertalingstelsels toon 'n neiging om multidimensionele evalueringsraamwerke te bou, wat kwantitatiewe en kwalitatiewe metodes kombineer om terselfdertyd die kwaliteit van semantiese vertaling en die mate van bewaring van die oorspronklike dokumentformaat te meet, twee onafskeidbare aspekte in die algehele assessering van stelseldoeltreffendheid (Vaswani et al., 2020:7). Literatuuroorsig toon dat evalueringsraamwerke dikwels gevorm word op grond van vyf hoofgroepe aanwysers, insluitend semantiese vertalingskwaliteit, vlak van formaatbewaring, gebruikerservaring, tegniese werkverrigting en etiese nakoming, insluitend 'n kombinasie van algemene aanwysers wat wyd gebruik word in die evaluering van masjienvertalingstelsels soos BLEU Score, TER en METEOR, tesame met spesifieke aanwysers wat die probleem van dokumentbewaring Racury en Laout weerspieël. Strukturele integriteit (Smith, 2019; Park et al., 2021). Groep vertalingskwaliteit-indekse wat deur navorsing gebruik word

gebruik om die vlak van semantiese ekwivalensie tussen outomatiese vertaling en verwysingsvertaling te evalueer, om sodoende die kernuitdaging uit te wys om getrouheid aan die bronteks en natuurlikheid in die doeltaal te balanseer, veral belangrik vir tegniese dokumente wat absolute terminologiese akkuraatheid vereis (Hassan et al., 2020; Sato, 2025).

7 Gevolgtrekking

Hierdie studie het 'n omvattende oorsig van formaatbewarende teksvertalingstelsels deur kunsmatige intelligensie gedoen deur 'n sistematiese ontleding van 40 navorsingsreferate van 2016 tot 2025, insluitend akademiese studies en tegniese verslae in Viëtnamese en Engels. Die toegepaste navorsingsmetode is om kommersiële produkte, oopbronskode, datastelle, tegniese benaderings en evalueringsmetodes wat in vorige studies voorgestel is, sistematies te klassifiseer en te vergelyk. Die ontleding onthul drie groot tegnologieneigings in hierdie veld, insluitend statistiese masjienvertaling met die voordele van deursigtigheid en lae koste, maar met beperkte gehalte en gebrek aan inheemse formaatbewaringsmeganismes, neurale masjienvertaling met voortreflike semantiese gehalte en ondersteuning vir opmaakbewuste vertaling, maar wat steeds tekort skiet aan die 95%-formaatbewaringsdrempel wat besighede benodig, en die suksesvolle produkte soos 'n groot besigheidsmodel oorheers. professioneel, Google Wolk-vertaling met honderde miljoene API-oproepe per dag en Adobe Acrobat-posisionering in die hoë- en professionele segment.

Wat die produkmark en implementeringstegnologie betref, toon die ontleding 'n duidelike stratifikasie tussen verskillende teikengroepe met DeepL wat in die hoëgehaltesegment geposisioneer is, danksy sy tweestadiumverwerkingspyplyn wat inhoud van formaat skei en 31 tale ondersteun, Google Wolk-vertaling fokus op skaalbaarheid en ekosisteem-integrasie met 135 tale, en Adobe Acrobat wat die behoeftes van professionele gebruikers in die PDF-stelsel verwerk met komplekse PDF-integrasie. Kreatiewe Wolk. Die opkoms van oopbronprojekte soos translate-toolkit, py-pdf-vertaler en docx-vertaler sedert 2019 het die ontwikkelaargemeenskap in staat gestel om na te vors en pasgemaakte oplossings te bou. Ontleding van die tegniese benadering toon dat die LLM-gebaseerde pyplyn met temperatuur 0.2 en top_p 0.9 die beste vertaalkwaliteit behaal terwyl die hoogste formaatbewaringsyfer in beskikbare toetse gehandhaaf word.

Tài Liệu Tham Khảo

1. Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neurale masjienvertaling deur gesamentlik leer om in lyn te bring en te vertaal. Internasionale Konferensie oor Leervoorstellings (ICLR 2015). __HOU_0__
2. Bojar, O., Buck, C., Federmann, C., Haddow, B., Koehn, P., Leveling, J., Monz, C., Pecina, P., Post, M., Saint-Amand, H., Soricut, R., Specia, L., & Tamchyna, A. (2014). Bevindinge van die 2014-werkswinkel oor statistiese masjienvertaling. Verrigtinge van die negende werkswinkel oor statistiese masjienvertaling, 12–58. __HOU_0__

8 F. Skrywer en S. Skrywer

3. Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901. <https://arxiv.org/pdf/2005.14165.pdf>
4. Chiang, D.(2007). Hierarchical phrase-based translation. *Computational Linguistics*, 33(2), 201–228. <https://aclanthology.org/J07-2003.pdf>
5. Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Mejia-Gonzalez, G., Hansanti, P., Hoffman, J.,&Wang, C. (2022). Geen taal agtergelaat nie: Skaal mensgesentreerde masjienvertaling. *arXiv voordruk* arXiv: 2207.04672. <https://arxiv.org/pdf/2207.04672.pdf>
6. Devlin, J., Chang, M.-W., Lee, K.,&Toutanova, K. (2019). BERT: Vooropleiding van diep tweerigtingstransformators vir taalbegrip. *Verrigtinge van NAACL-HLT 2019*, 4171–4186. [__HOU_0__](#)
7. Dou, Z.-Y.,&Neubig, G. (2021). Woordbelyning deur inbeddings op parallel te verfyn korpuse. *Verrigtinge van die 16de Konferensie van die Europese Hoofstuk van die Vereniging vir Rekenaarlinguistiek*, 2112–2128. [__HOU_0__](#)
8. Edunov, S., Ott, M., Auli, M.,&Grangier, D. (2018). Verstaan terugvertaling by skaal. *Verrigtinge van die 2018-konferensie oor empiriese metodes in natuurlike taal Verwerking*, 489–500. [__HOU_0__](#)
9. Feng, S., Graham, Y.,&Baldwin, T. (2022). Dokumentvlak masjienvertaling met lang-dokument transformator. *Verrigtinge van die 2022-konferensie oor empiriese metodes in Natuurlik Taal Verwerking*, 3698–3711. <https://aclanthology.org/2022.emnlp-hoof.249.pdf>
10. Floridi, L., Cows, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., Luetge, C., Madelin, R., Pagallo, U., Rossi, F., Schafer, B., Valcke, P.,&Vayena, E. (2018). Die eties raamwerk vir a goeie AI samelewing: Geleenthede, risiko's, beginsels, en aanbevelings. *Gedagtes en masjiene*, 28(4), 689–707. <https://link.springer.com/content/pdf/10.1007/s11023-018-9482-5.pdf>
11. Gehring, J., Auli, M., Grangier, D., Yarats, &D.,&Dauphin, Y. N.(2017). Convolutional sequence to sequence learning. *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, 1243–1252. <https://arxiv.org/pdf/1705.03122.pdf>
12. Gu, J., Hassan, H., Devlin, J., & Li, V. O. K. (2018). Universal neural machine translation for extremely low resource languages. *Proceedings of NAACL-HLT 2018*, 344–354. <https://arxiv.org/pdf/1802.05368.pdf>
13. Hassan, H., Aue, A., Chen, C., Chowdhary, V., Clark, J., Federmann, C., Huang, X., Junczys-Dowmunt, M., Lewis, W., Li, M., Liu, S., Liu, T.-Y., Luo, R., Menezes, A., Qin, T., Seide, F., Tan, X., Tian, F., Wu, &L.,&Zhou, M.(2018). Achieving human parity on automatic Chinese to English news translation. *arXiv preprint arXiv: 1803.05567*. <https://arxiv.org/pdf/1803.05567.pdf>
14. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Madotto, A.,& Fung, P. (2023). Opname van hallusinasie in natuurlike taalgenerering. *ACM Computing Surveys*, 55(12), 1–38. [__HOU_0__](#)
15. Johnson, M., Schuster, M., Le, Q. V., Krikun, M., Wu, Y., Chen, Z., Thorat, N., Viégas, F., Wattenberg, M., Corrado, G., Hughes, M.,&Dean, J. (2017). Google se veeltalige neurale masjienvertalingstelsel: Maak nulskoot-vertaling moontlik. *Transaksies van die Vereniging vir Rekenaarlinguistiek*, 5, 339–351. <https://arxiv.org/pdf/1611.04558.pdf>

16. Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Hermann, U., Aji, A. F., Bogoychev, N., Martins, A. F. & T., & Birch, A. (2018). Marian: Fast neural machine translation in C++. Proceedings of ACL 2018 System Demonstrations, 116–121. <https://arxiv.org/pdf/1804.00344.pdf>
17. Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. International Conference on Learning Representations (ICLR 2015). <https://arxiv.org/pdf/1412.6980.pdf>
18. Klein, G., Kim, Y., Deng, Y., Senellart, & J., & Rush, A. M. (2017). OpenNMT: Open-source toolkit for neural machine translation. Proceedings of ACL 2017 System Demonstrations, 67–72. <https://arxiv.org/pdf/1701.02810.pdf>
19. Koehn, P., Hoang, H., Birch, A., Callison-Burch, C., Federico, M., Bertoldi, N., Cowan, B., Shen, W., Moran, C., Zens, R., Dyer, C., Bojar, O., Constantin, & A., & Herbst, E. (2007). Moses: Oopbrongereedskapstel vir statistiese masjienvertaling. Verrigtinge van die 45ste jaarvergadering van die ACL oor interaktiewe plakkaat- en demonstrasiesessies, 177–180. <https://arxiv.org/pdf/0710.1808.pdf>
20. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Herwinning-vergrote generasie vir kennisintensief NLP take. Voorskotte in Neurale Inligtingverwerkingstelsels, 33, 9459–9474. <https://arxiv.org/pdf/2001.08210.pdf>
21. Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Veeltalige denoising-vooropleiding vir neurale masjienvertaling. Transaksies van die Vereniging vir Rekenaarlinguistiek, 8, 726–742.
22. Luong, M.-T., Pham, H., & Manning, C. D. (2015). Effektiewe benaderings tot aandaggebaseerde neurale masjienvertaling. Verrigtinge van die 2015-konferensie oor empiriese metodes in Natuurlik Taal Verwerking, 1412–1421. <https://arxiv.org/pdf/1508.04025.pdf>
23. Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: 'n Metode vir outomatiese evaluering van masjienvertaling. Verrigtinge van die 40ste Jaarvergadering van die Vereniging vir Rekenaarlinguistiek, 311–318. <https://arxiv.org/pdf/1804.08771.pdf>
24. Post, M. (2018). A call for clarity in reporting BLEU scores. Proceedings of the Third Conference on Machine Translation: Research Papers, 186–191.
25. Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., & Liu, P. J. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of Machine Learning Research, 21(140), 1–67.
26. Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). COMET: A neural framework for MT evaluation. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, 2685–2702. <https://arxiv.org/pdf/2009.09025.pdf>
27. Sato, M. (2025). Triggering hallucinations in LLMs: A quantitative study of prompt-induced hallucination in large language models. arXiv preprint arXiv: 2505.00557. <https://arxiv.org/pdf/2505.00557.pdf>
28. Sahoo, P., Singh, A. K., Saha, S., Jain, V., Mondal, S., & Chadha, A. (2024). A systematic survey of prompt engineering in large language models: Techniques and applications. arXiv voordruk arXiv: 2402.07927. <https://arxiv.org/pdf/2402.07927.pdf>
29. Schulhoff, S., Ilie, M., Balepur, N., Kahadze, K., Liu, A., Si, C., Li, Y., Gupta, A., Han, H., Schulhoff, S., Dulepet, P. S., Vidyadhara, S., Ki, D., Agrawal, S., Chinakomnam, C., Feng, & Y., & Resnik, P. (2024). The prompt report: A systematic survey of prompt

10 F. Skrywer en S. Skrywer

ingenieurstechniek. arXiv voordruk arXiv: 2406.06608.

<https://arxiv.org/pdf/2406.06608.pdf>

30. Snover, M., Dorr, B., Schwartz, R., Micciulla, L., & Makhoul, J. (2006). 'n Studie van vertalingsredigeertempo met geteikende menslike annotasie. Verrigtinge van Vereniging vir Masjien Vertaling in die Amerikas (AMTA 2006), 223–231.

<https://aclanthology.org/2006.amta-papers.25.pdf>

31. Stahlberg, F. (2020). Neural machine translation: A review. *Journal of Artificial Intelligence Research*, 69, 343–418. <https://arxiv.org/pdf/1912.02047.pdf>

32. Tiedemann, J. (2012). Parallel data, tools and interfaces in OPUS. *Proceedings of the Eight International Conference on Language Resources and Evaluation (LREC 2012)*, 2214–2218.

<https://aclanthology.org/L12-1246.pdf>

33. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS 2017)*. <https://arxiv.org/pdf/1706.03762.pdf>

34. Weidinger, L., Mellor, J., Rauh, M., Griffin, C., Uesato, J., Huang, P.-S., Cheng, M., Glaese, M., Balle, B., Kasirzadeh, A., Kenton, Z., Brown, S., Hawkins, W., Stepleton, T., Biles, C., Birhane, A., Haas, J., Rimell, L., Hendricks, L. A., & Gabriel, I. (2021). Ethical and social risks of harm from language models. arXiv preprint arXiv: 2112.04359.

<https://arxiv.org/pdf/2112.04359.pdf>

35. Wu, Y., Schuster, M., Chen, Z., Le, Q. V., Norouzi, M., Macherey, W., Krikun, M., Cao, Y., Gao, Q., Macherey, K., Klingner, J., Shah, A., Johnson, M., Liu, X., Kaiser, Ł., Gouws, S., Kato, Y., Kudo, T., Kazawa, H., & Dean, J. (2016). Google's neural machine translation system: Bridging the gap between human and machine translation. arXiv preprint arXiv: 1609.08144. <https://arxiv.org/pdf/1609.08144.pdf>

36. Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., & Raffel, C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer.

Verrigtinge van NAACL-HLT 2021, 483–498. __HOU_0__

37. Zhang, B., & Sennrich, R. (2019). Root mean square layer normalization. *Advances in Neural Information Processing Systems*, 32. <https://arxiv.org/pdf/1910.07467.pdf>