

**Outomatiese teks-na-spraak-
stelsel vir Viëtnamees gebruik
Kunsmatige Intelligensie**

Thanh-Danh Vo 1, Ngo-Ho Anh-
Khoa 1 en Ngo-Ho Anh-Khoi 1*

1

F
a
k
u
l
t
e
i
t

I
n
l
i
g
t
i
n
g
s
t
e
g
n
o

l
o
g
i
e
,

N
a
m

C
a
n

T
h
o

U
n
i
v
e
r
s
i
t
e
i
t
,

N
g

u
y
e
n

V
a
n

C
u
s
t
r
a
a
t

1
6
8
,

A
n

B
i
n
h

W
y
k
,

C
a
n

T
h
o

C
i
t
y
,

V
i
e
t
n
a
m

—
—
H
O
U

—
0

—
—
,

,
,

n
h
a
k
h
o
i
@
n
c
t
u
.
e
d

**A
b
s
t**

**r
a
k
.**

I
n

d
i
e

k
o
n
t
e
k
s

v
a
n

d
i
g
i
t
a
l
e

t
r
a
n
s
f
o
r
m
a
s
i
e

e
n

d
i

e

v

i

n

n

i

g

e

v

o

o

r

u

i

t

g

a

n

g

v

a

n

k

u

n

s

m

a

t

i

g

e

i

n

t

e

l

l

i

g

e

n

s

i

e

,

h
e
t

d
i
e

v
r
a
a
g

n
a

t
e
k
s
-
n
a
-
s
p
r
a
a
k

(
T
T
S
)
-
s
t
e
l
s
e
l
s

r
a
a
k

t
o
e
n
e
m
e
n
d

k
r
i
t
i
e
s

o
o
r

d
o
m
e
i
n
e

s
o
o
s

v
i
r
t
u
e
l
e

a
s
s
i
s
t
e
n

t
e
,

o
n
d
e
r
w
y
s
,

o
u
t
o
m
a
t
i
e
s
e

o
p
r
o
e
p
s
e
n
t
r
u
m
s
,

e
n

t
o
e
g
a
n
k

l
i
k
h
e
i
d

g
e
r
e
e
d
s
k
a
p

v
i
r

d
i
e

v
i
s
u
e
e
l

b
e
n
a
d
e
e
l
.

G
e
n
e
r
e
e

r

e

g

t

e

r

n

a

t

u

u

r

l

i

k

,

k

o

n

t

e

k

s

b

e

w

u

s

e

n

p

r

o

s

o

d

i

e

s

g

e

p

a

s

t

e

s
p
r
a
a
k

b
l
y

,
n

g
r
o
o
t

u
i
t
d
a
g
i
n
g
,

v
e
r
a
l

v
i
r

V
i
ë
t
n
a
m
e
e
s

—
,
n

t
o
o
n
t
a
a
l

m
e
t

k
o
m
p
l
e
k
s
e

t
o
o
n
h
o
o
g
t
e
k
o
n
t
o
e
r
e

e
n

s
t
r

e
e
k
s

d
i
v
e
r
s
i
t
e
i
t
.

H
i
e
r
d
i
e

n
a
v
o
r
s
i
n
g

s
t
e
l

v
o
o
r

e
n

o
n
t

w
i
k
k
e
l

,
n

V
i
ë
t
n
a
m
e
s
e

T
T
S
-
s
t
e
l
s
e
l

w
a
t

g
e
b
o
u

i
s

o
p

m
o
d

e
r
n
e

d
i
e
p
l
e
e
r
m
o
d
e
l
l
e

o
m

d
i
e

b
e
p
e
r
k
i
n
g
s

v
a
n

t
r
a
d
i
s
i
o
n

e
l
e

t
e

o
o
r
k
o
m

m
e
t
o
d
e
s
.

D
i
e

s
t
e
l
s
e
l

m
a
a
k

g
e
b
r
u
i
k

v
a
n

d
i
e

n
u
u
t
s
t
e

a
r
g
i
t
e
k
t
u
r
e
,

i
n
s
l
u
i
t
e
n
d

T
a
c
o
t
r
o
n
,

F
a
s
t
S
p

e
e
c
h

e
n

V
I
T
S
,

g
e
k
o
m
b
i
n
e
e
r

m
e
t

m
a
s
j
i
e
n
l
e
e
r
t
e
g
n
i
e
k
e

s
i

n
t
e
s
e

k
w
a
l
i
t
e
i
t

t
e

v
e
r
b
e
t
e
r
.

K
o
n
s
t
r
u
k
s
i
e

e
n

e
v
a
l
u
e
r
i

n
g

w
o
r
d

u
i
t
g
e
v
o
e
r

o
p

a

d
i
v
e
r
s
e

V
i
ë
t
n
a
m
e
s
e

d
a
t
a
s
t
e
l
,

w
a
t

a
a
n
p
a
s
b
a
a
r
h
e
i
d

b
y

v
e
r
s
k
e
i
e

w
e
r
k
l
i
k
e

w
ê
r
e
l
d

v
e
r
s
e

k
e
r

k
o
n
t
e
k
s
t
e
.

R
e
s
u
l
t
a
t
e

t
o
o
n

d
a
t

d
i
e

s
t
e
l
s
e
l

n
a
t
u
u
r

l
i
k
,

d
u
i
d
e
l
i
k
,

h
o
o
g
s

b
e
r
e
i
k

b
u
i
g
s
a
m
e

s
p
r
a
a
k
u
i
t
s
e
t

m
e

t

b
r
e
ë

p
o
t
e
n
s
i
a
a
l

v
i
r

o
n
t
p
l
o
o
i
i
n
g

i
n

d
i
g
i
t
a
l
e

p
l
a
t
f
o

r
m
s

e
n

i
n
t
e
l
l
i
g
e
n
t
e

d
i
e
n
s
t
e
.

S
l
e
u
t
e
l
w
o
o
r
d
e
:

T
e
k
s
-

n
a
-
s
p
r
a
a
k

(
T
T
S
)
,

K
u
n
s
m
a
t
i
g
e

I
n
t
e
l
l
i
g
e
n
s
i
e

(
K
I
)

,

D
e
e
p

L
e
a
r
n
i
n
g
,

N
a
t
u
r
l
i
k
e

T
a
a
l
v
e
r
w
e
r
k
i
n
g

(
N
L
P
)
,

S
p
r
a

a
k
s
i
n
t
e
s
e
.

1 Inleiding

Gedryf deur digitale transformasie en die vordering
van kunsmatige intelligensie, die behoefte om

b
o
u

t
e
k
s
-
n
a
-
s
p
r
a
a
k

(
T
T
S
)
-
s
t
e
l
s
e
l
s

w
o
r
d

a

l
h
o
e

b
e
l
a
n
g
r
i
k
e
r
o
p

g
e
b
i
e
d
e

s
o
o
s

a
s

v
i
r
t
u
e
l
e

a
s
s
i
s
t
e
n
t
e
,

o

n
d
e
r
w
y
s
,

o
u
t
o
m
a
t
i
e
s
e

o
p
r
o
e
p
s
e
n
t
r
u
m
s
,

e
n

o
n
d
e
r
s
t
e
u
n
i
n
g

v
i
r

d
i
e

v
i
s
u
e
e
l

b
e
n
a
d
e
e
l
.

D
i
e

T
T
S
-
p
r
o
b
l
e
e
m

s
t
r
e
k

e
g
t
e
r

v
e
r
d
e

r

a
s

d
i
e

o
m
s
k
a
k
e
l
i
n
g

v
a
n

t
e
k
s

i
n

o
u
d
i
o
;

d
i
t

v
e
r
e
i
s

d
a
t

d
i

e

g
e
s
i
n
t
e
t
i
s
e
e
r
d
e

s
t
e
m

n
a
t
u
u
r
l
i
k

m
o
e
t

w
e
e
s
,

g
e
p
a
s
t
e

i
n
t
o
n

a
s
i
e

d
r
a
,

e
n

p
a
s

b
y

d
i
e

g
e
g
e
w
e

k
o
n
t
e
k
s

-

,

n

b
e
s
o
n
d
e
r

m
o
e
i

l
i
k
e

t
a
a
k

v
i
r

V
i
ë
t
n
a
m
e
e
s
,
,
n

t
a
a
l

m
e
t
,
n

k
o
m
p
l
e
k
s
e

t
o
o
n
s
t

e
l
s
e
l

e
n

a
a
n
s
i
e
n
l
i
k
e

s
t
r
e
e
k
s
v
a
r
i
a
s
i
e

(
D
o
,
2
0
2
6
)
.

T
r
a
d
i
s
i
o
n

e
l
e

k
o
n
k
e
t
e
n
a
t
i
e
w
e

e
n

f
o
r
m
a
n
t
-
g
e
b
a
s
e
e
r
d
e

T
T
S
-
m
e
t
o
d
e
s

(
Z
e
n

e
t

a
l
.
,

2
0
1
9
)

e
n

H
i
d
d
e
n

M
a
r
k
o
v

M
o
d
e
l

(
H
M
M
)

-
g
e
b
a
s
e
r
d
e

s
i
n

t
e
s
e

(
Z
e
n

e
t

a
l
.
,

2
0
1
9
)

v
e
r
t
o
o
n

b
e
p
e
r
k
i
n
g
s

i
n

b
u
i
g
s
a
a
m
h
e
i
d

,

n

a

t

u

u

r

l

i

k

h

e

i

d

e

n

s

k

a

a

l

b

a

a

r

h

e

i

d

.

I

n

r

e

a

k

s

i

e

,

m

o

d

e

r

n

e

d

i

e

p

l

e

e

r

m

o

d

e

l

l

e

s

o

o

s

T

a

c

o

t

r

o

n

(

W

a

n

g

e

t

a

l

.

,

2

0

1

7

)

,

T

a

c

o

t

r

o

n

2

(
S
h
e
n

e
t

a
l
.
,

2
0
1
8
)
,

F
a
s
t
S
p
e
e
c
h

(
R
e
n
)

2

F
.

S
k
r
y
w
e
r

e
n

S
.
S
k
r
y
w
e
r

e
t

a
l
.
,

2
0
1
9

,
2
0
2
0
)
,

e
n

V
I
T
S

(
K
i
m

e
t

a
l
.
,

2
0
2
1
)

h
e
t

m
e
e
r

e
f
f
e
k
t
i
e
w
e

w
e
ë

o
o
p
g
e
m
a
a
k

d
e
u
r

d
i
r
e
k

u
i
t

d
a
t
a

t
e

l
e
e
r
·

V
o
o
r
t
b
o
u

o
p

h
i
e
r
d
i
e

v
o
o
r
u
i
t
g
a
n
g
,

f
o
k
u
s

h
i
e
r
d
i
e

s
t
u

d
i
e

o
p

d
i
e

n
a
v
o
r
s
i
n
g

e
n

o
n
t
w
i
k
k
e
l
i
n
g

v
a
n

,
n

V
i
ë
t
n
a
m
e
s
e

T
T

S
-
s
t
e
l
s
e
l

w
a
t

d
a
a
r
o
p

g
e
m
i
k

i
s

o
m

s
t
e
m
k
w
a
l
i
t
e
i
t

e
n

p
r
a
k
t
i
e

s
e

t
o
e

p
a
s
l
i
k
h
e
i
d

t
e

v
e
r
b
e
t
e
r

.

2 Verwante werk

Die Viëtnamese TTS-mark beskik oor verskeie prominente plaaslike platforms saam met internasionale oplossings. FPT Smart Cloud Text to Speech, ontwikkel deur FPT Corporation, lewer 'n hoë-gehalte Viëtnamese TTS-diens deur 'n kommersiële API (Vu et al., 2025; Nguyen, 2023). Dit pas diepleer-argitekture soos Tacotron (Wang et al., 2017) en Transformer-variante (Vaswani et al., 2017) toe tesame met vokoders soos WaveNet (Oord et al., 2016) en HiFi-GAN (Kong et al., 2020) om met diverse spoed, stem- en streeksbeheer te produseer. Die stelsel word wyd gebruik in interaktiewe stemrespons (IVR), audioboëke, virtuele assistente en aanlyn onderwys (Do, 2026). Viettel AI Text-to-Speech bied 'n SaaS-gebaseerde oplossing wat vir Viëtnameses geoptimaliseer is (Vu et al., 2025; Nguyen, 2023), wat gebruik maak van gevorderde neurale modelle wat op grootskaalse, Viëtnameses-spesifieke spraakkorpora opgelei is om akkurate 206-uitspraak, en ekspressiewe, natuurlike uitspraak, oor- en uitspraak te verseker. al., 2016; Kong et al., 2020). Zalo AI Text to Speech, 'n produk van VNG Corporation, integreer diep NLP-modelle soos &PhoBERT(Nguyen&Tuan, 2020) en BERT-styl vooropleiding (Devlin et al., 2019) met sintese-argitekture insluitend Tacotron, FastSpeech, en Rens et al., VITS, 20 et al. 2019; Kim et al.,

2021), wat massiewe gebruikersdata gebruik om veelvuldige praatstyle te ondersteun (Vu et al., 2025). Voice.vn spesialiseer in spraaksintese en stemkloning (Vu et al., 2025) deur gebruik te maak van end-tot-end-modelle soos VITS (Kim et al., 2021) en stemomskakelingstegnieke (Casanova et al., 2022; Chen et al., 2022), wat pasmaak vir stemafsluiting moontlik maak en pasmaak vir advertensies, podcasting en speletjies. Google AI Studio verskaf 'n wolk-gebaseerde omgewing vir TTS via die Gemini-familie en Google Cloud Text-to-Speech (Vaswani et al., 2017; Ren et al., 2019), met veeltalige, natuurlike en konteks-aanpasbare stemgenerering (She et al., 2018, 2018). EventLab bied TTS- en stemkloningnutsmiddels gebou op end-tot-end TTS (Wang et al., 2017) en luidsprekerinbeddingsmodelle (Chen et al., 2022; Kim et al., 2021; Casanova et al., 2022). In die algemeen skuif die mark van eenvoudige teksleesstelsels na intelligente kommunikasieplatforms, met sterk neigings in stemkloning (Jia et al., 2018) en multimodale KI.

D
i
e

o
o
p
b

r
o
n

g
e
m

e
e
n

s
k
a

p

h
e
t

,

n

r
e
e
k
s

V
i
ë
t
n
a
m
e
s
e

T
T
S
-
m
o
d
e
l
l
e

b
y
g
e
d
r
a
.

V
i
e
t
T
T
S

i
s
,
n

v
e
r
t
e
e
n
w
o
o
r

d
i
g
e
n
d
e

s
t
e
l
s
e
l

w
a
t

g
e
b
o
u

i
s

m
e
t

e
n
k
o
d
e
e
r
d
e
r
-
d
e
k
o
d
e
e
r
d
e
r

o
f

t
r
a
n
s
f
o
r
m
a
t
o
r
-
a
r
g
i
t
e
k
t
u
r
e

(
W
a
n
g

e
t

a
l
.
,

2
0
1
7
;

V
a
s
w
a
n
i

e
t

a
l
.
,

2
0
1
7
;

R
e
n

e
t

a
l
.
,

2
0
1
9
)
,

o
p
g
e
l
e
i

o
p

n
o
u
k
e
u
r
i
g

g
e
n

o
r
m
a
l
i
s
e
e
r
d
e

V
i
ë
t
n
a
m
e
s
e

d
a
t
a

(
D
o
,

2
0
2
6
)

o
m

t
o
n
e
,

s
a
a
m
g
e
s
t

e
l
d
e

w
o
o
r
d
e

e
n

s
i
n
t
y
d
s
t
r
u
k
t
u
r
e

t
e

h
a
n
t
e
e
r
,

w
a
t

g
e
s
k
i
k
t
e

n

a
b
y
-
t
y
d
-
s
t
r
u
k
t
u
r
e

b
i
e
d
,

w
a
t

w
e
r
k
l
i
k
e

l
a
t
e
n
s
i
e

b
i
e
d
.

e
-
l
e
e

r

e
n

o
u
d
i
o
b
o
e
k
p
r
o
d
u
k
s
i
e

(
N
g
u
y
e
n
,

2
0
2
3
;

V
u

e
t

a
l
.
,

2
0
2
5
)
.

N
e
u
T
T
S
-
A
i
r

f
o
k
u
s

o
p

l
i
g
g
e
w
i
g
,

d
o
e
l
t
r
e
f
f
e
n
d
e

a
f
l
e
i
d
i
n
g
,

b
a

l
a
n
s
e
r
i
n
g

v
a
n

s
t
e
m
k
w
a
l
i
t
e
i
t

e
n

s
p
o
e
d

o
m

o
p

S
V
E
,

s
o
f

l
a
e
h
u

l
p
b
r
o
n
t
o
e
s
t
e
l
l
e

t
e

w
e
r
k

(
R
e
n

e
t

a
l
.
,

2
0
1
9
,
2
0
2
0
;
;

K
i
m

e
t

a
l

.
,
2
0
2
1
)
,

B
y
d
r
a
e

T
i
t
e
l

(
v
e
r
k
o
r
t

i
n
d
i
e
n

t
e

l
a
n
k
)

3

g
e
o
p
t

i
m
a
l
i
s
e
e
r

v
i
r

c
h
a
t
b
o
t
s
,

I
V
R

e
n

I
o
T
-
t
o
e
p
a
s
s
i
n
g
s

(
P
i
n
g

e
t

a
l
.
,

2
0
1
7
;

K
a
l
c
h
b
r
e
n
n
e
r

e
t

a
l
.
,

2
0
1
8
)
.

K
a
n
i
-
T
T
S

i
s

,
n

g
r

o
o
t
s
k
a
a
l
s
e

m
o
d
e
l

m
e
t

o
n
g
e
v
e
e
r

3
7
0

m
i
l
j
o
e
n

p
a
r
a
m
e
t
e
r
s
,

w
a

t

m
i
k

n
a

h
o
ë

e
k
s
p
r
e
s
s
i
w
i
t
e
i
t

e
n

p
r
o
f
e
s
s
i
o
n
e
l
e

k
l
a
n
k
g
e
h
a
l

t
e

(
K
i
m

e
t

a
l
.
,

2
0
2
1
;

C
a
s
a
n
o
v
a

e
t

a
l
.
,

2
0
2
2
)
,

w
a
t

u
i
t
b
l
i

n
k

i
n

o
u
d
i
o
b
o
e
k
-

e
n

m
e
d
i
a
p
r
o
d
u
k
s
i
e
,

m
a
a
r

k
r
a
g
t
i
g
e

G
P
U
,
s

b
e
n
o
d
i
g

v
i
r

o
n
t
p
l
o
o
i
i
n
g

(
R
e
n

e
t

a
l
.
,

2
0
1
9
;

K
a
l
l

e
t

a
l
.
,

2
0
1
9

e
t

a
l
.

2
0
1
8
)
.

V
i
e
N
e
u
-
T
T
S

k
o
m
b
i
n
e
e
r

T
T
S

m
e
t

s
t
e
m
k
l
o
n

i
n
g
,

o
n
t
t
r
e
k

s
p
r
e
k
e
r
k
e
n
m
e
r
k
e

v
i
a

t
e
g
n
i
e
k
e

s
o
o
s

A
u
t
o
V
C

(
Q

i
a
n

e
t

a
l
.
,

2
0
1
9
)

e
n

S
t
a
r
G
A
N
-
V
C

(
K
a
m
e
o
k
a

e
t

a
l
.
,

2
0
1
8
)

e

n

p
a
s

d
i
t

t
o
e

o
p

g
e
s
i
n
t
e
t
i
s
e
e
r
d
e

s
p
r
a
a
k

(
C
a
s
a
n
o
v
a

e
t

a
l
.

,

2

0

2

2

;

J

i

a

b

l

i

n

g

e

t

a

l

.

,

2

0

1

8

,

m

a

a

r

o

o

k

p

e

r

s

o

n

a

l

i

z

a

t

i

o

n

)

,

m
a
a
r

o
o
k
.

e
t
i
e
s
e

e
n

v
e
i
l
i
g
h
e
i
d
s
k
w
e
s
s
i
e
s
.

V
i
X
T
T
S

d
i
e
n

a

s

,

n

d

e

m

o

n

s

t

r

a

s

i

e

p

r

o

j

e

k

v

i

r

s

t

e

m

k

l

o

n

i

n

g

,

w

a

t

d

i

e

t

e

g

n

o

l

o

g
i
e

v
i
r

v
i
n
n
i
g
e

e
k
s
p
e
r
i
m
e
n
t
e
r
i
n
g

i
l
l
u
s
t
r
e
e
r

(
T
h
i
n
h
,

2
0
2
4

;

K
i
m

e
t

a
l
.

,

2
0
2
1
)
.

V
a
l
t
e
c
-
T
T
S

i
s

,

n

k
o
m
p
a
k
t
e

m
o
d
e
l

w
a
t

g
e
o
p
t
i
m
a
l
i
s
e
e
r

i
s

v
i
r

u
i
t
e
r
s

h
u
l
p
b
r
o
n
b
e
p
e
r
k
t
e

o
m
g
e
w
i
n
g
s

s
o
o
s

i
n
g
e
b
e
d
d
e

t
o
e
s
t
e
l
l
e

e
n

I
o
T

(
R
e
n

e
t

a
l
.
,

2
0
1
9
,
2
0
2
0
;

P
i
n
g

e
t

a
l
.
,

2
0
1
7
;

K
a
l
c
h
b
r
e
n
n
e
r

e
t

a
l
.
,

2
0
1
8
)
,

w
a
t

v
o
l
d

o
e
n
d
e

d
u
i
d
e
l
i
k
h
e
i
d

l
e
w
e
r

v
i
r

e
e
n
v
o
u
d
i
g
e

t
o
e
p
a
s
s
i
n
g
k
e
n
n
i
s

g
e
w
i
n
g

e
n

l
e
i
d
i
n
g
.

G
e
s
a
m
e
n
t
l
i
k

i
l
l
u
s
t
r
e
e
r

h
i
e
r
d
i
e

m
o
d
e
l
l

e

d
i
e

r
y
p
w
o
r
d
i
n
g

v
a
n

V
i
ë
t
n
a
m
e
s
e

T
T
S
,

m
e
t

g
e
s
p
e
s
i
a
l
i
s
e
e
r
d

e

t

a

k

k

e

w

a

t

w

i

s

s

e

l

v

a

n

h

o

ë

g

e

h

a

l

t

e

-

s

i

n

t

e

s

e

t

o

t

l

i

g

g

e

w

i

g

-

o

n
t
p
l
o
o
i
i
n
g

e
n

s
t
e
m
v
e
r
p
e
r
s
o
o
n
l
i
k
i
n
g

.

D
a
t
a
k
w
a
l
i
t
e
i
t

i
s

d
i
e

g
r
o
n
d
s
l
a
g

v
i
r

T
T
S
.

D
i
e

V
L
S
P

S
p
e
e
c
h

C
o
r
p
u
s

i
s

,
n

g
r
o
o
t
,

a
k

a
d
e
m
i
e
s

g
e
o
r
i
ë
n
t
e
e
r
d
e

d
a
t
a
s
t
e
l

m
e
t

m
u
l
t
i
-
l
u
i
d
s
p
r
e
k
e
r

o
p
n
a

m
e
s

i
n

g
e
k
o
n
t
r
o
l
e
e
r
d
e

t
o
e
s
t
a
n
d
e

(
A
r
d
i
l
a

e
t

a
l
.
,

2
0
2
0
;

V
u

e
t

a
l
.
,

2
0
2
5
)
,

r
y
k
l
i
k

g
e
a
n
n
o
t
e
e
r

m
e
t

f
o
n
e
t
i
e
s
e

e
n

s
t
r
e
e
k
s

i
n
l
i
g
t
i
n
g

(
Y
a
m
a
g
i
s
h
i

e
t

a
l
.
,

2
0
1
9
;

D
o
,

2
0
2
6
)
.

V
I
V
O
S

i
s

,
n

k
l
e
i
n
e
r

o
o
p
b
r
o
n
k
o
r
p
u
s

(
o
n
g
e
v
e
e
r

1
0
—
2
0

u
u
r
)

v
a
n

s
k
o
o
n
g
e
l
e

e
s
d
e

s
p
r
a
a
k

(
A
r
d
i
l
a

e
t

a
l
.
,

2
0
2
0
;

I
t
o

&

J
o
h
n
s
o
n
,

2
0
1
7
)
,

w

a
t

w
y
d

g
e
b
r
u
i
k

w
o
r
d

v
i
r

a
a
n
v
a
n
k
l
i
k
e

m
o
d
e
l
l
e
r
i
n
g

o
n
d
a
n
k
s

b

e
p
e
r
k
t
e

e
m
o
s
i
o
n
e
l
e

e
n

w
e
r
k
l
i
k
e

d
i
v
e
r
s
i
t
e
i
t

(
D
o
,

2
0
2
6
)
.

K
o

m
m
e
r
s
i
ë
l
e

d
a
t
a
s
t
e
l
l
e

v
a
n

F
P
T

C
o
r
p
o
r
a
t
i
o
n
,

V
i
e
t
t
e
l

G
r
o
u
p

e

n

V
N
G

C
o
r
p
o
r
a
t
i
o
n

i
s

b
a
i
e

g
r
o
t
e
r

e
n

m
e
e
r

g
e
d
e
t
a
i
l
l
e
e
r
d
.

F

P
T

s
e

d
a
t
a
s
t
e
l

b
e
s
t
a
a
n

u
i
t

h
o
n
d
e
r
d
e

t
o
t

d
u
i
s
e
n
d
e

u
r
e

s
e

o
p
n
a
m
e
s

v
a
n

a
t
e
l
j
e
e
g
e
h
a
l
t
e

m
e
t

v
o
l
l
e
d
i
g
e

a
a
n
t
e
k
e
n
i
n
g
e

(
V
u

e
t

a
l
.
,

2
0
2
5
;

D
o
,

2
0
2
6
;

O
o
r
d

e
t

a
l
.
,

2
0
1
6
;

K
o
n
g

e
t

a
l
.
,

2
0
2
0
)
·

V
i
e
t
t
e
l

s
e

d
a
t
a

k
o
m
b
i
n
e
e
r

a
t
e
l
j
e
e
-

e
n

w
e
r
k
l
i
k
e

w
ê
r

e
l
d
o
p
n
a
m
e
s

w
a
t

u
i
t
e
e
n
l
o
p
e
n
d
e

a
k
s
e
n
t
e

d
e
k

(
V
u

e
t

a
l
.
,

2
0
2
5

;

Y
a
m
a
g
i
s
h
i

e
t

a
l
.
,

2
0
1
9
;

J
i
a

e
t

a
l
.
,

2
0
1
8
;

D
o
,

2
0
2
6
)
.

Z
a

l
o

s
e

d
a
t
a

t
r
e
k

v
o
o
r
d
e
e
l

u
i
t

s
y

b
r
e
ë

g
e
b
r
u
i
k
e
r
s
e
k
o
s
i
s
t
e
e
m

,

w
a
t

k
o
n
t
e
m
p
o
r
ê
r
e

t
a
a
l
g
e
b
r
u
i
k

i
n
s
l
u
i
t

(
V
u

e
t

a
l
.

,

&
2
0
2
5
;

N
g
u
y
e
n
&
T
u
a
n
,

2
0
2
0
;

D
e
v
l
i
n

e
t

a
l
.
,

2
0
1
9
;

K
i
m

e
t

a
l
.
,

2
0
2
1

)
.

D
a
a
r
b
e
n
e
w
e
n
s

b
i
e
d

V
i
e
t
T
T
S

,
n

b
a
s
i
e
s
e

o
o
p

d
a
t
a
s
t
e
l

m
e
t

t
e
k
s
-
k
l
a
n
k
p
a
r
e

w
a
t

v
o
l
d
o
e
n
d
e

i
s

v
i
r

k
l
e
i
n
s
k
a
l
s
e

e
k
s
p
e
r
i
m

e
n
t
e

(
N
g
u
y
e
n
,

&
2
0
2
3
;

I
t
o
&
J
o
h
n
s
o
n
,

2
0
1
7
;

V
u

e
t

a
l
.
,

2
0
2
5
)
.

I
n

d
i
e

a
l
g
e
m
e
e
n

b
e
p
a
a
l

d
a
t
a
s
t
e
l
s
k
a
a
l
,

d
i
v
e
r
s
i
t
e
i
t
,

a
n
n
o
t

a
s
i
e
d
i
e
p
t
e

e
n

r
e
a
l
i
s
m
e

T
T
S
-
p
r
e
s
t
a
s
i
e

d
i
r
e
k
.

3 Stelselontwerp

V
r
o
e
ë

T
T
S
-

s
t
e
l
s
e
l
s

h
e
t

s
t
a
a
t
g
e
m
a
a
k

o
p

a
a
n
e
e
n
l
o
p
e
n
d
e

e
n

f
o
r
m
a
n
t

-
g
e
b
a
s
e
e
r
d
e

m
e
t
o
d
e
s
,

w
a
t

s
p
r
a
a
k
e
e
n
h
e
d
e

s
a
a
m
s
t
e
l

o
f

w

i
s
k
u
n
d
i
g

m
o
d
e
l
l
e
e
r
,

m
a
a
r

l
y

a
a
n

o
n
b
u
i
g
s
a
a
m
h
e
i
d
,

h
o
ë

d
a
t
a
b
a
s
i
s
k
o
s
t
e

e
n

o
n
n
a
t
u
u
r
l
i
k
e

p
r
o
s
o
d
i
e

(
Z
e
n

e
t

a
l
.
,

2
0
1
9
)
·

S
t
a
t
i
s
t
i
e
s
e

p
a
r
a
m
e
t
r
i
e
s
e

s
i
n
t
e
s
e

m
e
t

b
e
h
u
l
p

v
a
n

H
i
d
d
e
n

M
a
r
k
o
v

M
o
d
e
l
s

(
H
M
M
)

h
e
t

b
u
i
g
s
a
a
m
h
e
i
d

v
e
r
b

e
t
e
r
,

m
a
a
r

s
t
e
e
d
s

e
e
n
t
o
n
i
g
e
,

m
i
n
d
e
r

n
a
t
u
u
r
l
i
k
e

u
i
t
s
e

t

g
e
l
e
w
e
r

(
Z
e
n

e
t

a
l
.
,

2
0
1
9
)
.

D
i
e

k
o
m
s

v
a
n

d
i
e
p

l
e
e
r

h
e
t

e
n
d

-
t
o
t

-
e
n
d

-
m

o
d
e
l
l
e

g
e
b
r
i
n
g

s
o
o
s

T
a
c
o
t
r
o
n

e
n

T
a

c
o
t
r
o
n

2
,

w
a
t

e
n
k
o
d
e
e
r
d
e
r
-
d
e
k
o
d
e
e
r
d
e
r
-
a
r
g
i
t
e
k
t
u
r
e

g
e

b
r
u
i
k

m
e
t

a
a
n
d
a
g

a
a
n

d
i
r
e
k

k
a
a
r
t
t
e
k
s

n
a

4 F. Skrywer en S. Skrywer

mel-spektrogramme, gevolg deur vokoders soos WaveNet (Oord et al., 2016) of WaveGlow (Prenger et al., 2019) om golfvorms te genereer (Wang et al., 2017; Shen et al., 2018; Vaswani et al., 2017). Hierdie modelle leer outomaties fonetiese en prosodiese kenmerke, wat aansienlik meer natuurlike spraak lewer, maar het beperkings in afleidingsspoed en aandagfoute. FastSpeech en FastSpeech 2 het hierdie kwessies aangespreek deur aandag tydens afleiding te verwyder en duur-, toonhoogte- en energievoorspellers te gebruik, om vinniger en meer stabiele sintese met eksplisiete prosodiebeheer te bewerkstellig (Ren et al., 2019,2020; Vaswani et al., 2017). Die jongste sprong, VITS, integreer 'n &variasie-oto-enkodeerder (Kingma&Welling, 2014) met 'n generatiewe teenstandernetwerk (Goodfellow et al., 2014) om golfvorms direk vanaf teks in 'n enkele end-tot-end-raamwerk te genereer, wat 'n aparte vocoder uitskakel en gehalte en doeltreffendheid verder bevorder.,

nova20 et al. 2022). Stemkloning en multi-luidsprekersintese het ook gevorder, met behulp van luidsprekerinbeddings en styltekens om verpersoonliking en nultskoot-aanpassing moontlik te maak (Jia et al., 2018; Casanova et al., 2022; Chen et al., 2022; Wang et al., 2018). Boonop versag oordrag en self-toesig leermetodes (Baeviski et al., 2020; Hsu et al., 2021; Radford et al., 2022) dataskaarste vir Viëtnamees deur vooropleiding op groot veeltalige korpus. 'n Moderne TTS-pyplyn sluit tipies data-insameling en voorverwerking, teksnormalisering (Do, 2026), modelopleiding en golfvormgenerering in (Wang et al., 2017; Kim et al., 2021).


Die voorgestelde stelsel implementeer 'n emosionele TTS-pyplyn: invoerteks wat emosie-etikette bevat, word volgens emosie gesegmenteer, elke segment word via viXTTS gesintetiseer, en die gevolglike golfvorms word aaneengeskakel met stiltegapings om die finale oudiolêr te produseer

Bydrae Titel (verkort indien te lank) 5

Fig. 1. *Werkvloei van die voorgestelde emosie-gebaseerde spraaksintese stelsel*

In die eerste laag word teksreël vir reële geskandeer. Wanneer 'n reël 'n emosie-etiket tussen hakies bevat, kan die stelsel dit na 'n emosie-kaart-etiket deur 'n Viëtnamese sleutelwoordeboek te gebruik. Openvolgende reëls wat dieselfde emosie deel, word in 'n stuk (teks, emosie) gegroepeer. Vir sintese word die teks skoon merker-inhoud te verwyder, spasies te normaliseer in Vietnamese ortografie te standaardiseer. In die tweede laag word elke deel na die viXTTS-inferensie-enjin oorgedra tesame met luidsprekermerke wat uit 'n verwysingsoudiolêr onttrek is. 'n Emosiekaart ken 'n toe

verwysing Leer per emosie (bv. neutraal → base_voice.wav, vrolik → cheerful_ref.wav). Om konsekwente spreker-identiteit te handhaaf, word latente spreker-inbeddings een keer uit 'n gebruiker-verskafde stemmonster onttrek en oor alle stukke hergebruik (Jia et al., 2018; Casanova et al., 2022). Die sintese produseer 'n golfvorm vir elkeen



() II IIII II √ √

stuk, soos geformaliseer in die volgende algoritme

In die derde laag word die gegenereerde golfvorms opeenvolgend aaneengeskakel met 300 ms se stilte wat ingevoeg word om emosionele draaie te skei en abrupte snye te vermy. Die finale uitset word as 'n WAV-lêer gestoor. Hierdie ontwerp kombineer effektief sleutelwoord-gebaseerde emosieklassifikasie met voorwaardelike TTS en audio-verwerking, wat merkergedrewe, ekspressiewe spraaksintese moontlik maak deur 'n verenigde stemidentiteit te gebruik.

4 Evalueringsmetrieke

Om die teks-na-spraak- en stemkloningstelsel volledig te assesseer, word twee komplementêre diep-leer-gebaseerde maatstawwe gebruik: sprekerooreenkoms via Resemblyzer, en waargenome spraakkwaliteit via DNSMOS.

Resemblyzer is 'n neurale netwerk-gebaseerde instrument vir sprekerverifikasie en stemooreenkomsmeting (Mishra et al., 2023). In sy kern gebruik dit 'n sprekerverifikasie-enkodeerder wat opgelei is met 'n algemene end-tot-end verlies (Wan et al., 2018). Die operasionele beginsel is soos volg: eerstens, 'n insetuiting - óf die oorspronklike verwysingstem óf die gesintetiseerde gekloonde stem - word verwerk deur 'n diep neurale netwerk wat 'n vaste-dimensionele inbeddingsvektor onttrek (dikwels na verwys as 'n d-vektor of luidsprekerinbedding). Hierdie vektor is ontwerp om die unieke vokale identiteit van die spreker vas te vang, insluitend eienskappe soos timbre, toonhoogte kontoer en praatstyl, terwyl dit grootliks onveranderlik is van die linguistiese inhoud of die spesifieke woorde wat gespreek word. Met ander woorde, ongeag wat die persoon sê, moet die inbedding konsekwent bly vir dieselfde spreker en duidelik verskillend vir verskillende sprekers (Wan et al., 2018).

Sodra die inbeddingsvektore vir beide die verwysingsaudio A (die oorspronklike spreker se stem) en die gesintetiseerde audio B (die gekloonde stem) verkry is, word hul ooreenkoms gekwantifiseer deur die cosinus-ooreenkoms metriek te gebruik:

Cosine Gelykvormigheid = $A, B = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}}$

$A, B \in \mathbb{R}^d$

$\sum_{i=1}^d A_i^2$

$\sum_{i=1}^d B_i^2$

Die cosinus-ooreenkoms meet die hoek tussen die twee vektore in die hoë-dimensionele inbeddingsruimte. 'n Waarde naby aan 1 dui aan dat die vektore in byna dieselfde rigting wys, wat beteken dat die twee stemme as hoogs eenders of amper identies in terme van sprekeridentiteit beskou word (Jia et al., 2018; Wan et al., 2018). Omgekeerd, 'n waarde naby aan 0 of negatief sal verskillende sprekers voorstel. Resemblyzer verskaf dus 'n objektiewe, outomatiese en reproduceerbare maatstaf om te evalueer hoe getrou 'n stemkloningstelsel die oorspronklike spreker se vokale eienskappe bewaar.

DNSMOS (Deep Noise Suppression Mean Opinion Score) is 'n nie-indringende, diep leer-gebaseerde maatstaf wat ontwerp is om die perseptuele kwaliteit van spraakseine te skat sonder om 'n skoon verwysing oudiosein te vereis (Reddy et al., 2021). Dit maak dit

5 Eksperimente en resultate

Opleiding . datastel. Die stelsel is opgelei en geëvalueer deur gebruik te maak van die viVoice-korpus (Le, 2024), die eerste publiek beskikbare grootskaalse Viëtnamese spraakdatastel wat ontwerp is vir veelsprekende teks-na-spraak. viVoice bestaan uit meer as 1 000 uur se skoongemaakte audio en gepaardgaande transkripsies afkomstig van 186 YouTube-kanale. Alle oudiomonsters word verskaf teen 'n 24 kHz-steekproeftempo in WAV-formaat, met agtergrondmusiek en geraas verwyder om skoon opleidingsdata te verseker. Die datastel dek 'n wye verskeidenheid luidsprekers, aksente (Noordelike, Sentraal, Suidelike) en praatstyle, wat dit veral geskik maak vir die opleiding van robuuste multi-luidspreker Viëtnamese TTS-modelle soos XTTS-v2. viVoice word

vergestel onder die CC BY-NC-SA 4.0-lisensie. Die datastel is beskikbaar gestel deur die viVoice-korpus en is beskikbaar gestel deur die viVoice-korpus.

Komponent	Spesifikasie
Model	GIGABYTE G5 GD
SVE	Intel Core i5-11400H (8 kerne, 12 drade, 2,70 GHz basis)
RAM	16 GB DDR4 (15,8 GB bruikbaar)
GPU	Intel UHD-grafika (geïntegreer)
Diskrete	NVIDIA GeForce RTX (Ampere, toegewyd)
GPU-	Windows 11 Huis Enkeltaal
bedryfstelsel	

Stemooreenkoms en spraakkwaliteit. . Die stelsel is geëvalueer deur oorspronklike en gesintetiseerde (gekloonde) spraakmonsters van vier sprekers te vergelyk. Elke monsterpaar het bestaan uit 'n reference.wav-lêer en sy kloon. Twee assesseringsmetodes is toegepas: Resemblyzer vir stemooreenkoms (Wan et al., 2018; Mishra et al., 2023), en DNSMOS vir waargenome klankkwaliteit (Reddy et al., 2021). Stemooreenkomsresultate word in Tabel 2 aangebied. Alle pare bereik 'n cosinus-ooreenkoms van ongeveer 0.90 (wat wissel van 0.9013 tot 0.9346), wat bevestig dat die VITS-model, ten spyte van die gebruik van die SVE, vokale timbre en sprekeridentiteit merkwaardig goed bewaar (Jia et al., 2018).

Stemooreenkoms-resultate vir die viXTTS-model word in Tabel 2 aangebied. Alle pare bereik 'n cosinus-ooreenkoms van ongeveer 0.90 (wat wissel van 0.9013 tot 0.9346), wat bevestig dat die model vokale timbre en sprekeridentiteit merkwaardig goed bewaar (Jia et al., 2018). Luidspreker-ooreenkoms vir ander enjins is nie in hierdie evaluasieloope gemeet nie, aangesien die meeste van hulle nie inheems stemkloning ondersteun nie of 'n aparte verwysing-inbedding-onttrekkingstap vereis.

Tabel 2. Stemooreenkoms tussen oorspronklike en gekloonde spraak.

Knap klank	Ooreenkomstigheid
giong_goc af giong_clone	0,9038
Danh_1 en Danh_clone	0,9019
Khang1 en Khang_clone	0,9346
Ngoc1 en Ngoc_clone	0,9013

Spraakkwaliteitsresultate van DNSMOS oor al sewe geëvalueerde enjins word in Tabel 3 opgesom. Vier maatstawwe is aangeteken: OVRL (algehele kwaliteit), SIG (spraakkwaliteit), BAK (agtergrondgeraas-indringendheid), en die aanvullende P808-telling ('n algehele luisterkwaliteitberamer wat met ITU-T P.808 belyn is). Tellings is op die standaard 1–5 gemiddelde opinietellingskaal, waar hoër waardes beter perseptuele kwaliteit aandui.

Tabel 3. DNSMOS-evaluering van gesintetiseerde Viëtnamese spraakkwaliteit..

Model	Leer klank	OVRL MOS	SIG MOS	BAK MOS	P808 MOS
Voorgestelde viXTTS-gebaseerde	giong_clone.wav	3,38	3,60	4.14	4.03
Stem kloning stelsel					
Piper Vietnamese TTS	Piper_Viëtnameses_TTS	3.00	3,40	3,81	3.15
Valtec Vietnamese TTS v2	Valtec Viëtnameses TTS_ver2.wav	3.07	3,34	4.04	3,95
Viëtnamese TTS	ViëtnamesesTTS.wav	2.07	2,75	2,86	2,73
Valtec Vietnamese TTS	Valtec_Viëtnamese.wav	3,37	3,58	4.16	4.21

VietTTS				4.15	3,64
	VietTTS.wav	3.05	3,25		
VieNeu-TTS	VietNeu_TTS.wav	3.31	3,54	4.16	3,68

10 F.
Skrywer
en S.
Skrywer

Die DNSMOS-evalueringsresultate toon merkbare verskille in gesintetiseerde Viëtnamese spraakkwaliteit tussen die geëvalueerde TTS-stelsels. Oor die algemeen behaal die voorgestelde viXTTS-gebaseerde stemkloningstelsel, verteenwoordig deur giong_clone.wav, die hoogste OVRL MOS-telling van 3.38 en die hoogste SIG MOS-telling van 3.60. Hierdie resultate dui aan dat die voorgestelde stelsel spraak produseer met sterk algehele perseptuele kwaliteit en duidelike spraakseine. Die hoë BAK MOS-telling van 4.14 dui ook daarop dat die gegenereerde klank baie min agtergrondgeraas bevat. Daarom demonstreer die viXTTS-gebaseerde model sterk prestasie in beide spraakhelderheid en geraasonderdrukking.

Onder die vergelykende stelsels presteer Valtec_Vietnamese.wav ook mededingend, met 'n OVRL MOS van 3.37 en 'n SIG MOS van 3.58, wat baie na aan die voorgestelde stelsel is. Boonop behaal hierdie model die hoogste P808 MOS-telling van 4.21, wat daarop dui dat luisteraars die algehele klankgehalte daarvan gunstig kan waarneem. Die voorgestelde giong_clone.wav presteer egter steeds effens beter as dit in die twee hoof DNSMOS-aanwysers, OVRL en SIG. Dit dui daarop dat die voorgestelde model 'n klein maar meetbare voordeel het in terme van algehele spraakkwaliteit en seinhelderheid.

Die VietNeu_TTS.wav-model behaal ook sterk resultate, met 'n OVRL MOS van 3.31, SIG MOS van 3.54, BAK MOS van 4.16 en P808 MOS van 3.68. Hierdie tellings plaas dit in die hoëpresterende groep, veral in terme van agtergrondgeraasonderdrukking. Sy BAK-telling is van die hoogste in die vergelyking, wat wys dat die gegenereerde klank skoon en stabiel is. Alhoewel sy algehele en seinkwaliteitellings effens laer is as dié van giong_clone.wav en Valtec_Vietnamese.wav, bly dit 'n betroubare model vir Viëtnamese spraaksintese.

Die middelpresterende groep sluit Valtec Vietnamese TTS_ver2.wav, VietTTS.wav en Piper_Vietnamese_TTS in. Hierdie modelle verkry OVRL MOS-tellings wat wissel van 3.00 tot 3.07, wat aanvaarbare maar nie uitstaande gesintetiseerde spraakkwaliteit aandui nie. Hul SIG MOS-tellings, wat wissel van 3,25 tot 3,40, dui daarop dat die spraaksein redelik duidelik is, maar steeds minder natuurlik of minder gedetailleerd as die toppresterende stelsels. Veral, VietTTS.wav behaal 'n hoë BAK MOS-telling van 4.15, wat wys dat die klankuitset relatief skoon is. Die laer OVRL- en SIG-tellings dui egter daarop dat agtergrondskoonheid alleen nie voldoende is om hoë algehele spraakkwaliteit te verseker nie.

Die stelsel wat die laagste presteer is VietnameseTTS.wav, wat 'n OVRL MOS van 2.07, SIG MOS van 2.75, BAK MOS van 2.86 en P808 MOS van 2.73 verkry. Hierdie tellings is aansienlik laer as dié van die ander modelle. Die lae OVRL- en SIG-tellings dui veral daarop dat die gesintetiseerde spraak merkbare artefakte, verminderde natuurlikheid of onduidelike uitspraak kan bevat. Die lae BAK-telling dui ook aan dat die audio meer agtergrondinterferensie of geraas kan insluit in vergelyking met die ander stelsels.

'n Algemene neiging kan oor die sterker modelle waargeneem word: die meeste stelsels behaal hoë BAK MOS-tellings bo 4.0, wat beteken dat moderne Viëtnamese TTS-modelle oor die algemeen effektief is om skoon audio met beperkte agtergrondgeraas te produseer. Verskille in OVRL- en SIG-tellings toon egter dat skoon klank nie altyd nie

Bydrae Titel (verkort indien te lank) 11

waarborg natuurlike en verstaanbare spraak. Spraaknatuurlikheid, duidelikheid en seinkwaliteit bly belangrike faktore om die beste presterende modelle te onderskei. Op die gebied van spraaknatuurlikheid, behaal die beste modelle die hoogste BAK MOS-tellings, wat dui op 'n natuurlike klank. Hierdie modelle behaal ook hoë OVRL- en SIG-tellings, wat dui op 'n duidelike spraak.

Intydse prestasie- en vertragsanalise: : Die mees kritieke prestasiemaatstaf van die huidige prototipe is die einde-tot-einde sintese latency. Vir 'n tipiese invoerteks van 750 karakters (gelykstaande aan ongeveer 50 sekondes se gegenereerde audio teen 'n standaard Viëtnamese-sprekende tempo van ongeveer 900 karakters per minuut), benodig die stelsel ongeveer 2 minute en 50 sekondes (170 sekondes) om die finale WAV-lêer te produseer. Dit lewer 'n Real-Time Factor (RTF) van ongeveer 3.4, ver bo die intydse drempel van 1.0. Die latensie is egter nie vas nie; dit wissel meetbaar na gelang van die linguistiese kompleksiteit van die invoerteks. Twee faktore oorheers die bykomende verwerkingsbokoste: 1. Emosie-etiket. Elke emosionele grens dwing 'n nuwe sintese-stuk af met 'n aparte viXTTS-afleidingsoproep, wat lei tot veelvuldige konteksskakelaar en modellaaibokoste. Meer merkers verhoog die aantal stukke en die kumulatiewe pouse-invoegtyd.

☐ Engelse woorde en nie-Viëtnamese segmente. Dit vereis ekstra grafeem-tot-foneemstappe binne die teksnormaliseringslaag (Do, 2026), en kan aandagfoute veroorsaak wat die dekodeerder dwing om herbelyning te probeer, wat bydra tot die totale looptyd.

Die waargenome latensie spruit uit die loop van die volle VITS-pyplyn op die SVE sonder om die beskikbare RTX GPU te gebruik. Die SVE-enigste PyTorch-bou kan nie die massiewe parallelisme van die GPU se tensorskerne ontgin nie, wat matriksvermenigvuldigings en konvolusies laat om opeenvolgend bereken te word. Ten spyte hiervan, bly die stelsel aanvaarbaar vir nabylyn-inhoudskeppingstake soos podcast-oorklanking, opvoedkundige vertelling of stemposgenerering – toepassings waar 'n paar minute se leweringstyd geduld word in ruil vir hoëgehalte, emosioneel ekspressiewe uitset.

Die masjien is krities toegerus met 'n NVIDIA GeForce RTX GPU, wat ten volle in staat is om die afleiding te versnel. Om na 'n CUDA-geaktiveerde PyTorch-installasie te skuif, sal die RTF tot ver onder 0.1 verminder (gebaseer op tipiese GPU-maatstawwe vir VITS), wat intydse stroomsintese moontlik maak. Daarbenewens kan modelkwantisering na FP16 of INT8, en oorskakeling na geoptimaliseerde inferensie-enjins soos ONNX Runtime met OpenVINO, latensie verder halveer terwyl die hoë ooreenkomste en MOS-tellings behoue bly.

6 Gevolgtrekking

In hierdie navorsing is 'n Viëtnamese teks-na-spraak-stelsel wat op kunsmatige intelligensie en diep leer gebaseer is, deeglik ontwerp, geïmplementeer en geëvalueer. Die stelsel

ontwikkelde 'n Viëtnamese teks-na-spraak-stelsel wat op kunsmatige intelligensie en diep leer gebaseer is, deeglik ontwerp, geïmplementeer en geëvalueer. Die resultate wat behaal is, bevestig nie net die doeltreffendheid van diep leer in Viëtnamese spraaksintese nie, maar beklemtoon ook die stelsel se breë toepaslikheid in die praktyk, veral in virtuele assistente, onderwys, outomatiese oproepsentrums en hulpmiddels vir gesigsgestremdes. Toekomstige werk kan fokus op die uitbreiding en verryking van die spraakdatastel, die verbetering van plaaslike natuurlikheid, die optimalisering van modelle vir hulpbronbeperkte toestelle, en die integrasie van die stelsel in werklike wêreldplatforms om uitvoerbaarheid en bruikbaarheid te verbeter.

Verwysings

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. & M., & Weber, G. (2020). Common Voice: A massively- multilingual speech corpus. arXiv. <https://arxiv.org/abs/1912.06670>
2. Baevski, A., Zhou, Y., Mohamed, & A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, & E., & Ponti, M. A. (2022).

YourTTS: Na nul-skoot multi-luidspreker TTS en zero-shot stem omskakeling vir almal. arXiv. __HOU_0__

4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Pratap, V., Conneau, A., Collobert, R., Synnaeve, G., & Auli, M. (2022). WavLM: Grootse selftoesig voorafopleiding vir volle stapel spraakverwerking. arXiv. __HOU_1__
5. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Vooropleiding van diep tweerigtingstransformators vir taalbegrip. arXiv. __HOU_0__

6. Doen, N. (2026). VietNormalizer: 'n Oopbron, afhanklikheidsvrye Python-biblioteek vir Viëtnamese teksnormalisering in TTS- en NLP-toepassings. arXiv. __HOU_0__

7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, & Y. (2014). Generatiewe teenstandersnetwerke. arXiv. __HOU_0__

8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhotia, K., Salakhutdinov, R., & Mohamed, A.

(2021). HuBERT: Self-toesig spraakvoorstelling leer deur gemaskerde voorspelling van verborge eenhede. arXiv. __HOU_0__

9. Ito, K., & Johnson, & L. (2017). Die LJ Speech Dataset. [https://keithito.com/LJ-Speech-](https://keithito.com/LJ-Speech-Dataset/) Datastel/

10. Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, X., Chen, Z., Nguyen, P., Pang, R., Moreno, I. L., & Wu, Y. (2018). Dra leer oor van sprekerverifikasie na multiluidspreker teks-na-spraak-sintese. Vooruitgang in neurale inligtingverwerkingstelsels, 31.

<https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Efficient neural audio synthesis. arXiv. <https://arxiv.org/abs/1802.08435>
 12. Kameoka, H., Kaneko, T., Tanaka, & K., & Hojo, N. (2018). StarGAN-VC: Non-parallel many-to-many voice conversion using star generative adversarial networks. arXiv.
- __HOU_0__
13. Kim, J., Kong, J., & Seun, J. & (2021). Voorwaardelike variasie-oto-enkodeerder met teenstrydige leer vir end-tot-end teks-na-spraak. arXiv. __HOU_1__
 14. Kingma, D. P., & Welling, M. (2014). Oto-enkodering variasie baaie. arXiv.
- __HOU_0__
15. Kong, J., Kim, J., & Bae, J. & (2020). HiFi-GAN: Generatiewe teenstandersnetwerke vir doeltreffende en hoëtrou-spraaksintese. arXiv.
- __BEHOU_1__
16. Mishra, P., Choudhury, J. A., Kho, E., Basu, B., & Nandi, A. & (2023). Luidsprekeridentifikasie, differensiasie en verifikasie met behulp van diep leer vir menslike masjienkoppelvlak. In 2023 Photonics & Electromagnetics Research Symposium (PIERS) (pp. 861–870). IEEE. __HOU_2__
 17. Nguyen, D. Q., & Tuan, N. D. (2020). PhoBERT: Vooraf opgeleide taalmodelle vir Viëtnameses. arXiv. __HOU_3__
 18. Nguyen, N. (2023). VietTTS: Viëtnamese teks-na-spraak-biblioteek. GitHub.
- __HOU_0__
19. Oord, A. van den, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, & K. (2016). WaveNet: 'n Generatiewe model vir rou klank. arXiv. __HOU_1__
 20. Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Raiman, J., Miller, J., & Sengupta, S. (2017). Deep Voice 3: Skaal teks-na-spraak met konvolusionele volgorde-leer. arXiv. __HOU_2__
 21. Prenger, R., Valle, R., & Catanzaro, B. & (2019). WaveGlow: 'n Vloei-gebaseerde generatiewe netwerk vir spraaksintese. arXiv. __HOU_3__
 22. Qian, K., Zhang, Y., Chang, S., Yang, X., & Hasegawa-Johnson, M. (2019). AutoVC: Zero-shot stem styl oordrag met slegs oto-enkodeerder verlies. arXiv.
- __HOU_0__
23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022). Robuuste spraakherkenning deur grootskaalse swak toesig. arXiv.
- __HOU_0__
24. Reddy, C. K., Gopal, V., & Cutler, R. & (2021). DNSMOS: 'n Nie-indringende perseptuele objektiewe spraakwaliteit maatstaf om geraasdemppers te evalueer. In ICASSP 2021–2021 IEEE Internasionale Konferensie oor akoestiek, spraak en seinverwerking (pp. 6493–6497). IEEE. __HOU_0__
 25. Ren, Y., Ruan, Y., Chen, X., Qin, T., Zhao, S., & Liu, T. (2019). FastSpeech: Vinnige, robuuste en beheerbare teks na spraak. arXiv. __HOU_1__
 26. Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T. (2020). FastSpeech 2: Vinnige en hoë kwaliteit end-tot-end teks na spraak. arXiv. __BEHOU_2__
 - 27.

Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y.,
Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., &Agiomyrgi, Y., 201.
Natuurlike TTS-sintese deur WaveNet te kondisioneer op mel-spektrogramvoorspellings. arXiv.

__HOU_0__

28. Thinh, L. (2024). viXTTS: 'n Viëtnamese stem kloning teks-na-spraak model. GitHub.

<https://github.com/thinhlp/vixtts-demo>

14 F. Skrywer en S. Skrywer

29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Aandag is al wat jy nodig het. arXiv. __HOU_0__

30. Vu, T., Nguyen, L. T., & Nguyen, D. Q. (2025). Zero-shot text-to-speech for Vietnamese. arXiv. __HOU_0__

31. Wan, L., Wang, Q., Papir, & A., & Moreno, I. L. (2018). Generalized end-to-end loss for spreker verifikasie. In 2018 IEEE Internasionale Konferensie oor akoestiek, spraak en Seinverwerking (ICASSP) (pp. 4879–4883). IEEE.

<https://ieeexplore.ieee.org/abstract/document/8462665>

32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao,

Y., Chen, Z., Bengio, S., Le, Q., Agiomyrgiannakis, Y., Clark,
R., & Saurous, R.A.

(2017). Tacotron: Op pad na end-tot-end spraaksintese. arXiv.
<https://arxiv.org/abs/1703.10132>

33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R. J., Battenberg, E., Shor, J., Xiao, Y.,
Jia, Y., Ren, F., & Saurous, R. A. (2018). Styltekens: stylmodellering sonder toesig,
beheer en oordrag in end-tot-end spraaksintese. arXiv.
<https://arxiv.org/abs/1803.09017>

34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: English multi-
sprekerskorpus vir CSTR stem kloning toolkit (weergawe 0.92). Universiteit van Edinburgh.
<https://datashare.ed.ac.uk/handle/10283/3443>

35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R. J., Jia, Y., Chen, Z., & Wu, Y. (2019).
LibriTTS: 'n Korpus afgelei van LibriSpeech vir teks-na-spraak. arXiv.
<https://arxiv.org/abs/1904.02882>

36. Le, T. (2024). viVoice: A large-scale multi-speaker Vietnamese speech dataset for text-to-

toespraak. Gesig omhels. __HOU_0__