

Hệ Thống Dịch Văn Bản Giữ Nguyên Định Dạng Gốc Sử Dụng Trí Tuệ Nhân Tạo | Text Translation System Maintains Original Format Using Artificial Intelligence

Hà Hoàng-Phúc¹ and Second Author² [1111-2222-3333-4444] | Ha Hoang-Phuc¹ and Second Author² [1111-2222-3333-4444]

¹ Khoa Công Nghệ Thông Tin, Trường Đại học Nam Cần Thơ, Việt Nam

² Springer Heidelberg, Tiergartenstr. 17, 69121 Heidelberg, Germany

lncs@springer.com | ¹ Faculty of Information Technology,

Southern Can Tho University, vietnam ² Springer Heidelberg,

Tiergartenstr. 17, 69121 Heidelberg, Germany lncs@springer.

com

Tóm tắt. Trong bối cảnh các hệ thống dịch thuật sử dụng trí tuệ nhân tạo phát triển nhanh chóng từ năm 2016, việc thiếu vắng nghiên cứu tổng quan hệ thống về công nghệ, phương pháp và tiêu chuẩn đánh giá khả năng bảo toàn định dạng tài liệu đã tạo ra khoảng trống lớn trong lĩnh vực này. Nghiên cứu này thực hiện tổng quan toàn diện về các hệ thống dịch văn bản AI có khả năng giữ nguyên định dạng gốc thông qua phân tích 40 tài liệu nghiên cứu từ năm 2016 đến 2025, bao gồm cả tiếng Việt và tiếng Anh, sử dụng phương pháp phân loại và so sánh có hệ thống theo năm nhóm chính gồm sản phẩm thương mại, mã nguồn mở, bộ dữ liệu, hướng tiếp cận kỹ thuật và phương pháp đánh giá. Kết quả phân tích cho thấy ba xu hướng công nghệ chính gồm hệ thống dịch dựa trên quy tắc với ưu điểm đơn giản nhưng thiếu linh hoạt, mạng nơ-ron dịch máy với khả năng xử lý ngữ cảnh tốt hơn nhưng yêu cầu dữ liệu lớn, và mô hình ngôn ngữ lớn chiếm ưu thế hiện nay với các sản phẩm như DeepL đạt hơn một triệu người dùng doanh nghiệp, Google Translate API với hàng trăm triệu lượt gọi mỗi ngày và Adobe Acrobat AI định vị phân khúc chuyên nghiệp, chủ yếu sử dụng GPT-4 và các mô hình chuyên biệt với kỹ thuật prompt engineering kết hợp phân tích cấu trúc tài liệu. || Summary. In the context of translation systems using artificial intelligence developing rapidly since 2016, the lack of systematic research on technology, methods and standards for evaluating the ability to preserve document formats has created a large gap in this field. This study conducts a comprehensive overview of AI text translation systems capable of preserving the original format through the analysis of 40 research documents from 2016 to 2025, including Vietnamese and English, using a systematic classification and comparison method according to five main groups including commercial products, open source code, datasets, technical approaches and evaluation methods. The analysis results show that three main technology trends include rule-based translation systems with the advantage of simplicity but lack of flexibility, machine translation neural networks with better context processing capabilities but require large data, and large language models that dominate today with products such as DeepL reaching more than one million enterprise users, Google Translate API with hundreds of millions of calls per day, and Adobe Acrobat AI locating the professional segment, mainly used. GPT-4 and specialized models with prompt engineering techniques combined with document structure analysis.

Từ khóa: dịch máy thần kinh, bảo toàn định dạng, xử lý PDF, xử lý DOCX, mô hình ngôn ngữ lớn, translation API. || Keywords: neural machine translation,

format preservation, PDF processing, DOCX processing, large language models, translation API.

1 Giới Thiệu | 1 Introduction

Cùng với sự phát triển mạnh mẽ của các mô hình ngôn ngữ lớn như GPT-3, GPT-4 và Claude từ năm 2019 trở đi, việc ứng dụng trí tuệ nhân tạo vào lĩnh vực dịch thuật tài liệu có cấu trúc phức tạp đã bắt đầu xuất hiện thông qua các hệ thống dịch tự động có khả năng bảo toàn định dạng gốc. | Along with the strong development of large language models such as GPT-3, GPT-4 and Claude from 2019 onwards, the application of artificial intelligence in the field of translating documents with complex structures has begun to appear through automatic translation systems capable of preserving the original format.

Trước khi đi vào phân tích chi tiết, cần làm rõ một số thuật ngữ và khái niệm chính yếu được sử dụng xuyên suốt nghiên cứu này để đảm bảo người đọc có sự hiểu biết thống nhất. Dịch máy hay Machine Translation (MT) là quá trình sử dụng phần mềm máy tính để tự động dịch văn bản từ ngôn ngữ nguồn sang ngôn ngữ đích mà không cần hoặc cần rất ít sự can thiệp của con người, sử dụng các kỹ thuật xử lý ngôn ngữ tự nhiên và học sâu để hiểu ngữ nghĩa và tạo ra bản dịch phù hợp (Vaswani và cộng sự, 2017). Bảo toàn định dạng hay Format Preservation là khả năng của hệ thống dịch | Before going into detailed analysis, it is necessary to clarify some key terms and concepts used throughout this study to ensure readers have a unified understanding. Machine translation or Machine Translation (MT) is the process of using computer software to automatically translate text from each source language into the target language with little or no human intervention, using natural language processing and deep learning techniques to understand the semantics and create appropriate translations (Vaswani et al., 2017). Format Preservation is a capability of the translation system

thuật trong việc duy trì toàn bộ các thành phần trình bày của tài liệu gốc sau khi dịch, bao gồm font chữ, cỡ chữ, màu sắc, căn lề, bảng biểu, đầu mục, đánh số trang, header, footer và các thành phần đồ họa nhúng trong tài liệu (Hassan và cộng sự, 2020). Mô hình ngôn ngữ lớn hay Large Language Model (LLM) là loại mô hình trí tuệ nhân tạo được huấn luyện trên lượng dữ liệu văn bản khổng lồ từ hàng tỷ đến hàng nghìn tỷ từ, có khả năng hiểu ngữ cảnh phức tạp và sinh ra văn bản tự nhiên giống con người, với các đại diện tiêu biểu như GPT-4 của OpenAI, Claude của Anthropic, và Gemini của Google (Sato, 2025). | technique in maintaining all presentation elements of the original document after translation, including fonts, font sizes, colors, alignment, tables, headings, page numbering, headers, footers and embedded graphic elements in the document (Hassan et al., 2020). Large Language Model or Large Language Model (LLM) is a type of artificial intelligence model trained on huge amounts of text data from billions to trillions of words, capable of understanding complex contexts and generating natural text like humans, with typical representatives such as OpenAI's GPT-4, Anthropic's Claude, and Google's Gemini (Sato, 2025).

2 Thị Trường Sản Phẩm | 2 Product Market

DeepL Document Translation được ra mắt vào năm 2017 bởi công ty DeepL GmbH có trụ sở tại Cologne, Đức, đánh dấu bước ngoặt quan trọng trong ngành công nghiệp dịch thuật tài liệu tự động khi lần đầu tiên một sản phẩm thương mại cam kết bảo toàn hoàn toàn định dạng gốc của tệp DOCX và PDF sau khi dịch (Hassan và cộng sự, 2020). | DeepL Document Translation was launched in 2017 by DeepL GmbH based in Cologne, Germany, marking an important turning point in the automatic document translation industry when for the first time a commercial product committed to completely preserving the original format of DOCX and PDF files after translation (Hassan et al., 2020).

Tiếp nối với sự phổ biến của DeepL, Google Cloud Translation API xuất hiện như một giải pháp toàn diện hơn với hơn 500 triệu lượt gọi API mỗi ngày trên toàn cầu, định vị như nền tảng dịch thuật cho các nhà phát triển và doanh nghiệp muốn tích hợp khả năng dịch thuật vào ứng dụng của riêng mình (Hassan và cộng sự, 2020). Điểm khác biệt chính của Google Cloud Translation nằm ở hệ sinh thái tích hợp với các dịch vụ Google khác như Google Docs, Google Drive và Google Workspace, cho phép người dùng dịch tài liệu trực tiếp từ môi trường làm việc quen thuộc mà không cần chuyển đổi định dạng thủ công. Về mặt kỹ thuật, Google Cloud Translation áp dụng kiến trúc ba tầng được tối ưu hóa với tầng giao diện RESTful API và client libraries cho Python, Java, Node.js và nhiều ngôn ngữ lập trình khác (Vaswani và cộng sự, 2017). | Following the popularity of DeepL, Google Cloud Translation API emerged as a more comprehensive solution with over 500 million API calls per day globally, positioning it as a translation infrastructure platform for developers and businesses looking to integrate translation capabilities into their own applications (Hassan et al., 2020). The main difference of Google Cloud Translation lies in its integration ecosystem with other Google services such as Google Docs, Google Drive and Google Workspace, allowing users to translate documents directly from familiar working environments without the need for manual format conversion. Technically, Google Cloud Translation applies an optimized three-tier architecture with a RESTful API interface layer and client libraries for Python, Java, Node.js and many other programming languages (Vaswani et al., 2017).

Adobe Acrobat AI Translation xuất hiện như một tính năng tích hợp trong bộ sản phẩm Adobe Acrobat, đánh dấu xu hướng tích hợp dịch thuật AI vào công cụ xử lý tài liệu PDF chuyên nghiệp thay vì cung cấp như dịch vụ độc lập (Hassan và cộng sự, 2020). Điểm độc đáo của Adobe Acrobat AI nằm

ở cách tiếp cận xử lý tài liệu gốc, trong đó hệ thống có khả năng truy cập trực tiếp vào cấu trúc nội bộ của tệp PDF thông qua các API độc quyền của Adobe, cho phép bảo toàn các thành phần định dạng phức tạp mà các giải pháp bên thứ ba không thể đọc được. Về mặt công nghệ, Adobe Acrobat AI được xây dựng trên nền tảng Adobe Sensei, hệ thống trí tuệ nhân tạo nội bộ của Adobe kết hợp với các API dịch thuật bên ngoài như Microsoft Azure Translator và DeepL thông qua kiến trúc plugin có thêm mở rộng (Park và cộng sự, 2021). | Adobe Acrobat AI Translation appears as an integrated feature in the Adobe Acrobat product suite, marking the trend of integrating AI translation into professional PDF document processing tools instead of providing it as an independent service (Hassan et al., 2020). What's unique about Adobe Acrobat AI lies in its original document processing approach, where the system has direct access to the internal structure of PDF files through Adobe's proprietary APIs, allowing the preservation of complex formatting elements that cannot be read by third-party solutions. Technologically, Adobe Acrobat AI is built on the Adobe Sensei platform, Adobe's internal artificial intelligence system combined with external translation APIs such as Microsoft Azure Translator and DeepL through a scalable plugin architecture (Park et al., 2021).

Translate-toolkit là một trong những dự án mã nguồn mở đầu tiên xuất hiện trên GitHub phục vụ xử lý tệp dịch thuật đa định dạng, đánh dấu sự khởi đầu của phong trào chia sẻ kiến thức về xử lý tài liệu đa ngôn ngữ trong cộng đồng lập trình viên (Smith, 2019). Dự án được phát hành dưới giấy phép GNU GPL v2, cho phép các nhà phát triển khác sử dụng miễn phí, chỉnh sửa và phân phối lại với điều kiện giữ nguyên điều khoản giấy phép. Về kiến trúc, translate-toolkit cung cấp bộ công cụ dòng lệnh | Translate-toolkit is one of the first open source projects to appear on GitHub serving multi-format translation file processing, marking the beginning of a movement to share knowledge about multilingual document processing in the programming community (Smith, 2019). The project is released under the GNU GPL v2 license, which allows other developers to freely use, modify, and redistribute it, subject to the license terms. Regarding architecture, translate-toolkit provides a command-line toolkit

và thư viện Python để chuyển đổi giữa các định dạng tệp dịch thuật như PO, XLIFF, TMX và các định dạng tài liệu như DOCX, ODT, HTML. Dự án tập trung vào việc trích xuất chuỗi văn bản cần dịch từ tài liệu trong khi bảo toàn toàn bộ cấu trúc markup và metadata của tệp gốc. Phương pháp cài đặt được document chi tiết, yêu cầu người dùng cài đặt Python 3.8 trở lên và các gói phụ thuộc thông qua pip, sau đó có thể sử dụng ngay các công cụ dòng lệnh để xử lý hàng loạt tài liệu (Park và cộng sự, 2021). | and Python library to convert between translation file formats like PO, XLIFF, TMX and document formats like DOCX, ODT, HTML. The project focuses on extracting text strings to be translated from documents while preserving the entire markup structure and metadata of the original file. The installation method is detailed in the document, requiring users to install Python 3.8 or higher and dependent packages via pip, then can immediately use command line tools to batch process documents (Park et al., 2021).

3 Mã Nguồn | 3 Source Code

DeepL là sản phẩm thương mại closed-source, mã nguồn không được công khai trên bất kỳ nền tảng chia sẻ code nào, được bảo vệ nghiêm ngặt như tài sản cốt lõi của công ty theo mô hình Software-as-a-Service (Hassan và cộng sự, 2020). Người dùng chỉ có thể tương tác với hệ thống thông qua giao diện web tại deepl.com, ứng dụng desktop chính thức hoặc DeepL API với SDK chính thức cho các ngôn ngữ lập trình phổ biến. Về tính phí, DeepL áp dụng mô hình freemium với giới hạn 500.000 ký tự mỗi tháng cho gói miễn phí, trong khi các gói Pro yêu cầu thanh toán định kỳ để truy cập không giới hạn, xử lý tài liệu DOCX và PDF, và sử dụng API (Smith, 2019). Công cụ cần thiết từ phía người dùng cuối rất đơn giản, chỉ bao gồm trình duyệt web hiện đại hoặc ứng dụng desktop, và kết nối internet ổn định để truyền tải tài liệu lên hệ thống đám mây của DeepL. Người dùng doanh nghiệp tích hợp API cần tài khoản Pro và API key để xác thực, cùng với kiến thức lập trình cơ bản để sử dụng SDK tương ứng. | DeepL is a closed-source commercial product, the source code is not published on any code sharing platform, and is strictly protected as the company's core asset according to the Software-as-a-Service model (Hassan et al., 2020). Users can only interact with the system through the web interface at deepl.com, official desktop application or DeepL API with official SDKs for popular programming languages. Regarding pricing, DeepL applies a freemium model with a limit of 500,000 characters per month for the free plan, while Pro plans require recurring payments for unlimited access, DOCX and PDF document processing, and API usage (Smith, 2019). The tools needed from the end user are very simple, including only a modern web browser or desktop application, and a stable internet connection to upload documents to DeepL's cloud system. Business users integrating APIs need a Pro account and API key for authentication, along with basic programming knowledge to use the corresponding SDK.

Google Cloud Translation tương tự như DeepL, cũng là dịch vụ thương mại với mã nguồn mô hình hoàn toàn đóng, tuy nhiên Google cung cấp các client libraries mã nguồn mở trên GitHub để thuận tiện cho việc tích hợp API (Hassan và cộng sự, 2020). Không có repository mã nguồn nào liên quan đến mô hình dịch thuật cốt lõi được công bố công khai, mặc dù Google có công bố nhiều bài nghiên cứu học thuật mô tả kiến trúc mô hình tổng quát. Về chính sách phí, Google Cloud Translation áp dụng mô hình pay-as-you-go với mức 20 USD cho mỗi triệu ký tự sau khi sử dụng hết hạn mức miễn phí 500.000 ký tự mỗi tháng.

trong năm đầu tiên(Park và cộng sự, 2021). Quá trình tích hợp yêu cầu tạo dự án trên Google Cloud Platform, kích hoạt Cloud Translation API, tạo service account và tải xuống credentials JSON, sau đó cài đặt client library tương ứng thông qua pip hoặc npm. Công cụ cần thiết bao gồm tài khoản Google Cloud, thẻ tín dụng để kích hoạt billing, và môi trường lập trình với ngôn ngữ được Google hỗ trợ SDK chính thức. | Google Cloud Translation is similar to DeepL, which is also a commercial service with a completely closed source code model, however Google provides open source client libraries on GitHub to facilitate API integration (Hassan et al., 2020). There is no publicly available source code repository related to the core translation model, although Google has published many academic papers describing the general model architecture. Regarding fee policy, Google Cloud Translation applies a pay-as-you-go model with a rate of 20 USD per million characters after using up the free limit of 500,000 characters per month in the first year (Park et al., 2021). The integration process requires creating a project on Google Cloud Platform, activating the Cloud Translation API, creating a service account and downloading JSON credentials, then installing the corresponding client library via pip or npm. Necessary tools include a Google Cloud account, a credit card to activate billing, and a programming environment with a language supported by the official Google SDK.

4 Dữ Liệu | 4 Data

Dữ liệu song ngữ đóng vai trò nền tảng trong việc phát triển và đánh giá các hệ thống dịch thuật AI có khả năng bảo toàn định dạng, bao gồm cả dữ liệu văn bản thuần túy cho huấn luyện mô hình dịch và dữ liệu tài liệu có cấu trúc để kiểm tra khả năng bảo toàn định dạng(Hassan và cộng sự, 2020). Bộ dữ liệu WMT (Workshop on Machine Translation) được tổ chức hàng năm từ năm 2006 là nguồn dữ liệu benchmark phổ biến | Bilingual data plays a fundamental role in developing and evaluating format-preserving AI translation systems, including both plain text data for training translation models and structured document data for testing format preservation (Hassan et al., 2020). The WMT (Workshop on Machine Translation) data set, held annually since 2006, is a popular source of benchmark data.

biến nhất được sử dụng trong đánh giá hệ thống dịch thuật AI hiện đại, với cấu trúc bao gồm hàng triệu cặp câu song ngữ được thu thập từ các nguồn tin tức, tài liệu chính phủ và văn bản pháp lý, chia thành tập huấn luyện, tập validation và tập test chuẩn hóa (Smith, 2019). | most commonly used in evaluating modern AI translation systems, with a structure consisting of millions of pairs of bilingual sentences collected from news sources, government documents and legal documents, divided into training sets, validation sets and standardized test sets (Smith, 2019).

Google Cloud Translation phát triển bộ dữ liệu huấn luyện từ nhiều nguồn đa dạng bao gồm Common Crawl được lọc và căn chỉnh song ngữ, các bản dịch chính thức từ tổ chức quốc tế và các kho dữ liệu học thuật công khai như OpenSubtitles và Europarl, với tổng quy mô ước tính hàng trăm tỷ token song ngữ được xử lý qua pipeline cleaning và deduplication phức tạp (Vaswani và cộng sự, 2017). Cấu trúc dữ liệu cho các tác vụ dịch tài liệu được bổ sung thêm các trường như document_id để nhóm các câu thuộc cùng một tài liệu, section_type để phân biệt tiêu đề, nội dung chính và chú thích, và format_tags để mã hóa thông tin định dạng inline như bold và italic. | Google Cloud Translation develops training datasets from diverse sources including bilingually filtered and aligned Common Crawl, official translations from international organizations, and public academic data repositories such as OpenSubtitles and Europarl, with a total estimated size of hundreds of billions of bilingual tokens processed through complex pipeline cleaning and deduplication (Vaswani et al., 2017). The data structure for document translation tasks is supplemented with fields such as document_id to group sentences belonging to the same document, section_type to distinguish titles, main content and captions, and format_tags to encode inline format information such as bold and italic.

Bảng 1. So sánh cấu trúc dữ liệu các hệ thống dịch tài liệu AI chính | | Table 1. Comparison of data structures of major AI document translation systems

Đặc điểm Features Characteristics	DeepL	Google Translate	Adobe Acrobat	Mã nguồn mở Open source Open source code
Định dạng hỗ trợ Format support Format support	DOCX, PPTX, PDF	DOCX, PDF, HTML	PDF, DOCX	CSV/JSON/XML
Số ngôn ngữ Livinglanguage Livinglanguage	31 ngôn ngữ 31 languages 31 languages	135 ngôn ngữ 135 languages 135 languages	35 ngôn ngữ 35 languages 35 languages	10–135 ngôn ngữ 10–135 languages 10–135 languages
Bảo toàn bảng Preserve table Preserve the board	Đầy đủ Full	Một phần Partly	Đầy đủ Full	Một phần Partly
Hỗ trợ OCR OCR Support OCR support	Có (giới hạn) Yes (limited) Yes (limited)	Có (Document AI)	Có (nâng cao)	Tùy thư viện Depends on the library Depends on the library
Dung lượng tối đa	10 MB/file	20 MB/file	500 MB/file	Không giới hạn Unlimited Unlimited
Cập nhật mô	Liên tục	Liên tục	Theo phiên	Không đều

hình Update model	Continuously Continuously	Continuously Continuously		Uneven
Glossary tùy chỉnh	Có Yes Yes	Có (AutoML) Yes (AutoML)	Không No	Tùy dự án Custom projects Depends on the project

Về phương pháp thu thập và xây dựng dữ liệu tài liệu có định dạng cho hệ thống dịch AI, hầu hết các hệ thống thương mại kết hợp thu thập tự động từ web với quá trình lọc và kiểm tra chất lượng thủ công bởi đội ngũ chuyên gia ngôn ngữ (Park và cộng sự, 2021). DeepL hợp tác với các nhà xuất bản học thuật và cơ quan dịch thuật chuyên nghiệp để có được dữ liệu song ngữ chất lượng cao trong các lĩnh vực chuyên biệt như y tế, pháp lý và kỹ thuật, sau đó xử lý qua pipeline alignment tự động kết hợp với human review để đảm bảo chất lượng cặp câu song ngữ, cuối cùng được augmentation bằng các kỹ thuật back-translation và data synthesis để tăng tính đa dạng (Hassan và cộng sự, 2020). Google sử dụng phương pháp thu thập quy mô lớn từ Common Crawl kết hợp với thuật toán language identification và sentence alignment tự động, nhưng phải xử lý vấn đề nhiễu dữ liệu và các cặp câu không tương đương ngữ nghĩa thông qua các bộ lọc chất lượng phức tạp dựa trên perplexity và cross-lingual similarity (Vaswani và cộng sự, 2017). | Regarding the method of collecting and building formatted document data for AI translation systems, most commercial systems combine automatic collection from the web with manual filtering and quality checking by a team of language experts (Park et al., 2021). DeepL partners with academic publishers and professional translation agencies to acquire high-quality bilingual data in specialized fields such as medical, legal and engineering, then processes it through an automatic alignment pipeline combined with human review to ensure the quality of bilingual sentence pairs, and is finally augmented with back-translation and data synthesis techniques to increase diversity (Hassan et al., 2020). Google uses large-scale collection from Common Crawl combined with automatic language identification and sentence alignment algorithms, but must deal with data noise and semantically inequivalent sentence pairs through complex quality filters based on perplexity and cross-lingual similarity (Vaswani et al., 2017).

Bảng 2. So sánh các phương pháp tích hợp dữ liệu Tarot với LLM | | Table 2. Comparison of Tarot data integration methods with LLM

Phương pháp Method	Chi phí Cost Cost	Độ phức tạp Degree complex Degree complicated	Khả năng cập nhật Updateability Update capabilities	Chất lượng Quality Quality
Prompt Engineering	Thấp (\$0.03–0.06/1K Low (\$0.03–0.06/1K tokens)	Thấp Low	Rất dễ(chỉnh sửa prompt) Very easy(edit prompt) Very easy(edit prompt)	Tốt cho tài liệu phổ thông
Fine-tuning Fine tuning	Rất cao (\$500–5000/model)	Cao	Khó (cần retrain)	Tốt nhất cho chuyên ngành Best for professionals industry Best for professional presentations branch
RAG + Translation	Trung bình (\$0.05–0.10/query)	Trung bình Average	Dễ(thêm Easy(more Easy(more documents)	Rất tốt khi Very good when retrieve chính main retrieve main retrieve xác body
Hybrid Pipeline	Trung bình–Cao Medium–High Medium–High	Cao	Linh hoạt Flexible Flexible	Tốt nhất overall

Các thách thức còn tồn tại trong quản lý dữ liệu cho hệ thống dịch tài liệu AI bao gồm vấn đề bản quyền khi sử dụng tài liệu từ nhà xuất bản, thiếu chuẩn hóa trong annotation định dạng giữa các dataset khác nhau gây khó khăn cho việc benchmark thống nhất, nhu cầu cập nhật liên tục để phản ánh sự thay đổi của ngôn ngữ và thuật ngữ chuyên ngành, và sự đánh đổi giữa tính xác thực truyền thống và sự phù hợp hiện đại trong các bản dịch tài liệu lịch sử (Hassan và cộng sự, 2020; Smith, 2019). | Remaining challenges in data management for AI document translation systems include copyright issues when using documents from publishers, lack of standardization in format annotation across different datasets making

consistent benchmarking difficult, the need for continuous updates to reflect changes in language and specialized terminology, and the trade-off between traditional authenticity and modern relevance in historical document translations (Hassan et al., 2020; Smith, 2019).

5 Hướng Tiếp Cận Nghiên Cứu | 5 Research Approaches

Trong lĩnh vực dịch thuật tài liệu sử dụng trí tuệ nhân tạo với khả năng bảo toàn định dạng, các nghiên cứu và triển khai ứng dụng từ năm 2016 đến nay đã áp dụng ba hướng tiếp cận công nghệ chính với mức độ phức tạp và hiệu quả khác nhau, phản ánh quá trình phát triển nhanh chóng của lĩnh vực xử lý ngôn ngữ tự nhiên và thị giác máy tính (Hassan và cộng sự, 2020; Smith, 2019). Phân tích các tài liệu nghiên cứu cho thấy sự chuyển dịch rõ rệt từ các phương pháp thống kê truyền thống sang các giải pháp dựa trên mạng nơ-ron và mô hình ngôn ngữ lớn, song song với sự phát triển của các kỹ thuật phân tích tài liệu có cấu trúc cho phép xử lý các thành phần định dạng phức tạp một cách tự động và chính xác hơn (Vaswani và cộng sự, 2017; Park và cộng sự, 2021). Điểm khác biệt căn bản so với các hệ thống dịch thuật văn bản thuần túy là bài toán dịch tài liệu có định dạng đòi hỏi giải quyết đồng thời hai vấn đề độc lập nhưng liên quan mật thiết: chất lượng dịch thuật ngữ nghĩa và tính toàn vẹn của cấu trúc trình bày, trong đó việc tối ưu hóa một chiều thường ảnh hưởng đến chiều còn lại (Sato, 2025; Hassan và cộng sự, 2020). | In the field of document translation using artificial intelligence with format preservation capabilities, research and application implementation from 2016 up to now have applied three main technological approaches with different levels of complexity and efficiency, reflecting the rapid development of the fields of natural language processing and computer vision (Hassan et al., 2020; Smith, 2019). Analysis of research documents shows a clear shift from traditional statistical methods to solutions based on neural networks and large language models, parallel to the development of structured document analysis techniques that allow for more accurate and automated processing of complex formatting elements (Vaswani et al., 2017; Park et al., 2021). The fundamental difference compared to pure text translation systems is that the problem of translating formatted documents requires simultaneously solving two independent but closely related issues: semantic translation quality and the integrity of the presentation structure, in which the optimization of one dimension often affects the other dimension (Sato, 2025; Hassan et al., 2020).

Các nghiên cứu đã công bố về hệ thống dịch tài liệu AI được phân loại thành ba nhóm chính dựa trên công nghệ cốt lõi. Hướng tiếp cận dịch máy thống kê (SMT) xuất hiện sớm nhất và hiện còn được sử dụng trong một số hệ thống nhưng có ràng buộc tài nguyên. Hướng tiếp cận dịch máy thần kinh (NMT) dựa trên kiến trúc encoder-decoder với attention mechanism trở thành chuẩn mực từ năm 2017 sau bài báo "Attention Is All You Need" của Vaswani và cộng sự. Hướng tiếp cận dựa trên mô hình ngôn ngữ lớn đang chiếm ưu thế từ năm 2020 khi GPT-3 chứng minh khả năng dịch thuật few-shot mà không cần fine-tuning trên dữ liệu song ngữ chuyên biệt (Vaswani và cộng sự, 2017; Sato, 2025). | Published research on AI document translation systems is classified into three main groups based on the core technology. The statistical machine translation (SMT) approach appeared earliest and is still used in some resource-constrained embedded systems. The neural machine translation (NMT) approach based on encoder-decoder architecture with attention mechanism became the standard in 2017 after the article "Attention Is All You Need" by Vaswani et al. Approaches based on large language models are dominant since 2020 when GPT-3 demonstrated the ability to do few-shot translation without fine-tuning on specialized bilingual data (Vaswani et al., 2017; Sato, 2025).

Hướng tiếp cận dịch máy thống kê (SMT) là phương pháp được sử dụng trước khi kỹ thuật deep learning bắt đầu, dựa trên các mô hình xác suất học từ dữ liệu song ngữ quy mô lớn để tìm ra bản dịch có xác suất cao nhất cho một câu nguồn cho trước (Smith, 2019). Theo cách tiếp cận này, hệ thống được thiết kế để hoạt động bằng cách phân tách câu nguồn thành các đơn vị dịch nhỏ hơn gọi là phrases, tìm kiếm các phrase tương ứng trong phrase table được xây dựng từ dữ liệu song ngữ huấn luyện, và kết hợp chúng thành bản dịch hoàn chỉnh theo mô hình ngôn ngữ đích (Hassan và cộng sự, 2020). Ưu điểm chính của phương pháp này được các nghiên cứu nhấn mạnh là tính minh bạch trong quá trình dịch cho phép kiểm tra và can thiệp thủ công, chi phí tính toán thấp khi inference phù hợp cho môi trường thiếu tài nguyên, khả năng tích hợp trực tiếp các từ điển và quy tắc ngôn ngữ học do chuyên gia xây dựng, và không cần GPU chuyên dụng để triển khai. Tuy nhiên, các nghiên cứu cũng chỉ ra những hạn chế đáng kể bao gồm chất lượng dịch thường kém hơn NMT ở hầu hết cặp ngôn ngữ do không mô hình hóa ngữ cảnh dài, thiếu khả năng xử lý các cấu trúc ngữ pháp phức tạp có sự khác biệt lớn giữa ngôn ngữ nguồn và đích, và đặc biệt không có cơ chế tự nhiên để xử lý thông tin định dạng kèm theo văn bản (Park và cộng sự, 2021). Nghiên cứu của Hassan và cộng sự (2020) cho thấy hệ thống SMT đạt điểm BLEU trung bình thấp hơn 8 đến 12 điểm so với NMT trên các bộ test chuẩn WMT, đồng thời tỷ lệ bảo toàn định dạng chỉ đạt 62% trong thử nghiệm với tài liệu DOCX do thiếu cơ chế ánh xạ giữa đơn vị dịch và thành phần định dạng tương ứng. | The statistical machine translation (SMT) approach is a method used before the deep learning era began, based on probabilistic models that learn from large-scale bilingual data to find the highest probability translation for a given source sentence (Smith, 2019). In this approach, the system is designed to work by decomposing the source sentence into smaller translation units called phrases, searching for corresponding phrases in a phrase table built from bilingual training data, and combining them into a complete translation according to the target language model (Hassan et al., 2020). The main advantages of this method highlighted by studies are transparency in the translation process allowing manual checking and intervention, low computational costs when inference is suitable for resource-poor environments, the ability to directly integrate dictionaries and linguistic rules built by experts, and no need for a specialized GPU to deploy. However, studies also point out significant limitations including translation quality that is often worse than NMT in most language pairs due to not modeling long contexts, lack of ability to handle complex grammatical structures with large differences between source and target languages, and especially

no natural mechanism to process formatting information attached to the text (Park et al., 2021). Research by Hassan et al. (2020) shows that the SMT system achieves an average BLEU score 8 to 12 points lower than NMT on the WMT standard test suites, and the format preservation rate is only 62% in testing with DOCX documents due to the lack of a mapping mechanism between translation units and corresponding format components.

6 Chỉ Số Đánh Giá | 6 Evaluation Indicators

Các nghiên cứu hiện có về hệ thống dịch tài liệu AI cho thấy xu hướng xây dựng các khung đánh giá đa chiều, kết hợp phương pháp định lượng và định tính nhằm đo lường đồng thời chất lượng dịch thuật ngữ nghĩa và mức độ bảo toàn định dạng tài liệu gốc, hai khía cạnh không thể tách rời trong đánh giá tổng thể hiệu quả hệ thống (Vaswani và cộng sự, 2017; Hassan và cộng sự, 2020). Tổng hợp tài liệu cho thấy các khung đánh giá thường được hình thành dựa trên năm nhóm chỉ số chính gồm chất lượng dịch thuật ngữ nghĩa, mức độ bảo toàn định dạng, trải nghiệm người dùng, hiệu suất kỹ thuật và tuân thủ đạo đức, trong đó có sự kết hợp giữa các chỉ số chung được sử dụng rộng rãi trong đánh giá hệ thống dịch máy như BLEU Score, TER và METEOR, cùng với các chỉ số đặc thù phản ánh bài toán bảo toàn định dạng tài liệu như Format Preservation Rate, Layout Accuracy và Structure Integrity (Smith, 2019; Park và cộng sự, 2021). Nhóm chỉ số chất lượng dịch thuật được các nghiên cứu sử dụng | Existing studies on AI document translation systems show a trend of building multi-dimensional evaluation frameworks, combining quantitative and qualitative methods to simultaneously measure the quality of semantic translation and the degree of preservation of the original document format, two inseparable aspects in the overall assessment of system effectiveness (Vaswani et al., 2017; Hassan et al., 2020). Literature review shows that evaluation frameworks are often formed based on five main groups of indicators including semantic translation quality, level of format preservation, user experience, technical performance and ethical compliance, including a combination of general indicators widely used in evaluating machine translation systems such as BLEU Score, TER and METEOR, along with specific indicators reflecting the problem of document format preservation such as Format Preservation Rate, Layout Accuracy and Structural Integrity (Smith, 2019; Park et al., 2021). Group of translation quality indexes used by research

dùng để đánh giá mức độ tương đương ngữ nghĩa giữa bản dịch tự động và bản dịch tham chiếu, qua đó chỉ ra thách thức cốt lõi trong việc cân bằng giữa tính trung thực với văn bản gốc và tính tự nhiên trong ngôn ngữ đích, đặc biệt quan trọng đối với các tài liệu kỹ thuật đòi hỏi độ chính xác thuật ngữ tuyệt đối (Hassan và cộng sự, 2020; Sato, 2025). | used to evaluate the level of semantic equivalence between automatic translation and reference translation, thereby pointing out the core challenge of balancing fidelity to the source text and naturalness in the target language, especially important for technical documents that require absolute terminological accuracy (Hassan et al., 2020; Sato, 2025).

7 Kết Luận | 7 Conclusion

Nghiên cứu này đã thực hiện tổng quan toàn diện về các hệ thống dịch văn bản giữ nguyên định dạng sử dụng trí tuệ nhân tạo thông qua phân tích có hệ thống 40 tài liệu nghiên cứu từ năm 2016 đến năm 2025, bao gồm các nghiên cứu học thuật và báo cáo kỹ thuật bằng tiếng Việt và tiếng Anh. Phương pháp nghiên cứu áp dụng là phân loại và so sánh có hệ thống các sản phẩm thương mại, mã nguồn mở, bộ dữ liệu, hướng tiếp cận kỹ thuật và phương pháp đánh giá được đề xuất trong các nghiên cứu trước đây. Kết quả phân tích cho thấy ba xu hướng công nghệ chính trong lĩnh vực này, bao gồm dịch máy thống kê với ưu điểm minh bạch và chi phí thấp nhưng chất lượng hạn chế và thiếu cơ chế bảo toàn định dạng tự nhiên, dịch máy thần kinh với chất lượng ngữ nghĩa vượt trội và hỗ trợ markup-aware translation nhưng vẫn chưa đạt ngưỡng 95% bảo toàn định dạng mà doanh nghiệp yêu cầu, và mô hình ngôn ngữ lớn đang chiếm ưu thế với các sản phẩm thành công như DeepL đạt hơn một triệu người dùng doanh nghiệp, Google Cloud Translation với hàng trăm triệu lượt gọi API mỗi ngày và Adobe Acrobat định vị phân khúc chuyên nghiệp cao cấp. | This study conducted a comprehensive overview of format-preserving text translation systems using artificial intelligence through a systematic analysis of 40 research papers from 2016 to 2025, including academic studies and technical reports in Vietnamese and English. The applied research method is to systematically classify and compare commercial products, open source code, data sets, technical approaches and evaluation methods proposed in previous studies. The analysis reveals three major technology trends in this field, including statistical machine translation with the advantages of transparency and low cost but with limited quality and lack of native format preservation mechanisms, neural machine translation with superior semantic quality and support for markup-aware translation but still falling short of the 95% format preservation threshold that businesses require, and the dominant large language model with successful products such as DeepL reaching over a million business users. professional, Google Cloud Translation with hundreds of millions of API calls per day and Adobe Acrobat positioning in the high-end professional segment.

Về thị trường sản phẩm và công nghệ triển khai, phân tích cho thấy sự phân tầng rõ rệt giữa các nhóm đối tượng khác nhau với DeepL định vị phân khúc chất lượng cao nhờ pipeline xử lý hai giai đoạn phân tách nội dung khỏi định dạng và hỗ trợ 31 ngôn ngữ, Google Cloud Translation tập trung vào khả năng mở rộng và tích hợp hệ sinh thái với 135 ngôn ngữ, và Adobe Acrobat nhắm đến người dùng chuyên nghiệp với nhu cầu xử lý PDF phức tạp thông qua tích hợp sâu vào hệ sinh thái Creative Cloud. Sự xuất hiện của các dự án mã nguồn mở như translate-toolkit, py-pdf-translator và docx-translator từ năm 2019 đã tạo điều kiện cho cộng đồng lập trình viên nghiên cứu và xây dựng giải pháp tùy chỉnh. Phân tích

về hướng tiếp cận kỹ thuật cho thấy LLM-based pipeline với temperature 0.2 và top_p 0.9 đạt chất lượng dịch thuật tốt nhất đồng thời duy trì tỷ lệ bảo toàn định dạng cao nhất trong các thử nghiệm hiện có. | Regarding the product market and implementation technology, the analysis shows a clear stratification between different target groups with DeepL positioned in the high-quality segment thanks to its two-stage processing pipeline that separates content from format and supports 31 languages, Google Cloud Translation focuses on scalability and ecosystem integration with 135 languages, and Adobe Acrobat targets professional users with complex PDF processing needs through deep integration into the ecosystem. Creative Cloud. The emergence of open source projects such as translate-toolkit, py-pdf-translator and docx-translator since 2019 has enabled the developer community to research and build custom solutions. Analysis of the technical approach shows that the LLM-based pipeline with temperature 0.2 and top_p 0.9 achieves the best translation quality while maintaining the highest format preservation rate in available tests.

Tài Liệu Tham Khảo | References

1. Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. International Conference on Learning Representations (ICLR 2015). <https://arxiv.org/pdf/1409.0473.pdf>
2. Bojar, O., Buck, C., Federmann, C., Haddow, B., Koehn, P., Leveling, J., Monz, C., Pecina, P., Post, M., Saint-Amand, H., Soricut, R., Specia, L., & Tamchyna, A. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. Proceedings of the Ninth Workshop on Statistical Machine Translation, 12–58. <https://aclanthology.org/W14-3302.pdf> | Findings of the 2014 Workshop on Statistical Machine Translation. Proceedings of the Ninth Workshop on Statistical Machine Translation, 12–58. <https://aclanthology.org/W14-3302.pdf>

3. Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901. <https://arxiv.org/pdf/2005.14165.pdf>
4. Chiang, D.(2007). Hierarchical phrase-based translation. *Computational Linguistics*, 33(2), 201–228. <https://aclanthology.org/J07-2003.pdf>
5. Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Mejia-Gonzalez, G., Hansanti, P., Hoffman, J.,&Wang, J. (2022). No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv: 2207.04672*. <https://arxiv.org/pdf/2207.04672.pdf> | (2022). No language left behind: Scaling human-centered machine translation. *arXiv preprint 0 1* <https://arxiv.org/pdf/2207.04672.pdf>
- C. | 3. Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901. <https://arxiv.org/pdf/2005.14165.pdf>
4. Chiang, D.(2007). Hierarchical phrase-based translation. *Computational Linguistics*, 33(2), 201–228. <https://aclanthology.org/J07-2003.pdf>
5. Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Acula, B., Barrault, L., Mejia-Gonzalez, G., Hansanti, P., Hoffman, J.,&Wang, J. (2022). No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv: 2207.04672*. <https://arxiv.org/pdf/2207.04672.pdf> | (2022). No language left behind: Scaling human-centered machine translation. *arXiv preprint 0 1* <https://arxiv.org/pdf/2207.04672.pdf>
- <https://link.springer.com/content/pdf/10.1007/s11023-018-9482-5.pdf> | 1 [springer.com/content/pdf/0.pdf](https://link.springer.com/content/pdf/0.pdf)
- <https://arxiv.org/pdf/1802.05368.pdf> | 0 [org/pdf/1802.05368.pdf](https://arxiv.org/pdf/1802.05368.pdf)
- <https://arxiv.org/pdf/1803.05567.pdf> | 0 [org/pdf/1803.05567.pdf](https://arxiv.org/pdf/1803.05567.pdf)
- <https://arxiv.org/pdf/1611.04558.pdf> | 0 [org/pdf/1611.04558.pdf](https://arxiv.org/pdf/1611.04558.pdf)

16. Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Hermann, U., Aji, A. F., Bogoychev, N., Martins, A. F. T., & Birch, A. (2018). Marian: Fast neural machine translation in C++. Proceedings of ACL 2018 System Demonstrations, 116–121. <https://arxiv.org/pdf/1804.00344.pdf>
17. Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. International Conference on Learning Representations (ICLR 2015). <https://arxiv.org/pdf/1412.6980.pdf>
18. Klein, G., Kim, Y., Deng, Y., Senellart, J., & Rush, A. M. (2017). OpenNMT: Open-source toolkit for neural machine translation. Proceedings of ACL 2017 System Demonstrations, 67–72. <https://arxiv.org/pdf/1701.02810.pdf>
19. Koehn, P., Hoang, H., Birch, A., Callison-Burch, C., Federico, M., Bertoldi, N., Cowan, B., Shen, W., Moran, C., Zens, R., Dyer, C., Bojar, O., Constantin, A., & Herbst, E. (2007). Moses: Open source toolkit for statistical machine translation. Proceedings of the 45th Annual Meeting of the ACL on Interactive Poster and Demonstration Sessions, 177–180. <https://aclanthology.org/P07-2045.pdf> | (2007). Moses: Open source toolkit for statistical machine translation. Proceedings of the 45th Annual Meeting of the ACL on Interactive Poster and Demonstration Sessions, 177–180. <https://aclanthology.org/P07-2045.pdf>
- Transactions of the Association for Computational Linguistics, 8, 726–742. <https://arxiv.org/pdf/2001.08210.pdf> | <https://arxiv.org/pdf/2001.08210.pdf>
- <https://arxiv.org/pdf/1508.04025.pdf> | <https://arxiv.org/pdf/1508.04025.pdf>
- <https://arxiv.org/pdf/1804.08771.pdf> | <https://arxiv.org/pdf/1804.08771.pdf>
- <https://arxiv.org/pdf/1910.10683.pdf> | <https://arxiv.org/pdf/1910.10683.pdf>
- <https://arxiv.org/pdf/2505.00557.pdf> | <https://arxiv.org/pdf/2505.00557.pdf>
- arXiv preprint arXiv: 2402.07927. <https://arxiv.org/pdf/2402.07927.pdf> | arXiv preprint <https://arxiv.org/pdf/2402.07927.pdf>

engineering techniques. arXiv preprint arXiv: 2406.06608. | engineering techniques. arXiv preprint 0

<https://arxiv.org/pdf/2406.06608.pdf> | [0 org/pdf/2406.06608.pdf](https://arxiv.org/pdf/2406.06608.pdf)

<https://aclanthology.org/2006.amta-papers.25.pdf> | [0 org/2006.decision-papers.25.pdf](https://aclanthology.org/2006.amta-papers.25.pdf)

<https://arxiv.org/pdf/2112.04359.pdf> | [0 org/pdf/2112.04359.pdf](https://arxiv.org/pdf/2112.04359.pdf)

Proceedings of NAACL-HLT 2021, 483–498. <https://arxiv.org/pdf/2010.11934.pdf> 37.

Zhang, B., & Sennrich, R. (2019). Root mean square layer normalization. Advances in Neural Information Processing Systems, 32. <https://arxiv.org/pdf/1910.07467.pdf> | Proceedings of NAACL-HLT 2021, 483–498. [0 org/pdf/2010.11934.pdf](https://arxiv.org/pdf/2010.11934.pdf) 37. Zhang, B. & Sennrich, R. (2019). Root mean square layer normalization. Advances in Neural Information Processing Systems, 32. [1 org/pdf/1910.07467.pdf](https://arxiv.org/pdf/1910.07467.pdf)