

Arkitektura e arsyetimit me shumë agentë për Astrology-AI (MARA-AI)

Nguyen Khoa-Lam¹ dhe Ngo-Ho Anh-Khoi²

¹ Shkenca Kompjuterike, Universiteti Nam Can Tho, Rruga Nguyen Van Cu 168, An Binh Ward, Can Tho City, Vietnam
lam226407@student.nctu.edu.vn

Abstrakt. Ky dokument propozon MARA-AI (Arkitektura e arsyetimit me shumë agentë për Astrologjinë AI), një kornizë me shumë agentë të përmirësuar nga GraphRAG për konsultime të automatizuara astrologjike. Interpretimi i bazuar në astrologji kërkon më shumë sesa gjenerim të drejtpërdrejtë të tekstit, sepse ai përfshin llogaritjet astronomike, njohuritë simbolike, arsyetimin relacional dhe kontekstin e personalizuar të përdoruesit. Për të adresuar këto kërkesat, MARA-AI integron astrologjike deterministe llogaritja, rikthimi semantik, arsyetimi i grafikut të njohurive dhe bashkëpunimi i agentëve të specializuar brenda një arkitekture të unifikuar. Sistemi i propozuar përbëhet nga pesë faza kryesore: parapërpunimi i të dhënave, analiza semantike kontekstuale, marrja e njohurive të bazuara në grafik, arsyetimi me shumë agentë dhe sinteza e përgjigjeve. Në fazën e parapërpunimit, hyrja e përdoruesit standardizohet përmes normalizimit të tekstit. Sistemi më pas aplikon moderimin e parmakut mbrojtës, analizën e qëllimit, analizën e ndjenjave dhe Njohjen e Entit të Emërtuar (NER) për të kuptuar pyetjen e përdoruesit dhe për të nxjerrë entitetet përkatëse astrologjike. Për

llogaritja astrologjike, korniza gjeneron informacione të grafikut të lindjes bazuar në pozicionet planetare, shtëpitë, shenjat e zodiakut dhe të dhënat përkatëse të grafikut. Për të përmirësuar cilësinë e rikthimit, MARA-AI kombinon gjenerimin standard të rikthimit të shtuar (RAG) me GraphRAG. Rikthimi semantik përdoret për të identifikuar pjesët përkatëse tekstuale nga interpretimet e ruajtura, ndërsa grafiku i njohurive përfaqëson

marrëdhëniet midis planetëve, shenjave të zodiakut, shtëpive, aspekteve dhe fushave të jetës. Një mekanizëm kalimi Breadth-First Search (BFS) zbatohet për të tërhequr faktet e grafikëve të lidhura për marrëdhënie më të thella arsyetimi. Sistemi përdor gjithashtu një multi-agjent paralel mekanizëm orkestrimi, ku analizojnë agjentë të specializuar dimensione të ndryshme astrologjike si personaliteti, dashuria, karriera, shëndeti dhe orientimi i përditshëm. Rezultatet e tyre sintetizohen nga një model i madh gjuhësor në një përgjigje përfundimtare koherente. Eksperimentale vlerësimi duke përdorur RAGAS tregon se sistemi i plotë MARA-AI përmirëson lidhjen e përgjigjeve, saktësinë e kontekstit dhe rikujtimin e kontekstit

krahasuar me bazën standarde të RAG, duke demonstruar potencialin e tij për detyra komplekse të arsyetimit simbolik.

Fjalë kyçe: Sisteme me shumë agjentë; GraphRAG; Rikthim-Gjenerimi i shtuar; Astrologjia AI; Breadth-First Search (BFS); Njohja e entitetit të emërtuar (NER)

Hyrje

Astrologjia është një disiplinë interpretuese simbolike në të cilën kuptimi rrjedh nga marrëdhëniet midis trupave qiellorë, shenjave të zodiakut, shtëpive astrologjike dhe aspekteve planetare. Ndryshe nga aplikacionet konvencionale bisedore të AI që mbështeten kryesisht në semantikën tekstuale, interpretimi astrologjik kërkon integrimi i astronomisë llogaritëse, arsyetimi simbolik, kuptimi kontekstual dhe konkluzioni i personalizuar. Astrologët njerëzorë zakonisht sintetizojnë faktorë të shumtë të ndërlidhur astrologjikë njëkohësisht për të gjeneruar interpretime koherente, duke e bërë arsyetimin e automatizuar astrologjik një problem sfidues për sistemet moderne të inteligjencës artificiale.

Përparimet e fundit në Modelet e Mëdha të Gjuhëve (LLM) dhe Arkitekturat e bazuara në transformator kanë përmirësuar ndjeshëm aftësinë e sistemeve të AI për të kuptuar gjuhën natyrore, kapjen kuptimin kontekstual dhe gjenerojnë përgjigje njerëzore. Të Arkitektura e transformatorëve e prezantuar nga Vaswani et al. (2017) demonstroi se mekanizmat e vetë-vëmendjes mund të modelojnë në mënyrë efektive varësitë kontekstuale me rreze të gjatë në të dhënat tekstuale, duke çuar në përmirësime të mëdha në të gjitha detyrat e Përpunimit të Gjuhës Natyrore (NLP). Më pas, Përfaqësimet e Enkoderit Dydrejtimësh nga Transformatorët (BERT) zgjeruan më tej kuptimin semantik përmes mësimi të përfaqësimit kontekstual dydrejtues (Devlin et al., 2019). Kohët e fundit, modelet e

transformatorëve të trajnuar paraprakisht gjenerues (GPT) kanë treguar performancë të fortë në AI bisedore. detyra intensive të arsyetimit dhe gjenerimi i përmbajtjes në formë të gjatë (Brown et al., 2020). Këto zhvillime kanë përshpejtuar adoptimin e LLM-ve në sistemet inteligjente asistente dhe specifike për domenin aplikacionet bisedore.

Pavarësisht këtyre përparimeve, sistemet ekzistuese të bazuara në LLM ende

shfaqin kufizime të rëndësishme kur zbatohen në fusha të arsytimit simbolik si astrologjia. Shumica e modeleve gjeneruese mbështeten kryesisht në parashikimin probabilistik të shenjës së ardhshme dhe për këtë arsye mund të prodhojnë përgjigje që janë të rrjedhshme nga ana gjuhësore, por logjikisht jokonsistente ose kontekstualisht të cekëta. Në astrologji, kuptimi interpretues nuk del nga fakte të izoluara, por nga marrëdhënie komplekse simbolike midis planetëve, shtëpive astrologjike, grupeve elementare dhe aspekteve planetare. Rrjedhimisht, arkitekturat tradicionale të bisedave me një agjent të vetëm shpesh luftojnë për të ruajtur konsistencën kontekstuale dhe arsytimin simbolik me shumë hapa gjatë bisedave të gjata.

Për të adresuar kufizimet e qasjeve thjesht gjeneruese, Arkitekturat e gjenerimit të shtuar (RAG) janë shfaqur si një paradigmë efektive për integrimin e njohurive të jashtme në rrjedhat e punës së gjenerimit të gjuhës. RAG kombinon gjenerimin e gjuhës nervore me sistemet e marrjes së jashtme, duke u mundësuar modeleve gjuhësore të aksesojnë informacionin kontekstual në mënyrë dinamike gjatë gjenerimi i përgjigjeve (Lewis et al., 2020). Në fushat e arsytimit simbolik, qasjet e rikthimit të bazuara në grafik janë veçanërisht të përshtatshme sepse konceptet simbolike formojnë natyrshëm struktura semantike shumë të ndërlidhura. Brenda astrologjisë, marrëdhëniet midis shenjave të zodiakut, planetëve, shtëpive astrologjike, modaliteteve dhe elementeve mund të përfaqësohen në mënyrë efektive duke përdorur grafikët e njohurive.

Hulumtimet e fundit në sistemet grafike të njohurive kanë demonstruar efektivitetin e arsytimit të bazuar në grafik në aplikacionet që kërkojnë konkluzion relacional dhe rikthim kontekstual. Grafikët e njohurive modelojnë entitetet si nyje dhe marrëdhëniet semantike si skaje,

duke mundësuar kështu arsytimin e strukturuar mbi të ndërlidhur rrjetet e informacionit (Hogan et al., 2021). Për më tepër, algoritmet e përshkimit të grafikëve si kërkimi Breadth-First (BFS) ofrojnë

mekanizma efikasë për marrjen e entiteteve të lidhura semantikisht duke ruajtur kontekstin relacional (Sedgewick & Wayne, 2011). Krahësoar me metodat tradicionale të marrjes vetëm me vektor, rikthimi i bazuar në grafik përmirëson interpretueshmërinë dhe arsyetimin me shumë hop duke përfaqësuar në mënyrë eksplicite marrëdhëniet semantike midis entiteteve. Këto karakteristika i bëjnë arkitekturat GraphRAG veçanërisht të përshtatshme për sistemet e arsyetimit të orientuara nga astrologjia që kërkojnë interpretim simbolik dhe relacional.

Paralelisht me arkitekturat e bazuara në rikthim, sistemet me shumë agjentë janë shfaqur si një paradigmë efektive për zgjidhjen e komplekseve detyrat e arsytimit përmes specializimit të shpërndarë. Arkitekturat me shumë agjentë ndajnë një problem kompleks në nën-detyra të shumta të përpunuara në mënyrë të pavarur nga agjentë të specializuar përpara se të sintetizuar në një përgjigje të unifikuar (Wooldridge, 2009). Studimet e fundit kanë treguar se orkestrimi bashkëpunues i agjentëve mund të përmirësojë diversitetin e arsytimit, thellësinë kontekstuale, shkallëzueshmërinë modulare dhe interpretueshmërinë në krahasim me sistemet monolitike me një agjent (Park et al., 2023). Arkitektura të tilla janë shumë të rëndësishme për astrologjia sepse fusha të ndryshme interpretuese – duke përfshirë analizën e personalitetit, interpretimin emocional, parashikimin e karrierës, përputhshmërinë e marrëdhënieve dhe parashikimin e përditshëm – kërkojnë perspektiva të ndryshme arsytimi dhe strategji kontekstuale.

Disa studime të fundit kanë eksploruar integrimin e LLM-ve, sistemeve të rikthimit dhe grafikëve të njohurive brenda inteligjencës kornizat bisedore. Megjithatë, shumica e sistemeve ekzistuese përqendrohuni kryesisht në përgjigjen e pyetjeve me qëllim të përgjithshëm, sisteme rekomandimi, ose asistentë të orientuar drejt detyrave dhe jo fusha interpretuese simbolike. Për më tepër, zbatimet aktuale të chatbot-it të astrologjisë zakonisht mbështeten në sisteme statike të bazuara në rregulla ose në strategji të drejtpërdrejta nxitëse pa përfshirë arsytimin e strukturuar të grafikut, orkestrimin e agjentëve bashkëpunues ose mekanizmat e rikthimit kontekstual. Si rezultat, këto sisteme shpesh vuajnë nga memoria e kufizuar kontekstuale, aftësia e dobët e arsytimit relacional dhe interpretueshmëria e reduktuar.

I motivuar nga këto kufizime, ky hulumtim propozon MARA-AI (Arkitektura e arsyetimit me shumë agjentë për Astrologjinë AI), një Korniza me shumë agjentë e përmirësuar me GraphRAG e krijuar për interpretimi i automatizuar astrologjik. Arkitektura e propozuar integron teknika të shumta plotësuese, duke përfshirë normalizimin e tekstit të bazuar në regex për përpunim paraprak, nxitjen e shkrepjes zero për vërtetimin e parmakut, analizën e ndjenjave dhe Entitetin e emërtuar

Njohja (NER) për kuptimin kontekstual, llogaritja Swiss Ephemeris për llogaritjet astronomike, marrja e grafikëve të njohurive të bazuara në Neo4j, kalimi i grafikëve të bazuar në BFS dhe arsyetimi bashkëpunues me shumë agjentë.

Arkitektura e propozuar e rrjedhës së punës është e organizuar në pesë faza të ndërlidhura. Faza e parë fokusohet në parapërpunimin dhe vlefshmërinë e hyrjes, ku kërkesat e përdoruesve normalizohen dhe filtrohen për të hequr zhurmën e parëndësishme tekstuale. Faza e dytë kryen analiza kontekstuale paralele, duke përfshirë nxjerrjen semantike, ndjenjën analiza, njohja e qëllimit dhe llogaritja e të dhënave astrologjike. Faza e tretë zbaton marrjen e njohurive të bazuara në GraphRAG duke përdorur Neo4j dhe BFS traversal për të identifikuar entitetet astrologjike të lidhura semantikisht dhe treshe relacionale. Faza e katërt në mënyrë dinamike aktivizon agjentë të specializuar përgjegjës për fusha të ndryshme interpretuese, duke përfshirë analizën e personalitetit, pajtueshmërinë e marrëdhënieve, tendencat e karrierës, interpretimin shëndetësor dhe

parashikimi i horoskopit ditor. Së fundi, faza e pestë sintetizon rezultatet e gjeneruara nga agjentë të specializuar në një përgjigje koherente dhe të vetëdijshme për kontekstin duke përdorur shkrirjen e përgjigjeve të bazuara në LLM mekanizmat.

Kontributi kryesor i këtij studimi qëndron në integrimin e rikthimit të GraphRAG dhe orkestrimit bashkëpunues me shumë agjentë në një kornizë të unifikuar të AI të orientuar nga astrologjia. Ndryshe nga arkitekturat konvencionale të chatbot-it që varen vetëm nga gjenerimi i drejtpërdrejtë arsyetimi, MARA-AI kombinon përfaqësimin simbolik të njohurive, arsyetimin e kalimit të grafikut, llogaritjen astronomike përcaktuese dhe bashkëpunimin e agjentëve të shpërndarë për të përmirësuar interpretueshmërinë, qëndrueshmërinë kontekstuale dhe shkallëzueshmërinë modulare. Për më tepër, korniza e propozuar demonstroi mundësinë e aplikimit të arkitekturave hibride të AI në

domene arsyetimi simbolike që kërkojnë si saktësi llogaritëse ashtu edhe gjuhë natyrore të vetëdijshme për kontekstin. brezi.

Propozimi ynë

Korniza e propozuar MARA-AI është projektuar si një arkitekturë arsyetimi me shumë agjentë e përmirësuar nga GraphRAG për të automatizuar interpretimi astrologjik që integron gjuhën natyrore përpunimi, llogaritja astronomike, rikthimi semantik, arsyetimi i bazuar në grafik dhe orkestrimi bashkëpunues me shumë agjentë në një rrjedhë të unifikuar pune. Ndryshe nga sistemet konvencionale të bisedës që mbështeten vetëm në gjenerimin e drejtpërdrejtë të përgjigjes së shpejtë, arkitektura e propozuar e ndan procesin e arsyetimit në shumëfish

faza të ndërlidhura për të përmirësuar kuptimin kontekstual, interpretueshmëria, shkallëzueshmëria modulare dhe qëndrueshmëria e përgjigjes. Rrjedha e përgjithshme e punës së kornizës së propozuar është ilustruar në Fig. 1.

Fig. 1. Tubacioni i sistemit të Chatbot Astrology MARA-AI.

Nga një perspektivë formale, korniza e propozuar mund të përfaqësohet si:

$$Y=F(U,Q)$$

Ku U tregon informacionin e strukturuar të përdoruesit, duke përfshirë datën e lindjes, kohën e lindjes dhe vendndodhjen e lindjes, ndërsa Q përfaqëson pyetjen e gjuhës natyrore të paraqitur nga përdoruesi. Dalja Y korrespondon me interpretimin astrologjik të krijuar. Prosesi i transformimit arrihet përmes dy mënyrave kryesore operacionale: rrjedhës së punës së inicializimit dhe rrjedhës së punës së arsyetimit pasues, të cilat së bashku mundësojnë kuptimin semantik, llogaritjen astrologjike, rikthimin kontekstual dhe arsyetimin bashkëpunues.

Për të zyrtarizuar rrjedhën e propozuar të punës, MARA-AI përmbledhet përmes tre algoritmeve kryesore. Algoritmi 1 përshkruan procesin e përgjithshëm të konkluzionit, duke përfshirë vërtetimin, zbulimin e modalitetit dhe gjenerimin e përgjigjes. Algoritmi 2 paraqet inicializimin

rrjedha e punës, ku grafiku i lindjes gjenerohet dhe shndërrohet në copa RAG të ripërdorshme. Algoritmi 3 përshkruan vazhdimin Rrjedha e punës e arsyetimit, e cila kombinon vërtetimin e parmakut, rikthimin semantik, pasurimin e GraphRAG, arsyetimin me shumë agentë dhe bashkimi i përgjigjes.

Algoritmi 1. Tubacioni i konkluzionit MARA-AI

Hyrja: Kërkesa e përdoruesit R, profili i përdoruesit U, historia e bisedës H, databaza DB, modeli i gjuhës LLM

Rezultati: Përgjigja e gjeneruar A, vizualizimi i grafikut SVG, kontekstet e marra C

1: Vërtetoni kërkesën dhe sesionin e përdoruesit

2: modaliteti $\leftarrow$ DetectInteractionMode (R, H)
3: nëse modaliteti = inicializimi atëherë
4: A, SVG, C $\leftarrow$ Inicializimi Pipeline (R, U, DB, LLM)
5: tjetër
6: A, SVG, C $\leftarrow$ FollowUpReasoningPipeline (R.pyetje, U, H, DB, LLM)
7: fundi nëse
8: Ruani regjistrin e bisedave në DB
9: kthimi A, SVG, C

Algoritmi 2. Inicializimi dhe Tubacioni i Gëlltitjes RAG

Hyrja: Të dhënat e lindjes së përdoruesit B, fusha e zgjedhur F, baza e të dhënave DB, modeli i gjuhës LLM

Produkti: Interpretimi fillestar Ainit, grafiku i lindjes SVG, copat e ruajtura Cinit

1: koordinatat $\leftarrow$ ResolveBirthLocation(B.city, B.country)

```
2: grafiku_natal ← ComputeNatalChart(B, koordinatat)
3: astrology_data ← ExtractPlanetsHousesSigns(chart_natal)
4: SVG ← GenerateChartSVG(natal_chart)
5: prompt_init ← BuildInitialAstrologyPrompt(astrology_data, F) 6:
A_init ← GenerateInterpretation(LLM, prompt_init)
7: SaveChartAndInterpretation(DB, B.user_id, A_init, SVG,
të dhënat e astrologjisë)
8: seed_text ← BuildRAGSeedText(A_init, astrology_data)
```

```
9: markdown_sections ← SplitByMarkdownHeaders(seed_tekst)
10: copa ← Text RecursiveSplit(seksionet_shënjuese)
11: për çdo pjesë c në copa bëni
12: c_context ← AttachHeaderMetadata(c)
13: e_c ← GenerateEmbedding(c_context)
14: SaveChunk (DB, B.user_id, c_context, e_c)
15: fund për
16: C_init ← copa
17: ktheni A_init, SVG, C_init
```

Algoritmi 3. Përcjellja e GraphRAG-Enhanced Multi-Agent

Tubacioni i arsytimit

Hyrja: Pyetja e përdoruesit q, historia e bisedës H, memoria e përdoruesit M, baza e të dhënave DB, modeli i gjuhës LLM

Rezultati: Përgjigja përfundimtare A, kontekstet e marra C

1: $q_norma \leftarrow \text{NormalizeQuestion}(q)$

2: $guard_rezultati \leftarrow \text{GuardAgent}(q_norm)$

3: nëse $guard_result.is_astrology = \text{false}$ ose $guard_rezult.besim < 0.8$

atëherë

4: $A \leftarrow \text{Refuzimi Response}()$

5: kthehu $\emptyset$

A, $\emptyset$

6: fundi nëse

7: $synimet, emocionet, entitetet \leftarrow \text{AnalyzeIntent}(\text{LLM}, q_norm, M)$

```
8: initial_log ← FindInitialChartLog(H)
9: if InitialChunksDoNotExist(DB, initial_log.conversation_id) then 10:
  RebuildInitialRAGChunks(initial_log, DB)
11: end if
12: stored_chunks ← LoadStoredChunks(DB,
  initial_log.conversation_id)
13: candidate_chunks ← RetrieveTopChunks(q_norm, stored_chunks,
  top_k = 5)
14: ranked_chunks ← RerankChunks(q_norm, candidate_chunks, top_k
  = 3)
15: C_rag ← ranked_chunks
16: q_rag ← ComposeQuestionWithRAGContext(q_norm, C_rag) 17:
  graph_facts ← GraphRAGContextExtraction(q_rag, entities, max_depth
  = 2)
18: q_final ← ComposeQuestionWithGraphFacts(q_rag, graph_facts) 19:
  agents ← SpawnSpecialistAgents(intents)
20: agent_outputs ← RunAgentsInParallel(agents, q_final, M,
  emotion)
21: if NumberOf(agent_outputs) = 1 then
22: A ← DirectAgentAnswer(agent_outputs)
23: else
24: A ← FusionLLM(LLM, q_final, agent_outputs)
```

25: end if

26: SaveAnswerAndSources(DB, A, C_rag, graph_facts)

27: kthimi A, C_rag

Rrjedha e punës së inicializimit aktivizohet kur përdoruesi ndërvepron me sistemin për herë të parë. Përdoruesi dorëzon lindjen informacion ose një pyetje astrologjike përmes frontendit React + Vite, i cili komunikon me fundin e FastAPI nëpërmjet API-ve REST të siguruara nga JWT. Backend-i më pas përcakton nëse kërkesa i përket një sesioni inicializimi ose një sesioni pasues. Për një seancë të re, AstrologyAgent aktivizohet për të gjeneruar tabelën natale. Ai përdor Kerykeion për të llogaritur pozicionet planetare, vendosjet e zodiakut, shtëpitë dhe aspektet nga të dhënat e lindjes së përdoruesit.

Të dhënat astrologjike të krijuara shndërrohen në të strukturuar metadata dhe një grafik SVG përpara se të dërgohen te Vertex AI Gemini për të prodhuar interpretimin fillestar. Ky proces mbështetet në aftësinë e modeleve gjuhësore të bazuara në Transformer për të sintetizuar informacion kontekstual përmes mekanizmave të vetë-vëmendjes (Vaswani et al., 2017). Grafiku, interpretimi dhe

meta të dhënat përkatëse ruhen në bazën e të dhënave. Në të njëjtën kohë, sistemi kryen gjëllitjen e RAG-së në sfond duke e ndarë atë gjeneroi interpretim në copa të bazuara në shënime, duke i futur ato me Vertex AI Embedding dhe duke i ruajtur ato për t'i marrë më vonë gjatë bisedave vijuese.

Për ndërveprimet vijuese, MARA-AI aktivizon një linjë arsyetimi që kombinon moderimin, analizën e qëllimit, rikthimin semantik, GraphRAG dhe arsyetimin me shumë agjentë. GuardAgent së pari kontrollon nëse pyetja është e vlefshme dhe e lidhur me astrologjinë. Kërkesa me zero-shot përdoret për të klasifikuar të dhëna të pavlefshme ose të parëndësishme pa kërkuar të dhëna të mbikëqyrura

trajnimi (Brown et al., 2020). Nëse pyetja refuzohet, sistemi kthen një përgjigje refuzimi.

Përndryshe, moduli Analyze Intent nxjerr qëllimin e përdoruesit, kontekstin emocional dhe entitetet astrologjike duke përdorur teknika NLP si klasifikimi i emocioneve dhe Njohja e entitetit të emërtuar.

Modelet e bazuara në transformator janë të përshtatshme për këtë detyrë, sepse ato mund të kapin varësitë kontekstuale në tekst (Devlin et al., 2019).

Pas analizës së qëllimit, sistemi kryen dy procese rikthimi paralelisht. Tubacioni semantik RAG fut pyetjen e përdoruesit dhe e krahason atë me ngulitje të copëzave të ruajtura duke përdorur ngjashmërinë e kosinuset.

Top-5 pjesët merren dhe më pas rirenditen për të zgjedhur

Top-3 kontekstet më të rëndësishme. Këto pjesë ofrojnë informacion bazë për arsyetimin në rrjedhën e poshtme dhe ndihmojnë në reduktimin

brez i pambështetur. Paralelisht, moduli GraphRAG nxjerr entitete astrologjike nga pyetja dhe i përdor ato si nyje të farës në një grafik njohurish. Grafiku përmban marrëdhëniet midis planetëve, shenjave të zodiakut, shtëpive, elementeve dhe fushave të jetës si dashuria, karriera dhe shëndeti. Breadth-First Search zbatohet për të tërhequr faktet e grafikut të lidhur brenda një thellësie të kufizuar (Sedgewick & Wayne, 2011). Ky rikthim i bazuar në grafik përmirëson interpretueshmërinë sepse marrëdhëniet simbolike përfaqësohen në mënyrë eksplicite.

Pjesët e marra dhe faktet e grafikut më pas kombinohen në një kërkesë përfundimtare të arsyetimit dhe i kalohen Orkestruesit të Sistemit AI. Orkestratori aktivizon agentë të specializuar si CareerAgent, LoveAgent, HealthAgent, PersonalityAgent dhe DailyAgent. Çdo agent e analizon pyetjen nga perspektiva e domenit të vet, duke e lejuar sistemin të prodhojë më të pasur dhe më të larmishëm interpretimet. Kjo ndjek parimin e sistemeve me shumë agentë, ku problemet komplekse zbërthehen në detyra më të vogla të specializuara (Wooldridge, 2009). Studimet e fundit tregojnë gjithashtu se bashkëpunimi i agentëve të bazuar në LLM mund të përmirësojë diversitetin e arsyetimit dhe pasurinë kontekstuale (Park et al., 2023).

Rezultatet e agentëve të specializuar sintetizohen nga një bashkim LLM në një përgjigje përfundimtare koherente. Kjo fazë sinteze rreshton rezultatet e ndryshme të agentëve, redukton kontradiktat, përmirëson rrjedhshmërinë dhe siguron që përgjigja përfundimtare të mbetet e vetëdijshme për kontekstin. Përgjigja e krijuar dhe burimet e saj kontekstuale ruhen në bazën e të dhënave për të mbështetur personalizimin e ardhshëm. Duke kombinuar llogaritja astrologjike, rikthimi semantik, GraphRAG dhe orkestrimi me shumë agentë, MARA-AI ofron një kornizë modulare dhe të

interpretueshme për arsyetimin bisedor të orientuar nga astrologjia.

Eksperimentet

Vlerësimi eksperimental i sistemit të propozuar MARA-AI u krye duke përdorur kornizën RAGAS për të vlerësuar cilësinë e rikuperimit dhe gjenerimit nëpër konfigurime të ndryshme chatbot. RAGAS u zgjodh sepse është krijuar për të vlerësuar rikthimin

Sistemet e gjenerimit të shtuar duke matur të dyja cilësinë e rikthimit

dhe cilësinë e gjenerimit të përgjigjeve. Në veçanti, RAGAS vlerëson nëse kontekstet e marra janë të dobishme dhe nëse përgjigja e gjeneruar është besnike ndaj provave të marra (Es et al., 2024). Kjo qasje e vlerësimit është e përshtatshme për MARA-AI sepse sistemi i propozuar kombinon rikthimin semantik, rikthimin e bazuar në grafik dhe sintezën e përgjigjes për të orientuar drejt astrologjisë arsyetimi bisedor.

Në këtë eksperiment, u krahasuan katër konfigurime: AstroAI, LLM, Semantic RAG dhe Proposed GraphRAG system. Konfigurimi AstroAI përdoret si një model referimi i jashtëm i bazuar në projektin me burim të hapur fatimaazfar/Astrology-Chatbot. Sipas depove të tij GitHub, AstroAI është një aplikacion ndërveprues desktop që gjeneron horoskopë të personalizuar dhe njohuri astrologjike duke përdorur detajet e lindjes të ofruara nga përdoruesi dhe modelin GPT-3.5-turbo të OpenAI. Aplikacioni zbatohet në Python me Tkinter dhe lejon përdoruesit të fusin detajet e lindjes, të gjenerojnë një horoskop të personalizuar dhe ndërveproni me një chatbot astrologjik (Azfar, n.d.). Megjithatë, të përshkrimi i depove nuk tregon përdorimin e kuptimit rikthimi, marrja e grafikëve të njohurive, GraphRAG ose orkestrimi me shumë agjentë. Prandaj, në këtë studim, AstroAI trajtohet si një referencë e drejtpërdrejtë chatbot astrologjike e bazuar në GPT sesa një arkitekturë e shtuar me rikthim.

Konfigurimi LLM përfaqëson një bazë gjenerimi të drejtpërdrejtë brenda eksperimentit MARA-AI. Në këtë cilësim, modeli i gjuhës merr vetëm pyetjen e përdoruesit dhe gjeneron një përgjigje drejtpërdrejt pa përdorur pjesët e marra, kontekstin e ruajtur të grafikut, faktet e grafikut ose arsyetimin me shumë agjentë. Ky konfigurim përfshihet për të vlerësuar sjelljen e një strategjie të përgjithshme të reagimit të

drejtpërdrejtë LLM. Të

Konfigurimi semantik RAG shton një hap rikthimi përpara gjenerimit të përgjigjeve. Në këtë cilësim, pyetja e përdoruesit futet dhe krahasohet me pjesët e ruajtura të tekstit duke përdorur ngjashmëri semantike.

Pjesët e marra më pas i jepen modelit të gjuhës si

kontekstin e jashtëm përpara se të gjenerohet përgjigja përfundimtare.

Kjo ndjek paradigmen e përgjithshme RAG, ku një model gjuhësor shtohet me informacionin e marrë nga një burim i jashtëm njohurish në

përmirësoni tokëzimin dhe zvogëloni gjenerimin e pambështetur (Lewis et al., 2020).

Sistemi i propozuar GraphRAG përfaqëson arkitekturën e plotë MARA-AI. Ndryshe nga Semantic RAG, sistemi i propozuar kombinon rikthimin semantik me rikthimin relacional të bazuar në grafik dhe orkestrimin me shumë agentë. Sistemi fillimisht merr pjesë semantike përkatëse nga interpretimi i grafikut të ruajtur. Më pas ekstrahon entitete astrologjike dhe merr fakte të lidhura me grafikun nga grafiku i njohurive. Këto kontekste përpunohen nga agentë të specializuar, si CareerAgent, LoveAgent, HealthAgent, PersonalityAgent dhe DailyAgent, përpara se të sintetizohet përgjigja përfundimtare. Ky dizajn synon të përmirësojë mbulimin e rikthimit dhe arsyetimin simbolik duke kombinuar rikthimin e bazuar në vektor me njohuritë relacionale dhe bashkëpunimin me shumë agentë.

Vlerësimi përdor katër metrika RAGAS: besnikërinë, rëndësinë e përgjigjeve, saktësinë e kontekstit dhe rikujtimin e kontekstit. Besnikëria mat nëse përgjigja e krijuar është

në përputhje me kontekstin e marrë. Përshtatshmëria e përgjigjes vlerëson se sa mirë përgjigja e gjeneruar adreson pyetjen e përdoruesit.

Saktësia e kontekstit mat nëse pjesët përkatëse të marra renditen më lart se pjesët e parëndësishme, ndërsa rikujtimi i kontekstit mat nëse komponenti i rikuperimit e merr me sukses informacionin e nevojshëm për t'iu përgjigjur pyetjes. Këto metrika janë të përshtatshme sepse sistemi i propozuar nuk është vetëm një chatbot, por edhe një arkitekturë arsyetimi e bazuar në rikthim (Es et al., 2024).

Tabela 1. Rezultatet e Studimit të Ablacionit të Bazuar në RAGAS.

Konfigurimi

Besnikëria

Pērgjigju

Relevanca

Konteksti

Preciziteti

Rikujtimi i kontekstit

AstroAI

0.000

0,613

0.000

0.000

LLM

0.000

0,637

0.000

0.000

RAG semantik

0,964

0,345

0,250

0,139

Sistemi i propozuar

GraphRAG

0,853

0,467

0,275

0,357

Fig. 2. Rezultatet e Studimit të Ablation Bazuar në Metrikat RAGAS.

Rezultatet tregojnë se chatbot referencë AstroAI arrin një

Rezultati i përshtatshmërisë së përgjigjes është 0.613, ndërsa rezultatet e besnikërisë, saktësisë së kontekstit dhe kthimit të kontekstit janë të gjitha 0.000. Ky rezultat pritet sepse AstroAI është një chatbot i drejtpërdrejtë i bazuar në GPT dhe nuk përdor një mekanizëm rikthimi. Megjithatë mund të gjenerojë përgjigje që janë të rëndësishme për pyetjet e lidhura me astrologjinë, përgjigjet e tij nuk bazohen në kontekstin e marrë sipas vlerësimit të RAGAS. Kjo tregon një kufizim të chatbot-eve të drejtpërdrejta të astrologjisë të bazuara në GPT kur vlerësohen nga një perspektivë rikthimi-bazimi.

Konfigurimi LLM arrin rezultatin më të lartë të rëndësisë së përgjigjes, me një vlerë prej 0,637. Megjithatë, ngjashëm me AstroAI, ai merr 0.000 për besnikërinë, saktësinë e kontekstit dhe rikujtimin e kontekstit sepse nuk merr ose përdor kontekstin e jashtëm. Kjo sugjeron që gjenerimi i drejtpërdrejtë i LLM mund të prodhojë përgjigje të rëndësishme, por ato përgjigjet nuk mbështeten nga provat e marra. Në arsyetimin e orientuar nga astrologjia, ky është një kufizim i rëndësishëm sepse përgjigjet e besueshme duhet të lidhen në mënyrë ideale me grafikun e ruajtur të lindjes. informacione, interpretime të mëparshme ose njohuri të strukturuar astrologjike.

Konfigurimi Semantic RAG arrin rezultatin më të lartë të besnikërisë, me një vlerë prej 0,964. Kjo tregon se kur përgjigja krijohet nga pjesët semantike të marra, modeli mbetet shumë në përputhje me provat e marra. Megjithatë, Semantic RAG merr rezultate më të ulëta të rëndësisë së përgjigjes dhe rikujtimit të kontekstit, me vlera përkatësisht 0.345 dhe 0.139. Kjo sugjeron që vetëm rikthimi semantik mund të përmirësojë tokëzimin, por mund të rikthehet informacion jo të plotë për pyetje komplekse të astrologjisë që kërkojnë arsyetim relacional ose simbolik. Me fjalë të tjera, përgjigja është besnike ndaj pjesëve të marra, por pjesët e marra mund të mos mbulojnë njohuri të mjaftueshme kontekstuale për të adresuar

plotësisht pyetjen e përdoruesit.

Sistemi i propozuar GraphRAG arrin një rezultat besnikërie prej 0,853, rëndësinë e përgjigjes prej 0,467, saktësinë e kontekstit prej 0,275 dhe tërheqjen e kontekstit prej 0,357. Krahësuar me Semantic RAG, sistemi i propozuar përmirëson lidhjen e përgjigjeve nga 0,345 në 0,467, saktësinë e kontekstit nga 0,250 në 0,275 dhe rikthimin e kontekstit nga 0,139 në 0,357. Përmirësimi më i fortë shfaqet në rikujtimin e kontekstit,

duke treguar se integrimi i rikthimit relacional të bazuar në grafik dhe orkestrimit me shumë agjentë e ndihmon sistemin të marrë informacione më të gjera dhe më të dobishme kontekstuale. Edhe pse besnikëria e tij është më e ulët se RAG Semantic, kjo pasqyron një shkëmbim ndërmjet argumentimit të rreptë tekstual dhe arsyetimit më të pasur simbolik. Që nga sistemi i propozuar sintetizon copa semantike, fakte grafiku dhe rezultate të specializuara të agjentëve, disa deklaratat interpretuese mund të mos jenë drejtpërdrejt të gjurmueshme në një pjesë të vetme të marrë.

Në përgjithësi, studimi i ablacionit i bazuar në RAGAS tregon se çdo konfigurim ka fuqi të ndryshme. AstroAI dhe LLM mund të gjenerojnë përgjigje përkatëse të lidhura me astrologjinë, por nuk kanë bazë rikthimi. RAG semantik arrin besnikëri të fortë, por ka rikujtim të kufizuar të kontekstit. Sistemi i propozuar GraphRAG ofron një ekuilibër më të mirë për arsyetimin e orientuar nga astrologjia sepse përmirëson përgjigjen rëndësia, saktësia e kontekstit dhe kujtimi i kontekstit duke ruajtur një rezultat relativisht të lartë besnikërie. Këto gjetje mbështesin efektivitetin e kombinimit të RAG semantik, rikthimi relacional i bazuar në grafik dhe orkestrimi me shumë agjentë në MARA-AI arkitekturës.

Një krahasim me chatbotin e jashtëm AstroAI sqaron më tej kontributin e MARA-AI. AstroAI është i dobishëm si një chatbot astrologjik i thjeshtë i bazuar në GPT, sepse mund të gjenerojë përgjigje të personalizuara të horoskopit nga informacioni i lindjes i dhënë nga përdoruesi (Azfar, n.d.).

Megjithatë, ai nuk zbaton në mënyrë të qartë rikthimin mbi pjesët e ruajtura të grafikut, arsyetimin e grafikut të njohurive ose bashkëpunimin e specializuar me shumë agjentë. Në të kundërt, MARA-AI ruan interpretimin fillestar të grafikut si pjesë të

rikuperueshme, zbaton rikthimin semantik gjatë pyetjeve vijuese, pasuron pyetjen me fakte astrologjike të bazuara në grafik dhe përdor agentë të shumtë të specializuar për të gjeneruar një përgjigje më të strukturuar. Prandaj, sistemi i propozuar nuk është vetëm një ndërfaqe chatbot, por edhe një arsyetim i bazuar në rikthim arkitekturë e krijuar për interpretim kompleks simbolik.

Si përfundim, vlerësimi i bazuar në RAGAS ofron një krahasim transparent midis një chatboti të drejtpërdrejtë të bazuar në GPT, një bazë të drejtpërdrejtë LLM, një bazë semantike RAG dhe asaj të propozuar

Sistemi MARA-AI i përmirësuar me GraphRAG. Rezultatet tregojnë se sistemi i propozuar përmirëson rëndësinë e përgjigjeve, saktësinë e kontekstit dhe

rikujtimi i kontekstit krahasuar me RAG Semantic, duke treguar se rikthimi i bazuar në grafik dhe orkestrimi me shumë agjentë ndihmojnë në marrjen e informacionit më të gjerë kontekstual. Megjithëse sistemi i propozuar ka një rezultat besnikërie më të ulët se RAG Semantic, ai arrin një ekuilibër më të mirë midis mbulimit të rikthimit dhe arsytimit simbolik. Këto rezultate sugjerojnë se MARA-AI është një kornizë premtuese për sistemet bisedore të orientuara nga astrologjia që kërkojnë rikthim semantik, njohuri relacionale dhe interpretim me shumë hapa.

konkluzioni

Ky studim propozoi MARA-AI (Architecture Multi-Agent Reasoning for Astrology AI), një kornizë shumë agjentësh të përmirësuar nga GraphRAG për interpretimin e automatizuar astrologjik. Sistemi kombinon

rikthimi semantik, arsytimi relacional i bazuar në grafik, llogaritja astrologjike dhe orkestrimi i specializuar me shumë agjentë për të përmirësuar AI bisedore të orientuar nga astrologjia. Në vend që të mbështetet në një model të vetëm chatbot, MARA-AI ndan procesin e arsytimit në disa faza, duke përfshirë analizën e hyrjes, rikthimin e RAG, nxjerrjen e njohurive të GraphRAG, arsytimin me shumë agjentë dhe sintezën e përgjigjes përfundimtare.

Sistemi u vlerësua duke përdorur kornizën RAGAS me katër metrikë: besnikërinë, përkatësinë e përgjigjes, saktësinë e kontekstit dhe rikujtimin e kontekstit. Rezultatet tregojnë se sistemi i propozuar GraphRAG përmirëson rëndësinë e përgjigjeve, saktësinë e kontekstit dhe rikujtimin e kontekstit në krahasim me bazën e semantic RAG. Kjo tregon se rikthimi i bazuar në grafik dhe orkestrimi me shumë agjentë e ndihmojnë sistemin të marrë informacione më të gjera dhe më të dobishme kontekstuale. Edhe pse rezultati i besnikërisë së tij është më i ulët se RAG Semantic, kjo pasqyron një shkëmbim ndërmjet argumentimit të rreptë tekstual dhe arsytimit më të pasur simbolik.

Kontributi kryesor i këtij hulumtimi është integrimi i RAG, arsyetimi i grafikut të njohurive dhe bashkëpunimi me shumë agentë në një arkitekturë të unifikuar të fokusuar në astrologji. RAG ofron bazë kontekstuale, GraphRAG kap marrëdhëniet midis entiteteve astrologjike dhe agentët e specializuar analizojnë fusha të ndryshme si personaliteti, dashuria, karriera, shëndeti dhe udhëzimet e përditshme.

Studimi ka ende kufizime. Të dhënat e vlerësimit duhet të jenë

zgjerohet, grafiku i njohurive duhet të rafinohet dhe RAGAS duhet të kombinohet me vlerësimin njerëzor. Puna e ardhshme mund të përmirësojë gjithashtu analizën e qëllimit, të integrojë reagimet e përdoruesve, të përmirësojë kujtesën afatgjatë dhe të mbështesë interpretimin multimodal të grafikut. Në përgjithësi, MARA-AI ofron një kornizë premtuese për detyrat e arsyetimit simbolik që kërkojnë rikthim kontekstual, njohuri relacionale dhe shpjegim me shumë hapa.

Referencat

Azfar, F. (n.d.). Astrology-Chatbot: AstroAI. GitHub. Marrë më 19 maj 2026, nga <https://github.com/fatimaazfar/Astrology-Chatbot>

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, Child, G. A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Grey, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., S., D.2, &

Modelet e gjuhës janë nxënës të paktë. Përparimet në Sistemet e Përpunimit të Informacionit Neural, 33, 1877-1901. <https://procedureings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Trajnim paraprak i transformatorëve të thellë dydrejtues për gjuhën të kuptuarit. Në J. Burstein, C. Doran, & T. Solorio (Eds.), Punimet e Konferencës 2019 të Kapitullit të Amerikës së Veriut të Shoqatës për Gjuhësinë Kompjuterike: Teknologjitë e Gjuhës Njerëzore, Vëllimi 1: Punime të gjata dhe të shkurtra (fq. 4171–4186).

Shoqata për Gjuhësi Kompjuterike.
<https://doi.org/10.18653/v1/N19-1423>

Es, S., James, J., Espinosa Anke, L., & Schockaert, S. (2024). RAGA: Vlerësim i automatizuar i gjenerimit të shtuar të rikthimit.

Në N. Aletras & O. De Clercq (Eds.), *Proceedings of the 18 Konferenca e Kapitullit Evropian të Asociacionit për Gjuhësi kompjuterike: Demonstrimet e sistemit* (fq. 150–158).

Shoqata për Gjuhësi Kompjuterike.

<https://doi.org/10.18653/v1/2024.eacl-demo.16>

Hogan, A., Blomqvist, E., Cochez, M., d'Amato, J., de Melo, G., Gutierrez, J., Kirrane, S., Gayo, J. E. L., Navigli, R., Neumaier, S., Ngomo, A.-C. N., Polleres, A., Rashid, S. M., Rula, A., Schmelzeisen, L., Sequeda, J., Staab, S., & Zimmermann, A. (2021). Grafikët e njohurive. *ACM Computing Surveys*, 54(4), Neni 71, 1–37. <https://doi.org/10.1145/3447772>

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Gjenerimi i shtuar me rikthim për detyrat NLP me njohuri intensive. *Përparimet në Sistemet e Përpunimit të Informacionit Neural*, 33, 9459–9474. [_MBAJ_0_letër/2020/hash/6b493230205f780e1bc26945df7481e5-Abstrakt.html](https://arxiv.org/abs/2010.03045)

Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Agjentët gjenerues: Simulakra ndërvepruese të sjelljes njerëzore. Në punimet e ACM-së së 36-të vjetore Simpoziumi mbi Softuerin dhe Teknologjinë e Ndërfaqes së Përdoruesit (Neni 2, f. 1–22). Shoqata për Makineri Kompjuterike. <https://doi.org/10.1145/3586183.3606763>

Sedgewick, R., & Wayne, K. (2011). *Algoritmet (botim i 4-të)*. Addison-Wesley Professional.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Vëmendja është gjithçka që ju nevojitet. Në I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems*, 30. Curran Associates. <https://papers.nips.cc/paper/7181-attention-is-all-you-need>

Wooldridge, M. (2009). Një hyrje në sistemet multiagjente (botim i dytë). John Wiley & Sons.