

Outomatiese teks-na-spraak-stelsel vir Viëtnamees gebruik

Kunsmatige Intelligensie

Thanh-Danh ¹o1, Ngo-Ho ¹Anh-kho1 en Ngo-Ho ¹Anh-Khoi*

¹ Fakulteit Inligtingstegnologie, Nam Can Tho Universiteit, Nguyen Van Custraat 168, An Binh Wyk, Can Tho City

__HOU_0__, , ,
nhakhoi@nctu.edu.vn

Abstrak. In die konteks van digitale transformasie en die vinnige vooruitgang van kunsmatige intelligensie, die vraag na teks-na-spraak (TTS)-stelsels word al hoe meer krities oor domeine soos virtuele assistente, onderwys, outomatiese oproepsentrums, en toeganklikheidhulpmiddels vir die visueel benadeel. Maar die skep van natuurlike, konteksbewuste, en prosodies

toepaslik toespraak bly 'n beduidende uitdaging, veral vir

Viëtnamees—atontaal met komplekse toonhoogtekontoure en streeks diversiteit. Hierdie navorsing stel voor en ontwikkel 'n Viëtnamese TTS-stelsel gebou op moderne dieponderrigmodelle om die beperking van tradisioneel te oorkom

metodes. Die stelsel hefbome state-of-the-art argitektuur insluitend

Tacotron, FastSpeech, en VITS, gekombineer met masjienleertegnieke om sintesekwaliteit te verbeter. Konstruksie-eenwaardering word uitgevoer diverse Viëtnamese datastel, wat aanpasbaarheid by veelvuldige werklike wêreld verseker kontekste. Resultate toon dat die stelsel natuurlik, duidelik, hoogs bereik buigsame spraakafvoer met breë potensiaal vir ontplooiing op digitale platforms en intelligente dienste.

Sleutelwoorde: Teks-na-spraak (TTS), Kunsmatige Intelligensie (KI), Deep Learning, Natuurlike Taalverwerking (NLP), Spraaksintese.

1 Inleiding

Gedryf deur digitale transformasie en die vordering van kunsmatige intelligensie, die behoefte om bou teks-na-spraak (TTS)-stelsels word al hoe belangriker as virtuele assistente, onderwys, outomatiese oproepsentrums en ondersteuning vir die visueel benadeel. Die TTS-probleem strek egter verder as net om teks in te omskakel audio; dit vereis dat die gesintetiseerde stem natuurlik moet wees, gepaste intonasie dra, en pas by die gegewe konteks - 'n besonder moeilike taak vir Viëtnamees, 'n taal met 'n komplekse toonstelsel en aansienlike streeksvariasie (Do, 2026).

Tradisionele konkatenatiewe en formant-gebaseerde TTS-metodes (Zenetal., 2019) en HiddenMarkovModel(HMM)-gebaseerde sintese (Zenetal., 2019)-uitstallingbeperkings

onbuigsaamheid, natuurlikheid, en skaalbaarheid. In reaksie, moderne diepleermodelle soos Tacotron (Wang et al., 2017), Tacotron 2 (Shen et al., 2018), FastSpeech (Ren)

etal., 2019, 2020), en VITS (Kimetal., 2021) het meer effektiewe weë oopgemaak deur direk uit data te leer. Hierdie studie fokus op die navorsing en ontwikkeling van 'n Viëtnamese TTS-stelsel om stemkwaliteit en praktiese toepaslikheid te verbeter.

2 Verwante werk

Die Viëtnamese TTS-mark beskik oor verskeie prominente plaaslike platforms saam met internasionale oplossings. FPTSmartCloudTexttoSpeech, ontwikkel deur FPT Corporation, lewer 'n Viëtnamese TTS-diens van hoë gehalte deur 'n kommersiële API (Vuetal., 2025; Nguyen, 2023). Dit is van toepassing op 'n diepgaande argitektuur. Tacotron (Wangetal., 2017) en Transformervariante (Vaswanietal., 2017) tesame met vokoders soos WaveNet (Oord et al., 2016) en HiFi-GAN (Kong et al., 2020) om natuurlike, streek-diverse stemme, te produseer, met beheerbare en spoedige stemme onderbreek. Die stelsel word wyd gebruik in interaktiewe stemrespons (IVR), audioboeke, virtuele assistente, en aanlyn onderwys (Do, 2026). ViettelAI Teks-na-Spraak bied 'n SaaS-gebaseerde oplossing wat geoptimaliseer is vir Viëtnameses (Vuetal., 2025; Nguyen, 2023), met gevorderde neurale modelle wat op grootskaalse, Viëtnameses-spesifieke spraak-natuurlike korporatiewe versekering gebruik en ekspressiewe afvoer (Do, 2026; Oordetal., 2016; Kongetal., 2020).

ZaloAITeks na Spraak, 'n produk van VNGCorporation, integreer diep NLP-modelle soos PhoBERT(Nguyen&Tuan, 2020) en BERT-stylvooropleiding (Devlinetal., 2019) met sintese-argitekture, insluitend Tacotron, FastSpeech, en VITS (Wangetal., 2017; Renetal., 2019; Kimetal., 2021), hefboom om massiewe gebruikersdata te ondersteun veelvuldige praatstyle(Vuetal., 2025). Voice.vnspesialiseer in spraaksintese enstemkloning(Vuetal., 2025) deur gebruik te maak van end-tot-end-modelle soos VITS(Kimetal., 2021) en stemomskakelingstegnieke(Casanovaetal., 202., 202., 202., 202., 202) wat hoëtroustemkloning en pasmaak vir advertensies, poduitsendings en speletjies moontlik maak. GoogleAISTudio bied 'n wolkgebaseerde omgewing virTTS via die Gemini-familie en Google CloudTeks-na-spraak (Vaswanietal., 2017; Renetal.

2019), met veeltalige, natuurlike enkonteksaanpasbare stemgenerering (Casanovaetal., 2022; Shenetal., 2018). EventLaboffersTTSenstemkloningnutsgoed wat gebou is vir einde-tot-eindeTTS(Wangetal.)- en 2017-modelle.

(Chenetal., 2022; Kimetal., 2021; Casanovaetal., 2022). Oor die algemeen skuif die mark van

eenvoudig tekslees stelsels na intelligent kommunikasieplatforms, met sterk neigings in stemkloning (Jia et al., 2018) en multimodale KI.

Die oopbrongemeenskap het 'n verskeidenheid Viëtnamese TTS-modelle bygedra. VietTTSis 'n verteenwoordigende stelsel wat gebou is met enkodeerder-dekodeerder-transformator-argitekture (Wangetal., 2017; Vaswanietal., 2017; Renetal., 2019), opgelei om Viëtnamese data (Do, 2026) noukeurig te normaliseer om te hanteertone, saamgestelde woorde, en sinstrukture, wat byna-intydse-tydvertraging bied wat geskik is vir virtuele assistente, e-leer, en klankboekproduksie (Nguyen, 2023; Vuetal., 2025). bedryf opCPUorde-hulpbrontoestelle

(Renetal., 2019,2020; Kimetal., 2021),

geoptimaliseer vir chatbots, IVR en IoTapplications (Pingetal., 2017; Kalchbrenner et al., 2018). 2021; Casanovaetal., 2022), wat uitblink in klankboek en mediaproduksie, maar vereis kragtige GPU's vir ontplooiing (Renetal.,2019;Pingetal.,2017; Kalchbrenner et al., 2018). ViNeu-TTS kombineer TTS met stemkloning, onttrek sprekerkenmerke deur tegnieke soos AutoVC(Qianetal.,2019) en StarGAN-VC(Kameokaetal., 2018) en pas hulle toe op gesintetiseerde spraak (Casanovaetal., 2022, 2022, 2022 personalization); verhoog etiese en sekuriteitsbepoornisse. ViXTTS dien as 'n demonstrasieprojek vir stemkloning, wat die tegnologie vir vinnige eksperimentering illustreer (Thinh, 2024; Kimetal., 2021). 2019,2020;Pingetal.,2017;Kalchbrenneretal.,2018), wat voldoende duidelikheid lewer vir eenvoudige kennisgewing- en leidingaansoeke. Gesamentlik illustreer hierdie modelle temamatering van Viëtnamese TTS, met gespesialiseerde takke wat wissel van sintese van hoë gehalte tot liggewig-ontplooiing en stemverpersoonliking.

Datakwaliteit is fundamenteel vir TTS. The VLSpeech Corpus is groot, akademiesgeoriënteerde datastel met multi-luidsprekeropnames in beheerde toestande (Ardilaetal., 2020; Vuetal., 2025), ryklik geannoteer met fonetiese en streeksinligting (Yamagishietal., 2016 as oopbron). korpus (ongeveer 10–20 uur) skoongeleesde spraak (Ardila et al., 2020; Ito & Johnson, 2017), wat wyd gebruik word vir aanvanklike modellering, ten spyte van beperkte emosies en diversiteit in die werklike wêreld (Do, 2026). Kommersiële datastelle van FPT Corporation, Viettel Group en VNG Corporation is baie groter en meer gedetailleerd. FPT se datastel bestaan uit honderde tot duisende ure se opnames van ateljeekwaliteit met volledige aantekeninge (Vu et al., 2025; Do, 2026; Oord et al., 2016; Kong et al., 2020). Viettel se data kombineer ateljee- en werklike opnames wat uiteenlopende aksente dek (Vu et al., 2025; Yamagishi et al., 2019; Jiaetal., 2018; Do, 2026). inkorporering van eietydse taalgebruik & (Vuetal., 2025; Nguyen&Tuan, 2020; Devlinetal., 2019; Kimetal., 2021). Boonop verskaf VietTTS 'n basiese oop datastel met teks–audiopare voldoende vir kleinskaalse eksperimente,(023jyen; &Ito&Johnson, 2017; Vuetal., 2025). Algehele, datastelskaal, diversiteit, annotasiediepte en realisme bepaal direk TTS-prestasie.


3 Stelselontwerp

Vroeë TTS-stelsels het staatgemaak op aaneenskakelende en formant-gebaseerde metodes, wat spraakeenhede saamstel of wiskundig modelleer, maar ly aan buigzaamheid, hoë databasiskoste en onnatuurlike prosodie (Zenetal., 2019). geproduseer eentonige, minder natuurlike uitset (Zenetal., 2019). Die koms van diep leer wat end-tot-end-modelle gebring is, soos Tacotron en Tacotron2, wat

enkodeerder-dekodeerder gebruik. argitektuur met aandag aan direk
kaart teks aan

mel-spektrogramme, gevolg deur vokoders soos WaveNet (Oordetal., 2016) of WaveGlow (Prengeretal., 2019) genereer golfvorms (Wangetal., 2017; Shenet al., 2018; Vaswanietal., 2017). Hierdie modelle leer outomaties en outomaties prosodiese kenmerke, wat aansienlik meer natuurlike spraak oplewer, maar het beperkings in afleidingsspoed en aandagfoute. FastSpeechandFastSpeech2 het hierdie kwessies aangespreek deur aandag tydens inferensie te verwyder en tydsduur, toonhoogte, en energievoorspellers te gebruik, om vinniger en meer stabiele sintese met eksplisiete beheer te bereik (Renetal., 2019,2020; Vaswanietal., 2017). &Die jongste sprong, VITS, integreer 'n variasie-oto-enkodeerder (Kingma&Welling, 2014) met 'n generatiewe teenstrydige netwerk (Goodfellowetal., 2014) om golfvorms direk uit teksin te genereer enkelpunt-tot-eindraamwerk, wat afsonderlike stemkode uitskakel en kwaliteit en doeltreffendheid verder bevorder (Kimetal., 2021; Casanovaetal., 2022). teken om verpersoonliking en nul-skoot-aanpassing (Jiaetal., 2018; Casanova et al., 2022; Chenetal., 2022; Wangetal., 2018). Verder, oordrag en self-toesig leermetodes (Baevskietal., 2020, 2020; al., 2022) verminder dataskaarste vir Viëtnamese deur vooropleiding op groot meertalige korpus. 'n Moderne TTS-pyplyn sluit tipies data-insameling en voorverwerking, teksnormalisering (Do, 2026), modelopleiding en golfvormgenerering in (Wang et al., 2017; Kim et al., 2021).

Die voorgestelde stelsel implementeer 'n emosionele TTS-pyplyn: invoerteks wat emosiemerkers bevat, word volgens emosie gesegmenteer, elke segment word deur middel van XTTS gesintetiseer, en die gevolglike golfvorms word aaneengeskakel met stiltegapings om die finale oudiolêer te produseer



stuk, soos geformaliseer in die volgende algoritme

In die derde laag word die gegenereerde golfvorms opeenvolgend saamgevoeg met 300 ms se stilte wat ingevoeg word om emosionele draaie te skei en skielike snye te vermy. Die finale uitset is as 'n WAV-lêer geregistreer. Hierdie ontwerp kombineer doeltreffend sleutelwoord-gebaseerde emosieklassifikasie met voorwaardelike TTS en klankpostverwerking, wat merkergedrewe, ekspressiewe spraaksintese moontlik maak deur 'n verenigde stemidentiteit te gebruik.

4 Evalueringsmetrieke

Om die teks-na-spraak-en-stemkloningstelsel omvattend te evalueer, word twee komplementêre diepleer-gebaseerde statistieke gebruik: sprekersooreenkoms deur Resemblyzer, en waargenome spraakkwaliteit via DNSMOS.

Ooreenkoms is 'n instrument wat op 'n neurale netwerk gebaseer is vir luidsprekerverifikasie en stemooreenkomsmeting (Mishraetal., 2023). Op sy punt gebruik dit as 'n luidsprekerverifikasie-enkodeerder wat opgelei is met 'n algemene einde-tot-einde verlies (Wan et al., 2018). Die operasionele beginsel is soos volg: eerstens word 'n invoeruiting—óf die oorspronklike verwysingstem óf die gesintetiseerde gekloonde stem—verwerk deur diep neurale netwerk wat 'n vaste-dimensionele inbedvektor onttrek (dikwels na verwys as 'n d-vektor of luidsprekerinbedding). identiteit van die spreker, insluitende kenmerke soos timbre, toonhoogte en praatstyl, terwyl dit grootliks verskil van die taalkundige inhoud van die spesifieke woorde wat gepraat word. 2018).

Sodra die beddegoedvektore verkry is vir beide die verwysing audio A (die oorspronklike spreker se stem) en die gesintetiseerde audio B (die gekloonde stem), word hul ooreenkoms gekwantifiseer deur die cosinus-ooreenkoms metriek te gebruik:

$$\text{Cosine Gelykvormigheid} = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}}$$

Die gelyksoortigheidsmaatreëls die hoek tussen die twee vektore in die hoë-dimensionele inbedruimte. 'n Waarde naby aan 1 dui aan dat die vektore binne dieselfde rigting wys, wat beteken dat die twee stemme baie soortgelyke mondelinge en tydelike tussenpunte van sprekeridentiteit waargeneem word (Jiaetal., 2018; Wanetal., 2018). Omgekeerd sal 'n waarde naby aan 0ornegatief andersoortige luidsprekers voorstel. Dus verskaf Resemblyzer 'n objektiewe, outomatiese en reproduceerbare maatstaf om te evalueer hoe getrou die stemkloningstelsel die oorspronklike spreker se stemkenmerke bewaar.

DNSMOS (Deep Noise Suppression Mean Opinion Score) is 'n nie-indringende, diepleer-gebaseerde maatstaf wat ontwerp is om die perseptuele kwaliteit van spraakseine te skat sonder om 'n verwysingklanksein te vereis (Reddyetal., 2021).

5 Eksperimente en resultate

Opleidingdatastel. . Die stelsel is opgelei en geëvalueer met behulp van die viVoicecorpus (Le, 2024), die eerste publiek beskikbare grootskaalse Viëtnamese spraakdatastel wat ontwerp is vir meersprekende teks-na-spraak. oudiomonsters verskaf data van 24 kHz steekproeftempo in WAV-formaat, met agtergrondmusiek en geraas wat verskuif word om skoon opleidingsdata te verseker. Die datastel dek 'n wye verskeidenheid luidsprekers, aksente (Noordelike, Sentraal, Suidelike) en praatstyle, wat dit veral geskik maak vir die opleiding van 'n groot multi-spreker Viëtnameses TTS-modelle soos XTTS-v2.viVoice word onder die CCBY-NC-SA4.0-lisensie vrygestel.

Die voorverwerkingspyplyn is ontwerp om wisselvalligheid uit te skakel wat sprekersooreenkoms kan verswak. Stappe ingesluit:(i)handverifikasie van transkripsieakkuraatheid om volmaakte belyning te verseker;(ii)teksnormalisering deur gebruik te maak van VietNormalizer(Do, 2026) om afkortings uit te brei, getalle na woorde om te skakel en te standaardiseer(iii)met 'n foonbelyningopleiding; Viëtnameses, wat raamvlak-foongrense oplewer;(iv)energiegebaseerde stilte wat aan die begin en die einde van uiting stoor, beweeg leiding/slanke stilte; en(v)hardheidnormalisasie na-23 LUFShandhaaf konsekwente waargenome volume oor luidsprekers. elke luidsprekerinbed van hoë gehalte is met die Resemblyzer-enkodeerder onttrek en as 'n verwysingsvektor gestoor. Die kondisionering van die generatiewe model op hierdie inbeddings tydens opleiding, moedig diekodeerder aan om luidsprekeridentiteit te bewaar, wat direk bygedra het tot die hoë cosinus-ooreenkomstellings (0.90+) wat in die eksperimente waargeneem is.

Eksperimentele opstelling. Die evaluering is uitgevoer op 'n GIGABYTEG5GD-skootrekenaar, spelgeoriënteerde notaboek waarvan die spesifikasies in Tabel 1 gelys is. Die stelsel het veral 'n toegewyde NVIDIA GeForce RTXGPU (Ampere-argitektuur, diskreet) saam met 'n geïntegreerde IntelUHD-grafiese adapter. Die PyTorch-omgewing wat vir inferensie gebruik is, was egter slegs 'n SVE-bou, wat beteken dat alle sintese-bewerkings op die Intel Core i5-11400H-verwerker sonder GPU-versnelling uitgevoer is. Hierdie opstelling weerspieël 'n algemene ontplooiingsscenario waar CUDA-bestuurders of biblioteke nie geïnstalleer is nie, of waar die stelsel versoenbaarheid bo maksimum spoed prioritiseer.

Tabel 1. Stelselkonfigurasie van die toetsplatform.

Komponent	Spesifikasie
Model	GIGABYTE G5 GD
ALMAL	Intel Core i5-11400H (8 kerne, 12 drade, 2,70 GHz basis)
RAM	16 GB DDR4 (15,8 GB bruikbaar)
GPU	Intel UHD-grafika (geïntegreer)
Diskrete	NVIDIA GeForce RTX (Ampere, toegewyd)
GPU-	Windows 11 Huis Enkeltaal

VoiceSimilarityandSpeechQuality. Die .stelsel is geëvalueer deur oorspronklike en gesintetiseerde (gekloonde) spraakmonsters van vier luidsprekers te vergelyk. Elke steekproefpaar het bestaan uitverwysing.wavlêer en die kloon. Twee assesseringsmetodes is toegepas: Resemblyzer forvoice-ooreenkoms, (Wan et al., M. 2023), en DNSMOS vir waargenome klankkwaliteit (Reddyetal., 2021). Stemooreenkomste-resultate word in Tabel 2 aangebied. Alle pare behaal 'n gelyksoortigheid van ongeveer 0,90 (wat wissel van 0,9013 tot 0,9346), wat bevestig dat die VITS-model gebruik word. die SVE, behou vokaltimbreen en sprekeridentiteit merkwaardig goed (Jiaetal., 2018).

Stemmegelykvormigheidresultate vir die vorige XTTS-model word in Tabel 2 aangebied. Alle pare behaal 'n gelyksoortigheid van ongeveer 0,90 (wat wissel van 0,9013 tot 0,9346), wat bevestig dat die model stembande en sprekeridentiteit merkwaardig goed behou (Jiaetal., 2018 is nie vir 'n ander duisend jaar nie). evaluasie word uitgevoer, soveel van hulle ondersteun nie stemkloning nie of vereis 'n aparte verwysing-inbedding-onttrekkingstap.

Tabel 2. Stemooreenkoms tussen oorspronklike en gekloonde spraak.

Lekker klank	Ooreenkomstigheid
giong_goc en giong_clone	0,9038
Danh_1 en Danh_clone	0,9019
Khang1 en Khang_clone	0,9346
Ngoc1 en Ngoc_clone	0,9013

Spraakkwalityresultate van DNSMOSoor al sewe geëvalueerde enjins word in Tabel 3 opgesom. Vier metrieë is opgeneem: OVRL (algehele kwaliteit), SIG (spraakkwality), BAK (agtergrondgeraasindringendheid), en die aanvullende P808-telling ('n algehele luistergehalteberamer wat met ITU-T P.808 belyn is). Tellings is op die standaard 1–5 Gemiddelde Opinie-tellingskaal, waar hoër waardes beter perseptuele kwaliteit aandui.

Tabel 3. DNSMOS-evaluering van gesintetiseerde Viëtnamese spraakkwality..

Model	Leer klank	OVRL	MOSSIG	MOSBAK	MOS	P808 MOS
Voorgestelde viXTTS-gebaseer	giong_clone.wav	3,38	3,60	4,14		4,03
Stemkloningstelsel						
Piper Viëtnamese TTS	Piper_Viëtnamees_TTS	3,00	3,40	3,81		3,15
Valtec Viëtnamese TTS v2	Valtec Viëtnamees TTS_ver2.wav	3,07	3,34	4,04		3,95
Viëtnamese TTS	ViëtnameesTTS.wav	2,07	2,75	2,86		2,73
Valtec Viëtnamese TTS	Valtec_Viëtnamese.wav	3,37	3,58	4,16		4,21
VietTTS	VietTTS.wav	3,05	3,25	4,15		3,64
VieNeu-TTS	VietNeu_TTS.wav	3,31	3,54	4,16		3,68

Die DNSMOS-evalueringsresultate wys merkbare verskille in gesintetiseerde Viëtnamese spraakkwaliteit onder die geëvalueerde TTS-stelsels. Algeheel behaal die voorgestelde viXTTS-gebaseerde stemkloningstelsel, verteenwoordig deur giong_clone.wav, die hoogste OVRLMOS-telling van 3.38 en die hoogste SIGMOS-telling. Resultate dui aan dat die voorgestelde stelsel spraak produseer met sterk algehele perseptuele kwaliteit en duidelike spraakseine. Die hoë BAKMOS-telling van 4.14 dui ook daarop dat die gegenereerde audio baie min agtergrondgeraas bevat. Daarom demonstreer die viXTTS-gebaseerde model sterk prestasie in beide spraakhelderheid en geraasonderdrukking.

Onder die vergelykende stelsels, Valtec_Viëtnamese.wav ook presteer mededingend, met 'n OVRLMOS van 3,37 en SIGMOS van 3,58, wat baie na aan die voorgestelde stelsel is. Boonop behaal hierdie model die hoogste P808MOS-telling van 4,21, wat daarop dui dat luisteraars sy algehele klankgehalte gunstig kan ervaar. Die voorgestelde giong_clone.wav presteer egter steeds effens beter as in die twee hoofDNSMOS-aanwysers, OVRLandSIG. Dit dui daarop dat die voorgestelde model 'n klein maar meetbare voordeel tussen algehele spraakkwaliteit en seinhelderheid het.

Die VietNeu_TTS.wav-model behaal ook sterk resultate, met 'n OVRL MOS van 3,31, SIGMOS van 3,54, BAKMOS van 4,16, en P808MOS van 3,68. Die vergelyking, wat wys dat die gegenereerde audio skoon en stabiel is. Alhoewel sy algehele landseinkwaliteitellings effens laer is as dié van giong_clone.wav en Valtec_Vietnamese.wav, bly dit 'n betroubare model vir Viëtnamese spraaksintese.

Die middelpresterende groep sluit in Valtec Viëtnamese TTS_ver2.wav, VietTTS.wav, en Piper_Vietnamese_TTS. Hierdie modelle verkry ORLMOS-tellings wat wissel van 3.00 tot 3.07, wat aanvaarbare maar nie uitstaande gesintetiseerde spraakkwaliteit aandui nie. Hul SIGMOS-tellings, wat wissel van 3,25 tot 3, spraaksein is redelik duidelik, maar steeds onnatuurlik of minder gedetailleerd as die stelsels wat die beste presteer. Veral, VietTTS.wav behaal 'n hoë BAK MOS-telling van 4.15, wat wys dat sy klankuitset relatief skoon is. Sy laer OVRLandSIG-tellings dui egter aan dat die agtergrondskeunlyn saloon nie voldoende is om 'n hoë algehele spraakkwaliteit te verseker nie.

Die stelsel wat die laagste presteer, is die ViëtnameseTTS.wav, wat 'n OVRL MOS van 2.07, SIGMOS van 2.75, BAKMOS van 2.86 en P808MOS van 2.73 verkry. Hierdie tellings is aansienlik laer as dié van die ander modelle. Veral die lae OVRLandSIG-telling dui daarop dat die gesintetiseerde spraak merkbare artefakte, verminderde natuurlikheid, of onduidelike uitspraak kan bevat. Die lae BAK-telling dui ook aan dat die audio meer agtergrondinterferensie of geraas kan insluit in vergelyking met die ander stelsels.

'n Algemene neiging kan oor die sterker modelle waargeneem word: die meeste stelsels behaal hoë BAK MOS-tellings bo 4.0, wat beteken dat moderne Viëtnamese TTS-modelle oor die algemeen effektief is om skoon audio met beperkte agtergrondgeraas te produseer. Verskille in OVRL- en SIG-tellings toon egter dat skoon klank nie altyd nie

waarborgnatuurlike en verstaanbare spraak. Spraaknatuurlikheid, duidelikheid en seinkwaliteit bly belangrike faktore om die beste presterende modelle te onderskei.

Samevattend, die voorgestelde viXTTS-gebaseerde stemkloningmodel giong_clone.wav behaal die beste algehele prestasie in terme van OVRL en SIG MOS, wat dit die sterkste stelsel in hierdie vergelyking maak. Intussen wys ViëtnameseTTS.wav die swak resultate en benodig dalk verdere optimalisering om spraaknatuurlikheid, helderheid en agtergrondgeraasbeheer te verbeter.

Intydse Prestasie- en Latency-analise: Die mees kritieke prestasie-metriek van die huidige prototipe is die eind-tot-einde sintese-latensie. Vir 'n tipiese invoerteks van 750 karakters (gelykstaande aan ongeveer 50 sekondes van gegenereerde audio teen 'n standaard Viëtnamese praatkoers van ongeveer 900 karakters per minuut), benodig die stelsel ongeveer 2 minute sekondes (WA) en 50 sekondes sekondes (om 50 sekondes) te produseer. lêer. Dit lewer 'n Real-TimeFactor(RTF) van ongeveer 3.4, ver bo die intydse drempel van 1.0. Die vertraging is egter nie vasgestel nie; dit wissel egter meetbaar na gelang van die taalkundige kompleksiteit van die invoerteks. Twee faktore oorheers die bykomende verwerkingsbokoste:

- ❑ Emosie-etiket. Elke emosionele grens dwing 'n nuwe sintese-stuk af met 'n aparte viXTTS-afleidingsoproep, wat lei tot meervoudige konteksskakelaar en modellaai bokoste. Meer merkers verhoog die aantal stukke en die kumulatiewe pouse-invoegingstyd.

- ❑ Engelse woorde en nie-Viëtnamese segmente. Hierdie benodig ekstra grafeem na foneem stappe binne die teks normalisering laag (Doen, 2026), en kan aandagfoute veroorsaak wat die dekodeerder dwing om weer te probeer belyning, wat bydra tot die totale looptyd.

Die waargenome latensie spruit uit die loop van die volle VITS-pyplyn op die SVE sonder om die beskikbare RTX GPU te gebruik. Die SVE-enigste PyTorch-bou kan nie die massiewe parallelisme van die GPU se tensorkerne ontgin nie, wat matriksvermenigvuldigings en konvolusies laat om opeenvolgend bereken te word. Ten spyte hiervan, bly die stelsel aanvaarbaar vir nabylyn-inhoudskeppingsake soos podcast-oorklanking, opvoedkundige vertelling of stemposgenerering – toepassings waar 'n paar minute se leweringstyd geduld word in ruil vir hoëgehalte, emosioneel ekspressiewe uitset.

Die masjien is krities toegerus met 'n NVIDIA GeForce RTX GPU, wat ten volle in staat is om die afleiding te versnel. Om na 'n CUDA-geaktiveerde PyTorch-installasie te skuif, sal die RTF tot ver onder 0.1 verminder (gebaseer op tipiese GPU maatstawwe vir VITS), wat intydse stroomsintese moontlik maak. Daarbenewens kan modelkwantisering na FP16 of INT8, en oorskakeling na geoptimaliseerde inferensie-enjins soos ONNX Runtime met OpenVINO, latensie verder halveer terwyl die hoë ooreenkomste en MOS-tellings behoue bly.

6 Gevolgtrekking

In hierdie navorsing is 'n Viëtnamese teks-na-spraakstelsel wat op kunsmatige intelligensie en diep leer gebaseer is, deeglik ontwerp, geïmplementeer en geëvalueer.

Die sisteem

ontgin moderne modelle soos Tacotron, FastSpeech en VITS om teks outomaties in natuurlike spraakseine om te skakel, om die unieke fonetiese en prosodiese kenmerke van Viëtnameses te leer. Eksperimentele uitkomst wys dat die voorgestelde model duidelike, natuurlike spraak genereer met gepaste intonasie en handhaaf 'n stabiele prestasie oor verskeie toestande en kontekste.

Die bereiking van resultate bevestig nie net die doeltreffendheid van die leer in Viëtnamese spraaksintese nie, maar beklemtoon ook die stelsel se breë toepaslikheid in die praktyk, veral virtuele assistente, onderwys, outomatiese oproepsentrums en hulpmiddels vir visueel gestremdes. Toekomstige werk kan fokus op die uitbreiding van die spraakdatastel en ryk. verbeter streeks natuurlikheid, optimalisering modelle vir hulpbronbeperkte toestelle, en die integrasie van die stelsel in 'n werklike wêreldplatform om uitvoerbaarheid en bruikbaarheid te verbeter.

Verwysings

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. M., & Weber, G. (2020). CommonVoice: A massively-meertalige spraakkorpus. arXiv. [__HOU_0__](#)
2. Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). wav2vec2.0: A framework for self-toesig leer van spraakvoorstellings. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, E., & Ponti, M. A. (2022). JouTTS: Op pad na nul-skoot-multi-luidsprekerTTS en nul-skoot-stemomskakeling vir almal. arXiv. [__HOU_0__](#)
4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Pratap, V., Conneau, A., Collobert, R., Synnaeve, G., & Auli, M. (2022). WavLM: Grootse selftoesig vooropleiding vir volle stapel spraakverwerking. arXiv. [__HOU_0__](#)
5. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Vooropleiding van diep tweerigting transformators vir taal begrip. arXiv. <https://arxiv.org/abs/1810.04805>
6. Do, N. (2026). VietNormalizer: Anoopbron, afhanklikheidsvry Pythonbiblioteek vir Viëtnamese teks normalisering in TTS en NLP toepassings. arXiv. <https://arxiv.org/abs/2603.04145>
7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generatiewe teenstander netwerke. arXiv. <https://arxiv.org/abs/1406.2661>
8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhota, K., Salakhutdinov, R., & Mohamed, A. (2021). HuBERT: Self-toesig spraakvoorstelling leer deur gemaskerde voorspelling van verborge eenhede. arXiv. [__HOU_0__](#)
9. Ditt, K., & Johnson, L. (2017). The LJSpeech Dataset. [__BEHOU_0__](#) Datastel/
10. Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, X., Chen, Z., Nguyen, P., Pang, R., Moreno, I. L., & Wu, Y. (2018). Dra leer van sprekerverifikasie oor na multisprekerteke-na-spraaksintese. Vooruitgang in Neurale Inligtingverwerking Stelsels, 31.

<https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Doeltreffende neurale klanksintese.

arXiv. [__HOU_0__](#)

StarGAN-VC: Nie-parallele & veel-tot-baie stemme-omskakeling deur gebruik te maak van stergeneratiewe teenstrydige netwerke. arXiv.

<https://arxiv.org/abs/1806.02169>

&13. Kim, J., Kong, J., & Seun, J. (2021). Voorwaardelike variasie-oto-enkodeerder met teenstrydige leer vir end-tot-end teks-na-spraak. arXiv. [__HOU_0__](#)

&14. Kingma, D. P., & Welling, M. (2014). Outo-encoding variational bayes. arXiv.

<https://arxiv.org/abs/1312.6114>

15. Kong, J., Kim, J., & Bae, J. (2020). HiFi-GAN: Generatiewe teëstanderige netwerke vir doeltreffende en hoëtrou-spraak-sintese. arXiv. [__BEHOU_0__](#)

16. Mishra, P., Choudhury, J. A., Kho, E., Basu, B., & Nandi, A. (2023). Spreker-identifikasie, differensiasie en verifikasie deur diepe leer vir mensmasjien-koppelvlak. In 2023 Photonics & Electromagnetics Research Symposium (PIERS) (pp. 861–870). IEEE. [__HOU_0__](#)

17. Nguyen, D. Q., & Tuan, N. D. (2020). PhoBERT: Voorafopgeleide taalmodelle vir Viëtnameses.

arXiv. [__HOU_0__](#)

18. Nguyen, N. (2023). VietTTS: Viëtnameses teks tot spraak biblioteek. GitHub.

<https://github.com/NTT123/vietTTS>

19. Oord, A. vanden, Dieleman, S., Zen, H., Simonyan, K., Vijals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). WaveNet: A generatiewe model vir rou klank.

arXiv. [__HOU_0__](#)

20. Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Rayman, J., Miller, J., & Sengupta, S. (2017). DeepVoice3: Skalering van teks-na-spraak met konvolusionele volgordeleer. arXiv. [__HOU_0__](#)

21. Prenger, R., Valle, R., & Catanzaro, B. (2019). WaveGlow: A flow-gebaseerde generatiewe netwerk vir spraak-sintese. arXiv. [__HOU_0__](#)

22. Qian, K., Zhang, Y., Chang, S., Yang, X., & Hasegawa-Johnson, M. (2019). AutoVC: Zero-shot

stem styl oordrag met slegs oto-enkodeerder verlies. arXiv.

<https://arxiv.org/abs/1905.05879>

23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022).

Robuuste spraakherkenning deur grootskaalse swak toesig. arXiv.

<https://arxiv.org/abs/2212.04356>

24. Reddy, C. K., Gopal, V., & Cui, R. (2021). DNSMOS: Anon-indringende perseptuele objektiewe spraakwaliteit-metriek om geraasdempers te evalueer. In ICASSP 2021–2021 IEEE

Internasionale Konferensie oor Akoesties, Spraak en Seinverwerking (pp.6493–6497).

IEEE. __HOU_0__

25. Ren, Y., Ruan, Y., Chen, X., Qin, T., Zhao, S., & Liu, T. (2019). FastSpeech: Vinnige, robuuste en beheerbare teks na spraak. arXiv. __HOU_0__

26. Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T. (2020). FastSpeech 2: Vinnige en hoë kwaliteit end-tot-end teks na spraak. arXiv. <https://arxiv.org/abs/2006.04558>

27. Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., & Agiomyrgi,..., 20ki, Y)..

NatuurlikeTTSintese deur kondisioneringWaveNetonmelspektrogrampvoorspellings.arXiv.

<https://arxiv.org/abs/1712.05884>

28. Thinh, L.(2024).viXTTS: AVietnamesestemkloningteks-na-spraakmodel. GitHub.

<https://github.com/thinhlpg/vixtts-demo>

29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Aandag is al wat jy nodig het. arXiv. __HOU_0__

30. Vu, T., Nguyen, L. T., & Nguyen, D. Q. (2025). Zero-shot teks-na-spraak vir Viënamees.

arXiv. __HOU_0__

31. Wan, L., Wang, Q., Papir, A., & Moreno, I. L. (2018). Algemeen einde-tot-eindeverlies vir sprekerverifikasie. In 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) (pp. 4879–4883). IEEE.

<https://ieeexplore.ieee.org/abstract/document/8462665>

32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Agiomyrgiannakis, Y., Clark, R., & Saurous, R. A.

(2017). Tacotron: Op pad na end-tot-end spraaksintese. arXiv.

<https://arxiv.org/abs/1703.10132>

33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R. J., Battenberg, E., Shor, J., Xiao, Y., Jia, Y., Ren, F., & Saurous, R. A. (2018). Styltekens: Stylmodellering sonder toesig, beheer en oordrag in end-tot-end spraaksintese. arXiv.

<https://arxiv.org/abs/1803.09017>

34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: Engelse multi-sprekerkorpus vir CSTR stemkloning gereedskapstel (Weergawe 0.92). University of Edinburgh.

<https://datashare.ed.ac.uk/handle/10283/3443>

35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R. J., Jia, Y., Chen, Z., & Wu, Y. (2019). LibriTTS: 'n Korpus afgelei van LibriSpeech vir teks-na-spraak. arXiv.

<https://arxiv.org/abs/1904.02882>

36. Le, T. (2024). viVoice: 'n Grootse multi-spreker Viënamees spraakdatastel vir teks-na-toespraak. Gesig omhels. __HOU_0__