

Hệ thống chuyển văn bản thành giọng nói tự động cho người Việt sử dụng Trí tuệ nhân tạo

Thanh-Danh Vo¹, Ngo-Ho Anh-Khoa¹ and Ngo-Ho Anh-Khoi^{1*}

¹FACULTY OF INFORMATION TECHNOLOGY, Đại học Nam Cần Thơ, 168 Nguyễn Văn Cừ, An
Phường Bình, Thành phố Cần Thơ, Vietnam

— GIỮ_0 —, , ,
nhakhoi@nctu.edu.vn

Trừu tượng. Trong bối cảnh chuyển đổi kỹ thuật số và sự tiến bộ nhanh chóng của trí tuệ nhân tạo, nhu cầu về hệ thống Chuyển văn bản thành giọng nói (TTS) ngày càng tăng ngày càng trở nên quan trọng trên các lĩnh vực như trợ lý ảo, giáo dục, trung tâm cuộc gọi tự động và các công cụ trợ năng dành cho người dùng trực quan bị suy yếu. Tuy nhiên, tạo ra sự tự nhiên, nhận thức được ngữ cảnh và nhịp điệu

lời nói phù hợp vẫn là một thách thức đáng kể, đặc biệt đối với Tiếng Việt—một ngôn ngữ thanh điệu với cao độ phức tạp và sự đa dạng. Nghiên cứu này đề xuất và phát triển hệ thống TTS Việt Nam được xây dựng dựa trên các mô hình học sâu hiện đại để khắc phục những hạn chế của phương pháp truyền thống phương pháp. Hệ thống tận dụng các kiến trúc tiên tiến bao gồm

Tacotron, FastSpeech và VITS, kết hợp với kỹ thuật học máy để nâng cao chất lượng tổng hợp. Việc xây dựng và đánh giá được thực hiện một cách bộ dữ liệu tiếng Việt đa dạng, đảm bảo khả năng thích ứng với nhiều thể giới thực bối cảnh. Kết quả chứng minh hệ thống đạt được độ tự nhiên, rõ nét, cao đầu ra giọng nói linh hoạt với tiềm năng triển khai rộng rãi trên nền tảng kỹ thuật số và các dịch vụ thông minh.

Từ khóa: Chuyển văn bản thành giọng nói (TTS), Trí tuệ nhân tạo (AI), Học sâu, Xử lý ngôn ngữ tự nhiên (NLP), Tổng hợp giọng nói.

1 Giới thiệu

Được thúc đẩy bởi sự chuyển đổi kỹ thuật số và sự tiến bộ của trí tuệ nhân tạo, nhu cầu xây dựng hệ thống Chuyển văn bản thành giọng nói (TTS) ngày càng trở nên quan trọng hơn trong các lĩnh vực như

như trợ lý ảo, giáo dục, trung tâm cuộc gọi tự động và hỗ trợ trực quan bị suy yếu. Tuy nhiên, vấn đề TTS không chỉ dừng lại ở việc chuyển đổi văn bản thành âm thanh; đòi hỏi giọng nói tổng hợp phải tự nhiên, có ngữ điệu phù hợp, và phù hợp với bối cảnh nhất định—một nhiệm vụ đặc biệt khó khăn đối với tiếng Việt, một ngôn ngữ có một hệ thống âm sắc phức tạp và sự khác biệt đáng kể theo vùng (Do, 2026).

Các phương pháp TTS dựa trên định dạng và nổi truyền thống (Zen và cộng sự, 2019) và Tổng hợp dựa trên Mô hình Markov ẩn (HMM) (Zen và cộng sự, 2019) bộc lộ những hạn chế về tính linh hoạt, tự nhiên và khả năng mở rộng. Đáp lại, các mô hình học sâu hiện đại chẳng hạn như Tacotron (Wang và cộng sự, 2017), Tacotron 2 (Shen và cộng sự, 2018), FastSpeech (Ren

2 F. Tác giả và S. Tác giả

etal.,2019,2020), andVITS(Kimetal.,2021) haveopenedmoreeffectiveavenues bylearningdirectlyfromdata.Buildingontheseadvances,thisstudyfocusesonthe researchanddevelopmentofaVietnameseTTSsystemaimedatimprovingvoice quality and practical applicability.

2 công việc liên quan

The Vietnamese TTS market features several prominent domestic platforms alongside international solutions. FPT Smart Cloud Text-to-Speech, developed by FPT Corporation, delivers a high-quality Vietnamese TTS service through a commercial API (Vu et al., 2025; Nguyen, 2023). It applies deep learning architectures such as Tacotron (Wang et al., 2017) and Transformer variants (Vaswani et al., 2017) together with vocoders like WaveNet (Oord et al., 2016) and HiFi-GAN (Kong et al., 2020) to produce natural, region-diverse voices with controllable speed, pitch, and pausing. The system is extensively used in interactive voice response (IVR), audiobooks, virtual assistants, and online education (Do, 2026). Viettel AI Text-to-Speech offers a SaaS-based solution optimized for Vietnamese (Vu et al., 2025; Nguyen, 2023), employing advanced neural models trained on large-scale, Vietnamese-specific speech corpora to ensure accurate pronunciation, natural breaks, and expressive output (Do, 2026; Oord et al., 2016; Kong et al., 2020). Zalo AI Text to Speech, a product of VNG Corporation, integrates deep NLP models like PhoBERT (Nguyen & Tuan, 2020) and BERT-style pre-training (Devlin et al., 2019) with synthesis architectures including Tacotron, FastSpeech, and VITS (Wang et al., 2017; Ren et al., 2019; Kim et al., 2021), leveraging massive user data to support multiple speaking styles (Vu et al., 2025). Voice.vn specializes in speech synthesis and voice cloning (Vu et al., 2025) using end-to-end models like VITS (Kim et al., 2021) and voice conversion techniques (Casanova et al., 2022; Chen et al., 2022), enabling high-fidelity voice cloning and customization for advertising, podcasting, and gaming. Google AI Studio provides a cloud-based environment for TTS via the Gemini family and Google Cloud Text-to-Speech (Vaswani et al., 2017; Ren et al., 2019), featuring multi-lingual, natural, and context-adaptive voice generation (Casanova et al., 2022; Shen et al., 2018). EventLab offers TTS and voice cloning tools built on end-to-end TTS (Wang et al., 2017) and speaker embedding models (Chen et al., 2022; Kim et al., 2021; Casanova et al., 2022). Overall, the market is shifting from simple text-reading systems toward intelligent communication platforms, with strong trends in voice cloning (Jia et al., 2018) and multimodal AI. The open-source community has contributed a range of Vietnamese TTS models. VietTTS is a representative system built with encoder-decoder or Transformer architectures (Wang et al., 2017; Vaswani et al., 2017; Ren et al., 2019), trained on carefully normalized Vietnamese data (Do, 2026) to handle tones, compound words, and sentence structures, offering near-real-time latency suitable for virtual assistants, e-learning, and audiobook production (Nguyen, 2023; Vu et al., 2025). NeuTTS-Air focuses on lightweight, efficient inference, balancing voice quality and speed to operate on CPU or low-resource devices (Ren et al., 2019, 2020; Kim et al., 2021),

optimized for chatbots, IVR, and IoT applications (Ping et al., 2017; Kalchbrenner et al., 2018). Kani-TTS is a large-scale model with approximately 370 million parameters, aiming for high expressiveness and professional audio quality (Kim et al., 2021; Casanova et al., 2022), excelling in audiobook and media production but requiring powerful GPUs for deployment (Ren et al., 2019; Ping et al., 2017; Kalchbrenner et al., 2018). VieNeu-TTS combines TTS with voice cloning, extracting speaker characteristics via techniques like AutoVC (Qian et al., 2019) and StarGAN-VC (Kameoka et al., 2018) and applying them to synthesized speech (Casanova et al., 2022; Jia et al., 2018), enabling strong personalization but also raising ethical and security concerns. ViXTTS serves as a demonstration project for voice cloning, illustrating the technology for rapid experimentation (Thinh, 2024; Kim et al., 2021). Valtec-TTS is a compact model optimized for extremely resource-constrained environments such as embedded devices and IoT (Ren et al., 2019, 2020; Ping et al., 2017; Kalchbrenner et al., 2018), delivering adequate clarity for simple notification and guidance applications. Collectively, these models illustrate the maturation of Vietnamese TTS, with specialized branches ranging from high-quality synthesis to lightweight deployment and voice personalization.

Data quality is foundational for TTS. The VLSP Speech Corpus is a large, academically oriented dataset with multi-speaker recordings in controlled conditions (Ardila et al., 2020; Vu et al., 2025), richly annotated with phonetic and regional information (Yamagishi et al., 2019; Do, 2026). VIVOS is a smaller open-source corpus (around 10–20 hours) of clean read speech (Ardila et al., 2020; Ito & Johnson, 2017), widely used for initial modeling despite limited emotional and real-world diversity (Do, 2026). Commercial datasets from FPT Corporation, Viettel Group, and VNG Corporation are far larger and more detailed. FPT's dataset comprises hundreds to thousands of hours of studio-quality recordings with exhaustive annotations (Vu et al., 2025; Do, 2026; Oord et al., 2016; Kong et al., 2020). Viettel's data blends studio and real-world recordings covering diverse accents (Vu et al., 2025; Yamagishi et al., 2019; Jia et al., 2018; Do, 2026). Zalo's data benefits from its broad user ecosystem, incorporating contemporary language use (Vu et al., 2025; Nguyen & Tuan, 2020; Devlin et al., 2019; Kim et al., 2021). Additionally, VietTTS provides a basic open dataset with text–audio pairs sufficient for small-scale experiments (Nguyen, 2023; Ito & Johnson, 2017; Vu et al., 2025). Overall, dataset scale, diversity, annotation depth, and realism directly determine TTS performance.


3 Thiết kế hệ thống

Early TTS systems relied on concatenative and formant-based methods, which assemble or mathematically model speech units but suffer from inflexibility, high database costs, and unnatural prosody (Zen et al., 2019). Statistical parametric synthesis using Hidden Markov Models (HMM) improved flexibility but still produced monotonous, less natural output (Zen et al., 2019). The advent of deep learning brought end-to-end models such as Tacotron and Tacotron2, which employ encoder–decoder architectures with attention to directly map text to

4 F. Tác giả và S. Tác giả

mel-spectrograms, followed by vocoders like WaveNet (Oord et al., 2016) or WaveGlow (Prenger et al., 2019) to generate waveforms (Wan et al., 2017; Shen et al., 2018; Vaswani et al., 2017). These models automatically learn phonetic and prosodic features, yielding significantly more natural speech, but have limitations in inference speed and attention errors. FastSpeech and FastSpeech2 addressed these


issues by removing attention during inference and using duration, pitch, and energy predictors, achieving faster and more stable synthesis with explicit prosody control (Ren et al., 2019, 2020; Vaswani et al., 2017). The latest leap, VITS, integrates a variational autoencoder (Kingma & Welling, 2014) with a generative adversarial network (Goodfellow et al., 2014) to directly generate waveforms from text in a single end-to-end framework, eliminating a separate vocoder and further boosting




Hình 1. Quy trình làm việc của Hệ thống tổng hợp giọng nói dựa trên cảm xúc được đề xuất

In the first layer, text is scanned line by line. When a line contains an emotion tag in parentheses, the system maps it to an emotion label using a Vietnamese keyword dictionary. Consecutive lines sharing the same emotion are grouped into a chunk of (text, emotion). Before synthesis, the text is cleaned by removing tag content, normalizing spaces, and standardizing Vietnamese orthography. In the second layer, each chunk is passed to the viXTTS inference engine together with speaker characteristics extracted from a reference audio file. An emotion map assigns a tài liệu tập mỗi cảm xúc (e.g., neutral → base_voice.wav, cheerful → tham tin khảo cheerful_ref.wav).

To maintain consistent speaker identity, latent speaker embeddings are extracted once from a user-provided voice sample and reused across all chunks (Jia et al., 2018; Casanova et al., 2022). The synthesis produces a waveform for each





6 F. Tác giả và S. Tác giả

chunk, như được chính thức hóa trong thuật toán sau

Ở lớp thứ ba, các dạng sóng được tạo ra được nối tuần tự với khoảng im lặng 300 mili giây được chèn vào để tách các bước chuyển cảm xúc và tránh bị cắt đột ngột. Đầu ra cuối cùng được lưu dưới dạng tệp WAV. Thiết kế này kết hợp hiệu quả việc phân loại cảm xúc dựa trên từ khóa với TTS có điều kiện và xử lý hậu kỳ âm thanh, cho phép tổng hợp giọng nói biểu cảm, dựa trên thẻ bằng cách sử dụng nhận dạng giọng nói thống nhất.

4 thước đo đánh giá

Để đánh giá toàn diện hệ thống sao chép giọng nói và chuyển văn bản thành giọng nói, hai chỉ số dựa trên học sâu bổ sung được sử dụng: độ tương tự của người nói qua Resemblyzer và chất lượng giọng nói được cảm nhận qua DNSMOS.

Resemblyzer is a neural network-based tool for speaker verification and voice similarity measurement (Mishra et al., 2023). At its core, it employs a speaker verification encoder trained with a generalized end-to-end loss (Wan et al., 2018). The operational principle is as follows: first, an input utterance—either the original reference voice or the synthesized cloned voice—is processed by a deep neural network that extracts a fixed-dimensional embedding vector (often referred to as a d-vector or speaker embedding). This vector is designed to capture the unique vocal identity of the speaker, including characteristics such as timbre, pitch contour, and speaking style, while being largely invariant to the linguistic content of the specific words spoken. In other words, regardless of what the person says, the embedding should remain consistent for the same speaker and distinctly different for different speakers (Wan et al., 2018).

Once the embedding vectors are obtained for both the reference audio A (the original speaker's voice) and the synthesized audio B (the cloned voice), their similarity is quantified using the cosine similarity metric:

Cosine Similarity A, B =
$$\frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^d A_i B_i}{\sqrt{\sum_{i=1}^d A_i^2} \sqrt{\sum_{i=1}^d B_i^2}}$$

The cosine similarity measures the angle between the two vectors in the high-dimensional embedding space. A value close to 1 indicates that the vectors point in nearly the same direction, meaning the two voices are perceived as highly similar or almost identical in terms of speaker identity (Jia et al., 2018; Wan et al., 2018). Conversely, a value close to 0 or negative would suggest dissimilar speakers. Thus,

Resemblyzer provides an objective, automatic, and reproducible metric for evaluating how faithfully a voice cloning system preserves the original speaker's vocal characteristics.

DNSMOS (Deep Noise Suppression Mean Opinion Score) is a non-intrusive, deep learning-based metric designed to estimate the perceptual quality of speech signals without requiring a clean reference audio signal (Reddy et al., 2021). This makes it

đặc biệt thích hợp cho các ứng dụng trong thế giới thực nơi có bản ghi gốc nguyên sơ không có sẵn. Trong khuôn khổ DNSMOS, điểm chủ quan của con người cho mỗi khía cạnh chất lượng có thể được biểu thị dưới dạng giá trị trung bình của các xếp hạng được chỉ định bởi nhiều người nghe:

$$MOS_{i,k} = \frac{1}{R} \sum_{r=1}^R \sum_{s \in \{SIG, BAK, OVRL\}} s_{i,r,k}$$

trong đó R biểu thị số lượng người xếp hạng và $s_{i,r,k}$ là điểm do người xếp hạng r đưa ra cho lần thứ k kích thước. Dạng sóng giọng nói đầu vào Dạng sóng giọng nói đầu vào $x[n]$ là dạng sóng đầu tiên được phân đoạn thành các khung chồng chéo ngắn và chuyển đổi thành log-power quang phổ X thông qua phân tích Fourier thời gian ngắn. Nói chung, quá trình này có thể được mô tả như sau:

$$x[n] \rightarrow (24, X_y, X_y) \rightarrow X$$

trong đó X là biểu diễn tần số thời gian được trích xuất từ tiếng nói bị suy giảm tín hiệu. Sau đó, biểu đồ phổ được đưa vào mạng lưới thần kinh được huấn luyện trước để dự đoán ba giá trị MOS tương ứng với chất lượng giọng nói, tiếng ồn xung quanh và chất lượng cảm nhận tổng thể:

$$Chúng\ tôi = Fo(X_i)$$

$$F_j = [STG, BAK, OVRL]$$

Đối với một tệp âm thanh hoàn chỉnh, điểm dự đoán cuối cùng thường có được bằng cách tính trung bình các dự đoán trên tất cả các phân đoạn:

$$\begin{aligned} MOS_{i,k} &= \frac{1}{R} \sum_{r=1}^R \sum_{s \in \{SIG, BAK, OVRL\}} s_{i,r,k} \\ MOS_{i,k} &= \frac{1}{R} \sum_{r=1}^R \sum_{s \in \{SIG, BAK, OVRL\}} s_{i,r,k} \\ MOS_{i,k} &= \frac{1}{R} \sum_{r=1}^R \sum_{s \in \{SIG, BAK, OVRL\}} s_{i,r,k} \end{aligned}$$

Trong quá trình đào tạo, mô hình được tối ưu hóa bằng cách sử dụng sai số bình phương trung bình đối với xếp hạng chủ quan được thu thập theo tiêu chuẩn ITU-T P.835 (Reddy et al., 2021)

$$ae_{n=1}^{12} > ae_{n=1}^{12} - \text{Hôm nay}$$

Bằng cách kết hợp DNSMOS với Resemblyzer, khung đánh giá sẽ nắm bắt được hai khía cạnh bổ sung của giọng nói nhân bản: bảo tồn danh tính người nói, được đo bằng độ tương tự và chất lượng giọng nói cảm nhận được đo bằng DNSMOS. Cùng với nhau, các số liệu này cung cấp đánh giá mạnh mẽ, hoàn toàn tự động và khách quan về hiệu suất nhân bản giọng nói.

5 thí nghiệm và kết quả

Training Dataset. The system was trained and evaluated using the viVoice corpus (Le, 2024), the first publicly available large-scale Vietnamese speech dataset designed for multi-speaker text-to-speech. viVoice comprises over 1,000 hours of cleaned audio and accompanying transcriptions sourced from 186 YouTube channels. All audio samples are provided at a 24 kHz sampling rate in WAV format, with background music and noise removed to ensure clean training data. The dataset covers a wide variety of speakers, accents (Northern, Central, Southern), and speaking styles, making it particularly suitable for training robust multi-speaker Vietnamese TTS models such as XTTS-v2. viVoice is released under the CCBY-NC-SA 4.0 license.

The preprocessing pipeline was designed to eliminate variability that could degrade speaker similarity. Steps included: (i) manual verification of transcript accuracy to ensure perfect alignment; (ii) text normalization using VietNormalizer (Do, 2026) to expand abbreviations, convert numbers to words, and standardize punctuation; (iii) phonetic alignment with a forced aligner trained on Vietnamese, yielding frame-level phoneme boundaries; (iv) energy-based silence stripping at the beginning and end of utterances to remove leading/trailing silence; and (v) loudness normalization to -23 LUFS to maintain consistent perceived volume across speakers. Crucially, for each speaker, a high-quality speaker embedding was extracted using the Resemblyzer encoder and stored as a reference vector. Conditioning the generative model on these embeddings during training encourages the decoder to preserve speaker identity, which directly contributed to the high cosine similarity scores (0.90+) observed in the experiments.

Experimental Setup. The evaluation was conducted on a GIGABYTE G5 GD laptop, a gaming-oriented notebook whose specifications are listed in Table 1. Notably, the system features a dedicated NVIDIA GeForce RTX GPU (Ampere architecture, discrete) alongside an integrated Intel UHD Graphics adapter. However, the PyTorch environment used for inference was a CPU-only build, meaning all synthesis operations ran on the Intel Core i5-11400H CPU without GPU acceleration. This configuration reflects a common deployment scenario where CUDA drivers or libraries are not installed, or where the system prioritizes compatibility over maximum speed.

Bảng 1. Cấu hình hệ thống của nền tảng thử nghiệm.

Component	Specification
Model	GIGABYTE G5 GD
CPU	Intel Core i5-11400H (8 lõi, 12 luồng, cơ sở 2,70 GHz)
ĐẬP	16 GB DDR4 (có thể sử dụng 15,8 GB)
GPU	Đồ họa Intel UHD (tích hợp)
Hệ điều hành	NVIDIA GeForce RTX (Ampere, tận tụy)
GPU rời	Ngôn ngữ đơn Windows 11 Home

Voice Similarity and Speech Quality. The system was evaluated by comparing original and synthesized (cloned) speech samples from four speakers. Each sample pair consisted of a reference .wav file and its clone. Two assessment methods were applied: Resemblyzer for voice similarity (Wan et al., 2018; Mishra et al., 2023), and DNSMOS for perceived audio quality (Reddy et al., 2021). Voice similarity results are presented in Table 2. All pairs achieve a cosine similarity of approximately 0.90 (ranging from 0.9013 to 0.9346), confirming that the VITS model, despite running on the CPU, preserves vocal timbre and speaker identity remarkably well (Jia et al., 2018).

Voice similarity results for the viXTTS model are presented in Table 2. All pairs achieve a cosine similarity of approximately 0.90 (ranging from 0.9013 to 0.9346), confirming that the model preserves vocal timbre and speaker identity remarkably well (Jia et al., 2018). Speaker similarity for other engines was not measured in this evaluation run, as most of them do not natively support voice cloning or require a separate reference embedding extraction step.

Bảng 2. Độ tương tự của giọng nói giữa lời nói gốc và lời nói nhân bản.

Cặp audio	Similarity
giọng_goc và giọng_clone	0,9038
Danh_1 và Danh_clone	0,9019
Khang1 và Khang_clone	0,9346
Ngoc1 và Ngoc_clone	0,9013

Speech quality results from DNSMOS across all seven evaluated engines are summarized in Table 3. Four metrics were recorded: OVRL (overall quality), SIG (speech quality), BAK (background noise intrusiveness), and the supplementary P808 score (an overall listening quality estimator aligned with ITU-T P.808). Scores are on the standard 1–5 Mean Opinion Score scale, where high values indicate better perceptual quality.

Bảng 3. Đánh giá DNSMOS chất lượng giọng nói tiếng Việt tổng hợp..

Model	File audio	OVRL MOS	SIG MOS	BAK MOS	P808 MOS
Proposed viXTTS-based Hệ thống nhân bản giọng nói	giọng_clone.wav	3.38	3.60	4.14	4.03
Piper Việt TTS	Piper_Tiếng Việt_TTS	3,00	3,40	3,81	3,15
Valtec Việt TTS v2	Valtec Tiếng Việt TTS_ver2.wav	3.07	3,34	4.04	3,95
Tiếng Việt TTS	Tiếng Việt TTS.wav	2.07	2,75	2,86	2,73
Valtec Việt TTS	Valtec_Tiếng Việt.wav	3,37	3,58	4.16	4.21
VietTTS	VietTTS.wav	3.05	3,25	4.15	3,64
VieNeu-TTS	VietNeu_TTS.wav	3,31	3,54	4.16	3,68

10 F. Tác giả và S. Tác giả

The DNSMOS evaluation results show noticeable differences in synthesized Vietnamese speech quality among the evaluated TTS systems. Overall, the proposed

viXTTS-based voice cloning system, represented by `giong_clone.wav`, achieves the highest OVRL MOS score of 3.38 and the highest SIG MOS score of 3.60. These results indicate that the proposed system produces speech with strong overall perceptual quality and clear speech signals. The high BAK MOS score of 4.14 also suggests that the generated audio contains very little background noise. Therefore, the viXTTS-based model demonstrates strong performance in both speech clarity and noise suppression.

Among the compared systems, `Valtec_Vietnamese.wav` also performs competitively, with an OVRL MOS of 3.37 and a SIG MOS of 3.58, which are very close to the proposed system. In addition, this model obtains the highest P808 MOS score of 4.21, suggesting that listeners may perceive it as overall audio quality favorably. However, the proposed `giong_clone.wav` still slightly outperforms it in the two main DNS MOS indicators, OVRL and SIG. This suggests that the proposed model has a small but measurable advantage in terms of overall speech quality and signal clarity.

The `VietNeu_TTS.wav` model also achieves strong results, with an OVRL MOS of 3.31, SIG MOS of 3.54, BAK MOS of 4.16, and P808 MOS of 3.68. These scores place it in the high-performing group, especially in terms of background noise suppression. Its BAK score is among the highest in the comparison, showing that the generated audio is clean and stable. Although its overall and signal quality scores are slightly lower than those of `giong_clone.wav` and `Valtec_Vietnamese.wav`, it remains a reliable model for Vietnamese speech synthesis.

The middle-performing group includes `Valtec_Vietnamese_TTS_ver2.wav`, `VietTTS.wav`, and `Piper_Vietnamese_TTS`. These models obtain OVRL MOS scores ranging from 3.00 to 3.07, indicating acceptable but not outstanding synthesized speech quality. Their SIG MOS scores, ranging from 3.25 to 3.40, suggest that the speech signal is reasonably clear but still less natural or less detailed than the top-performing systems. Notably, `VietTTS.wav` achieves a high BAK MOS score of 4.15, showing that its audio output is relatively clean. However, its lower OVRL and SIG scores indicate that background cleanliness alone is not sufficient to ensure high overall speech quality.

The lowest-performing system is `VietnameseTTS.wav`, which obtains an OVRL MOS of 2.07, SIG MOS of 2.75, BAK MOS of 2.86, and P808 MOS of 2.73. These scores are substantially lower than those of the other models. In particular, the low OVRL and SIG scores suggest that the synthesized speech may contain noticeable artifacts, reduced naturalness, or unclear pronunciation. The low BAK score also indicates that the audio may include more background interference or noise compared with the other systems.

Có thể nhận thấy xu hướng chung trên các mẫu máy mạnh hơn: hầu hết các hệ thống đều đạt điểm BAK MOS cao trên 4.0, điều đó có nghĩa là các mẫu TTS hiện đại của Việt Nam nhìn chung có hiệu quả trong việc tạo ra âm thanh trong trẻo với tiếng ồn xung quanh hạn chế. Tuy nhiên, sự khác biệt về điểm OVRL và SIG cho thấy âm thanh sạch không phải lúc nào cũng

Tiêu đề đóng góp (rút ngắn nếu dài quá) 11

đảm bảo lời nói tự nhiên và dễ hiểu. Độ tự nhiên, rõ ràng và chất lượng tín hiệu của giọng nói vẫn là những yếu tố quan trọng để phân biệt các mô hình hoạt động tốt nhất. In summary, the proposed viXTTS-based voice cloning model `giong_clone.wav` achieves the best overall performance in terms of OVRL and SIG MOS, making it the strongest system in this comparison. `Valtec_Vietnamese.wav` and `VietNeu_TTS.wav` also demonstrate competitive performance and can be considered strong alternatives. Meanwhile, `VietnameseTTS.wav` shows the weakest results and may require further

optimization to improve speech naturalness, clarity, and background noise control.

Real-Time Performance and Latency Analysis: The most critical performance metric of the current prototype is the end-to-end synthesis latency. For a typical input text of 750 characters (equivalent to approximately 50 seconds of generated audio at a standard Vietnamese speaking rate of about 900 characters per minute), the system requires roughly 2 minutes and 50 seconds (170 seconds) to produce the final WAV file. This yields a Real-Time Factor (RTF) of approximately 3.4, well above the real-time threshold of 1.0. The latency is not fixed, however; it varies measurably depending on the linguistic complexity of the input text. Two factors dominate the additional processing overhead:

⑦

Emotion tags. Each emotional boundary forces a new synthesis chunk with a separate viXTTS inference call, leading to multiple context switch and model loading overheads. More tags increase the number of chunks and the cumulative pause insertion time.

⑦ Từ tiếng Anh và các đoạn không phải tiếng Việt. Những điều này đòi hỏi thêm các bước từ grapheme đến âm vị trong lớp chuẩn hóa văn bản (Do, 2026) và có thể gây ra lỗi chú ý buộc bộ giải mã phải thử lại cần chỉnh, thêm vào tổng thời gian chạy.

Độ trễ quan sát được bắt nguồn từ việc chạy toàn bộ quy trình VITS trên CPU mà không sử dụng GPU RTX có sẵn. Bản dựng PyTorch chỉ dành cho CPU không thể khai thác tính song song lớn của các lõi tensor của GPU, khiến các phép nhân và tích chập ma trận phải được tính toán tuần tự. Mặc dù vậy, hệ thống vẫn có thể chấp nhận được đối với các tác vụ tạo nội dung gần như lồng tiếng podcast, tường thuật mang tính giáo dục hoặc tạo thư thoại—các ứng dụng có thời gian hiển thị là vài phút. được chấp nhận để đòi lấy sản phẩm chất lượng cao, giàu cảm xúc.

Điều quan trọng là máy được trang bị GPU NVIDIA GeForce RTX, hoàn toàn có khả năng tăng tốc suy luận. Việc chuyển sang cài đặt PyTorch hỗ trợ CUDA sẽ giảm RTF xuống dưới 0,1 (dựa trên GPU thông thường đi kèm chuẩn cho VITS), cho phép tổng hợp phát trực tuyến theo thời gian thực. Ngoài ra, lượng tử hóa mô hình thành FP16 hoặc INT8 và chuyển sang các công cụ suy luận được tối ưu hóa như ONNX Runtime với OpenVINO, có thể giảm một nửa độ trễ trong khi vẫn duy trì độ tương tự cao và điểm MOS.

6 Kết luận

Trong nghiên cứu này, hệ thống chuyển văn bản sang giọng nói tiếng Việt dựa trên trí tuệ nhân tạo và deep learning đã được thiết kế, triển khai và đánh giá kỹ lưỡng. hệ thống

12 F. Tác giả và S. Tác giả

khai thác các mô hình hiện đại như Tacotron, FastSpeech, VITS để tự động chuyển đổi văn bản thành tín hiệu giọng nói tự nhiên, học các đặc điểm ngữ âm và ngữ điệu độc đáo của tiếng Việt. Kết quả thử nghiệm cho thấy mô hình đề xuất tạo ra lời nói rõ ràng, tự nhiên với ngữ điệu phù hợp và duy trì hiệu suất ổn định trong nhiều điều kiện và bối cảnh khác nhau.

Kết quả đạt được không chỉ khẳng định tính hiệu quả của deep learning trong tổng hợp giọng nói tiếng Việt mà còn nêu bật khả năng ứng dụng rộng rãi của hệ thống trong thực tế, nổi bật là trợ lý ảo, giáo dục, tổng đài tự động và các công cụ hỗ trợ người

kiếm thị. Công việc trong tương lai có thể tập trung vào việc mở rộng và làm phong phú tập dữ liệu giọng nói, cải thiện tính tự nhiên của khu vực, tối ưu hóa mô hình cho các thiết bị có hạn chế về tài nguyên và tích hợp hệ thống vào các nền tảng trong thế giới thực để nâng cao tính khả thi và khả năng sử dụng.

Tài liệu tham khảo

1. Ardila, R., Branson, M., Davis, K., Henretty, M., Kohler, M., Meyer, J., Morais, R., Saunders, L., Tyers, F. M., & Weber, G. (2020). Common Voice: A massively-multilingual speech corpus. arXiv. <https://arxiv.org/abs/1912.06670>
2. Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). wav2vec2.0: A framework for self-supervised learning of speech representations. arXiv. <https://arxiv.org/abs/2006.11477>
3. Casanova, E., Weber, J., Shulby, C. N., Junior, A. S., Gölge, E., & Ponti, M. A. (2022). YourTTS: Towards zero-shot multi-speaker TTS and zero-shot voice conversion for everyone. arXiv. <https://arxiv.org/abs/2112.02418>
4. Chen, M., Baevski, A., Likhomanenko, T., Kahn, J., Pratap, V., Conneau, A., Collobert, R., Synnaeve, G., & Auli, M. (2022). WavLM: Large-scale self-supervised pre-training for full stack speech processing. arXiv. <https://arxiv.org/abs/2110.13900>
5. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. arXiv. <https://arxiv.org/abs/1810.04805>
6. Do, N. (2026). VietNormalizer: An open-source, dependency-free Python library for Vietnamese text normalization in TTS and NLP applications. arXiv. <https://arxiv.org/abs/2603.04145>
7. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). sáng tạo đối địch mạng. arXiv. <https://arxiv.org/abs/1406.2661>
8. Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhota, K., Salakhutdinov, R., & Mohamed, A. (2021). HuBERT: Self-supervised speech representation learning by masked prediction of hidden units. arXiv. <https://arxiv.org/abs/2104.05136>
9. Ito, K., & Johnson, L. (2017). The LJSpeech Dataset. <https://keithito.com/LJ-Speech-Dataset/>
10. Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, X., Chen, Z., Nguyen, P., Pang, R., Moreno, I. L., & Wu, Y. (2018). Transfer learning from speaker verification to multi-speaker text-to-speech synthesis. Advances in Neural Information Processing Systems, 31. <https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>

Tiêu đề đóng góp (rút ngắn nếu dài quá) 13

11. Kalchbrenner, N., Elsen, E., Simonyan, K., Noury, S., Casagrande, N., Lockhart, E., Stimberg, F., van den Oord, A., Dieleman, S., & Kavukcuoglu, K. (2018). Efficient neural audio synthesis. arXiv. <https://arxiv.org/abs/1802.08435>
12. Kameoka, H., Kaneko, T., Tanaka, K., & Hojo, N. (2018). StarGAN-VC: Non-parallel many-to-many voice conversion using star generative adversarial networks. arXiv. <https://arxiv.org/abs/1806.02169>
13. Kim, J., Kong, J., & Son, J. (2021). Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech. arXiv. <https://arxiv.org/abs/2106.06103>
14. Kingma, D. P., & Welling, M. (2014). Auto-encoding variational bayes. arXiv. <https://arxiv.org/abs/1312.6114>
15. Kong, J., Kim, J., & Bae, J. (2020). HiFi-GAN: Generative adversarial networks for efficient and high fidelity speech synthesis. arXiv. <https://arxiv.org/abs/2010.05646>
16. Mishra, P., Choudhury, J. A., Kho, E., Basu, B., & Nandi, A. (2023). Speaker identification, differentiation and verification using deep learning for human-machine interface. In

- 2023 Photonics & Electromagnetics Research Symposium (PIERS) (pp. 861–870). IEEE.
<https://ieeexplore.ieee.org/document/10221344>
17. Nguyen, D. Q., & Tuan, N. D. (2020). PhoBERT: Pre-trained language models for Vietnamese. arXiv. <https://arxiv.org/abs/2003.00744>
18. Nguyen, N. (2023). VietTTS: Vietnamese text to speech library. GitHub. <https://github.com/NTT123/vietTTS>
19. Oord, A. vanden, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). WaveNet: A generative model for raw audio. arXiv. <https://arxiv.org/abs/1609.03499>
20. Ping, W., Peng, K., Gibiansky, A., Arik, S. O., Kannan, A., Narang, S., Raiman, J., Miller, J., & Sengupta, S. (2017). DeepVoice3: Scaling text-to-speech with convolutional sequence learning. arXiv. <https://arxiv.org/abs/1710.07654>
21. Prenger, R., Valle, R., & Catanzaro, B. (2019). WaveGlow: A flow-based generative network for speech synthesis. arXiv. <https://arxiv.org/abs/1811.00002>
22. Qian, K., Zhang, Y., Chang, S., Yang, X., & Hasegawa-Johnson, M. (2019). AutoVC: Zero-shot voice style transfer with only autoencoder loss. arXiv. <https://arxiv.org/abs/1905.05879>
23. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, & C., & Sutskever, I. (2022). Nhận dạng giọng nói mạnh mẽ thông qua giám sát yếu trên quy mô lớn. arXiv. <https://arxiv.org/abs/2212.04356>
24. Reddy, C. K., Gopal, V., & Cutler, R. (2021). DNSMOS: Anon-intrusive perceptual objective speech quality metric to evaluate noise suppressors. In ICASSP 2021–2021 IEEE International Conference on Acoustics, Speech and Signal Processing (pp. 6493–6497). IEEE. <https://arxiv.org/abs/2010.15258>
25. Ren, Y., Ruan, Y., Chen, X., Qin, T., Zhao, S., & Liu, T. (2019). FastSpeech: Fast, robust and controllable text to speech. arXiv. <https://arxiv.org/abs/1905.09263>
26. Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T. (2020). FastSpeech 2: Fast and high-quality end-to-end text to speech. arXiv. <https://arxiv.org/abs/2006.04558>
27. Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyrgiannakis, Y., & Wu, Y. (2018). Tổng hợp TTS tự nhiên bằng cách điều chỉnh WaveNet trên các dự đoán phổ mel. arXiv. <https://arxiv.org/abs/1712.05884>
28. Thinh, L. (2024). viXTTS: A Vietnamese voice cloning text-to-speech model. GitHub. <https://github.com/thinhlp/vixtts-demo>

14 F. Tác giả và S. Tác giả

29. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Sự chú ý là tất cả những gì bạn cần. arXiv. __GIỮ_0__
30. Vu, T., Nguyen, L. T., & Nguyen, D. Q. (2025). Zero-shot text-to-speech for Vietnamese. arXiv. __GIỮ_0__
31. Wan, L., Wang, Q., Papir, & A., & Moreno, I. L. (2018). Generalized end-to-end loss for xác minh loa. Năm 2018 Hội nghị quốc tế IEEE về Âm học, Lời nói và Xử lý tín hiệu (ICASSP) (trang 4879–4883). IEEE. <https://ieeexplore.ieee.org/abstract/document/8462665>
32. Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., Yang, Z., Xiao, Y., Chen, Z., Bengio, S., Le, Q., Agiomyrgiannakis, Y., Clark, & R., & Saurous, R. A. (2017). Tacotron: Hướng tới tổng hợp giọng nói từ đầu đến cuối. arXiv. <https://arxiv.org/abs/1703.10132>
33. Wang, Y., Stanton, D., Zhang, Y., Skerry-Ryan, R. J., Battenberg, E., Shor, J., Xiao, Y., Jia, Y., Ren, & F., & Saurous, R. A. (2018). Mã thông báo kiểu: Lập mô hình kiểu không giám sát,

điều khiển và chuyển giao trong quá trình tổng hợp tiếng nói từ đầu đến cuối. arXiv.

<https://arxiv.org/abs/1803.09017>

34. Yamagishi, J., Veaux, C., & MacDonald, K. (2019). CSTR VCTK Corpus: English multi-
ngữ liệu loa cho bộ công cụ nhân bản giọng nói CSTR (Phiên bản 0.92). Đại học Edinburgh.
<https://datashare.ed.ac.uk/handle/10283/3443>
35. Zen, H., Dang, V., Clark, R., Zhang, Y., Weiss, R. J., Jia, Y., Chen, Z., & Wu, Y. (2019).
LibriTTS: Một kho văn bản có nguồn gốc từ LibriSpeech để chuyển văn bản thành giọng nói.
arXiv.
<https://arxiv.org/abs/1904.02882>
36. Le, T. (2024). viVoice: A large-scale multi-speaker Vietnamese speech dataset for text-to-
bài phát biểu. Ôm Mặt. __ GIỮ_0__